Guia do Projeto Prático
Projeto e Análise de Experimentos Computacionais

Prof. Carlos Henrique Gomes Ferreira

Objetivo do Projeto

O projeto prático tem como objetivo consolidar os conceitos abordados ao longo da disciplina por meio da aplicação prática de técnicas de experimentação e análise de dados. De forma obrigatória, os projetos devem contemplar:

- **Contextualização e definição do problema**, com a apresentação da motivação e da relevância do estudo;
- **Hipótese geral do estudo**, formulada com base no problema investigado e indicando a relação esperada entre os fatores e a variável de resposta;
- **Análise Exploratória dos Dados (AED)**, utilizando estatísticas descritivas, estudo de distribuições e visualizações para caracterizar os dados e avaliar sua qualidade frente ao projeto proposto;
- Aplicação de um **Projeto Fatorial** $2^k r$, composto pelas 2^k combinações dos níveis dos fatores e por $r \geq 10$ replicações independentes de cada combinação experimental. Esta é a técnica obrigatória de experimentação.

A **hipótese geral do estudo** deve ser definida antes da execução do experimento e posteriormente avaliada por meio dos resultados do projeto fatorial. Não é necessário apresentá-la no formato de hipótese nula e hipótese alternativa. A hipótese geral não deve ser confundida com os achados da análise exploratória.

A **Análise Exploratória dos Dados** constitui uma etapa descritiva anterior à análise experimental. Sua finalidade é compreender as características, a qualidade e as limitações dos dados, além de orientar o planejamento do experimento. A AED não substitui a avaliação da hipótese geral nem a análise dos efeitos do projeto fatorial.

Cada replicação deve corresponder a uma nova execução completa da combinação experimental, com nova amostra, divisão dos dados ou semente aleatória, conforme a natureza do projeto. As partições de uma única validação cruzada não devem ser consideradas automaticamente como replicações independentes.

Espera-se que os alunos demonstrem domínio das etapas do ciclo experimental completo, desde a definição do problema até a apresentação e a interpretação dos resultados.

Formação dos Projetos

O projeto deverá ser desenvolvido individualmente por discentes da pós-graduação e, caso desejável, em ***dupla*** por discentes da graduação. Cada discente ou dupla será responsável pela concepção, implementação, análise e apresentação do seu próprio experimento. Essa organização visa a participação efetiva de todos os integrantes em cada etapa do projeto.

Etapas e Entregas

O projeto será desenvolvido ao longo do semestre em três etapas principais, além do relatório final. As datas e a ordem das apresentações serão definidas por sorteio e divulgadas com antecedência. **A participação na apresentação é obrigatória. A ausência do discente ou de qualquer integrante**

da dupla na data agendada e no momento correspondente à ordem definida para a apresentação implicará nota zero para o trabalho. Não serão permitidas trocas de ordem sem autorização prévia do professor.

Entrega e Apresentação 1: Proposta e Análise Exploratória dos Dados

Data de entrega: 21/09
Formato: Apresentação em **PDF** enviada pelo formulário disponibilizado
Tempo de apresentação: 15–20 minutos
Pontuação: 20%

Conteúdo esperado:

- **Contextualização e definição do problema:** Explique a motivação prática ou teórica do estudo e destaque a relevância do problema a ser investigado;
- **Objetivo:** Defina claramente o que será investigado, comparado ou avaliado;
- **Hipótese geral do estudo:** Apresente a relação esperada entre os fatores e a variável de resposta. A hipótese deve ser definida antes da execução do experimento e será avaliada por meio do projeto fatorial;
- **Estrutura experimental:** Apresente a unidade experimental, os **fatores**, seus **níveis**, a **variável de resposta**, as condições mantidas constantes e o procedimento de aleatorização;
- **Projeto Fatorial $2^k r$:** Apresente todas as 2^k combinações experimentais e estabeleça $r \geq 10$ **replicações independentes** para cada combinação;
- **Fonte dos dados:** Descreva a origem dos dados, como base pública, coleta direta ou simulação;
- **Ambiente computacional:** Indique as ferramentas, bibliotecas, versões de software e recursos computacionais que serão utilizados;
- **Análise Exploratória dos Dados:** Apresente separadamente as estatísticas descritivas, distribuições e visualizações que caracterizam os dados iniciais e justificam a viabilidade do experimento. Nesta etapa, não devem ser antecipadas as conclusões da análise fatorial. Atente-se aos aspectos estatísticos e gráficos discutidos na aula.

Entrega e Apresentação 2: Resultados Preliminares

Data de entrega: 26/10
Formato: Apresentação em PDF enviada via Moodle
Tempo de apresentação: 15–20 minutos
Pontuação: 30%

Conteúdo esperado:

- Evidências de viabilidade do projeto experimental;
- Apresentação dos primeiros resultados obtidos com o projeto fatorial $2^k r$;
- Interpretação preliminar dos efeitos principais e das interações entre os fatores;
- Apresentação dos intervalos de confiança e dos testes de significância aplicáveis;
- Avaliação preliminar da hipótese geral do estudo com base nos resultados obtidos;
- Indicação de ajustes ou aprimoramentos planejados para a versão final.

Entrega Final: Relatório e Apresentação Final

Data de entrega: 30/11
Formato: Apresentação final em PDF e relatório final em PDF. O relatório, elaborado em LaTeX conforme o modelo disponibilizado, deverá incorporar as correções solicitadas durante as apresentações.
Tempo de apresentação: 15–20 minutos
Pontuação: 50%

O relatório final deverá conter as seguintes seções:

- **Cabeçalho:** Título, resumo, autor(es) e orientador, se houver;
- **Introdução:** Contextualização, motivação, definição do problema, objetivo e hipótese geral do estudo;
- **Análise Exploratória dos Dados:** Caracterização dos dados por meio de estatísticas descritivas, distribuições e visualizações, apresentada separadamente da avaliação da hipótese geral;
- **Materiais e Métodos:** Descrição detalhada da base de dados, do ambiente computacional e da unidade experimental. Apresentação dos fatores, níveis, variável de resposta, condições controladas, procedimento de aleatorização e estrutura do projeto fatorial $2^k r$, com $r \geq 10$ replicações independentes por combinação;
- **Resultados Experimentais:** Apresentação dos efeitos principais, das interações, dos intervalos de confiança e dos testes de significância;
- **Caracterização e Análises Finais:** Potencial aplicação do experimento a um estudo final. Por exemplo, se for um modelo de classificação, aplique o modelo para o propósito final que é classificar algo e mostre os resultados;
- **Discussão:** Interpretação dos resultados, avaliação da hipótese geral, limitações do estudo e possíveis próximos passos;
- **Conclusões e Trabalhos Futuros:** Síntese dos principais achados e indicação de trabalhos futuros.

Sugestões de Projetos

Nesta seção, são apresentadas ideias de projetos organizadas por fonte de dados, complexidade computacional e tipo de recurso necessário. As sugestões servem como pontos de partida. Cada projeto deverá apresentar um problema bem definido, uma hipótese geral, fatores e níveis, variável de resposta e um projeto fatorial $2^k r$ com $r \geq 10$ replicações independentes por combinação experimental.

Os projetos podem assumir diferentes naturezas:

- **Projetos educacionais:** Utilizam bases de dados públicas e tarefas bem definidas, como classificação, regressão, otimização, agrupamento, análise textual, análise de redes ou exploração de dados. São indicados para discentes da graduação ou da pós-graduação em estágio inicial que ainda não tenham um projeto de pesquisa definido;
- **Projetos integrados:** Podem estar associados a trabalhos de conclusão de curso, iniciação científica, mestrado/doutorado, projetos de extensão ou temas de interesse individual, permitindo aprofundamento técnico ou interdisciplinar.

Fontes de Dados e Repositórios

Antes de iniciar a coleta, recomenda-se verificar se já existe uma base adequada ao problema. A utilização de uma base pronta reduz o esforço de coleta e permite concentrar o projeto no planejamento experimental e na análise dos resultados.

- **Kaggle:** O Kaggle Datasets disponibiliza bases para classificação, regressão, séries temporais, PLN, visão computacional e outros problemas. A API pública do Kaggle e a ferramenta de linha de comando permitem pesquisar e baixar bases. Como exemplo, a base Brazilian E-Commerce Public Dataset by Olist contém múltiplas tabelas sobre pedidos, produtos, clientes, vendedores, pagamentos e avaliações;

- **Hugging Face Datasets:** O Hugging Face Hub possui bases para processamento de linguagem natural, áudio, imagens, dados tabulares e tarefas multimodais. Muitas bases podem ser carregadas diretamente em Python por meio da biblioteca `datasets`, utilizando a função `load_dataset`;
- **Outros repositórios científicos:** Bases também podem ser pesquisadas no UCI Machine Learning Repository, no Zenodo, no Google Dataset Search e em repositórios associados a artigos científicos;
- **Fóruns e comunidades:** A API do Hacker News e a API do Stack Exchange disponibilizam publicações, perguntas, respostas, comentários, avaliações, usuários e tags;
- **Redes sociais e plataformas de vídeo:** Dados podem ser obtidos por meio das APIs do YouTube, Bluesky e Mastodon. Bases prontas do Reddit também podem ser pesquisadas no Kaggle, no Hugging Face ou em repositórios públicos;
- **Repositórios de software:** A API REST do GitHub permite coletar informações sobre repositórios, commits, issues, pull requests, versões e colaboradores;
- **Dados científicos e educacionais:** A API do Crossref fornece metadados de publicações científicas. A Wikimedia Analytics API fornece dados sobre visualizações e edições de páginas da Wikipédia;
- **Dados públicos brasileiros:** A API de Dados Abertos da Câmara dos Deputados disponibiliza proposições, votações, discursos, despesas e informações sobre parlamentares. Também podem ser utilizados dados do IBGE, Banco Central, Portal Brasileiro de Dados Abertos e outros órgãos públicos;
- **Feeds RSS e Atom:** Portais de notícias, blogs e sites institucionais frequentemente fornecem feeds que podem ser coletados diretamente para estudos de classificação, tópicos e tendências temporais.

Ao utilizar uma base do Kaggle, Hugging Face ou outro repositório, o estudante deverá registrar o nome da base, seus autores ou responsáveis, versão, endereço de acesso, descrição das variáveis e referência à fonte original indicada pelo repositório.

Recursos para Projetos com Modelos de Linguagem

Projetos envolvendo modelos de linguagem podem utilizar modelos abertos executados localmente ou serviços de inferência externos. Entre as alternativas estão:

- **Hugging Face Hub e Transformers:** O Hugging Face Hub disponibiliza modelos para classificação de textos, análise de sentimentos, identificação de entidades, geração de texto, sumarização, tradução, embeddings e outras tarefas. A biblioteca `transformers` permite executar esses modelos localmente ou no Google Colab;
- **Hugging Face Inference Providers:** Permite acessar modelos por meio de uma API de inferência. Contas gratuitas recebem créditos limitados, que podem variar ao longo do tempo;
- **OpenRouter:** Oferece uma API unificada para diferentes modelos de linguagem. Alguns modelos possuem versões gratuitas, identificadas pelo sufixo `:free`, sujeitas a limites de requisições e disponibilidade;
- **Gemini e Groq:** Disponibilizam APIs com modalidades gratuitas e limites definidos por modelo, quantidade de tokens, requisições por minuto ou requisições por dia;
- **Ollama:** Permite executar modelos abertos localmente e acessá-los por meio de uma API disponível na própria máquina, evitando a dependência de cotas de provedores externos.

As cotas, os modelos e as condições de acesso podem mudar. Antes de definir o experimento, o estudante deverá verificar se o número total de chamadas necessárias para o projeto fatorial $2^k r$ é compatível com os recursos disponíveis.

Projetos com Baixa Complexidade Computacional (Notebook pessoal)

- **Comparação de algoritmos de classificação:** Avaliar o impacto de algoritmos, técnicas de normalização ou estratégias de balanceamento sobre o desempenho de uma tarefa de classificação. Podem ser comparados classificadores como regressão logística, árvores de decisão, Random Forest, LightGBM e máquinas de vetores de suporte;
- **Balanceamento de conjuntos de dados:** Comparar técnicas de sobreamostragem, subamostragem e ausência de balanceamento em bases com classes desbalanceadas. As variáveis de resposta podem incluir precisão, revocação, F1-score, acurácia balanceada e tempo de treinamento;
- **Classificação automática de textos:** Avaliar métodos de representação, algoritmos e estratégias de balanceamento em diferentes tarefas de classificação textual. Entre as possibilidades estão: análise de sentimentos; identificação de posicionamento (*stance*); toxicidade; discurso de ódio; misoginia; conteúdo ofensivo; ironia; spam; intenção; tópico; emoção; relevância e classificação de notícias. A tarefa pode ser binária, multiclasse ou multirrótulo;
- **Análise de séries temporais públicas:** Avaliar métodos de suavização, decomposição, detecção de anomalias ou previsão utilizando dados econômicos, climáticos, educacionais ou de visualizações de páginas da Wikipédia.

Projetos com Média Complexidade Computacional (Colab ou desktop/servidor com boa RAM)

- **Análise de redes de colaboração no GitHub:** Realizar coleta via API ou utilizar bases prontas. Investigar métricas como centralidade, cliques, componentes, comunidades e frequência de commits em projetos como Linux, TensorFlow ou Jupyter;
- **Avaliação de bibliotecas de grafos:** Comparar o desempenho de bibliotecas como NetworkX, igraph e SNAP em tarefas como detecção de comunidades, cálculo de centralidade, caminhos mínimos e agrupamento;
- **Análise de dados da web e de redes sociais:** Coletar publicações ou comentários do YouTube, Hacker News, Stack Exchange, Bluesky, Mastodon ou outras fontes. Podem ser investigados tópicos, sentimentos, posicionamentos, toxicidade, difusão de informação, engajamento ou evolução temporal;
- **Análise de mensagens do chat da Twitch:** Realizar a coleta de mensagens em tempo real por meio do EventSub e aplicar classificação automática ou análise lexical. Os fatores podem incluir categoria da transmissão, horário, tamanho do canal ou método de representação textual;
- **Estudo de tópicos em mensagens de canais abertos do Telegram:** Aplicar técnicas de modelagem de tópicos, classificação ou análise temporal a mensagens de canais abertos com diferentes temáticas, como tecnologia, política ou esportes. A coleta pode ser realizada por meio da API do Telegram, de acordo com as condições de acesso vigentes;
- **Classificação de textos com modelos do Hugging Face:** Comparar modelos como BERT, RoBERTa, DistilBERT ou modelos específicos para a língua portuguesa em tarefas como sentimentos, posicionamento, toxicidade, misoginia ou detecção de discurso de ódio;
- **Avaliação de LLMs por meio de APIs:** Comparar modelos, estratégias de prompt e parâmetros de geração em uma tarefa bem definida. Os fatores podem incluir modelo, prompt com ou sem exemplos e temperatura. As variáveis de resposta podem incluir acurácia, F1-score, latência, número de tokens, taxa de erros e validade do formato produzido;
- **Classificação zero-shot e few-shot:** Avaliar o efeito da quantidade de exemplos incluídos no prompt, do idioma ou do modelo sobre o desempenho da classificação;
- **Extração estruturada de informações:** Comparar modelos e estratégias de prompt na extração de entidades, datas, locais, categorias ou relações. As respostas podem ser avaliadas por correspondência exata, F1-score e proporção de respostas JSON válidas;
- **Rotulação automática e pseudorrotulação:** Utilizar modelos de linguagem para gerar rótulos iniciais e comparar modelos, estratégias de prompt, critérios de confiança ou métodos de seleção de amostras.

Projetos com Alta Complexidade Computacional (GPU ou execução externa)

- **PLN com arquiteturas modernas de redes neurais:** Realizar o ajuste fino de modelos como BERT, RoBERTa, DistilBERT ou modelos específicos para o português em tarefas de classificação, identificação de entidades nomeadas, similaridade textual ou resposta a perguntas em grandes volumes de dados;
- **Comparação entre ajuste fino e uso de LLMs por API:** Comparar um modelo ajustado para uma tarefa específica com modelos acessados por API em estratégias zero-shot e few-shot. As respostas podem incluir desempenho preditivo, latência, consumo de memória, número de tokens e custo estimado;
- **Geração Aumentada por Recuperação (RAG):** Avaliar fatores como modelo de embeddings, tamanho dos fragmentos, quantidade de documentos recuperados e modelo gerador. As variáveis de resposta podem incluir acurácia, cobertura, latência e número de tokens;
- **Execução local de modelos de linguagem:** Comparar modelos abertos executados com Hugging Face Transformers ou Ollama. Podem ser avaliados tamanho do modelo, quantização, tamanho do contexto e configuração de hardware;
- **Ajuste eficiente de LLMs:** Avaliar estratégias como LoRA ou outras técnicas de ajuste eficiente de parâmetros em modelos abertos, considerando qualidade, tempo de treinamento e consumo de memória;
- **Modelagem de tendências:** Utilizar dados temporais para prever picos de engajamento, variações de atenção pública, eventos políticos ou processos de difusão de informação. O projeto pode envolver métodos estatísticos, modelos de aprendizado de máquina, RNNs, LSTMs ou Transformers em grandes volumes de dados.

Antes de escolher seu projeto, reflita:

- Você já possui os dados ou sabe exatamente como coletá-los? Caso pretenda desenvolver um coletor, a coleta é tecnicamente viável e pode ser concluída dentro do prazo?
- A base possui uma descrição clara, referência, versão e informações suficientes sobre suas variáveis e classes?
- A tarefa está claramente definida? Trata-se de classificação, regressão, agrupamento, análise de redes, previsão, geração, recuperação de informação ou otimização?
- A hipótese geral, os fatores, os níveis e a variável de resposta estão claramente definidos?
- O número total de execuções do projeto fatorial $2^k r$ é compatível com as cotas das APIs e com os recursos computacionais disponíveis?
- O tamanho da base e dos modelos é compatível com a memória, o tempo e o hardware disponíveis?
- O projeto pode ser executado em seu notebook ou exige o uso do Google Colab, de uma máquina da UFOP, de GPU ou de outro recurso externo?
- As versões das bases, modelos, prompts, sementes aleatórias e configurações poderão ser registradas para permitir a reprodução do experimento?
- É possível concluir o projeto dentro do semestre?

Lembre-se: um bom projeto não precisa ser o mais complexo. Precisa apresentar um problema relevante, uma hipótese testável, um experimento viável e uma análise bem executada.