Revisão: Probabilidade e Estatística

Projeto e Análise de Experimentos

Prof. Carlos Henrique Gomes Ferreira



UFOP

decom
departamento
de computação

Espaço amostral, evento e variável aleatória

O **espaço amostral (Ω)** é o conjunto de todos os possíveis resultados de um experimento aleatório

Um **evento** é o subconjunto de resultados do espaço amostral que nos interessa

Uma variável é dita ser uma **Variável Aleatória (X)** quando assume valores de um conjunto definido, cada um com uma dada probabilidade

Uma variável aleatória é a função que traduz os resultados do espaço amostral em números:

- "X" representa a v.a., e (x) representa seus possíveis valores numéricos

Variável aleatória discreta

Uma variável aleatória é dita ser **discreta** se ela assume um número finito ou contável de valores

- Cada um desses valores é associado a uma probabilidade específica

Variáveis aleatórias discretas frequentemente surgem de processos de contagem. Por exemplo:

- O número de interações entre dois usuários, o número de *commits* em um projeto no *GitHub*, o número de colaborações entre dois desenvolvedores, etc

Variável aleatória discreta

A **Função de Massa de Probabilidade (PMF)** é fundamental para entender a distribuição de variáveis aleatórias discretas

- Associa cada valor possível da variável à sua probabilidade
- Permite analisar quantitativamente os eventos discretos

Essa probabilidade é escrita como P(X=x), representando a chance de (X) assumir o valor (x)

- **Propriedade fundamental:** Probabilidade sempre tem valor entre 0 e 1
- A soma de todas as probabilidades é 1 ($\sum P(X=x) = 1$)

Variável aleatória discreta

Assuma, como exemplo, uma pequena rede com 5 usuários (nós), e as conexões (arestas) entre eles são as seguintes:

- Usuário A tem 2 conexões (B e C). Logo, Grau = 2
- Usuário B tem 3 conexões (A, C, e D). Logo, Grau = 3
- Usuário C tem 3 conexões (A, B, e D). Logo, Grau = 3
- Usuário D tem 2 conexões (B e C). Logo, Grau = 2
- Usuário E não tem conexões. Logo, Grau = 0

Variável aleatória discreta

Aqui, a variável aleatória (X) representa o número de conexões (grau) de um usuário escolhido ao acaso. Os possíveis valores de (X) são 0, 2, e 3:

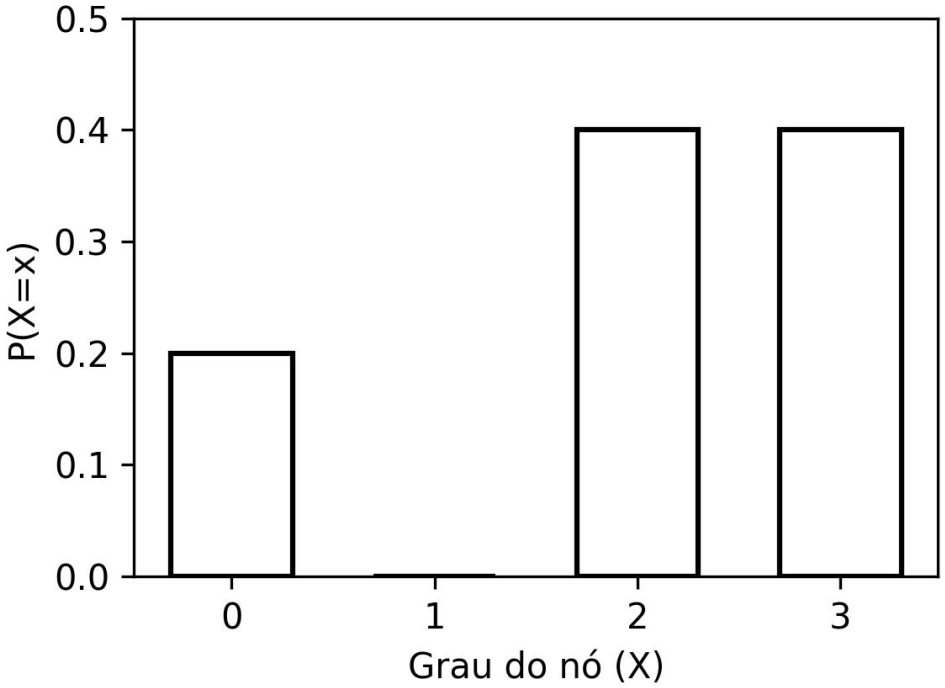
- P(X=0): A probabilidade de selecionar um usuário com 0 conexões. Apenas o usuário E não tem conexões, então P(X=0) = ⅕ = 0.2
- P(X=2): A probabilidade de selecionar um usuário com 2 conexões. Os usuários A e D têm 2 conexões, então P(X=2) = ⅖ = 0.4
- P(X=3): A probabilidade de selecionar um usuário com 3 conexões. Os usuários B e C têm 3 conexões, então P(X=3) = ⅖ = 0.4

Podemos ter interesse em um **evento F** específico. Por exemplo:

$P(F) = P(X \geq 2) = P(X=2) + P(X=3) = 0.4 + 0.4 = 0.8$

Variável aleatória discreta

Função de massa de probabilidade (PMF):



Variável aleatória contínua

Uma **variável aleatória** é considerada **contínua** se ela pode assumir um número não-enumerável de valores dentro de um intervalo

- As probabilidades são atribuídas a intervalos de valores, em vez de valores individuais, como na discreta

São utilizadas para modelar medidas, como tempo, temperatura, distância, etc., onde os valores podem variar de forma contínua

A escolha entre modelar uma variável aleatória como discreta ou contínua depende da natureza dos dados e do fenômeno sendo estudado

Variável aleatória contínua

Uma variável aleatória contínua (X) pode assumir qualquer valor dentro de um intervalo ou conjunto de intervalos

Por definição, a probabilidade de X assumir um valor exato é 0

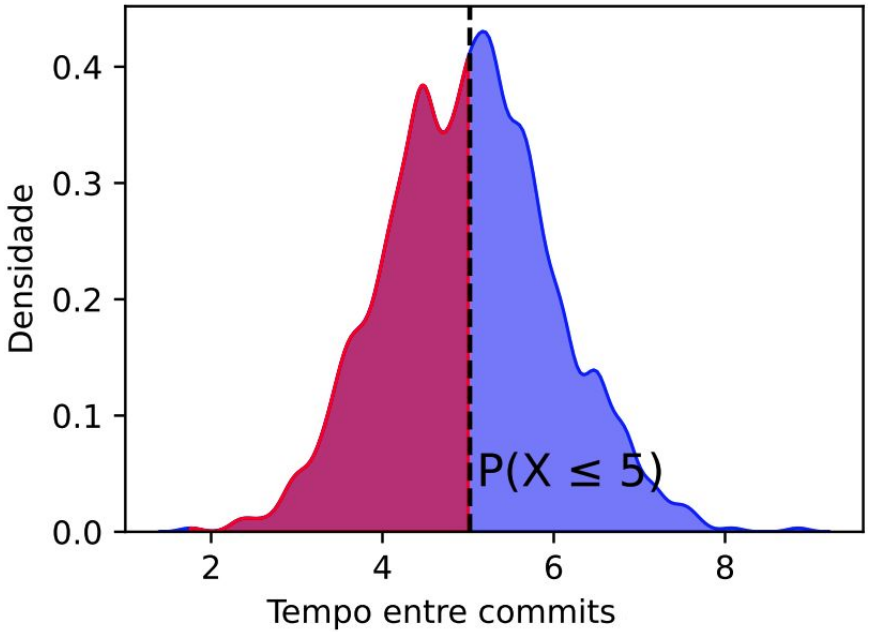
- As probabilidades são calculadas para intervalos: P(a<X<b) é a área sob a curva da **Função de Densidade de Probabilidade (PDF)**
- Por exemplo, para X≤5, calcula-se a integral da área sob a curva considerando o intervalo de integração de 0 a 5 minutos

Considere, por exemplo, o tempo entre *commit* de um dado projeto

- A variável aleatória contínua X representa o tempo entre um commit e outro, e estamos interessados na probabilidade desse tempo ser menor ou igual a 5 minutos

Variável aleatória contínua

Função de Densidade de Probabilidade (PDF):



A área sob a curva em destaque (vermelha) representa a probabilidade cumulativa do evento P(X<=5), que pode ser facilmente obtida por uma

Variável aleatória contínua

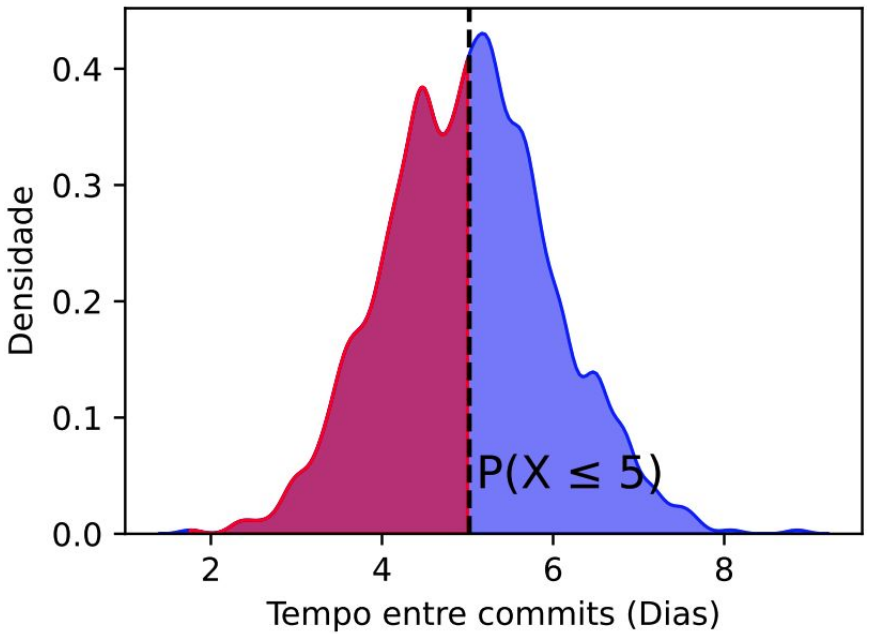
Para estimar a PDF, uma abordagem comum é usar a técnica de Estimativa de Densidade Kernel (KDE - Kernel Density Estimate), que exige:

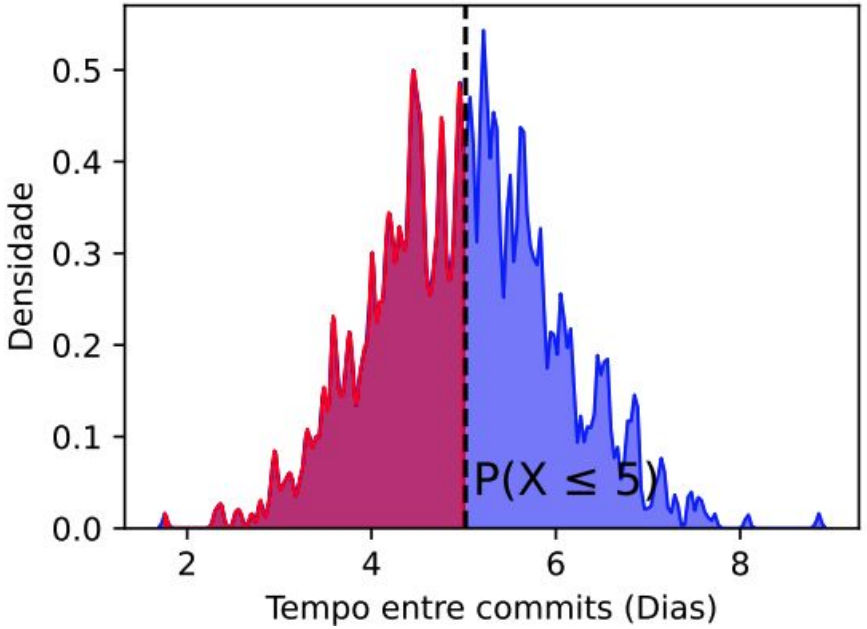
- **Kernel:** Uma função para suavizar a distribuição dando mais peso a pontos próximos e menos a distantes
- **Largura de Banda (Bandwidth):** Uma largura pequena pode capturar ruído (*overfitting*), enquanto uma largura grande pode perder detalhes (*underfitting*)
  - A escolha correta é crucial para uma estimativa precisa
  - Métodos automáticos podem ajudar, mas ajustes manuais são importantes para capturar a distribuição real dos dados. Ex: Regras de Silverman, Scott, etc

Ajuda muito na visualização dos dados, mas estimar a probabilidade exata de eventos pode sofrer com problemas de precisão

Variável aleatória contínua

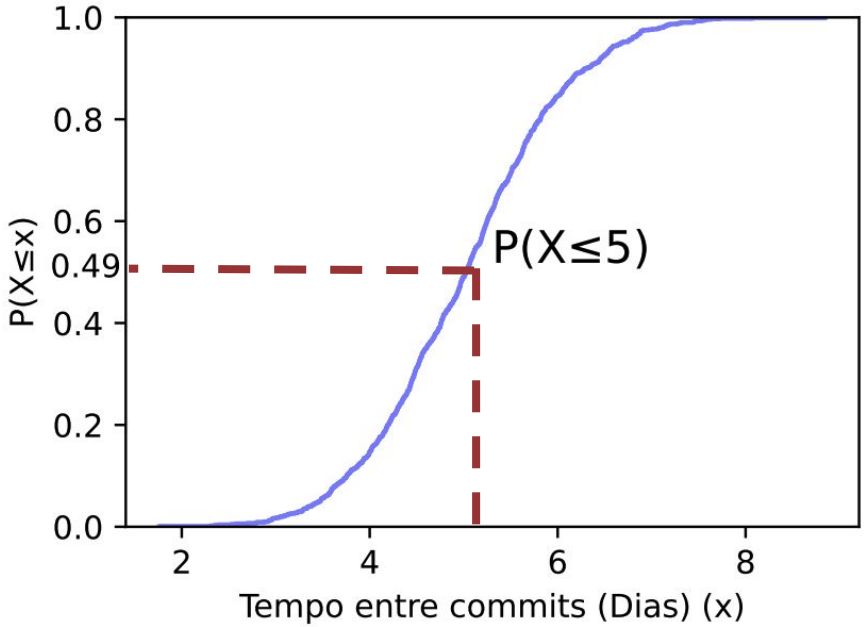
Impacto de diferentes parâmetros de largura de banda (Bandwidth):





Variável aleatória contínua

Uma alternativa é usar a **Função de Distribuição Cumulativa (CDF)** que é calculada diretamente a partir dos dados e oferece uma medida precisa



Para encontrar a probabilidade de X estar entre a e b, basta usar a seguinte propriedade: P(a<X<b) = (P(b) - P(a))

Variável aleatória: Resumindo

Ao estudar uma variável aleatória , é fundamental avaliar e entender as suas características

Essencial para resumir grandes conjuntos de dados de forma concisa e também a identificar padrões, tendências e anomalias

Essa análise deve ser associada a **técnicas de sumarização de dados** e **representações gráficas**

Técnicas de sumarização

Medidas de Tendência Central: Média, Mediana e Moda

Medidas de Dispersão: Variância, Desvio Padrão, Amplitude e Intervalo Interquartil (IQR)

Medidas de Forma: Assimetria (Skewness), Curtose (Kurtosis)

Medidas de Associação: Covariância e Coeficiente de Correlação

Técnicas de sumarização

Medidas de Tendência Central: Média, Mediana e Moda

Medidas de Dispersão: Variância, Desvio Padrão, Amplitude e Intervalo Interquartil (IQR)

Medidas de Forma: Assimetria (Skewness), Curtose (Kurtosis)

Medidas de Associação: Covariância e Coeficiente de Correlação

Medidas de Tendência Central: Média

A **média** é o valor que representa o centro do conjunto de dados, calculada pela soma de todos os valores dividida pelo número total de valores

$$\text{Média} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Medidas de Tendência Central: Média

A **média** é o valor que representa o centro do conjunto de dados, calculada pela soma de todos os valores dividida pelo número total de valores

$$\text{Média} = \frac{\sum_{i=1}^{n} x_i}{n}$$

x=Valor do i-ésimo elemento da sequência

Total de elementos

Medidas de Tendência Central: Média

A **média** é o valor que representa o centro do conjunto de dados, calculada pela soma de todos os valores dividida pelo número total de valores

$$\text{Média} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Código em Python:

```python
import numpy as np

# Calculando a média
dados = np.array([4, 5, 7, 10, 15])
media = np.mean(dados)
print("Média:", media)

#Saída: Média 8.2
```

Medidas de Tendência Central: Mediana

A **mediana** é o valor que divide um conjunto de dados ordenado em duas metades iguais

- Se o número de observações é ímpar, a mediana é o valor do meio. Se é par, a mediana é a média dos dois valores do meio

$$\text{Mediana} = \begin{cases} x_{(\frac{n+1}{2})} & \text{se } n \text{ é ímpar} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2} & \text{se } n \text{ é par} \end{cases}$$

Medidas de Tendência Central: Mediana

A **mediana** é o valor que divide um conjunto de dados ordenado em duas metades iguais

- Se o número de observações é ímpar, a mediana é o valor do meio. Se é par, a mediana é a média dos dois valores do meio

$$\text{Mediana} = \begin{cases} x_{(\frac{n+1}{2})} & \text{se } n \text{ é ímpar} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2} & \text{se } n \text{ é par} \end{cases}$$

n: Total de elementos

Medidas de Tendência Central: Mediana

A **mediana** é o valor que divide um conjunto de dados ordenado em duas metades iguais

- Se o número de observações é ímpar, a mediana é o valor do meio. Se é par, a mediana é a média dos dois valores do meio

$$\text{Mediana} = \begin{cases} x_{(\frac{n+1}{2})} & \text{se } n \text{ é ímpar} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2} & \text{se } n \text{ é par} \end{cases}$$



Apenas pega o elemento do meio

Medidas de Tendência Central: Mediana

A **mediana** é o valor que divide um conjunto de dados ordenado em duas metades iguais

- Se o número de observações é ímpar, a mediana é o valor do meio. Se é par, a mediana é a média dos dois valores do meio

$$\text{Mediana} = \begin{cases} x_{(\frac{n+1}{2})} & \text{se } n \text{ é ímpar} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2} & \text{se } n \text{ é par} \end{cases}$$

Média dos dois elementos centrais

Medidas de Tendência Central: Mediana

A **mediana** é o valor que divide um conjunto de dados ordenado em duas metades iguais

- Se o número de observações é ímpar, a mediana é o valor do meio. Se é par, a mediana é a média dos dois valores do meio

$$\text{Mediana} = \begin{cases} x_{(\frac{n+1}{2})} & \text{se } n \text{ é ímpar} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2} & \text{se } n \text{ é par} \end{cases}$$

Código em Python:

```python
import numpy as np

# Calculando a mediana
dados = np.array([1, 3, 3, 6, 7, 8, 9])
mediana = np.median(dados)
print("Mediana:", mediana)

#Saída: Mediana: 6
```

Medidas de Tendência Central: Moda

A **moda** é o valor ou valores mais frequentes em um conjunto de dados

- É possível que um conjunto de dados tenha mais de uma moda se houver dois ou mais valores com a mesma frequência máxima.

Código em Python:

```python
from scipy import stats

# Calculando a moda
dados = np.array([1, 2, 2, 3, 4])
moda = stats.mode(dados)
print("Moda:", moda.mode[0])
print("Frequência:", moda.count[0])

#Saídas: Moda: 2 e Frequência: 2
```

Medidas de Tendência Central: Resumo

Média

- **Uso:** Representa o valor central de um conjunto de dados, calculado somando todos os valores e dividindo pelo número total de valores
    - Adequada para dados mais bem distribuídos sem *outliers* significativos
- **Vantagens**: Fácil de calcular e entender. Útil para comparar conjuntos de dados
- **Desvantagens**: Sensível a *outliers*, o que pode distorcer a representação do valor central para distribuições assimétricas

Medidas de Tendência Central: Resumo

Mediana

- **Uso:** Valor que divide um conjunto de dados ordenado em duas metades iguais
    - Adequada para dados com outliers ou distribuições assimétricas, pois fornece uma medida central mais robusta
- **Vantagens:** Não é afetada por outliers. Reflete melhor o ponto central em distribuições assimétricas
- **Desvantagens:** Pode não capturar bem a tendência central em distribuições bimodais ou multimodais. Menos sensível a pequenas variações em dados extremos

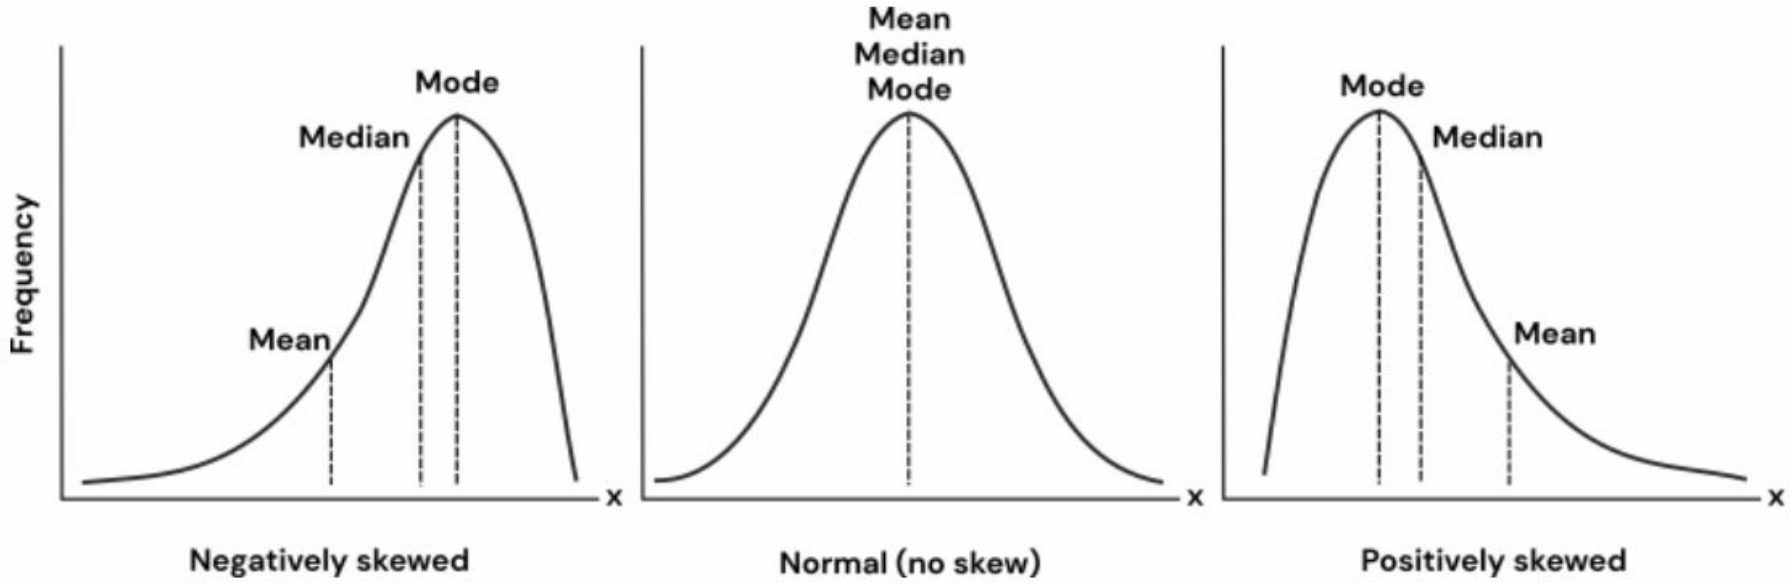
Medidas de Tendência Central: Resumo

Moda

- **Uso:** O valor mais frequente em um conjunto de dados
    - É a única medida de tendência central que pode ser usada com dados categóricos, além de numéricos
- **Vantagens:** Útil para identificar categorias ou valores predominantes; aplicável a qualquer tipo de dado (nominal, ordinal, intervalar, razão)
- **Desvantagens:** Pode não existir ou não ser única para um conjunto de dados. Fornece informações limitadas sobre a distribuição dos dados

Medidas de Tendência Central: Resumo

Representação visual da média, mediana e moda:



Técnicas de Sumarização

Medidas de Tendência Central: Média, Mediana e Moda

Medidas de Dispersão: Variância, Desvio Padrão, Amplitude e Intervalo Interquartil (IQR)

Medidas de Forma: Assimetria (Skewness), Curtose (Kurtosis)

Medidas de Associação: Covariância e Coeficiente de Correlação

Medidas de Dispersão: Variância

A variância mede quão dispersos estão os valores em relação à média

- É a média dos quadrados das diferenças entre cada valor e a média do conjunto de dados

$$\sigma^2 = \frac{\sum_{i=1}^{n}(x_i - \mu)^2}{n}$$

Populacional

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

Amostral

Medidas de Dispersão: Variância

A variância mede quão dispersos estão os valores em relação à média

- É a média dos quadrados das diferenças entre cada valor e a média do conjunto de dados

$$\sigma^2 = \frac{\sum_{i=1}^{n}(x_i - \mu)^2}{n}$$

Populacional

População: Conjunto completo de todos os elementos (pessoas, itens, eventos, etc.) que estão sendo estudados

- Representa o universo total de dados sobre o qual se deseja obter conclusões. Dificilmente alcançado!

Medidas de Dispersão: Variância

A variância mede quão dispersos estão os valores em relação à média

- É a média dos quadrados das diferenças entre cada valor e a média do conjunto de dados

$$\sigma^2 = \frac{\sum_{i=1}^{n}(x_i - \mu)^2}{n} \qquad s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

Populacional **Amostral**

Amostra: Subconjunto selecionado de uma população usado para fazer inferências ou estimativas sobre a população total

- Usada frequentemente devido à impraticabilidade, custo ou tempo necessário para examinar cada membro da população completa

Medidas de Dispersão: Variância

A variância mede quão dispersos estão os valores em relação à média

- É a média dos quadrados das diferenças entre cada valor e a média do conjunto de dados

$$\sigma^2 = \frac{\sum_{i=1}^{n}(x_i - \mu)^2}{n} \qquad s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

Populacional — Amostral

Graus de liberdade: Número de valores em uma estatística que são livres para variar quando algumas estatísticas da amostra quando uma ou mais estatísticas da amostra (como a média) já foram fixadas

- Simplificando, estamos usando amostras para estimar 1 parâmetro. Por isso, 1!

Medidas de Dispersão: Variância

Usamos amostras na maioria das vezes porque é mais prático, menos custoso e mais rápido do que estudar a população inteira

- Dificilmente temos acesso à população inteira

Técnicas de amostragem e inferência estatística permitindo que conclusões válidas sejam obtidas a partir da análise da amostra

Medidas de Dispersão: Variância

Código em Python:

```python
import numpy as np

# Dados do exemplo
dados = np.array([1, 2, 3, 4, 5])

# Calculando a variância para população
variancia_populacao = np.var(dados, ddof=0)
print("Variância (População):", variancia_populacao)

# Calculando a variância para amostra
variancia_amostra = np.var(dados, ddof=1)
print("Variância (Amostra):", variancia_amostra)

#Saídas: Variância (População):7.63
#        Variância (Amostra): 8.90
```

Medidas de Dispersão: Variância

Código em Python:

```python
import numpy as np

# Dados do exemplo
dados = np.array([1, 2, 3, 4, 5])

# Calculando a variância para população
variancia_populacao = np.var(dados, ddof=0)
print("Variância (População):", variancia_populacao)

# Calculando a variância para amostra
variancia_amostra = np.var(dados, ddof=1)
print("Variância (Amostra):", variancia_amostra)

#Saídas: Variância (População):7.63
#        Variância (Amostra): 8.90
```

Graus de liberdade = 0 (Padrão)

Graus de liberdade = 1 (Deve ser especificado)

Medidas de Dispersão: Desvio Padrão

O desvio padrão é uma medida de dispersão que indica quão espalhados os dados estão em relação à média do conjunto

- Valores de desvio padrão maiores indicam maior variabilidade nos dados. Seu valor é medido na mesma unidade da medida da V.A.

$$\sigma = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \mu)^2}{n}}$$

Populacional

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

Amostral

O desvio padrão é a raiz quadrada da variância e, portanto, também considera os conceitos de “População” e “Amostra”

Medidas de Dispersão: Desvio Padrão

Código em Python:

```python
import numpy as np

# Dados do exemplo
dados = np.array([1, 2, 3, 4, 5])

# Calculando o desvio padrão para população
desvio_padrao_populacao = np.std(dados, ddof=0)
print("Desvio Padrão (População):", desvio_padrao_populacao)

# Calculando o desvio padrão para amostra
desvio_padrao_amostra = np.std(dados, ddof=1)
print("Desvio Padrão (Amostra):", desvio_padrao_amostra)


#Saídas: Desvio Padrão (População):2.76
#        Desvio Padrão (Amostra): 2.98
```

Graus de liberdade = 0 (Padrão)

Graus de liberdade = 1 (Deve ser especificado)

Medidas de Dispersão: Amplitude

A amplitude é a diferença entre o maior e o menor valor em um conjunto de dados

- Captura a extensão da variação ou dispersão dos dados, mas pode ser influenciada por valores extremos

$$\text{Amplitude} = x_{\max} - x_{\min}$$

Código em Python:

```python
import numpy as np

# Dados do exemplo
dados = np.array([3, 7, 2, 9, 4])

# Calculando a amplitude
amplitude = np.max(dados) - np.min(dados)
print("Amplitude:", amplitude)

#Saída: Amplitude: 7
```

Medidas de Dispersão: Percentil

Um percentil é um valor abaixo do qual uma certa percentagem de observações em um grupo de observações cai

- Por exemplo, o 50º percentil é o valor abaixo do qual 50% das observações podem ser encontradas

$$P_k = X\left(\frac{k(N+1)}{100}\right)$$

Medidas de Dispersão: Percentil

Um percentil é um valor abaixo do qual uma certa percentagem de observações em um grupo de observações cai

- Por exemplo, o 50º percentil é o valor abaixo do qual 50% das observações podem ser encontradas

$$P_k = X\left(\frac{k(N+1)}{100}\right)$$

onde P_k é o k-ésimo percentil

X é o conjunto ordenado de dados

N é o número total de observações, e k é o percentual desejado

Medidas de Dispersão: Percentil

Código em Python:

```python
import numpy as np

# Dados do exemplo
dados = np.array([1, 3, 4, 7, 8, 9, 10])

# Calculando o 25º, 50º e 75º percentis
P25 = np.percentile(dados, 25)
P50 = np.percentile(dados, 50)
P75 = np.percentile(dados, 75)
print("25º Percentil (Q1):", P25)
print("50º Percentil (Mediana):", P50)
print("75º Percentil (Q3):", P75)

#Saídas: 25º Percentil (Q1): 3.5
#        50º Percentil (Mediana): 7
#        75º Percentil (Q3): 8.5
```

Medidas de Dispersão: Quartil

Quartis são valores que dividem o conjunto de dados em quatro partes iguais:

- 1º Quartil (Q1) é o mesmo que o 25º percentil
- 2º Quartil (Q2) é o mesmo que o 50º percentil (mediana)
- 3º Quartil (Q3) é o mesmo que o 75º percentil

O código para calcular os quartis é o mesmo utilizado para calcular os percentis correspondentes, como mostrado anteriormente

- Os quartis são simplesmente casos específicos de percentis

Medidas de Dispersão: Percentil/Quartil

Código em Python:

```python
import numpy as np

# Dados do exemplo
dados = np.array([1, 3, 4, 7, 8, 9, 10])

# Calculando o 25º, 50º e 75º percentis
P25 = np.percentile(dados, 25)
P50 = np.percentile(dados, 50)
P75 = np.percentile(dados, 75)
print("25º Percentil (Q1):", P25)
print("50º Percentil (Mediana):", P50)
print("75º Percentil (Q3):", P75)

#Saídas: 25º Percentil (Q1): 3.5
#        50º Percentil (Mediana): 7
#        75º Percentil (Q3): 8.5
```

Medidas de Dispersão: Intervalo Interquartil (IQR)

Descreve a diferença entre o terceiro quartil (Q3) e o primeiro quartil (Q1) em um conjunto de dados

- Representa a extensão da “metade média” dos dados e minimizando o impacto de outliers $\mathrm{IQR} = Q3 - Q1$

Medidas de Dispersão: Intervalo Interquartil (IQR)

Descreve a diferença entre o terceiro quartil (Q3) e o primeiro quartil (Q1) em um conjunto de dados

- Representa a extensão da “metade média” dos dados e minimizando o impacto de outliers

$$\text{IQR} = Q3 - Q1$$

Q3 é o terceiro quartil (o valor abaixo do qual estão 75% dos dados)

Q1 é o primeiro quartil (o valor abaixo do qual estão 25% dos dados)

Medidas de Dispersão: Intervalo Interquartil (IQR)

Descreve a diferença entre o terceiro quartil (Q3) e o primeiro quartil (Q1) em um conjunto de dados

- Representa a extensão da “metade média” dos dados e minimizando o impacto de outliers

$$\text{IQR} = Q3 - Q1$$

Código em Python:

```python
import numpy as np

# Dados do exemplo
dados = np.array([2, 3, 4, 8, 9, 11, 13])

# Calculando o IQR
Q1 = np.percentile(dados, 25)
Q3 = np.percentile(dados, 75)
IQR = Q3 - Q1
print("IQR:", IQR)

#Saída: IQR: 4
```

Técnicas de Sumarização

Medidas de Tendência Central: Média, Mediana e Moda

Medidas de Dispersão: Variância, Desvio Padrão, Amplitude e Intervalo Interquartil (IQR)

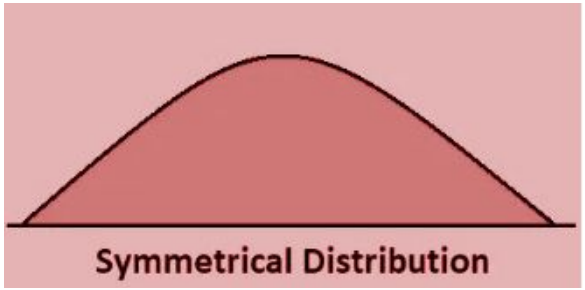
Medidas de Forma: Assimetria (Skewness), Curtose (Kurtosis)

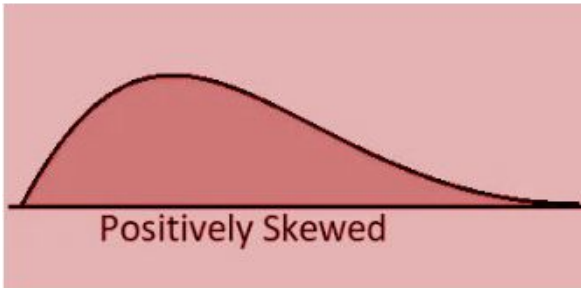
Medidas de Associação: Covariância e Coeficiente de Correlação

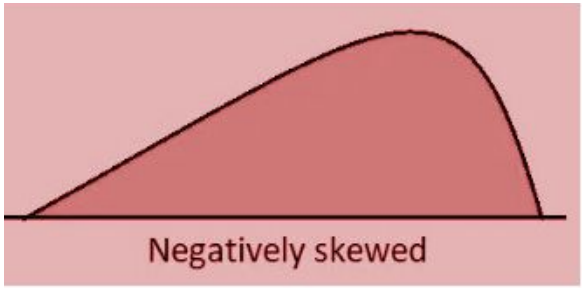
Medidas de Forma: Assimetria

Assimetria (Skewness) é uma medida de desvio ou distorção da simetria em uma distribuição de dados

- **Valor de Assimetria = 0:** Distribuição perfeitamente simétrica
- **Valor de Assimetria > 0:** Distribuição com cauda mais longa à direita (positiva)
- **Valor de Assimetria < 0:** Distribuição com cauda mais longa à esquerda (negativa)







Fonte: Link

Medidas de Forma: Assimetria

É calculada da seguinte forma:

$$S = \frac{n}{(n-1)(n-2)} \sum_{i=1}^{n} \left(\frac{x_i - \bar{x}}{s} \right)^3$$

onde *n* é o número de observações, x_i é cada observação individual, $\bar{x}$ é a média das observações, e *s* é o desvio padrão da amostra

Código em Python:

```python
from scipy.stats import skew

# Dados do exemplo
dados = np.array([2, 8, 0, 4, 1, 9, 9, 0])

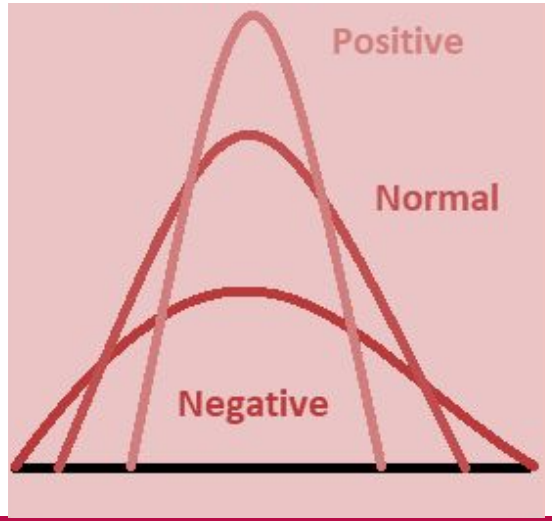
# Calculando a assimetria
assimetria = skew(dados)
print("Assimetria:", assimetria)

#Saída: Assimetria: 0.2650
```

Medidas de Forma: Curtose

Curtose (Kurtosis) mede o peso das caudas de uma distribuição, a propensão a valores extremos, em relação à distribuição normal

- **Curtose = 0:** caudas equivalentes às da distribuição normal
- **Curtose > 0:** caudas mais pesadas - valores extremos mais frequentes
- **Curtose < 0:** caudas mais leves - valores extremos mais raros



Medidas de Forma: Curtose

É calculada da seguinte forma:

$$K = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum_{i=1}^{n} \left(\frac{x_i - \bar{x}}{s} \right)^4 - \frac{3(n-1)^2}{(n-2)(n-3)}$$

onde *n* é o número de observações, x_i são as observações individuais, $\bar{x}$ é a média das observações, e *s* é o desvio padrão da amostra

- A subtração final de 3 ajusta a medida para que a curtose de uma distribuição normal seja zero

Assim como a Assimetria, não possui limites inferior e superior

Medidas de Forma: Curtose

Código em Python:

```python
from scipy.stats import kurtosis

# Dados de exemplo
dados_curtose = np.array([1, 2, 2, 3, 4, 4, 4, 5, 6])

# Calculando a curtose
curtose = kurtosis(dados_curtose, fisher=True)
print("Curtose:", curtose)

#Saída: Curtose: -0.94
```

A distribuição dos dados, com uma curtose negativa, é mais achatada do que uma distribuição normal

- Sugere caudas leves e uma menor probabilidade de valores extremos

Técnicas de Sumarização

Medidas de Tendência Central: Média, Mediana e Moda

Medidas de Dispersão: Variância, Desvio Padrão, Amplitude e Intervalo Interquartil (IQR)

Medidas de Forma: Assimetria (Skewness), Curtose (Kurtosis)

Medidas de Associação: Covariância e Coeficiente de Correlação

Medidas de Associação: Covariância

A covariância é uma medida que indica o grau de variação conjunta de duas variáveis aleatórias

- **Cov(X, Y) = 0:** Variáveis não possuem nenhuma associação linear.
- **Cov(X, Y) > 0:** Variáveis tendem a variar juntas diretamente
- **Cov(X, Y) < 0:** Variáveis tendem a variar juntas inversamente

$$\mathrm{Cov}(X,Y) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

onde x_i e y_i são os valores individuais das variáveis X e Y, respectivamente, $\bar{x}$ e $\bar{y}$ são as médias dessas variáveis, e n é o número de observações

Medidas de Associação: Covariância

Código em Python:

```python
import numpy as np

# Dados do exemplo
X = np.array([10, 2, 33, 4])
Y = np.array([20, 3, 44, 3])

# Calculando a covariância
cov_matrix = np.cov(X, Y)
print("Covariância entre X e Y:", cov_matrix[0, 1])

#Saída: Covariância entre X e Y: 270.8
```

A covariância não tem limites superiores ou inferiores estritos. Isso dificulta um pouco a interpretação

- O valor da covariância depende da escala das variáveis envolvidas e de quão fortemente elas estão linearmente relacionadas

Medidas de Associação: Correlação

O coeficiente de correlação é uma medida estatística que quantifica a força e a direção da relação linear entre duas variáveis

Existem várias formas de calcular a correlação. As duas principais são:

- **Pearson**: Use quando ambos os conjuntos de dados são quantitativos e têm uma relação linear
- **Spearman**: Use para dados ordinais ou quando não há certeza de uma relação linear, avaliando a correlação de ranque

Variam entre -1 e 1, onde 1 indica uma correlação positiva perfeita, -1 indica uma correlação negativa perfeita, e 0 indica nenhuma correlação linear

Medidas de Associação: Correlação

Definição da correlação de Pearson:

Covariância de X e Y

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2(y_i - \bar{y})^2}}$$

Verifica se quando uma variável se desvia da média, a outra também desvia

Medidas de Associação: Correlação

Definição da correlação de Pearson:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 (y_i - \bar{y})^2}}$$

Desvio padrão da variável X

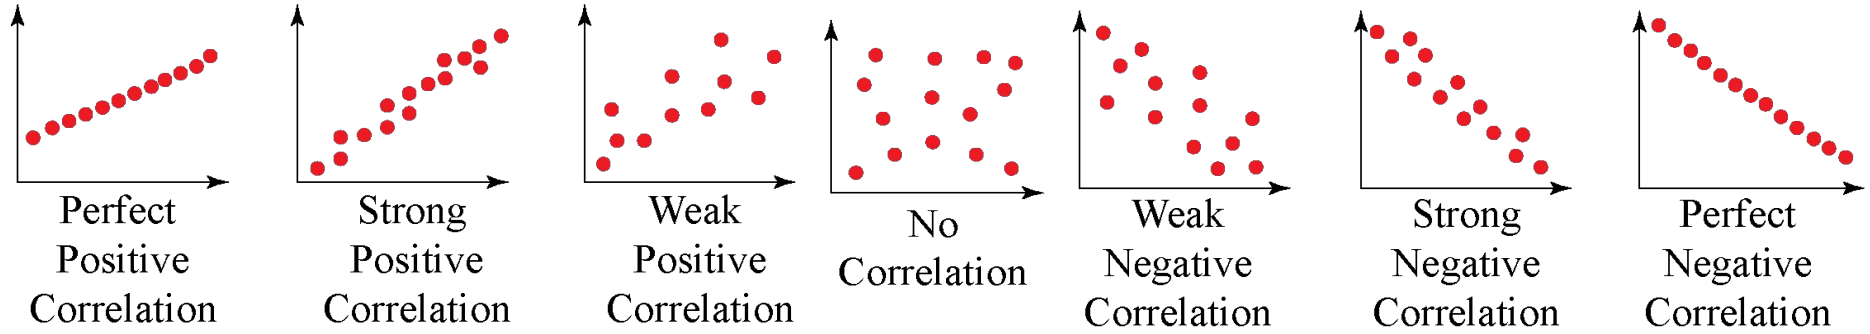
Desvio padrão da variável Y

Medidas de Associação: Correlação

Definição da correlação de Pearson:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 (y_i - \bar{y})^2}}$$

Exemplo visual:



Medidas de Associação: Correlação

Valores de referência:

Valor de r	**Grau da relação**	**Valor de r**
$-0.2 < r < 0$	Inexistente (Nula)	$0 \leq r < 0.2$
$-0.4 < r < -0.2$	Muito fraca	$0.2 \leq r < 0.4$
$-0.7 < r < -0.4$	Fraca/ Moderada	$0.4 \leq r < 0.7$
$-0.9 < r < -0.7$	Forte	$0.7 \leq r < 0.9$
$-1 < r < -0.9$	Muito forte	$0.9 \leq r < 1$
$r = -1$	Perfeita	$r = 1$

Estes valores mudam de acordo com a área e com a aplicação!

Medidas de Associação: Correlação

Exemplo em Python:

```python
import numpy as np

# Dados do exemplo
X = np.array([10, 22, 3, 5])
Y = np.array([2, 31, 4, 6])

# Calculando o coeficiente de correlação
coef_correlacao = np.corrcoef(X, Y)[0, 1]
print("Coeficiente de Correlação:", coef_correlacao)


#Saída: Coeficiente de Correlação: 0.90
```

Técnicas de representações gráficas

Existem várias formas de representar graficamente uma ou mais variáveis visando:

- Comparação
- Distribuição
- Composição
- Associação/Relação

Analisaremos algumas brevemente

Técnicas de representações gráficas

Comparação:

- **Gráficos de barras:** Úteis para comparar quantidades em diferentes categorias
- **Gráficos de linha:** Bom para visualizar a mudança de uma quantidade ao longo do tempo

Distribuição:

- **Histogramas:** Mostram a distribuição de frequências de uma variável contínua
- **PMF (Função de Massa de Probabilidade)**: Aplicável a variáveis discretas, mostra a probabilidade de cada valor ocorrer
- **PDF (Função de Densidade de Probabilidade)**: Indica a probabilidade de valores dentro de um intervalo específico para dados contínuos

Técnicas de representações gráficas

Distribuição (Continuação):

- **Box Plots:** Resumem a distribuição dos dados através de quartis e *outliers*
- **CDF (Função de Distribuição Cumulativa)**: Mostra a proporção de observações menores ou iguais a um certo valor
- **CCDF (Função de Distribuição Cumulativa Complementar):** Mostra a proporção de observações maiores que um valor

Composição:

- **Gráficos de Barras Empilhada**: Mostram como partes individuais contribuem

Técnicas de representações gráficas

Associação:

- **Diagramas de Dispersão (Scatter Plots)**: Excelentes para visualizar as relações entre duas variáveis quantitativas
- **Gráficos de Calor (Heatmaps):** Bom para visualizar a intensidade da correlação entre múltiplas variáveis ou a densidade de pontos

Biblioteca Seaborn

Seaborn é uma biblioteca de visualização de dados em Python baseada no *matplotlib*

- Fornece uma interface de alto nível para desenhar diversos tipos de gráficos estatísticos
- Trabalha bem com pandas DataFrame, facilitando o uso de dados estruturados

A biblioteca vem com uma grande variedade de estilos e paletas de cores para fazer os gráficos mais estéticos

- Permite ajustar complexidades de visualizações com poucos comandos

Saiba mais: Link!

Biblioteca Seaborn

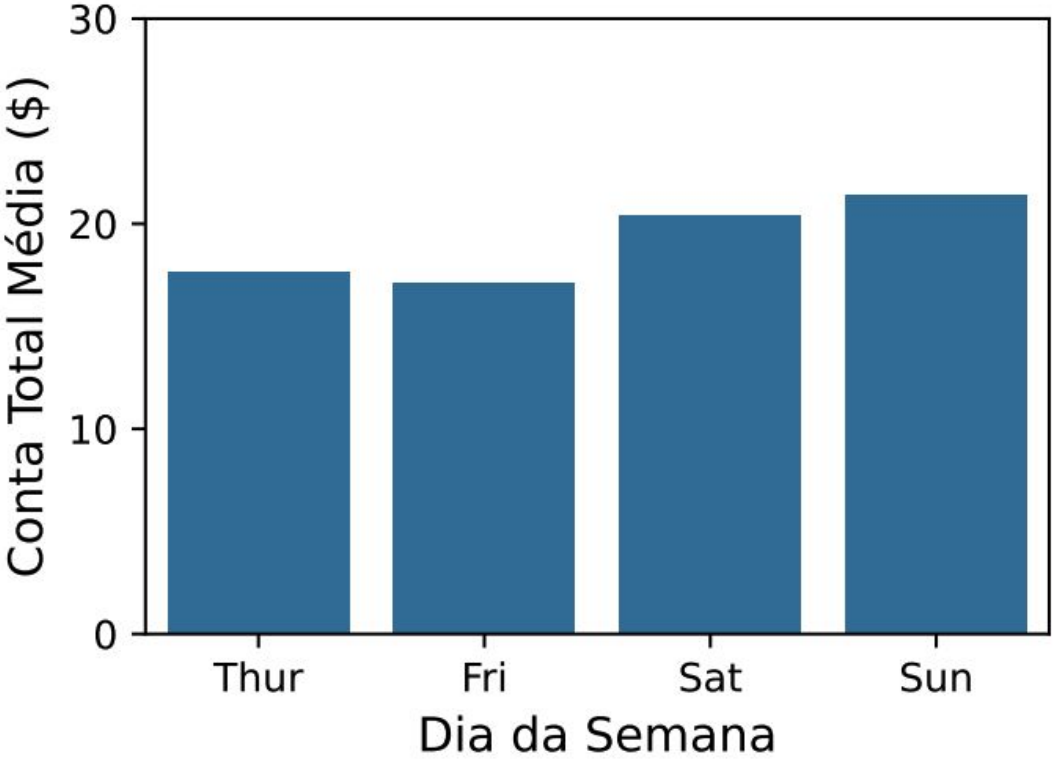
Muitas funções de plotagem da Seaborn permitem que você especifique um objeto Axes (ax) do Matplotlib como um argumento

- Se você não especificar um, o Seaborn criará um novo objeto Axes e o utilizará para o gráfico

Um objeto *Axes* sempre é retornado ou pode ser manipulado após a criação do gráfico

- Isso significa que você pode utilizar qualquer método de personalização do Matplotlib em gráficos do Seaborn
- Isso inclui ajustes nos rótulos, títulos, limites dos eixos, adição de anotações, entre outros

Gráfico de barras: Exemplo



Link da documentação contendo todos os parâmetros!

Gráfico de barras: Exemplo

```
%matplotlib inline
import seaborn as sns
import matplotlib.pyplot as plt

# Carregar dados de exemplo
tips = sns.load_dataset("tips")

# Definir o tamanho da figura
plt.figure(figsize=(4, 3))

# Criar um gráfico de barras
ax = sns.barplot(x="day", y="total_bill",
                 data=tips, errorbar=None)

# Personalizar rótulos dos eixos
ax.set_xlabel("Dia da Semana", fontsize=12)  # X label
ax.set_ylabel("Conta Total Média ($)", fontsize=12)  # Y label

# Alterar a escala do eixo Y, por exemplo, de 0 a 60 com intervalos de 10
ax.set_ylim(0, 30)
plt.yticks(range(0, 31, 10))

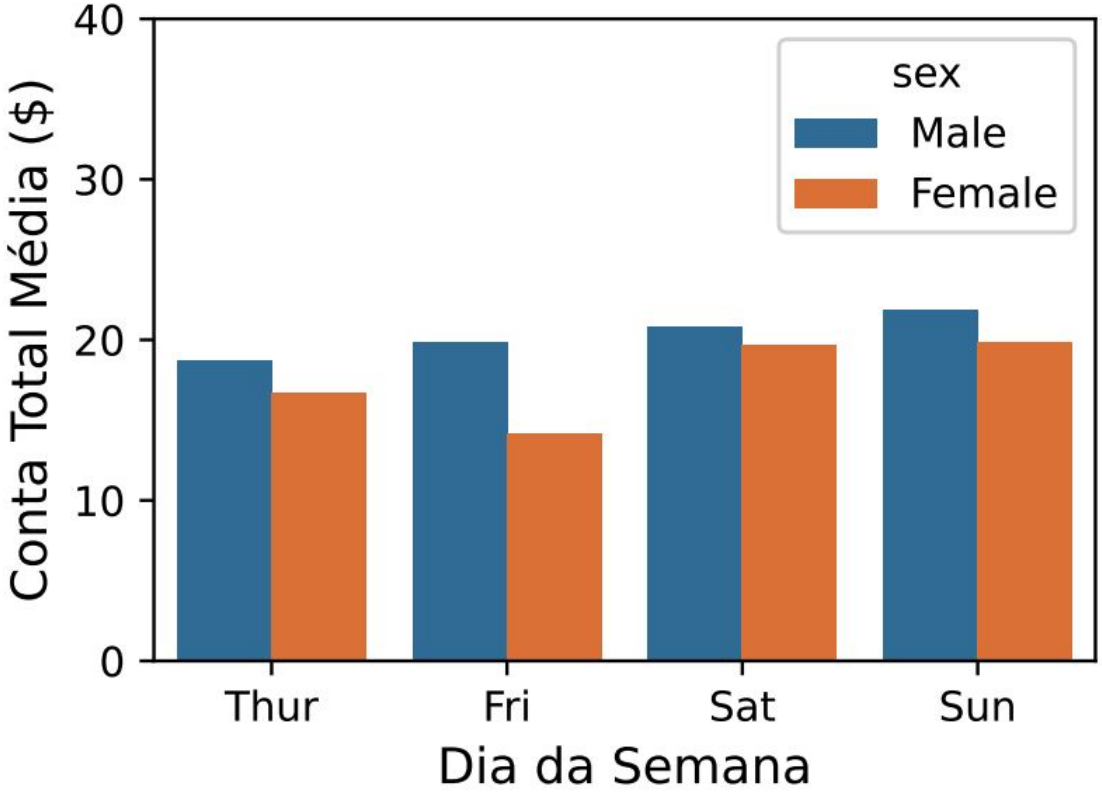
#Ajusta o preenchimento do plot
plt.tight_layout()

# Salvar a figura em .pdf
plt.savefig("Exemplo-Grafico-Barras.pdf")

plt.show()
```

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4

Gráfico de barras: Exemplo 2



Link da documentação contendo todos os parâmetros!

Gráfico de barras: Exemplo 2

```
%matplotlib inline
import seaborn as sns
import matplotlib.pyplot as plt

# Carregar dados de exemplo
tips = sns.load_dataset("tips")

# Definir o tamanho da figura
plt.figure(figsize=(4, 3))

# Criar um gráfico de barras com agrupamento por 'sex', sem barras de erro
ax = sns.barplot(x="day", y="total_bill", hue="sex", data=tips, errorbar=None)

# Personalizar rótulos dos eixos
ax.set_xlabel("Dia da Semana", fontsize=12)  # Rótulo do eixo X
ax.set_ylabel("Conta Total Média ($)", fontsize=12)  # Rótulo do eixo Y

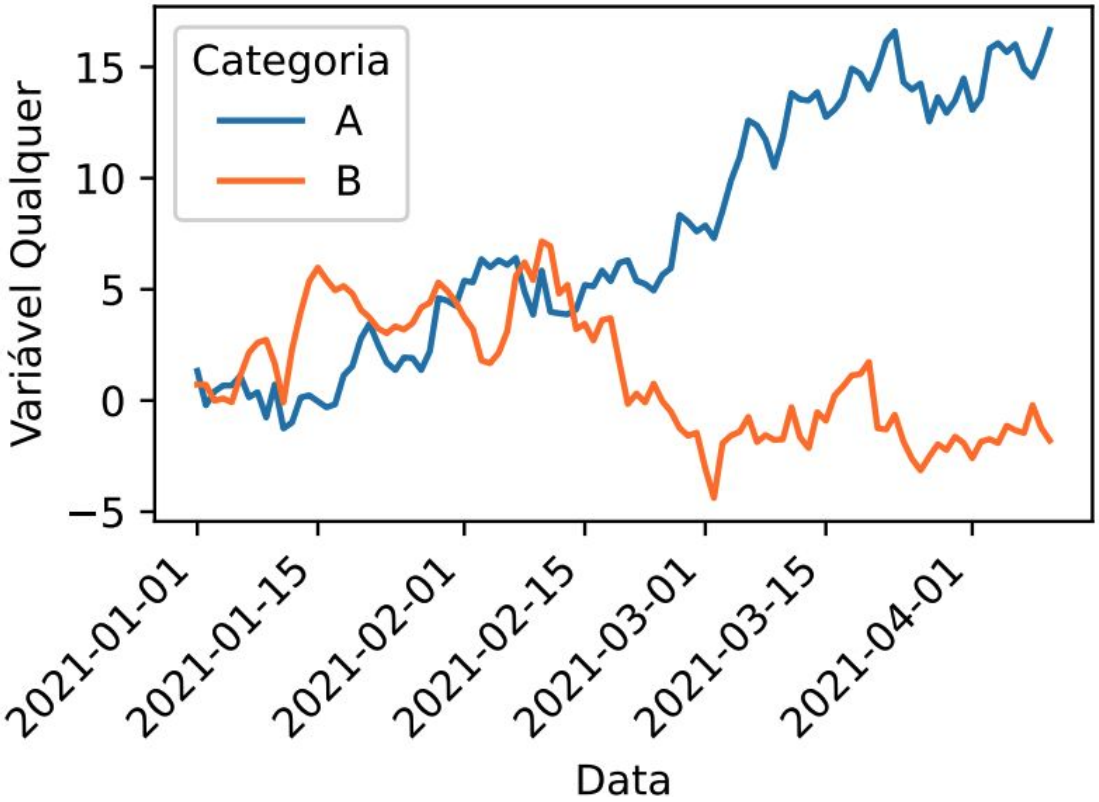
# Alterar a escala do eixo Y
ax.set_ylim(0, 40)  # Define os limites do eixo Y
plt.yticks(range(0, 41, 10))  # Define os intervalos de marcação no eixo Y

# Ajustar o layout para não cortar rótulos ou títulos
plt.tight_layout()

# Salvar a figura em formato PDF
plt.savefig("Exemplo_Grafico_Barras_Agrupadas.pdf")

# Exibir o gráfico
plt.show()
```

Gráfico de linhas: Exemplo



Link da documentação contendo todos os parâmetros!

Gráfico de linhas:

```
%matplotlib inline
import seaborn as sns
import matplotlib.pyplot as plt


# Definir o tamanho da figura
plt.figure(figsize=(4, 3))

# Criar um gráfico de linhas temporal
ax = sns.lineplot(x="Data", y="Valor", hue="Categoria", data=data)

# Personalizar rótulos dos eixos
ax.set_xlabel("Data")
ax.set_ylabel("Variável Qualquer")

# Rotacionar rótulos das datas e alinha os labels
plt.xticks(rotation=45, ha='right')

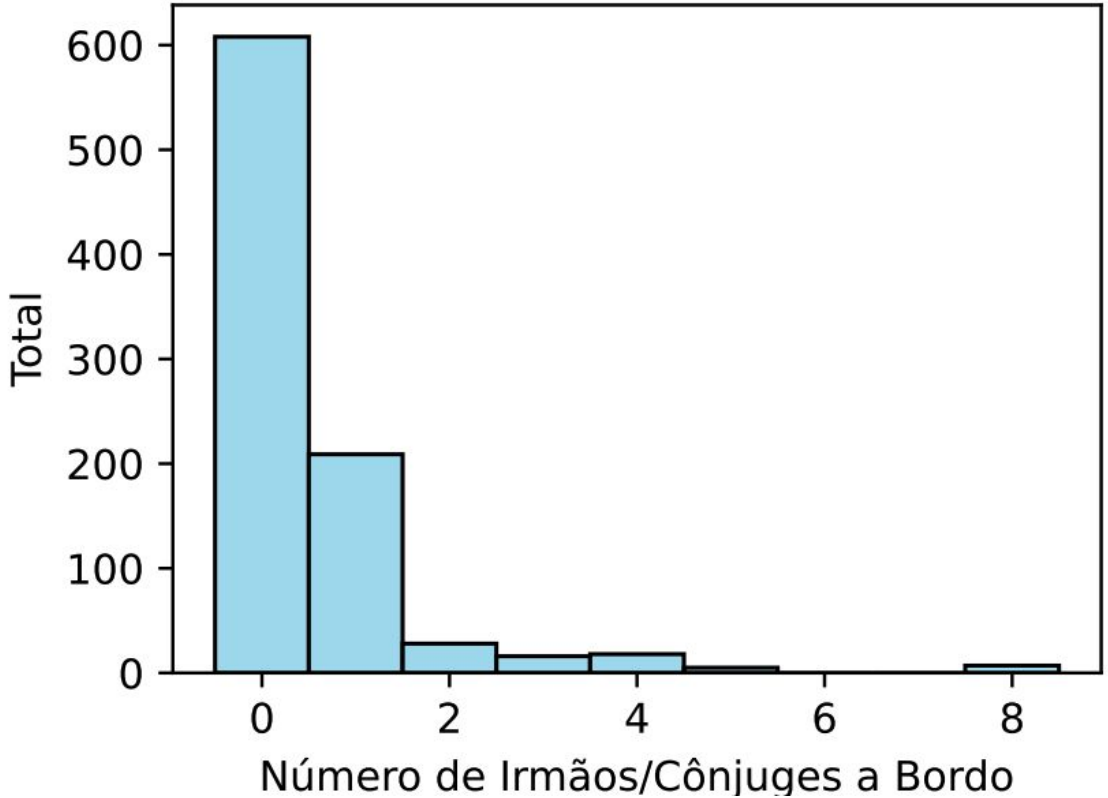
# Ajustar o layout para não cortar rótulos ou títulos
plt.tight_layout()

# Salvar a figura em formato PDF
plt.savefig("Exemplo_Grafico_Linhas_Temporal.pdf")

# Exibir o gráfico
plt.show()
```

	Data	Categoria	Valor
0	2021-01-01	A	1.331587
1	2021-01-02	A	-0.213814
2	2021-01-03	A	0.407522
3	2021-01-04	A	0.673034
4	2021-01-05	A	0.677325

Histograma: Exemplo



Link da documentação contendo todos os parâmetros!

Histograma: Exemplo

```
%matplotlib inline
import seaborn as sns
import matplotlib.pyplot as plt

# Carregar dados do Titanic
titanic = sns.load_dataset("titanic")

# Definir o tamanho da figura
plt.figure(figsize=(4, 3))

# Criar um histograma para a variável discreta 'sibsp'
ax = sns.histplot(titanic['sibsp'], discrete=True, color='skyblue')

# Personalizar rótulos dos eixos
ax.set_xlabel("Número de Irmãos/Cônjuges a Bordo")
ax.set_ylabel("Total")

# Ajustar o layout para não cortar rótulos ou títulos
plt.tight_layout()

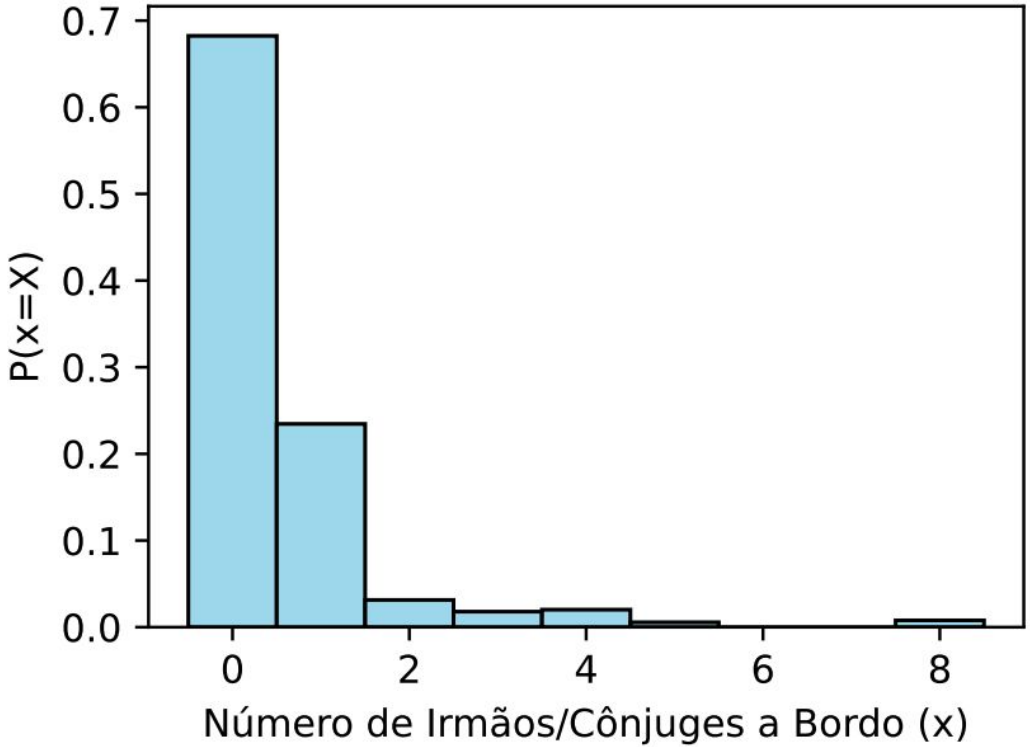
# Salvar a figura em formato PDF
plt.savefig("Histograma_Titanic_SibSp.pdf")

# Exibir o gráfico
plt.show()

```

	survived	pclass	sex	age	sibsp
0	0	3	male	22.0	1
1	1	1	female	38.0	1
2	1	3	female	26.0	0
3	1	1	female	35.0	1
4	0	3	male	35.0	0

PMF: Exemplo



Link da documentação contendo todos os parâmetros!

PMF: Exemplo

```
%matplotlib inline
import seaborn as sns
import matplotlib.pyplot as plt

# Carregar dados do Titanic
titanic = sns.load_dataset("titanic")

# Definir o tamanho da figura
plt.figure(figsize=(4, 3))

# Criar um histograma para a variável discreta 'sibsp'
# Repare que houve uma normalização stat
ax = sns.histplot(titanic['sibsp'], discrete=True,
                  color='skyblue', stat='probability')

# Personalizar rótulos dos eixos
ax.set_xlabel("Número de Irmãos/Cônjuges a Bordo (x)")
ax.set_ylabel("P(x=X)")

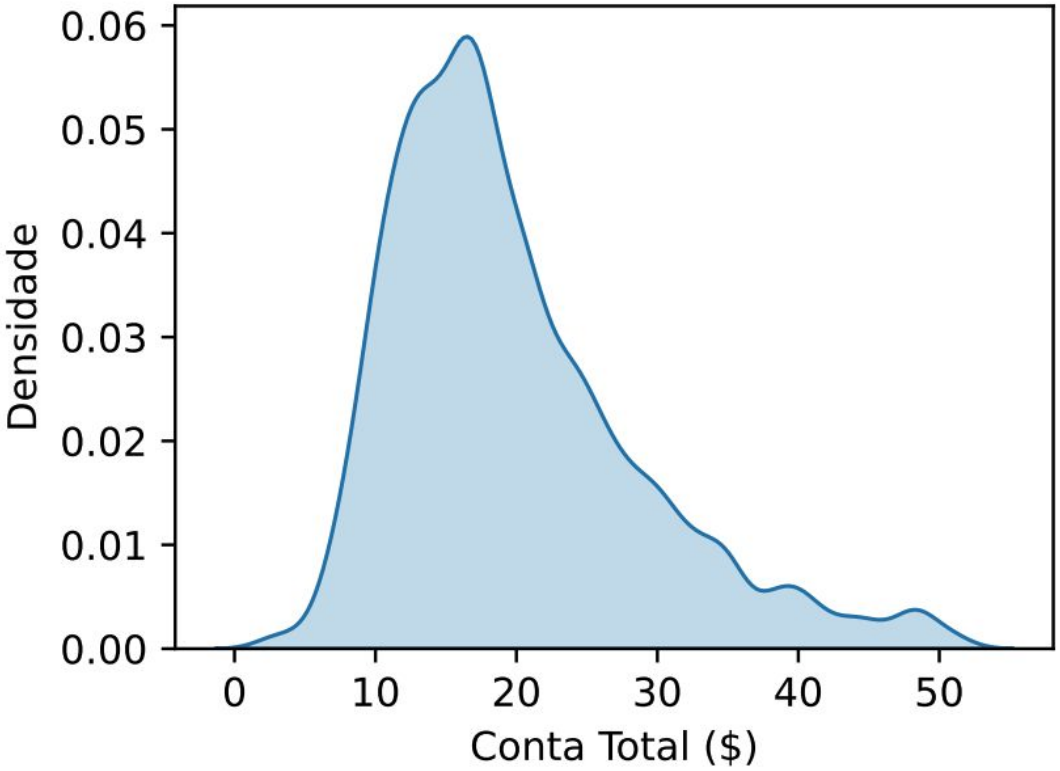
# Ajustar o layout para não cortar rótulos ou títulos
plt.tight_layout()

# Salvar a figura em formato PDF
plt.savefig("Histograma_Titanic_SibSp.pdf")

# Exibir o gráfico
plt.show()
```

	survived	pclass	sex	age	sibsp
0	0	3	male	22.0	1
1	1	1	female	38.0	1
2	1	3	female	26.0	0
3	1	1	female	35.0	1
4	0	3	male	35.0	0

PDF: Exemplo



Link da documentação contendo todos os parâmetros!

PDF: Exemplo

```
%matplotlib inline
import seaborn as sns
import matplotlib.pyplot as plt

# Carregar dados de exemplo
tips = sns.load_dataset("tips")

# Definir o tamanho da figura
plt.figure(figsize=(4, 3))

# Criar um gráfico PDF usando sns.kdeplot
sns.kdeplot(data=tips['total_bill'], bw_adjust=0.5,
            fill=True)

# Personalizar rótulos dos eixos
plt.xlabel("Conta Total ($)")
plt.ylabel("Densidade")

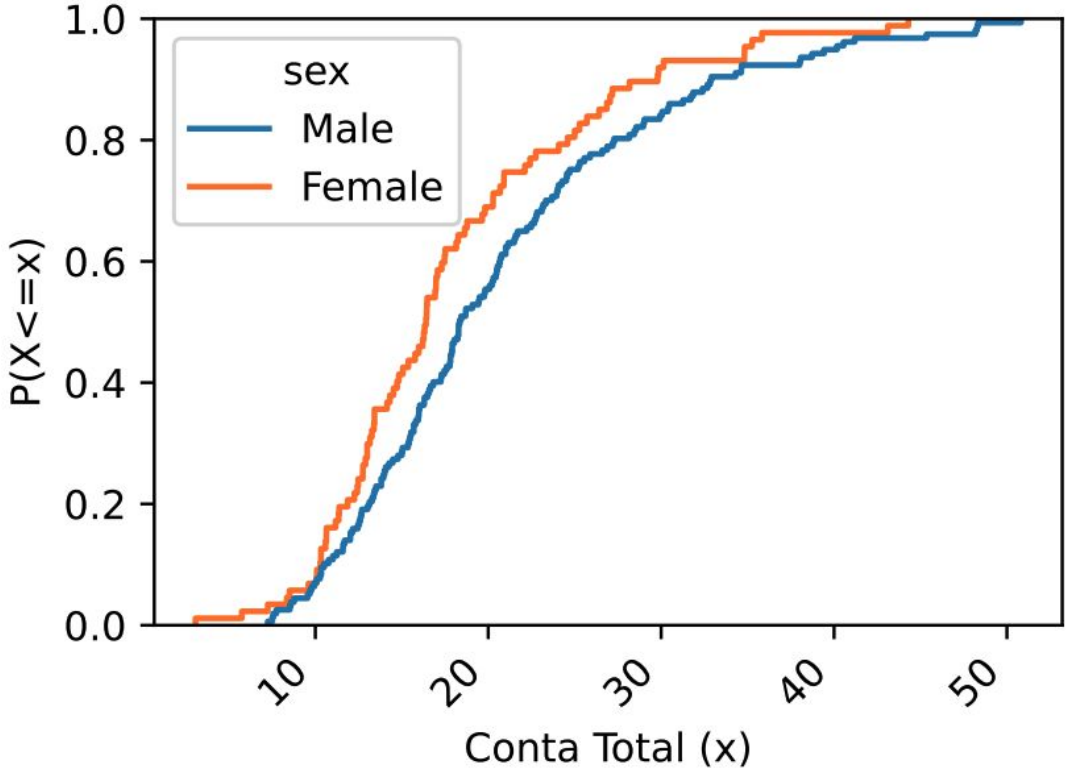
# Ajustar o layout para não cortar rótulos ou títulos
plt.tight_layout()

# Salvar a figura em formato PDF
plt.savefig("PDF_Total_Bill.pdf")

# Exibir o gráfico
plt.show()
```

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4

CDF: Exemplo



Link da documentação contendo todos os parâmetros!

CDF: Exemplo

```
%matplotlib inline
import seaborn as sns
import matplotlib.pyplot as plt

# Carregar dados de exemplo
tips = sns.load_dataset("tips")

# Definir o tamanho da figura
plt.figure(figsize=(4, 3))

# Criar um gráfico CDF
ax = sns.ecdfplot(data=tips, x="total_bill", hue="sex")

# Personalizar rótulos dos eixos
ax.set_xlabel("Conta Total (x)")
# Indicando que é a função de distribuição cumulativa
ax.set_ylabel("P(X<=x)")

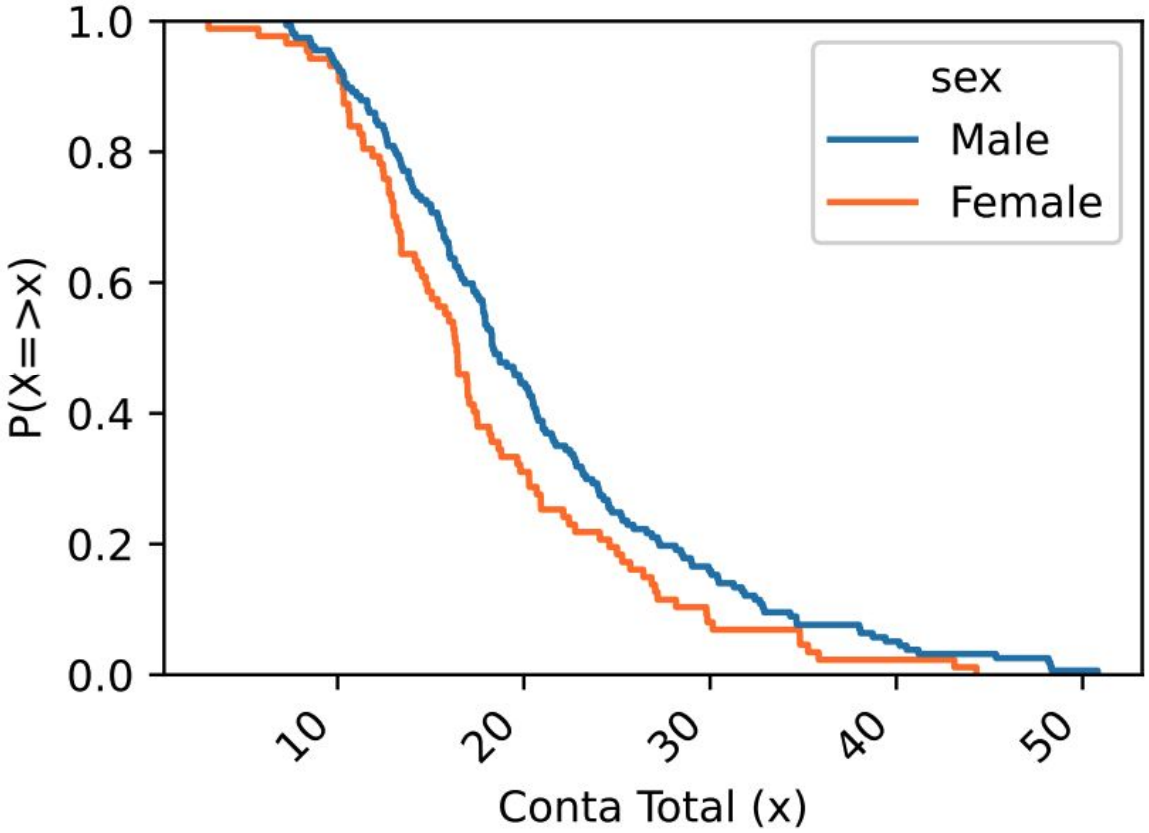
# Rotacionar rótulos das datas e alinha os labels
plt.xticks(rotation=45, ha='right')

# Ajustar o layout para não cortar rótulos ou títulos
plt.tight_layout()

# Salvar a figura em formato PDF
plt.savefig("Exemplo_CDF_Sexo.pdf")

# Exibir o gráfico
plt.show()
```

CCDF: Exemplo



Link da documentação contendo todos os parâmetros!

CCDF: Exemplo

```
%matplotlib inline
import seaborn as sns
import matplotlib.pyplot as plt

# Carregar dados de exemplo
tips = sns.load_dataset("tips")

# Definir o tamanho da figura
plt.figure(figsize=(4, 3))

# Criar um gráfico CDF
# Note que o parâmetro complementary é usado
ax = sns.ecdfplot(data=tips, x="total_bill", hue="sex",
                  complementary=True)

# Personalizar rótulos dos eixos
ax.set_xlabel("Conta Total (x)")
ax.set_ylabel("P(X>x)")  # Indicando que é a função de distribuição cumulativa

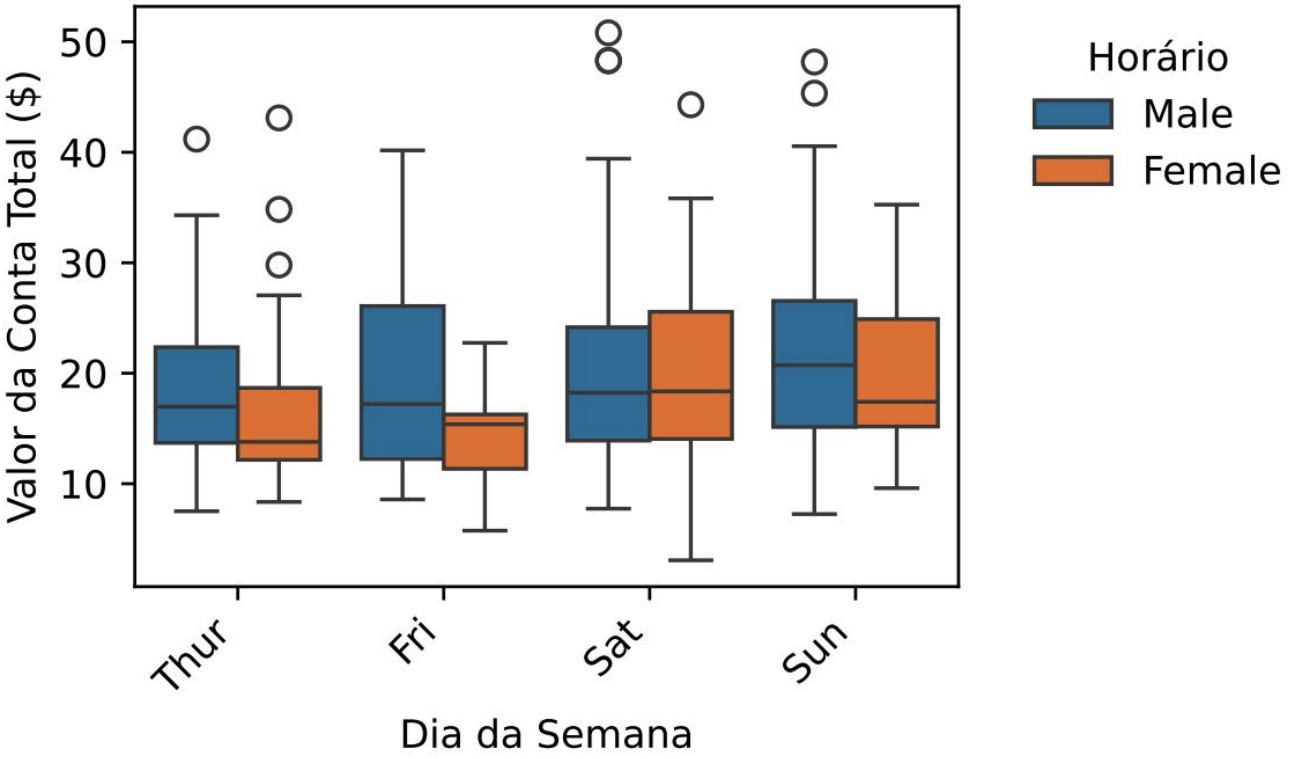
# Rotacionar rótulos das datas e alinha os labels
plt.xticks(rotation=45, ha='right')

# Ajustar o layout para não cortar rótulos ou títulos
plt.tight_layout()

# Salvar a figura em formato PDF
plt.savefig("Exemplo_CDF_Complementar_Sexo.pdf")

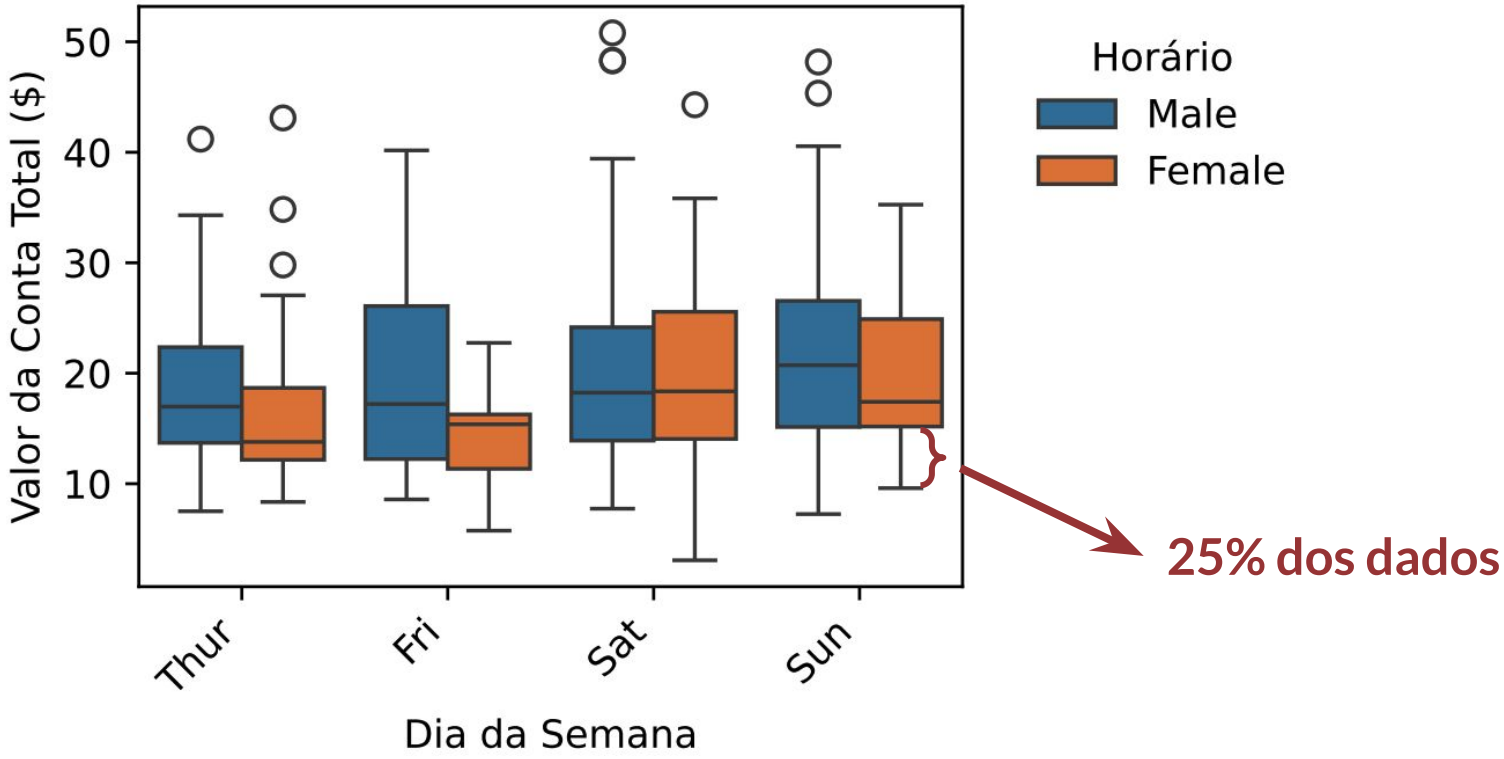
# Exibir o gráfico
plt.show()
```

Boxplot: Exemplo



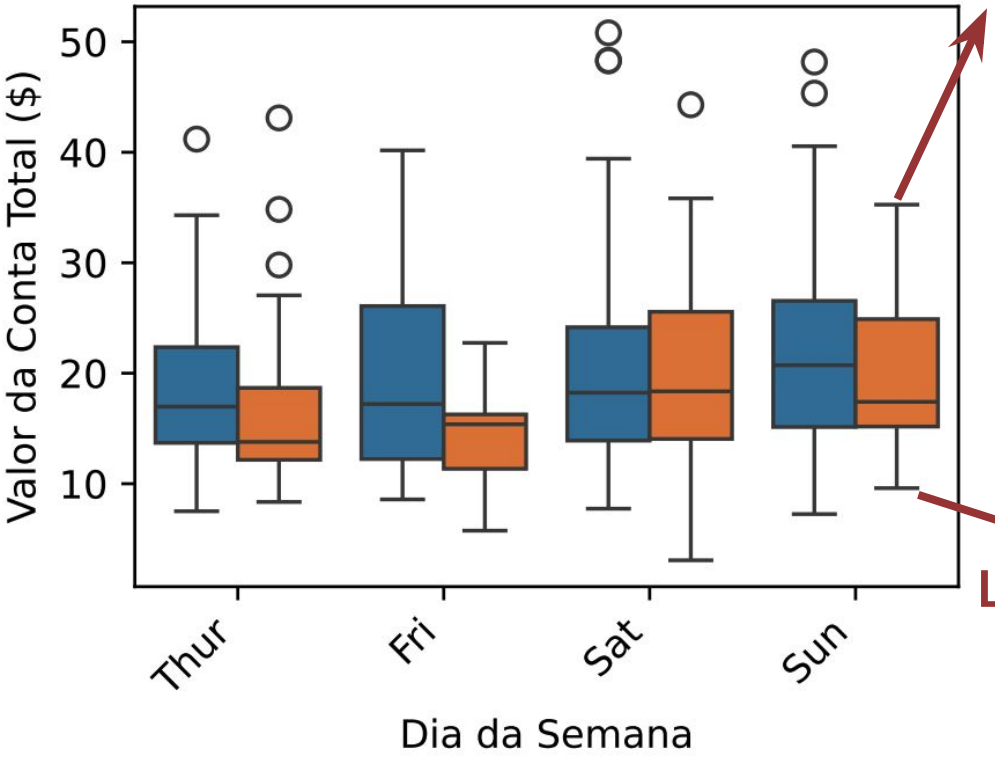
Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo



Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo

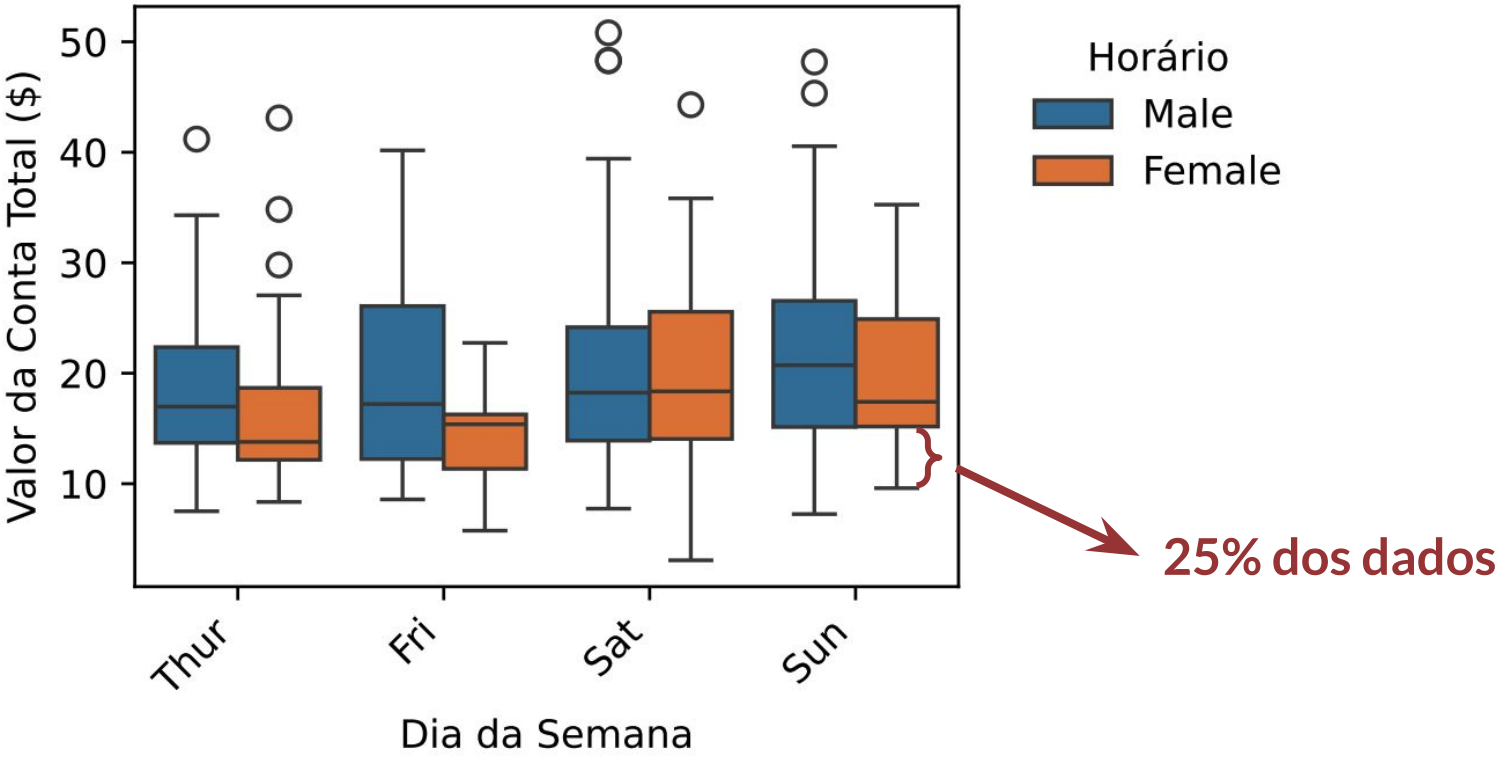


Limite Superior (Whiskers)
Bigodes

Limite Inferior (Whiskers)
Bigodes

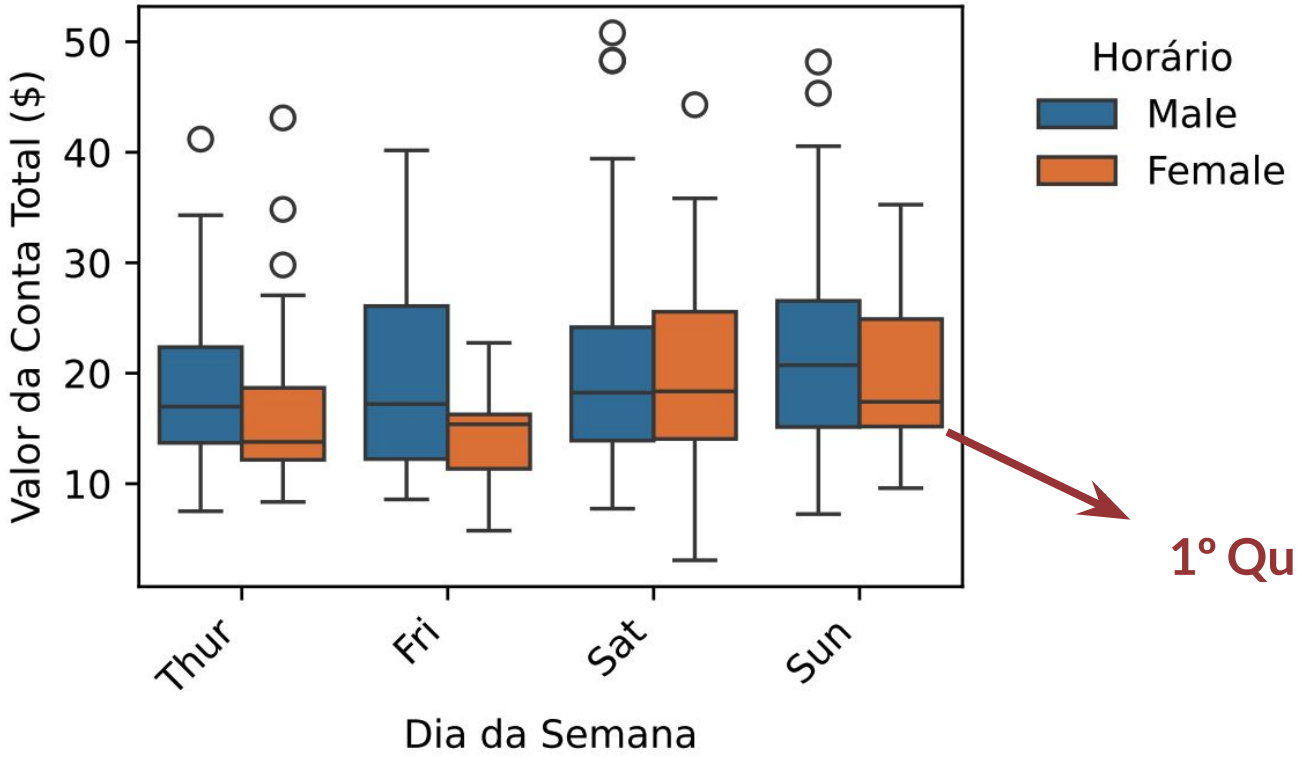
Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo



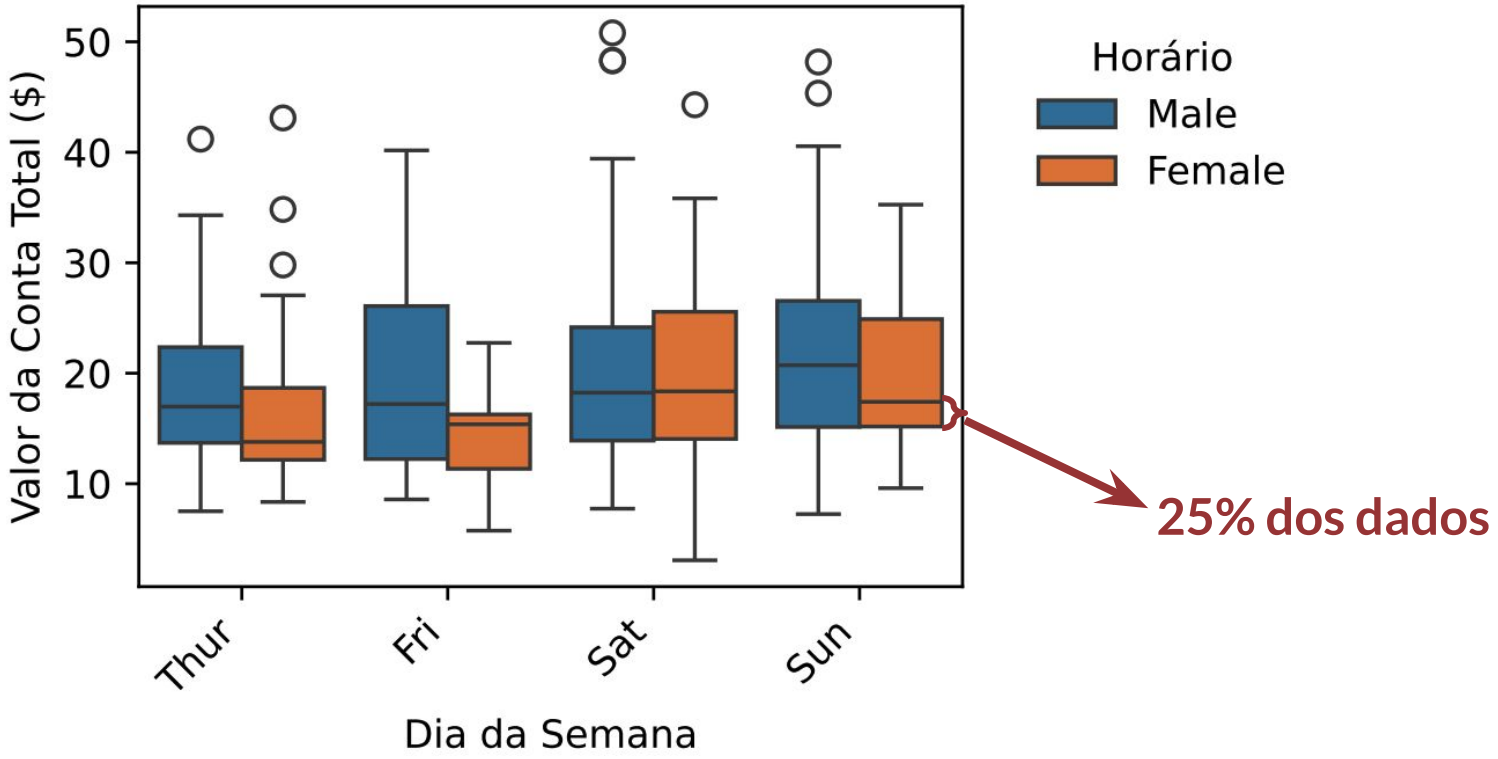
Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo



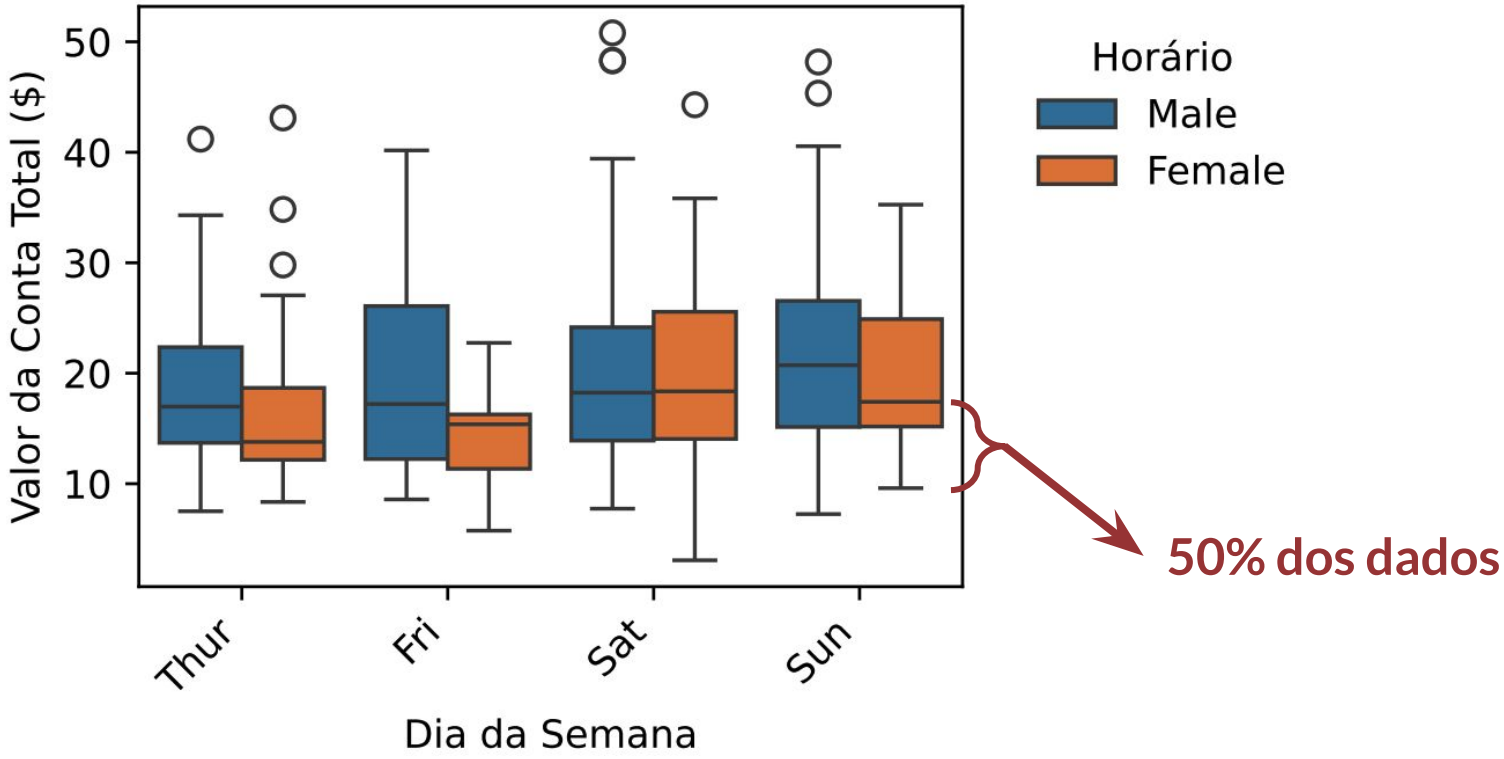
Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo



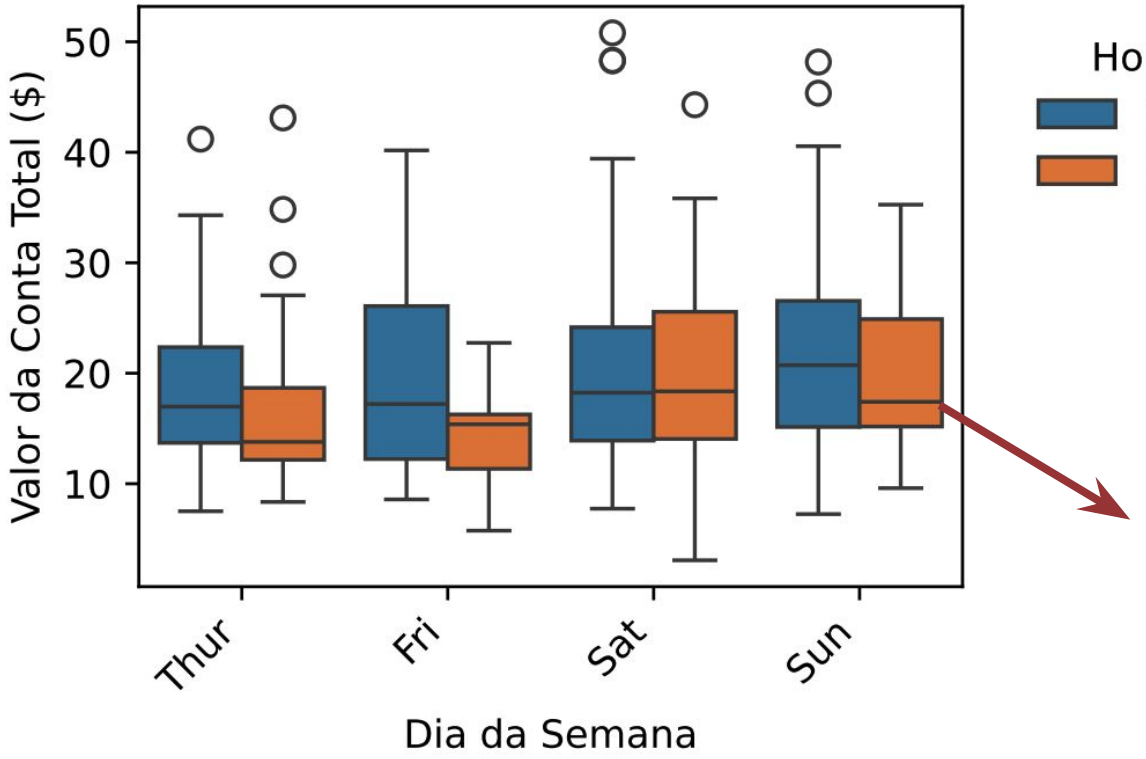
Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo



Link da documentação contendo todos os parâmetros!

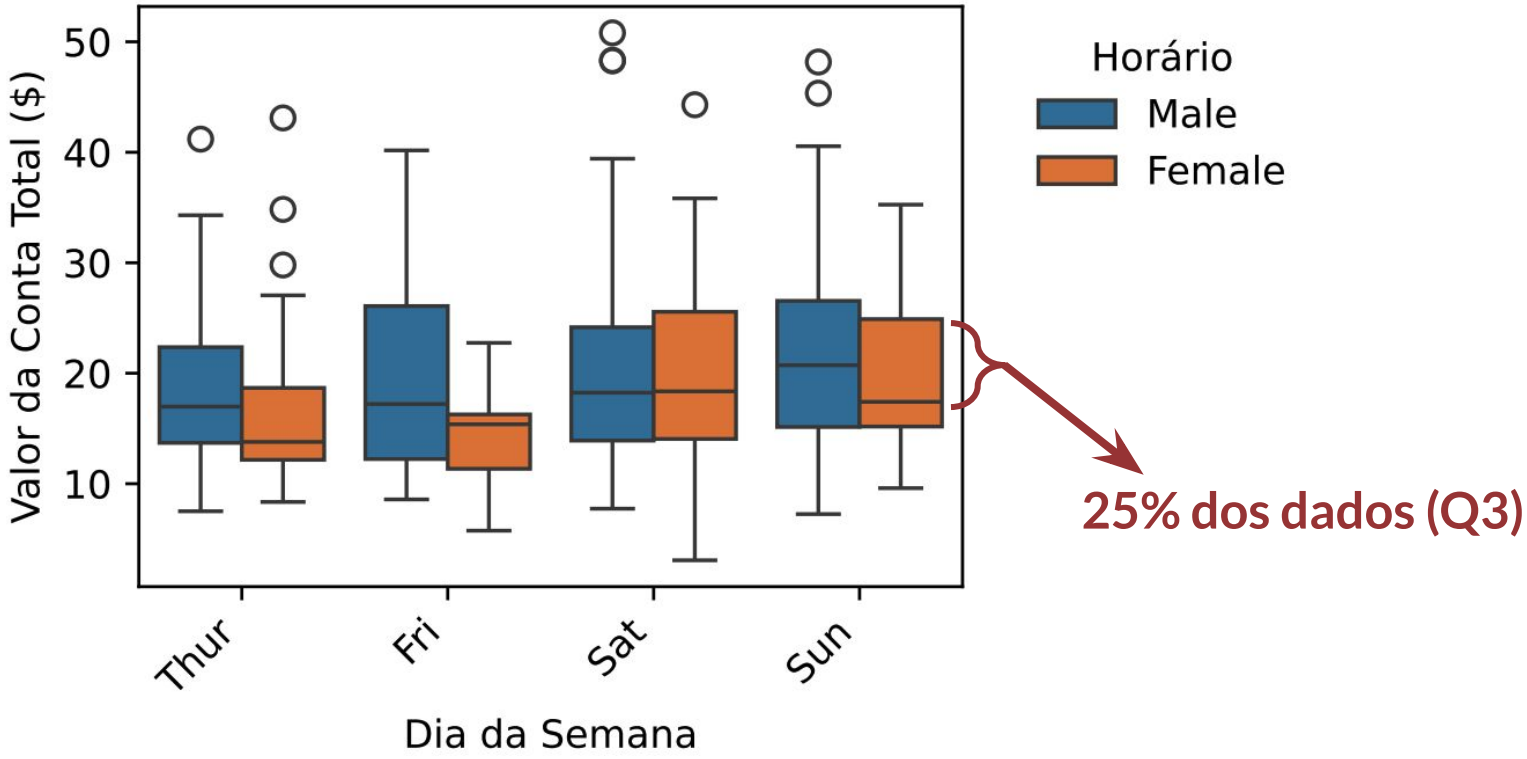
Boxplot: Exemplo



2º Quartil (Q2)
Mediana

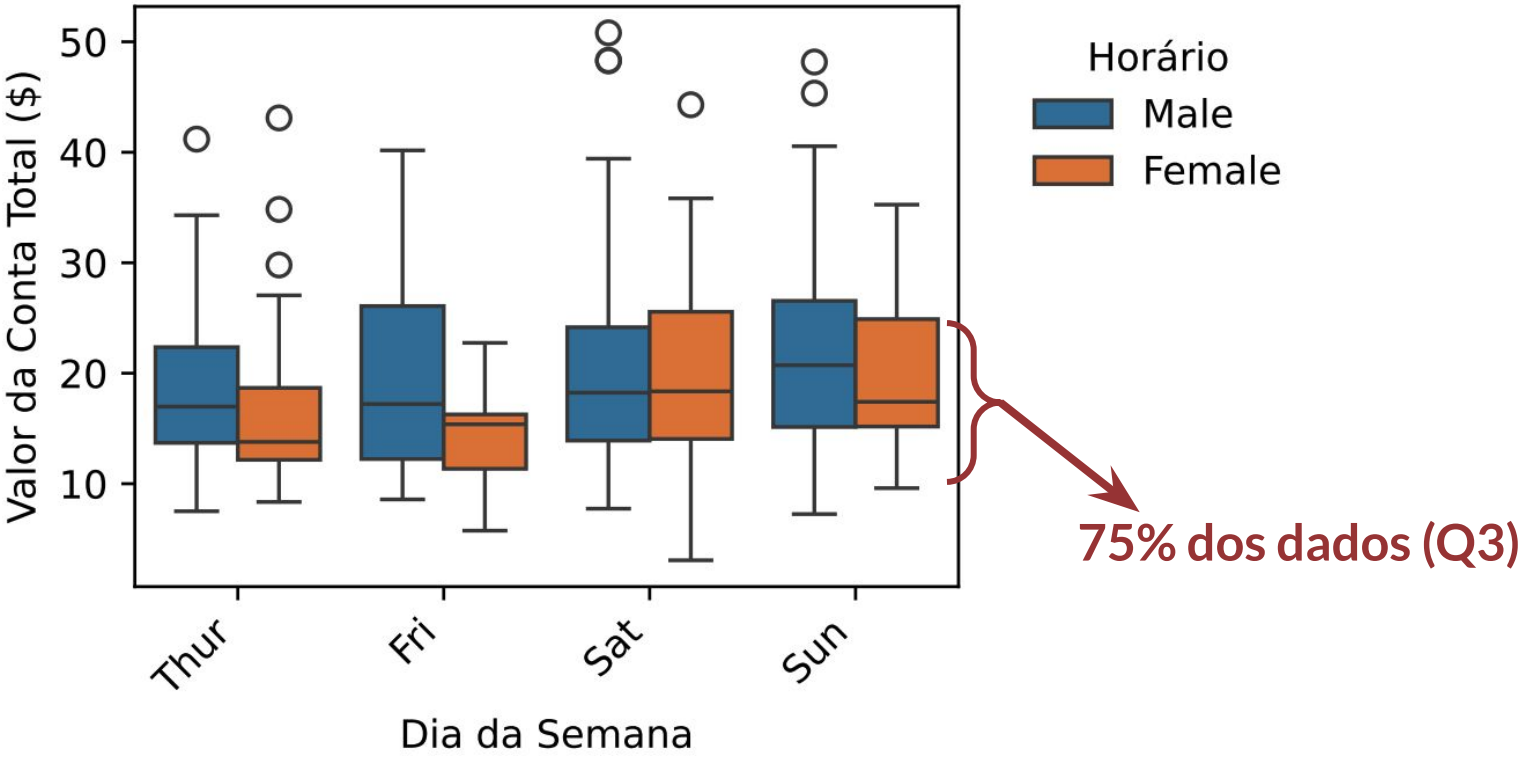
Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo



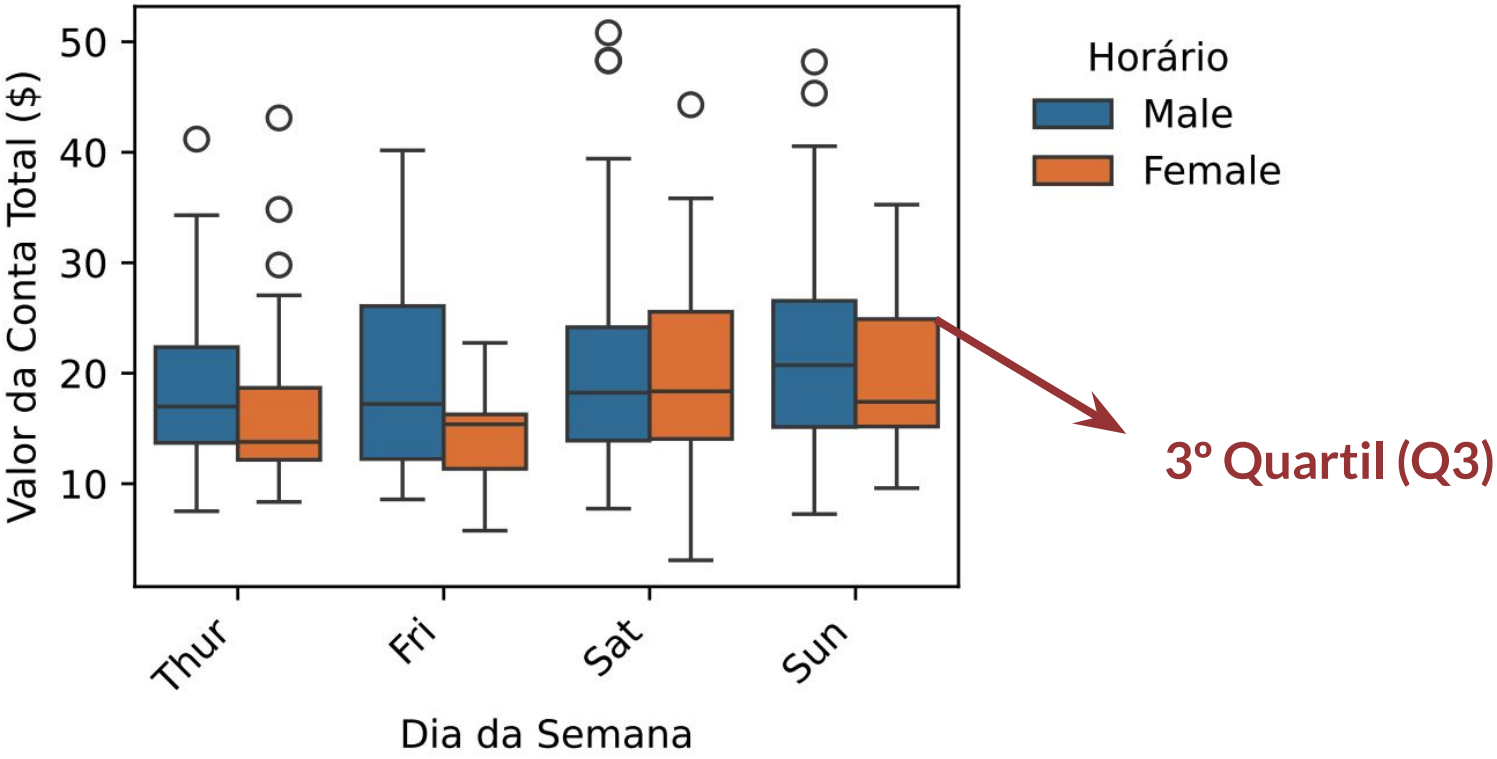
Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo



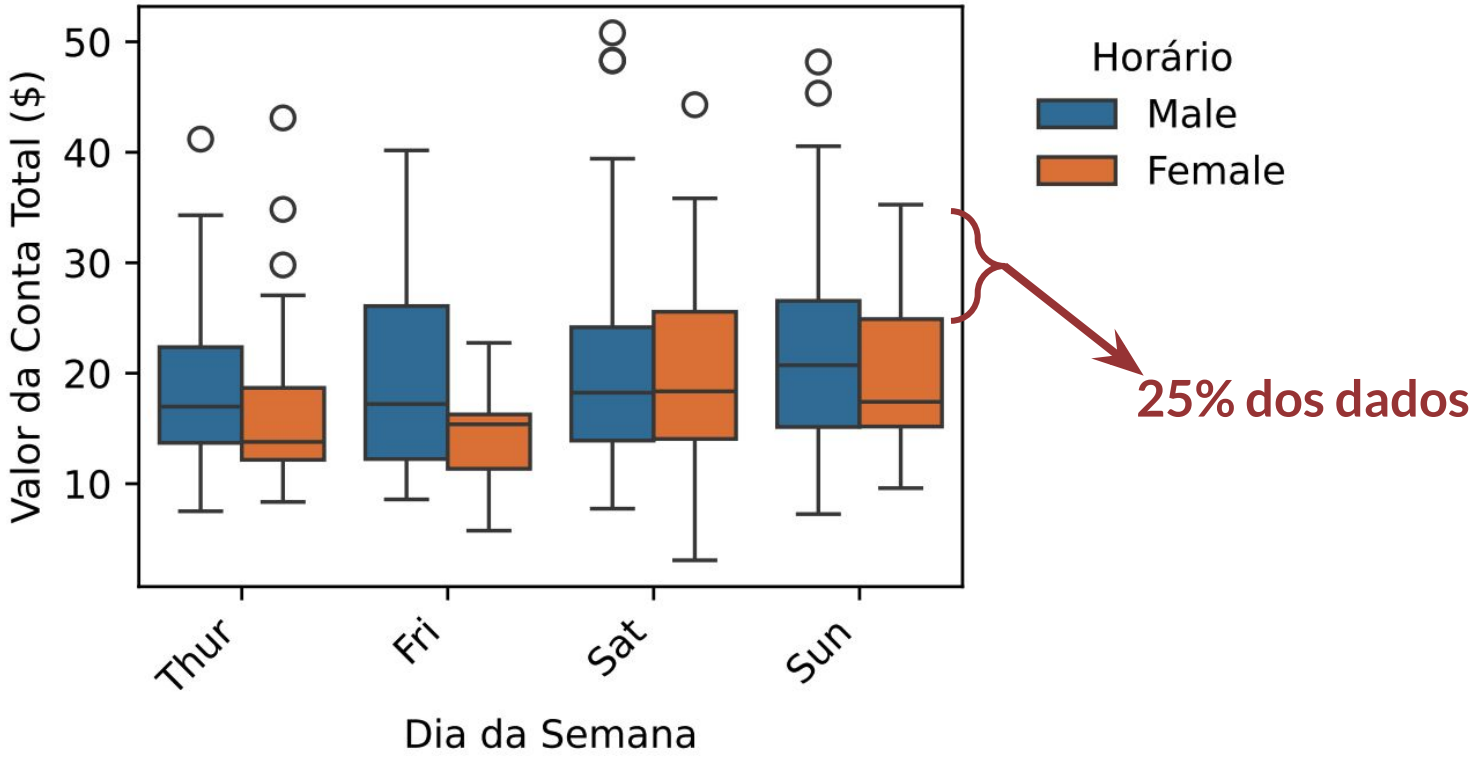
Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo



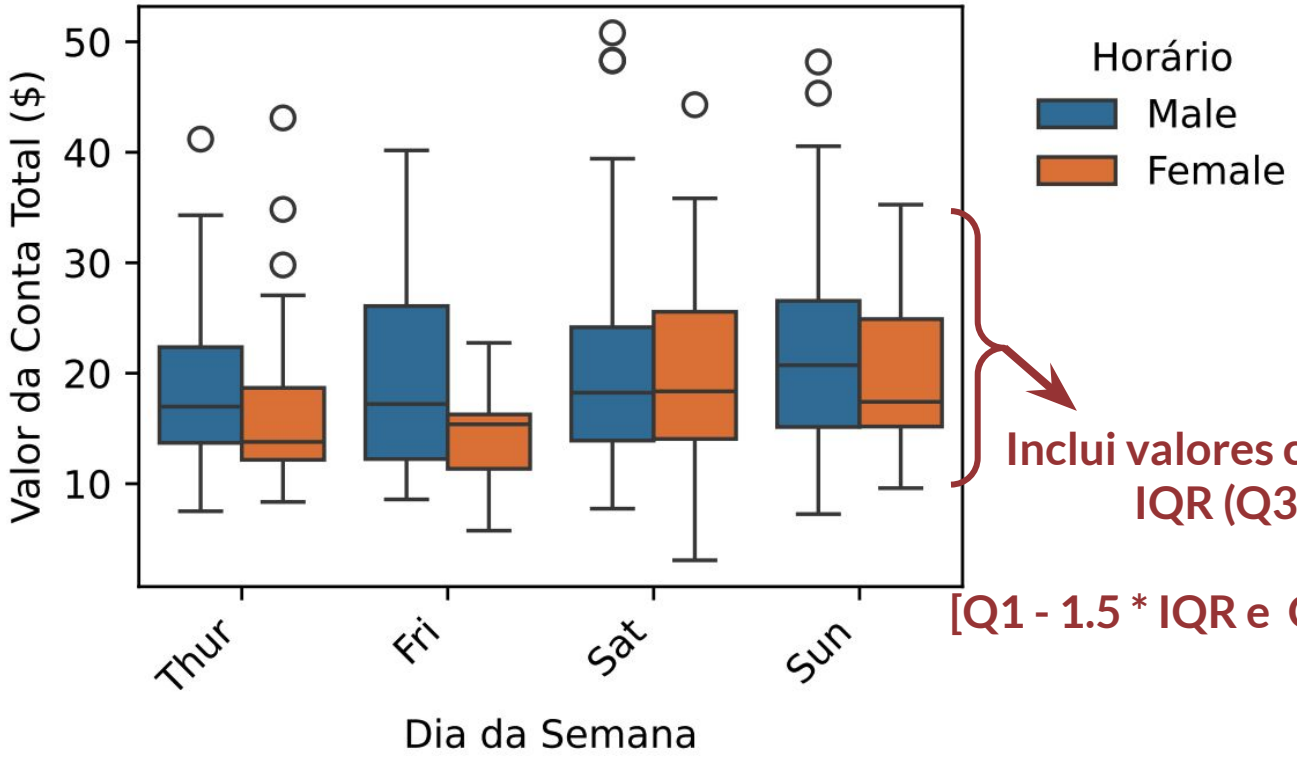
Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo



Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo

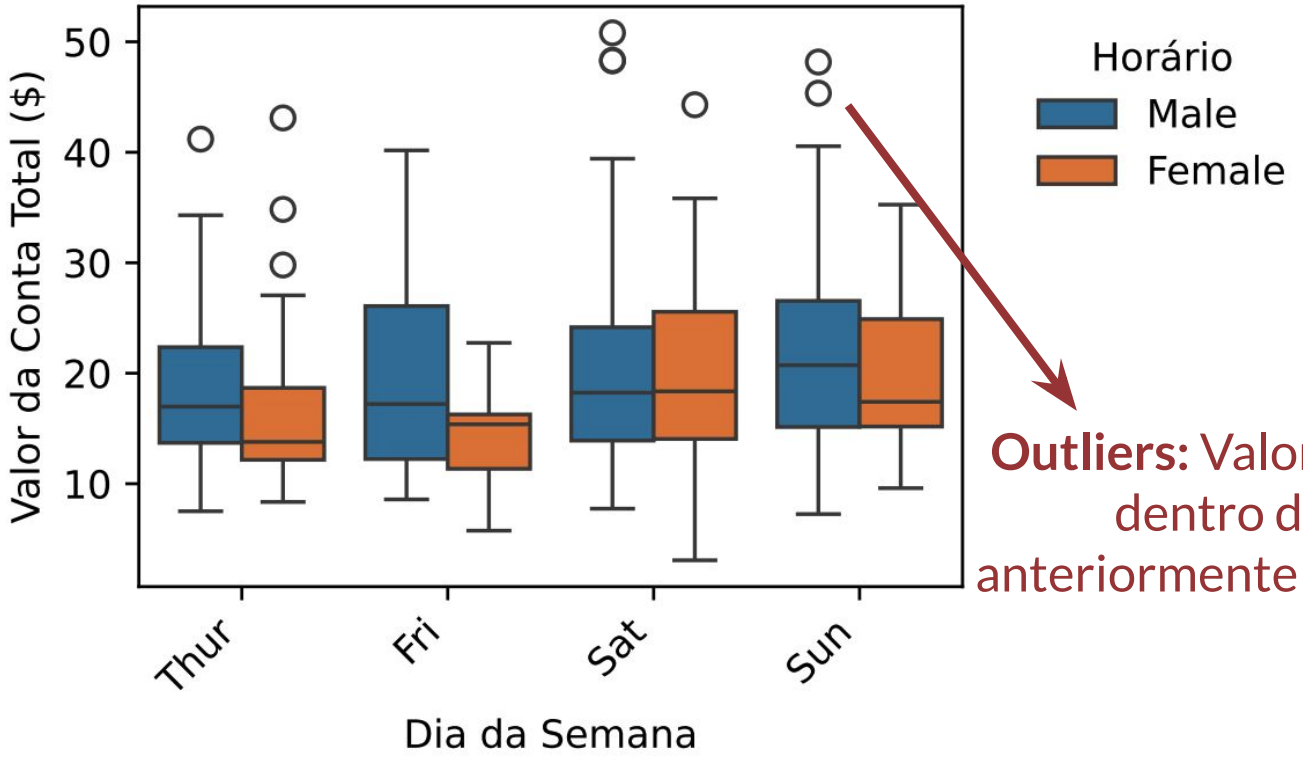


Inclui valores com base no IQR (Q3-Q1):

[Q1 - 1.5 * IQR e Q3 + 1.5 * IQR]

Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo



Outliers: Valores que estão dentro do limite anteriormente estabelecido!

Link da documentação contendo todos os parâmetros!

Boxplot: Exemplo

```
%matplotlib inline
import seaborn as sns
import matplotlib.pyplot as plt

# Carregar dados de exemplo
tips = sns.load_dataset("tips")

# Definir o tamanho da figura
plt.figure(figsize=(5, 3))

# Criar um boxplot múltiplo
ax = sns.boxplot(x="day", y="total_bill", hue="sex", data=tips)

# Personalizar rótulos dos eixos
ax.set_xlabel("Dia da Semana")
ax.set_ylabel("Valor da Conta Total ($)")

# Rotacionar rótulos das datas e alinha os labels
plt.xticks(rotation=45, ha='right')

# Renomear o título da legenda e a coloca para fora
plt.legend(title="Horário",  bbox_to_anchor=(1.05,1), frameon=False)

# Ajustar o layout para não cortar rótulos ou títulos
plt.tight_layout()

# Salvar a figura em formato PDF
plt.savefig("Exemplo_Boxplot_Multiplo.pdf")

# Exibir o gráfico
plt.show()
```

Parâmetro “whis” pode ser especificado para ajustar a cobertura e detecção de outliers

Histograma, PMF, PDF, CDF/CCDF e Boxplot

PMF: Para **variáveis discretas**, mostrando a probabilidade exata de cada valor

PDF: Para **variáveis contínuas**, representando a densidade de probabilidade em diferentes pontos

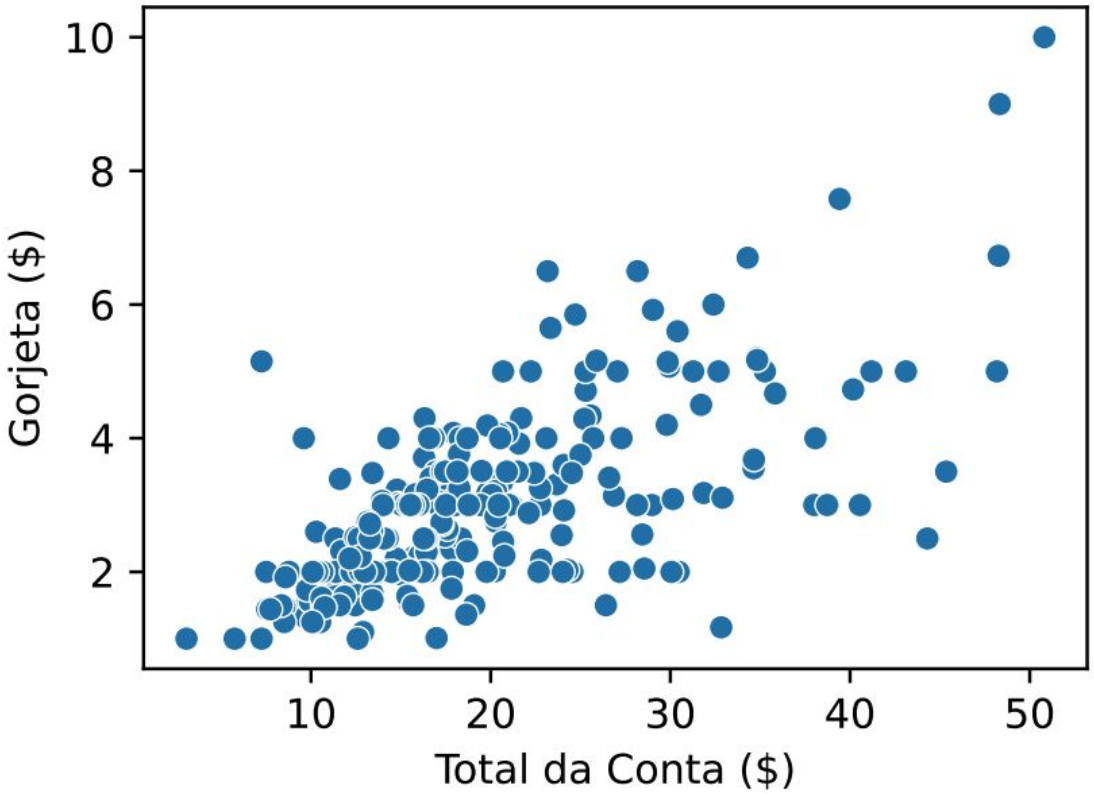
CDF/CCDF: Aplica-se a **ambos os tipos**, mostrando a probabilidade cumulativa até um ponto

Histograma: Para variáveis discretas, mostrando as frequências. Assemelha-se a uma PMF se normalizado

- Mas é utilizado para visualizar a distribuição de dados sem indicar diretamente probabilidades a menos que seja normalizado

Boxplot: Aplica-se a **ambos os tipos**, destacando medianas, quartis, e identificando outliers

Gráfico de Dispersão: Exemplo



Link da documentação contendo todos os parâmetros!

Gráfico de Dispersão: Exemplo

```
%matplotlib inline
import seaborn as sns
import matplotlib.pyplot as plt

# Carregar dados de exemplo
tips = sns.load_dataset("tips")

# Definir o tamanho da figura
plt.figure(figsize=(4, 3))

# Criar um gráfico de dispersão
sns.scatterplot(data=tips, x="total_bill", y="tip")

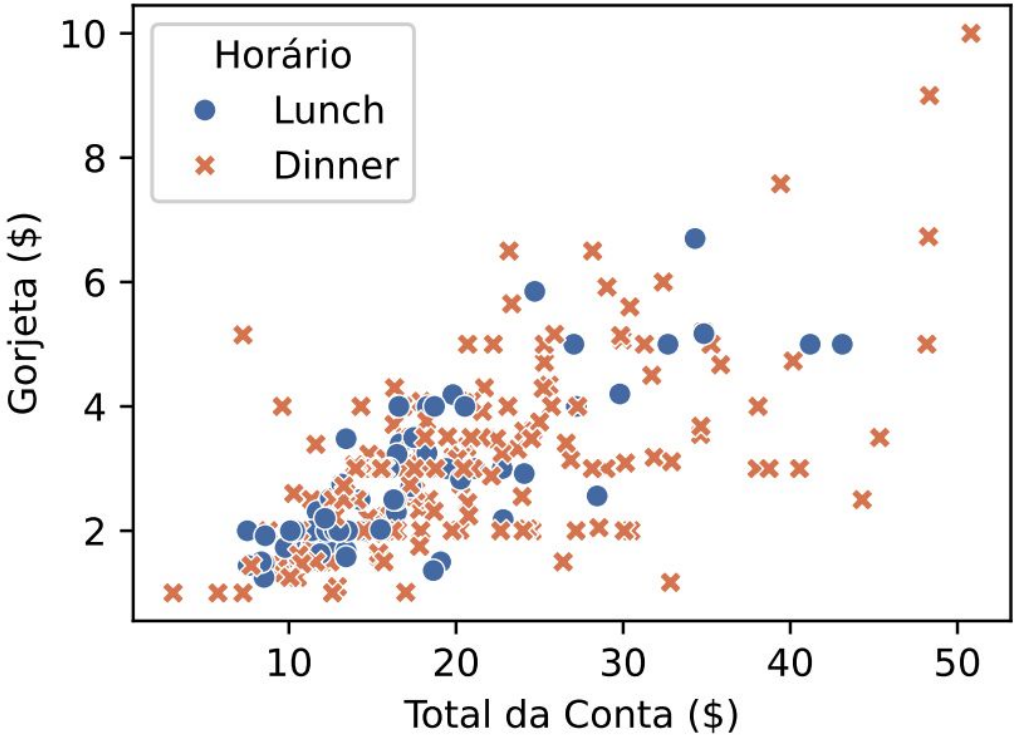
# Adicionar detalhes ao gráfico
plt.xlabel("Total da Conta ($)")
plt.ylabel("Gorjeta ($)")

# Mostrar o gráfico
plt.tight_layout()

# Salvar a figura em formato PDF
plt.savefig("Exemplo_Scatter_Plot.pdf")

plt.show()
```

Gráfico de Dispersão: Exemplo 2



Link da documentação contendo todos os parâmetros!

Gráfico de Dispersão: Exemplo 2

```
%matplotlib inline
import seaborn as sns
import matplotlib.pyplot as plt

# Carregar dados de exemplo
tips = sns.load_dataset("tips")

# Definir o tamanho da figura
plt.figure(figsize=(4, 3))

# Criar um gráfico de dispersão
sns.scatterplot(data=tips, x="total_bill", y="tip",
                hue="time", style="time", palette="deep")

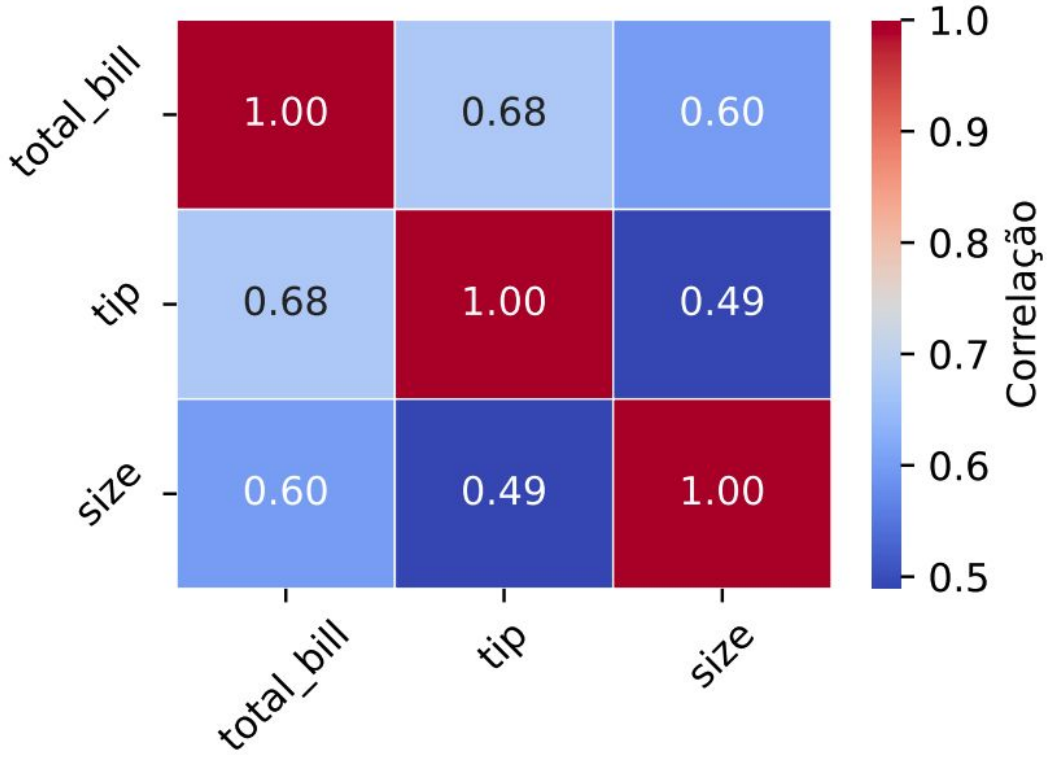
# Adicionar detalhes ao gráfico
plt.xlabel("Total da Conta ($)")
plt.ylabel("Gorjeta ($)")
plt.legend(title="Horário")

# Mostrar o gráfico
plt.tight_layout()

# Salvar a figura em formato PDF
plt.savefig("Exemplo_Scatter_Plot.pdf")

plt.show()
```

Heatmap: Exemplo



Link da documentação contendo todos os parâmetros!

Heatmap: Exemplo

```
%matplotlib inline
import seaborn as sns
import matplotlib.pyplot as plt

# Carregar dados de exemplo
tips = sns.load_dataset("tips")

# Calcular a correlação entre as variáveis
corr = tips.corr()

# Definir o tamanho da figura
plt.figure(figsize=(8, 6))

# Criar um heatmap
sns.heatmap(corr, annot=True, cmap='coolwarm', vmin=0.5, vmax=1,
            cbar_kws={"label": "Correlação"})

# Ajustar os detalhes do gráfico
plt.xticks(rotation=45)
plt.yticks(rotation=0)

# Ajustar layout
plt.tight_layout()

# Mostrar o gráfico
plt.show()

```

Resumindo...

Seaborn possui diversos gráficos interessantes além de inúmeras variações dos exemplos apresentados

Estes são apenas alguns exemplos do que é possível alcançar com o Seaborn. Ainda é possível explorar:

- Personalização avançada para atender a necessidades específicas de visualização
- Criar subplots com axes = plt.subplots(1, 2) e passar o ax como parâmetro
- Uso de paletas de cores e estilos para personalizar suas visualizações
- Visualizações muito mais modernas, por exemplo, *violinplot* e *swarmplot*

Apenas comece a usar: Link!

Distribuições estatísticas

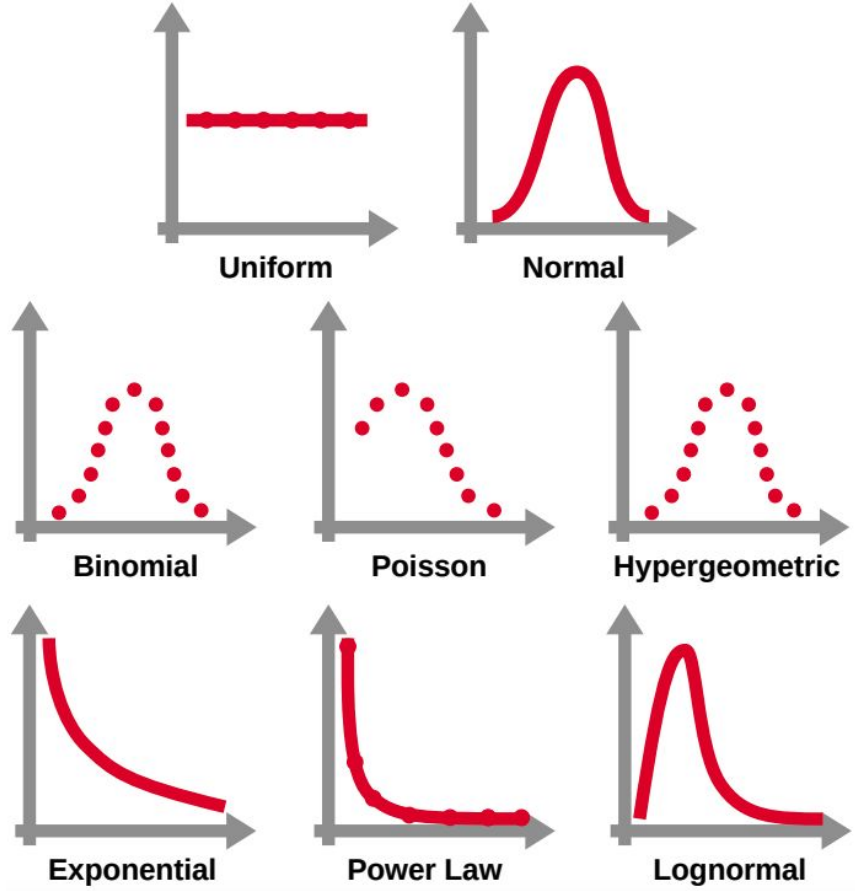
As variáveis aleatórias, tipicamente, seguem a uma distribuição conhecida

- Distribuições conhecidas já possuem propriedades bem estabelecidas
- Conhecer a distribuição ajuda a selecionar os métodos apropriados para análise e modelagem

Neste curso, algumas distribuições poderão ser mencionadas/usadas. Por isso, é crucial familiarizar-se com as formas. Alguns exemplos:

- **Discretas:** Uniforme, Binomial, Poisson, Hipergeométrica, e Lei de Potência
- **Contínuas:** Uniforme, Normal, Exponencial, Lognormal, e Lei de Potência

Distribuições estatísticas



Linhas sólidas: Distribuições contínuas

Linhas pontilhadas: Distribuições Discretas

Linhas sólidas com pontilhados: Ambas

Qual a distribuição dos meus dados?

Existem técnicas para descobrir qual distribuição uma dada variável aleatória segue

Primeiro Passo: Verificar se a variável aleatória é contínua ou discreta e plotá-la seja em forma de CDF ou histograma

- Isso já te mostra a forma da distribuição

Métodos estatísticos podem confirmar a aderência/adequação do diagnóstico visual

Qual a distribuição dos meus dados?

Alguns métodos (Ideia geral):

Kolmogorov-Smirnov (KS): Usado para comparar uma amostra com uma distribuição de referência

1. **Objetivo:** Compara a função de distribuição cumulativa (CDF) empírica dos dados com a CDF teórica da distribuição de referência
2. **Métrica:** Estatística KS, que mede a maior distância entre as duas CDFs

Anderson-Darling (AD): Similar ao KS, mas dá mais peso às caudas da distribuição

1. **Objetivo:** Semelhante ao KS, mas dá mais peso às caudas da distribuição
2. **Métrica:** Estatística AD, que mede a diferença entre as duas CDFs, ponderando mais as caudas

Qual a distribuição dos meus dados?

Teste de Qui-Quadrado: Usado para dados discretos para testar a adequação de uma distribuição observada a uma distribuição esperada

Quantil-Quantil Plot (Q-Q Plot): Comparação gráfica de duas distribuições

Algumas distribuições se parecem muito, mas possuem diferenças sutis

- A identificação visual pode ajuda na identificação de uma distribuição
- Mas frequentemente requer muitos testes de adequação para obter resultados precisos

Qual a distribuição dos meus dados?

Solução: Usar ferramentas que testam um amplo conjunto de distribuições

- Existem vários softwares (minitab, Matlab, R, etc) e bibliotecas
- **Fitter:** Biblioteca em Python que testa os dados com 100+ distribuições discretas e contínuas.
    - Faz o teste de forma automática para identificar a mais adequada

Problema: Testar todas as distribuições é computacionalmente custoso

- **Estratégia**: Usar uma amostra dos dados ou arriscar um subconjunto de opções
- Algumas distribuições são muito sensíveis, o que pode levar a encontrar uma distribuição "aceitável", mas não necessariamente a "melhor"

Qual a distribuição dos meus dados?

O fitter tenta ajustar várias distribuições aos seus dados

- Utiliza as funções de ajuste (fit) das distribuições fornecidas pela biblioteca scipy.stats

Avaliação da Qualidade do Ajuste. Para cada distribuição ajustada, o *fitter* calcula várias métricas para avaliar a qualidade do ajuste

Akaike Information Criterion (AIC):

- Considera a qualidade do ajuste e a complexidade do modelo
- Penaliza menos modelos complexos e é útil quando se deseja um equilíbrio entre ajuste e complexidade. Valor mais baixo de AIC indica um modelo melhor

Qual a distribuição dos meus dados?

Bayesian Information Criterion (BIC): Similar ao AIC, mas com penalização maior para modelos mais complexos.

- Penaliza mais modelos complexos e é mais rigoroso, preferido quando se deseja evitar o *overfitting*. Valor mais baixo de BIC indica um modelo melhor

Sum of Squared Errors (SSE):

- Mede a soma dos quadrados das diferenças entre os valores observados e os previstos pela distribuição ajustada
- Focado diretamente no erro de ajuste e útil para entender a precisão do ajuste em termos absolutos. Valor mais baixo de SSE indica um ajuste melhor

Distribuições muito parecidas podem ser confundidas dependendo do tamanho da amostra, o que pode influenciar na escolha da melhor distribuição

Exemplos

```
%matplotlib inline
import numpy as np
import matplotlib.pyplot as plt
from fitter import Fitter, get_common_distributions, get_distributions

# Gerar dados contínuos de exemplo
data_continuous = np.random.normal(loc=5, scale=.5, size=5000)

# Inicializar o Fitter com distribuições comuns
f = Fitter(data_continuous, distributions=['norm', 'lognorm',
                                           'gamma', 'exponpow'])


# Ajustar as distribuições
f.fit()

# Mostrar os melhores ajustes
f.summary()
```

Exemplos

```
%matplotlib inline
import numpy as np
import matplotlib.pyplot as pl
from fitter import Fitter, get

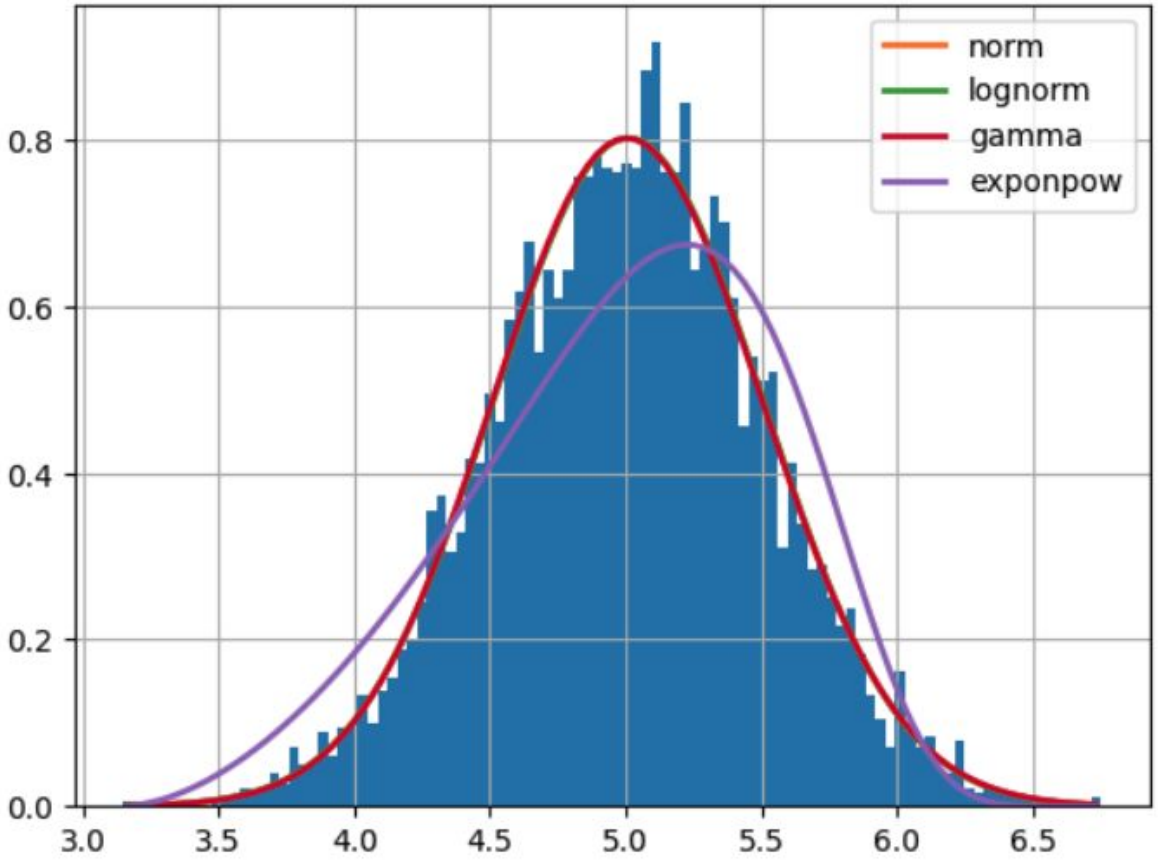
# Gerar dados contínuos de exe
data_continuous = np.random.no

# Inicializar o Fitter com dis
f = Fitter(data_continuous, di

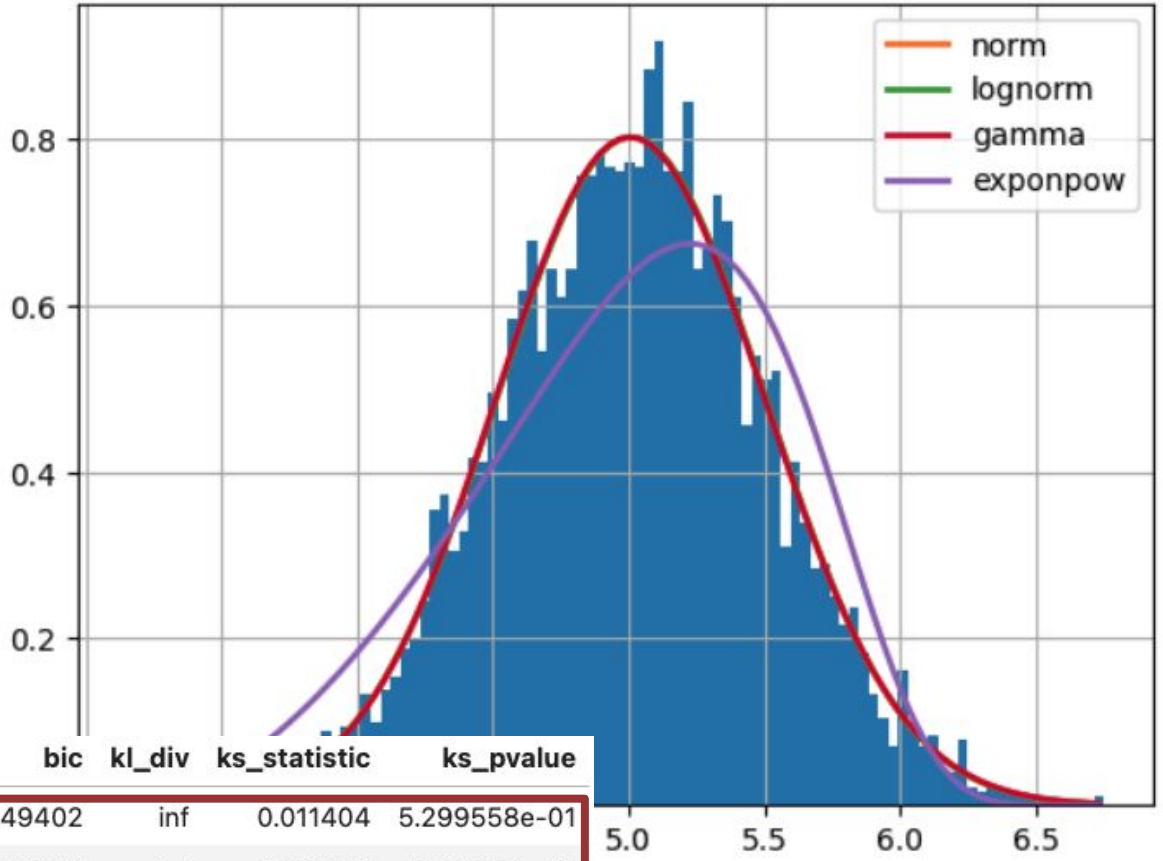


# Ajustar as distribuições
f.fit()

# Mostrar os melhores ajustes
f.summary()
```



Exemplos



	sumsquare_error	aic	bic	kl_div	ks_statistic	ks_pvalue
norm	0.154489	486.115016	499.149402	inf	0.011404	5.299558e-01
lognorm	0.154503	488.118480	507.670060	inf	0.011410	5.292771e-01
gamma	0.157825	488.850541	508.402121	inf	0.012810	3.816114e-01
exponpow	0.819182	551.611427	571.163007	inf	0.059962	4.538832e-16

Exemplos

```
%matplotlib inline
import numpy as np
import matplotlib.pyplot as plt
from fitter import Fitter, get_common_distributions, get_distributions

# Gerar dados contínuos de exemplo
data_continuous = np.random.normal(loc=5, scale=.5, size=5000)

# Inicializar o Fitter com distribuições comuns
f = Fitter(data_continuous, distributions=get_common_distributions())


# Ajustar as distribuições
f.fit()

# Mostrar os melhores ajustes
f.summary()
```

Exemplos

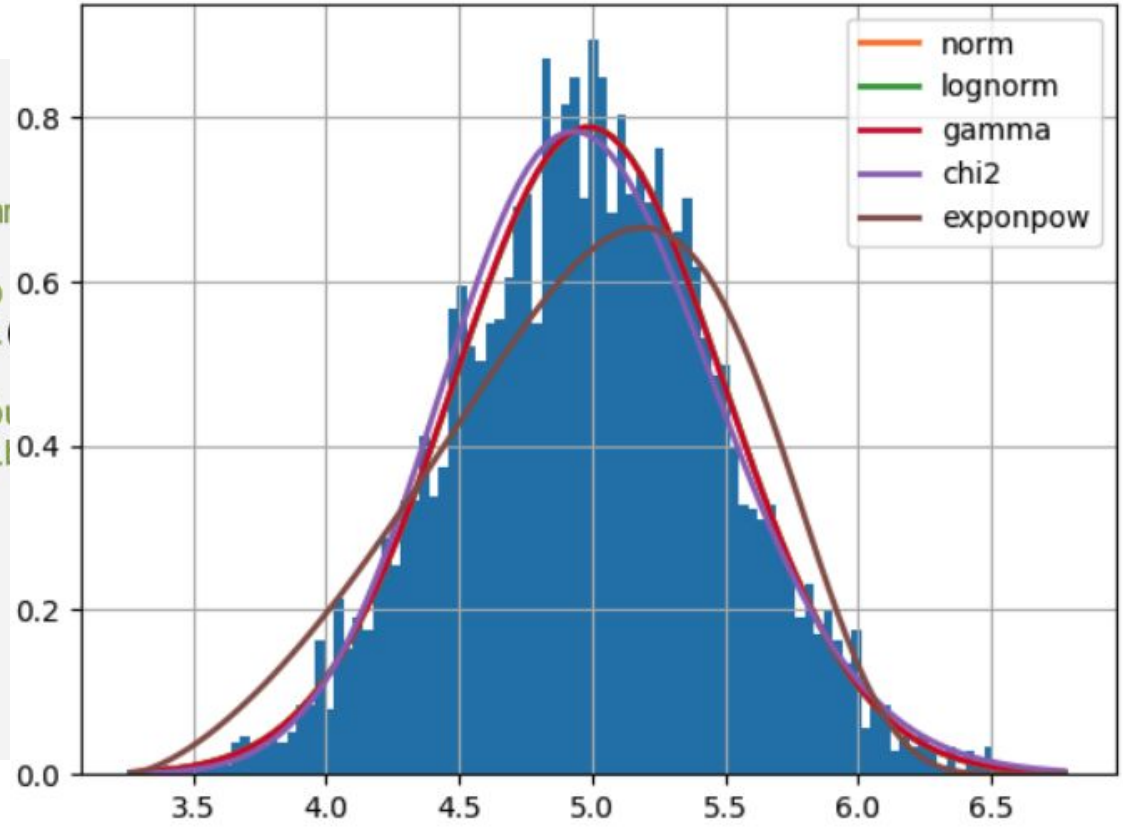
```
%matplotlib inline
import numpy as np
import matplotlib.pyplot as plt
from fitter import Fitter, get_comm

# Gerar dados contínuos de exemplo
data_continuous = np.random.normal(

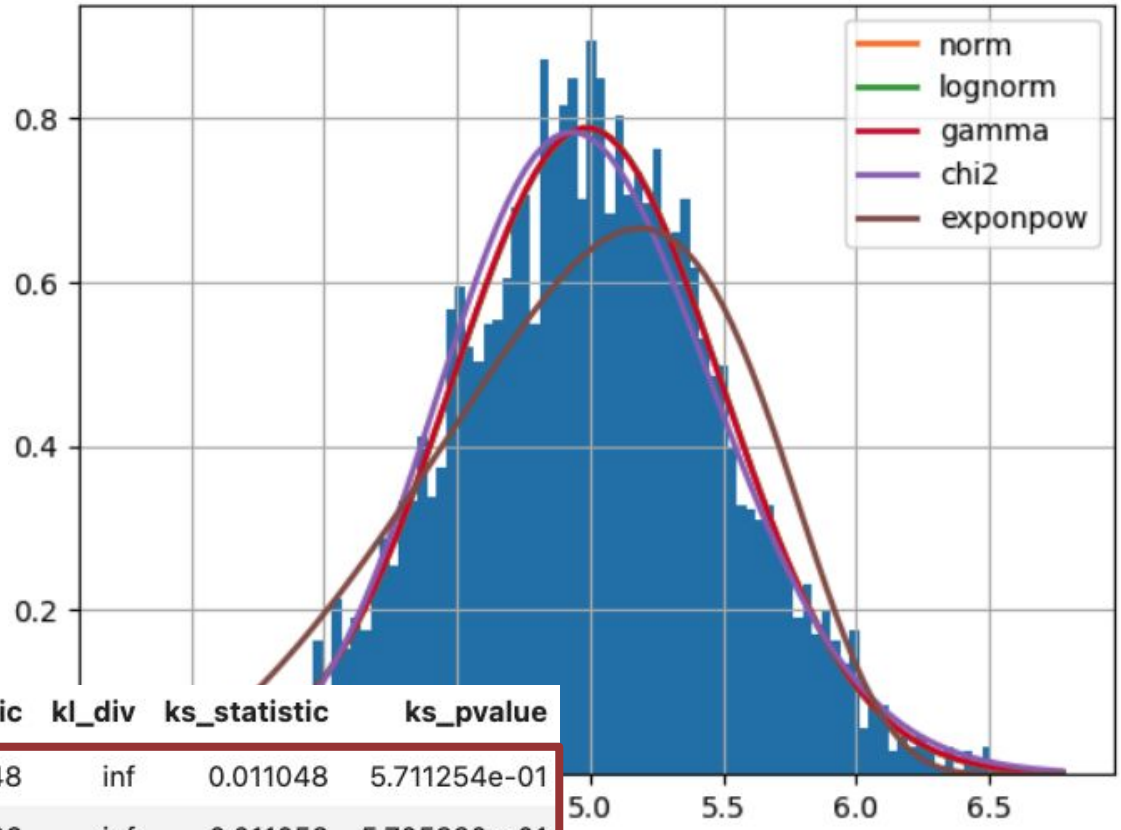
# Inicializar o Fitter com distribu
f = Fitter(data_continuous, distril


# Ajustar as distribuições
f.fit()

# Mostrar os melhores ajustes
f.summary()
```



Exemplos



	sumsquare_error	aic	bic	kl_div	ks_statistic	ks_pvalue
norm	0.191881	458.773162	471.807548	inf	0.011048	5.711254e-01
lognorm	0.191889	460.771147	480.322726	inf	0.011053	5.705320e-01
gamma	0.192893	460.555285	480.106865	inf	0.011609	5.068050e-01
chi2	0.257378	461.303483	480.855063	inf	0.027315	1.128344e-03
exponpow	0.795075	554.139761	573.691341	inf	0.054488	2.416819e-13

Exemplos

```
%matplotlib inline
from scipy import stats
from fitter import Fitter

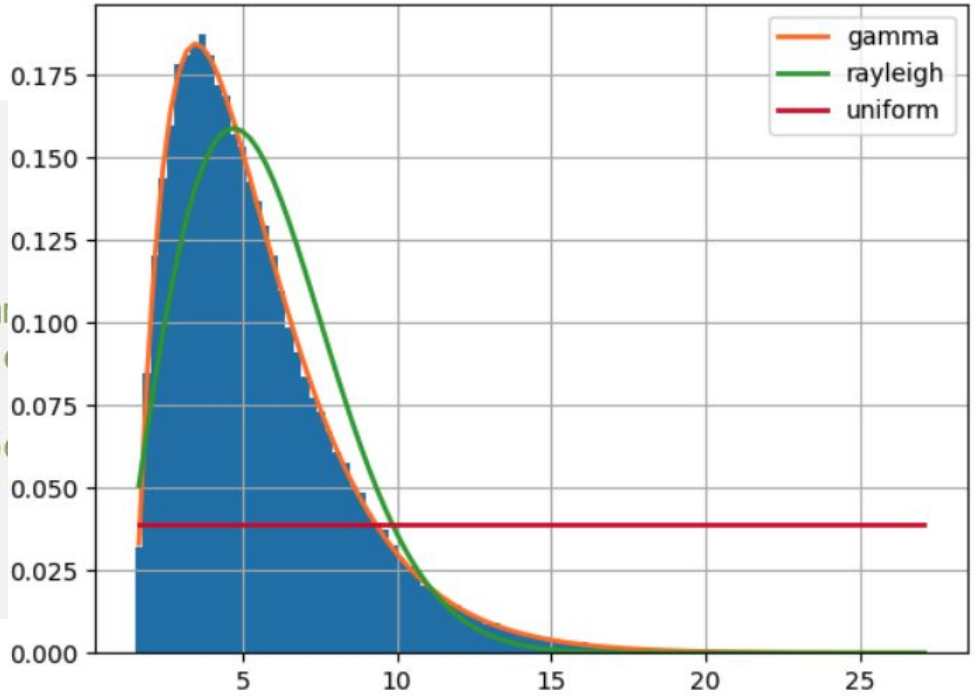
#Gerar os dados de uma distribuição gamma
data = stats.gamma.rvs(2, loc=1.5, scale=2, size=100000)

#Inicializar o Fitter com 3 distribuições
f = Fitter(data, distributions=["gamma", "rayleigh", "uniform"])
f.fit()
f.summary()
```

Exemplos

```
%matplotlib inline
from scipy import stats
from fitter import Fitter

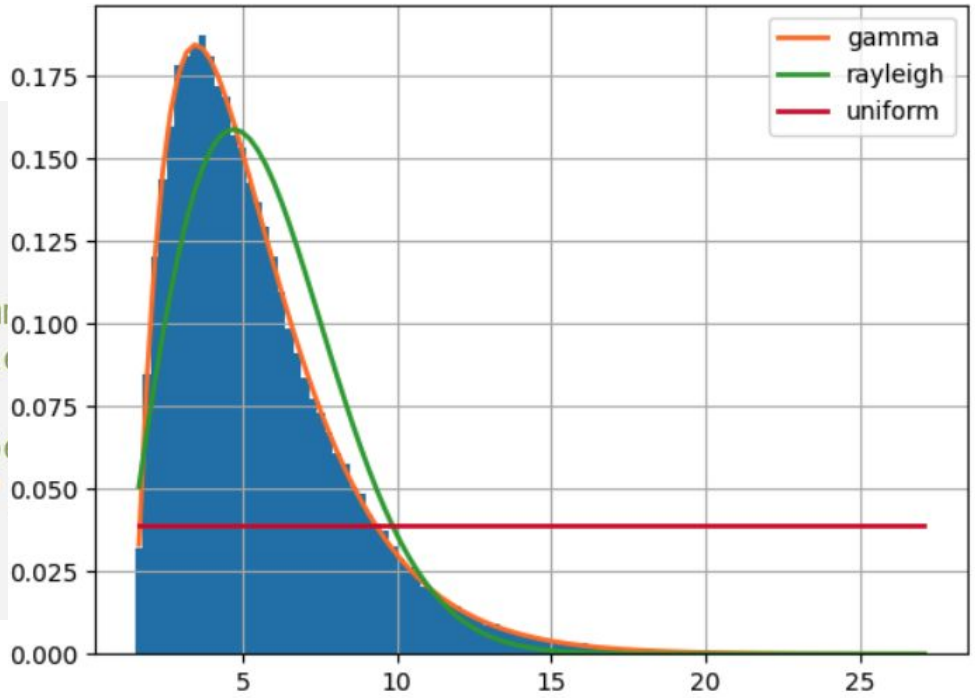
#Gerar os dados de uma distribuição gam
data = stats.gamma.rvs(2, loc=1.5, scal
#Inicializar o Fitter com 3 distribuiçõ
f = Fitter(data, distributions=["gamma"
f.fit()
f.summary()
```



Exemplos

```
%matplotlib inline
from scipy import stats
from fitter import Fitter

#Gerar os dados de uma distribuição gam
data = stats.gamma.rvs(2, loc=1.5, scal
#Inicializar o Fitter com 3 distribuiçõ
f = Fitter(data, distributions=["gamma"
f.fit()
f.summary()
```



	sumsquare_error	aic	bic	kl_div	ks_statistic	ks_pvalue
gamma	0.000141	1119.677144	1148.215921	inf	0.001617	0.955934
rayleigh	0.026320	1693.412796	1712.438647	inf	0.084516	0.000000
uniform	0.335184	653.395374	672.421225	inf	0.598601	0.000000

Dúvidas?

Créditos

Este material é baseado nos livros textos da disciplina em questão e foi desenvolvido pelo professor Carlos Henrique Gomes Ferreira. Além disso, ele está licenciado sob uma **Licença Creative Commons Atribuição 4.0 Internacional (CC BY 4.0)**. Versão 1.0. 02/2024.