Projetos Fatoriais

Projeto e Análise de Experimentos

Prof. Carlos Henrique Gomes Ferreira

UFOP

DECSI
DEPARTAMENTO DE COMPUTAÇÃO E SISTEMAS

Terminologia

Variável Resposta: O resultado medido no experimento

- **Exemplo:** em um estudo de classificação de e-mails quanto a *spam* ou não, a variável resposta pode ser a *acurácia* do modelo

Fatores: Variáveis que afetam a variável resposta e podem ser controladas

- **Exemplo:** os fatores podem ser o classificador usado (SVM, árvore de decisão, etc), a quantidade de dados de treino (10k, 50k exemplos), e o tipo de pré-processamento (normalização, sem pré-processamento)

Níveis: Os valores que os fatores podem assumir. Exemplo: O algoritmo de classificação pode ter 3 níveis (SVM, árvore de decisão, rede neural)

Terminologia

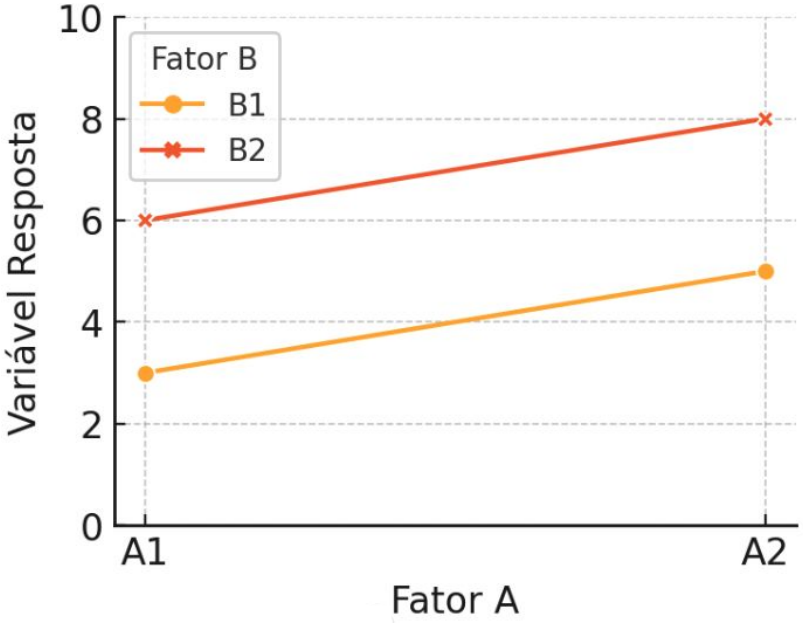
Replicação: Refere-se à repetição dos experimentos sob as mesmas condições para garantir que os resultados não sejam aleatórios

- No caso de classificação, isso pode significar realizar cada experimento dez vezes, utilizando diferentes divisões dos dados (ex.: validação cruzada)
- A variável resposta deve ser estocástica, ou seja, deve conter alguma variabilidade em cada repetição
- Ajuda a validar a consistência e a confiabilidade do modelo

Projeto Experimental: Combinação de níveis de fatores e replicações. Exemplo: testar todas as combinações de algoritmos e quantidades de dados, com dez replicações, totalizando 2x2x10 = 40 experimentos

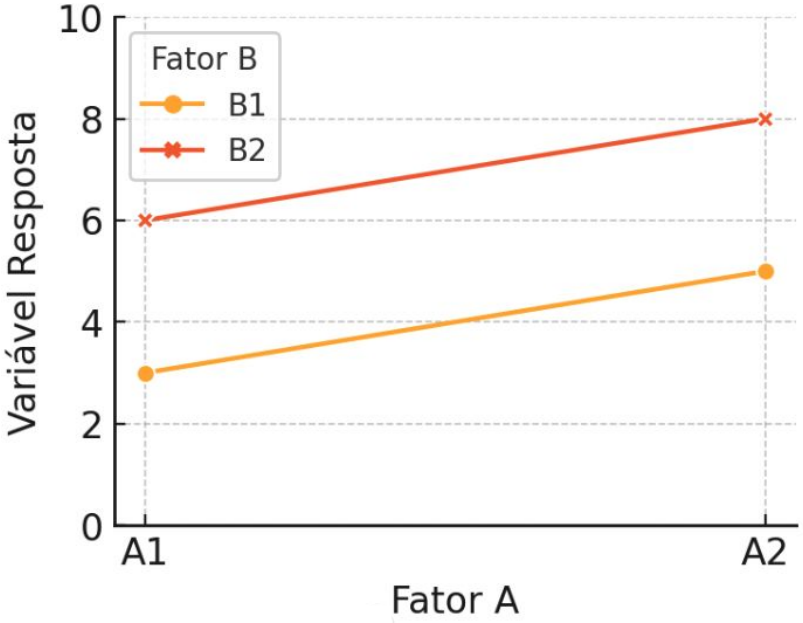
Exemplo de Interação entre fatores

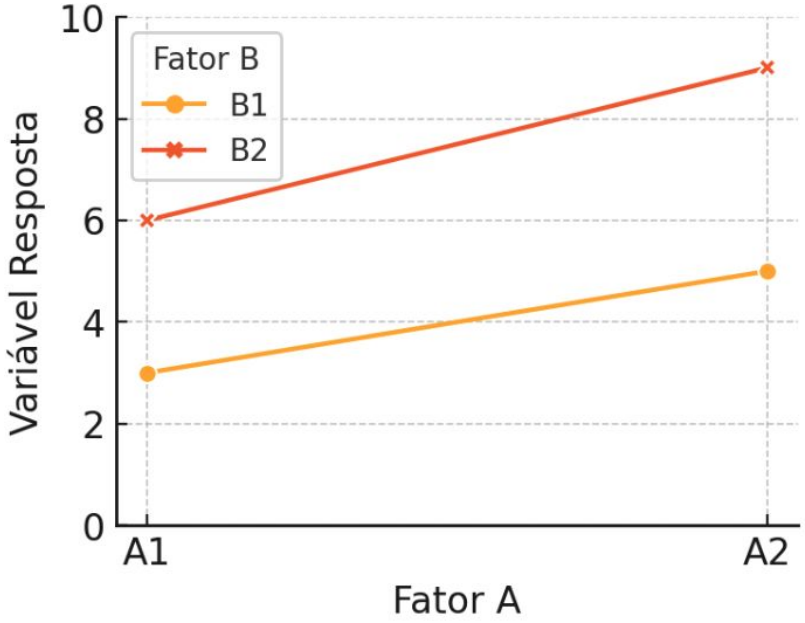
Representação gráfica:



Exemplo de Interação entre fatores

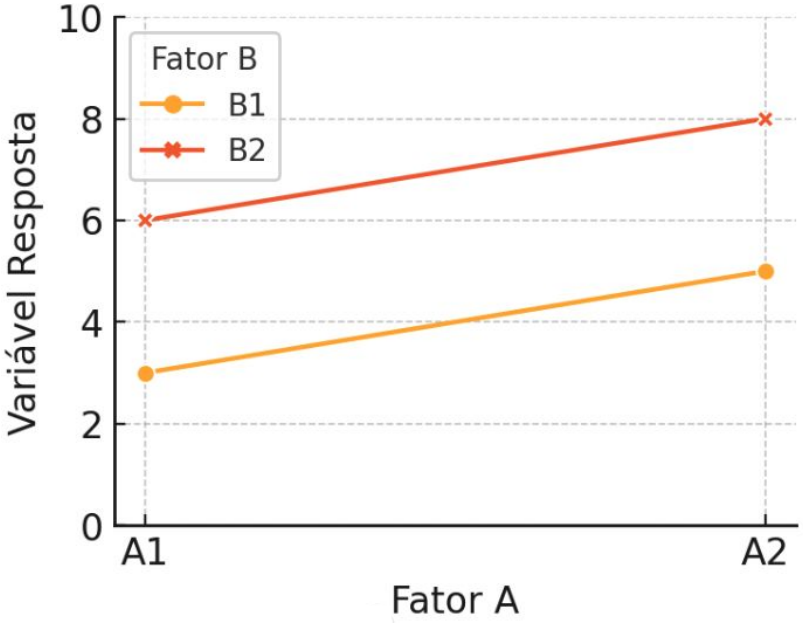
Representação gráfica:

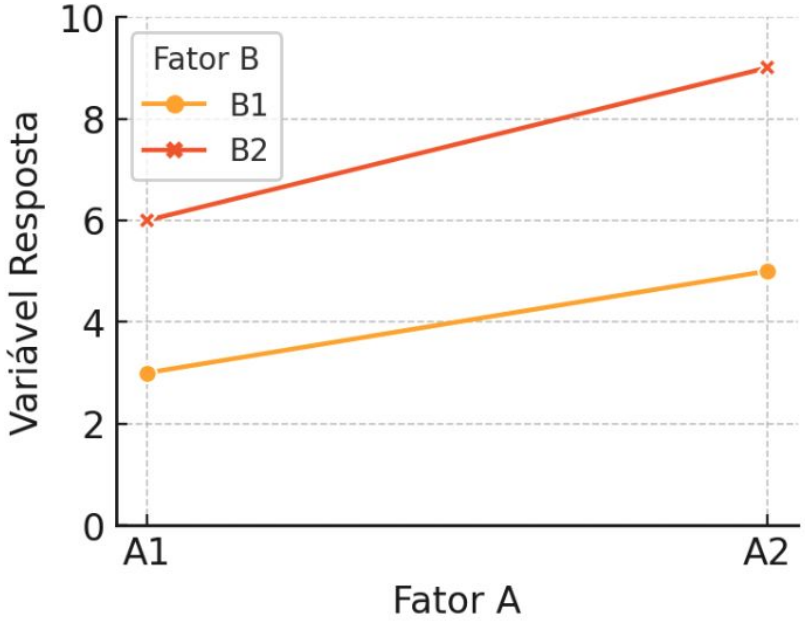




Exemplo de Interação entre fatores

Representação gráfica:





Qual dos experimentos apresenta ter interação?

Objetivos do Projeto de Experimentos Fatoriais

Maximizar a obtenção de informações relevantes: O objetivo é extrair o máximo de informações sobre os fatores e suas interações

- Isso ajuda a identificar os fatores que mais influenciam o sistema

Minimizar o esforço e os recursos necessários: Projetos fatoriais reduzem o número de experimentos necessários para obter bons resultados

- O foco é equilibrar o número de ensaios e a quantidade de informação

Evitar um número excessivo de experimentos: Muitos experimentos podem ser inviáveis devido ao custo de tempo e recursos

- Experimentos redundantes não trazem valor adicional e podem gerar desgaste, especialmente para quem executa

Objetivos do Projeto de Experimentos Fatoriais

Avaliar as interações entre fatores: Projetos fatoriais permitem avaliar o efeito de cada fator e suas interações

- Isso é essencial para entender melhor o comportamento do sistema

Melhorar a eficiência e qualidade do processo: Identificar fatores críticos e interações otimiza processos e melhora a qualidade

- Decisões baseadas em dados geram economia de recursos e aumentam a produtividade

Planejar experimentos com rigor estatístico: Técnicas como replicação, aleatorização e bloqueio garantem a validade dos resultados

- Isso permite generalizar as descobertas e controlar variações

Tipos de Projetos Experimentais Fatoriais

Existem vários tipos de projetos fatoriais:

- Projetos Fatoriais Simples
- Projetos Fatoriais Completo
- Projetos Fatoriais Fracionários

Cada um possui a sua vantagem e desvantagem

Projetos Simples

Varia-se um fator de cada vez, mantendo os outros constantes, para observar como esse fator afeta a variável resposta. # experimentos:

$$n = 1 + \sum_{i=1}^{k} (n_i - 1)$$

Projetos Simples

Varia-se um fator de cada vez, mantendo os outros constantes, para observar como esse fator afeta a variável resposta. # experimentos:

k → # fatores

$$n = 1 + \sum_{i=1} (n_i - 1)$$

Projetos Simples

Varia-se um fator de cada vez, mantendo os outros constantes, para observar como esse fator afeta a variável resposta. # experimentos:

$$n = 1 + \sum_{i=1}^{k} (n_i - 1)$$

níveis do i-ésimo fator

Projetos Simples: Exemplo

Considere o treinamento de um modelo de classificação para prever se um e-mail é *spam* ou não, com três fatores e os seguintes níveis:

- **Algoritmo de Classificação:** (SVM, Árvore de Decisão, Rede Neural)
- **Tamanho do Conjunto de Dados:** (10.000, 50.000, 100.000 exemplos)
- **Tipo de Pré-processamento:** (Sem pré-processamento, Normalização, Padronização)

Projetos Simples: Exemplo

No projeto simples, deve-se escolher uma **configuração de referência**
Por exemplo:

- **Classificador:** SVM
- **Tamanho dos Dados:** 10.000 exemplos
- **Pré-processamento:** Sem pré-processamento

Então, varie apenas um fator de cada vez e mantenha os outros fixos

- Faça isso fixando um fator e variando os demais considerando todas as possibilidades

Projetos Simples: Exemplo

Combinações do exemplo anterior:

- **Variar o classificador:**
  - Mantém o Tamanho dos Dados = 10.000 e Pré-processamento = Sem pré-processamento
  - Varia o Classificador: SVM (Referência) → Árvore de Decisão → Rede Neural
- **Variar o tamanho do conjunto de dados:**
  - Mantém o Classificador = SVM e Pré-processamento = Sem pré-processamento
  - Varia o Dado: 10.000 (Referência) → 50.000 → 100.000 exemplos

Projetos Simples: Exemplo

Combinações do exemplo anterior:

- **Variar o pré-processamento:**
  - Mantém o Classificador = SVM e Tamanho dos Dados = 10.000
  - Varia o Tipo de pré-processamento: Sem pré-processamento (Referência) → Normalização → Padronização

Projetos Simples: Exemplo

Combinações do exemplo anterior:

- **Variar o pré-processamento:**
  - Mantém o Classificador = SVM e Tamanho dos Dados = 10.000
  - Varia o Tipo de pré-processamento: Sem pré-processamento (Referência) → Normalização → Padronização

Aplicando a fórmula:

$$n = 1 + \sum_{i=1}^{3}(3-1) \qquad n = 1 + (2+2+2) = 7$$

7 experimentos no total para testar todas as combinações do projeto simples

Projetos Simples

Vantagens:

- **Simples e Rápido:** Simples de entender e rápido

Desvantagens:

- **Ineficiência:** Requer um número elevado de experimentos, mesmo que existam projetos mais eficientes que possam testar várias combinações ao mesmo tempo
- **Ignora Interações:** No exemplo anterior, pode haver interações entre o classificador e o tipo de pré-processamento
    - Por exemplo, o SVM pode funcionar melhor com normalização, enquanto as Redes Neurais podem não se beneficiar tanto desse pré-processamento
    - O projeto simples não captura essas interações, o que pode levar a conclusões incompletas ou incorretas

Projetos Fatoriais Completos

Cada fator é testado em todos os seus níveis possíveis, e todas as combinações de fatores são experimentadas

Isso permite analisar os efeitos de todos os fatores, incluindo interações entre eles

Total de experimentos: $$n = \prod_{i=1}^{k} n_i$$

Projetos Fatoriais Completos

Cada fator é testado em todos os seus níveis possíveis, e todas as combinações de fatores são experimentadas

Isso permite analisar os efeitos de todos os fatores, incluindo interações entre eles

Total de experimentos: $n = \prod_{i=1}^{k} n_i$

fatores

Projetos Fatoriais Completos

Cada fator é testado em todos os seus níveis possíveis, e todas as combinações de fatores são experimentadas

Isso permite analisar os efeitos de todos os fatores, incluindo interações entre eles

Total de experimentos: $n = \prod_{i=1}^{k} n_i$ → # níveis do i-ésimo fator

Projetos Fatoriais Completos: Exemplo

Considere o treinamento de um modelo de classificação para prever se um e-mail é *spam* ou não, com três fatores e os seguintes níveis:

- **Algoritmo de Classificação:** (SVM, Árvore de Decisão, Redes Neurais)
- **Tamanho do Conjunto de Dados:** (10.000, 50.000, 100.000 exemplos)
- **Tipo de Pré-processamento:** (Sem pré-processamento, Normalização, Padronização)

Total de experimentos: $n = 3^3 = 3 \times 3 \times 3 = 27$

Projetos Fatoriais Completos

Vantagens:

- **Cobertura completa:** Testa todas as combinações possíveis, permitindo identificar os efeitos de todos os fatores e suas interações
- **Análise detalhada:** Fornece uma visão clara de como os fatores influenciam o desempenho do modelo, individualmente e em combinação

Desvantagens:

- **Custo alto:** O número de experimentos aumenta exponencialmente com o número de fatores e níveis
    - Para um problema complexo com muitos fatores e níveis, o número de experimentos pode se tornar impraticável
- **Tempo e Recursos:** Pode ser bastante custoso

Projetos Fatoriais Completos

Como Reduzir o Número de Experimentos:

1. **Reduzir o número de níveis**: Em vez de testar muitos níveis para cada fator, pode-se testar apenas dois níveis
    - Ex.: SVM e Redes Neurais, 10.000 e 100.000 exemplos
2. **Reduzir o número de fatores**: Eliminar fatores menos importantes ou fatores cuja variação pode ser negligenciada
3. **Usar o projeto fatorial fracionado**: Testar apenas uma parte das combinações possíveis

Projetos Fatoriais Fracionados

Ideal para quando o número total de experimentos em um projeto fatorial completo apresenta custo ou o tempo de execução inviável

Em vez de testar todas as combinações possíveis de fatores e níveis, testa-se apenas uma fração das combinações

- Tem que justificar bem a escolha de fatores e níveis

Economiza tempo e recursos, embora seja possível perder informações cruciais, como interações mais detalhadas entre os fatores

Projetos Fatoriais Fracionados: Exemplo

Considere o exemplo anterior de classificação de e-mails (spam ou não) com quatro fatores principais e seus respectivos níveis:

- **Algoritmo de Classificação:** (SVM, Árvore de Decisão, Redes Neurais)
- **Tamanho do Conjunto de Dados:** (10.000, 50.000, 100.000 exemplos)
- **Tipo de Pré-processamento:** (Sem pré-processamento, Normalização, Padronização)
- **Método de Validação:** (Holdout, Validação Cruzada, Validação Leave-One-Out)

Fatorial completo exigiria 81 (3x3x3x3) experimentos: Bastante custoso!

Projetos Fatoriais Fracionados: Exemplo

Pode-se testar apenas um subconjunto de combinações:

Experimento	Algoritmo	Tamanho de Dados	Pré-processamento	Validação
1	SVM	10000	Sem Pré-processamento	Holdout
2	SVM	50000	Normalização	Validação Cruzada
3	SVM	100000	Padronização	Leave-One-Out
4	Árvore de Decisão	10000	Normalização	Leave-One-Out
5	Árvore de Decisão	50000	Padronização	Holdout
6	Árvore de Decisão	100000	Sem Pré-processamento	Validação Cruzada
7	Redes Neurais	10000	Padronização	Validação Cruzada
8	Redes Neurais	50000	Sem Pré-processamento	Leave-One-Out
9	Redes Neurais	100000	Normalização	Holdout

É ideal quando sabe-se que algumas interações entre os fatores são desprezíveis ou menos relevantes para o estudo

Projetos Fatoriais Fracionados

Vantagens:

- **Economia de Tempo e Recursos**: Reduz significativamente o número de experimentos
- **Representação Geral**: Embora não cubra todas as combinações, ainda oferece uma boa visão geral dos efeitos dos fatores

Desvantagens:

- **Menos Informações:** Não permite capturar todas as interações possíveis entre os fatores
- **Risco de Perda de Interações Importantes:** Se algumas interações forem significativas e forem negligenciadas, isso pode levar a uma análise incompleta

Projeto Fatorial 2^K

Um Projeto Fatorial 2^k é usado para determinar o efeito de k fatores, cada um com dois níveis

Essa classe de projeto fatorial merece uma atenção especial porque é “barato”

- Fácil de implementar e permite entender os fatores e suas interações

Muitas vezes é usado para reduzir o número de fatores, antes de usar um fatorial completo, por exemplo

Projeto Fatorial 2^k

Ainda não sabemos quais fatores realmente importam. O 2^k nos permite testar tudo de forma rápida e com baixo custo

Menos é mais: mesmo com dois níveis por fator, conseguimos identificar efeitos principais e interações relevantes

Assim que identificamos os fatores críticos, podemos aprofundar a análise com mais níveis ou outros métodos

Projeto Fatorial 2^K

Considere o problema de avaliar o impacto de dois fatores em um modelo de classificação de e-mails (spam ou não)

Fatores e níveis:

- Classificador: SVM ou Redes Neurais
- Quantidade de Dados: 10.000 ou 100.000.000 exemplos

Variável Resposta: Acurácia (%) do modelo de classificação

Projeto Fatorial 2^K

Medições realizadas:

Classificador	10.000 Exemplos	100.000.000 Exemplos
SVM	15%	45%
Redes Neurais	25%	75%

Definimos as variáveis x_A e x_B para representar os níveis dos fatores:

$$x_A = \begin{cases} -1 & \text{se Classificador} = \text{SVM} \\ 1 & \text{se Classificador} = \text{Redes Neurais} \end{cases}$$

$$x_B = \begin{cases} -1 & \text{se Dados} = 10.000 \text{ exemplos} \\ 1 & \text{se Dados} = 100.000.000 \text{ exemplos} \end{cases}$$

Projeto Fatorial 2^K

O desempenho da variável resposta pode agora ser ajustado em função de x_A e x_B usando um modelo de regressão

$$y = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

onde:

- q_0 é o efeito médio
- q_A é o efeito do fator Classificador
- q_B é o efeito do fator Dados
- q_{AB} é o efeito da interação entre Classificador e Dados

Projeto Fatorial 2^K

O desempenho da variável resposta pode agora ser ajustado em função de x_A e x_B usando um modelo de regressão

$$y = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

onde:

- q_0 é o efeito médio
- q_A é o efeito do fator Classificador
- q_B é o efeito do fator Dados
- q_{AB} é o efeito da interação entre Classificador e Dados

Como calcular esses efeitos?

Cálculo dos Efeitos: Sistema Linear

O desempenho da variável resposta pode agora ser ajustado em função de x_A e x_B usando um modelo de regressão

$$y = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

Para resolver o sistema de equações usamos as observações reais. Cada combinação de x_A e x_B resulta em um valor de y:

- Quando x_A=−1 (SVM) e x_B=−1 (10k), tem-se y=15

$$y = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

$$15 = q_0 + q_A(-1) + q_B(-1) + q_{AB}(-1)(-1)$$

$$15 = q_0 - q_A - q_B + q_{AB}$$

Cálculo dos Efeitos: Sistema Linear

O desempenho da variável resposta pode agora ser ajustado em função de x_A e x_B usando um modelo de regressão

$$y = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

Para resolver o sistema de equações usamos as observações reais. Cada combinação de x_A e x_B resulta em um valor de y:

- Quando x_A= 1 (Rede Neural) e x_B=−1 (10k), tem-se y=25

$$25 = q_0 + q_A(-1) + q_B(1) + q_{AB}(-1)(1)$$

$$25 = q_0 - q_A + q_B - q_{AB}$$

Cálculo dos Efeitos: Sistema Linear

O desempenho da variável resposta pode agora ser ajustado em função de x_A e x_B usando um modelo de regressão

$$y = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

Para resolver o sistema de equações usamos as observações reais. Cada combinação de x_A e x_B resulta em um valor de y:

- Quando x_A= 1 (Rede Neural) e x_B=−1 (10k), tem-se y=25

$$25 = q_0 + q_A(-1) + q_B(1) + q_{AB}(-1)(1)$$

$$25 = q_0 - q_A + q_B - q_{AB}$$

e assim sucessivamente…

Cálculo dos Efeitos: Sistema Linear

O desempenho da variável resposta pode agora ser ajustado em função de x_A e x_B usando um modelo de regressão

$$y = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

Para resolver o sistema de equações usamos as observações reais. Cada combinação de x_A e x_B resulta em um valor de y:

- Quando x_A=−1 (SVM) e x_B=−1 (10k), tem-se y=15
- Quando x_A= 1 (Rede Neural) e x_B=−1 (10k), tem-se y=25
- Quando x_A=−1 (SVM) e x_B= 1 (100M), tem-se y=45
- Quando x_A= 1 (Rede Neural) e x_B= 1 (100M), tem-se y=75

Cálculo dos Efeitos: Sistema Linear

O desempenho da variável resposta pode agora ser ajustado em função de x_A e x_B usando um modelo de regressão

$$y = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

Resolvendo o sistema linear com 4 eq. e 4 incógnitas usando Gauss e substituindo os valores de x_A, x_B e x_{AB} no modelo acima tem-se:

$$\begin{aligned} 15 &= q_0 - q_A - q_B + q_{AB} \\ 25 &= q_0 + q_A - q_B - q_{AB} \\ 45 &= q_0 - q_A + q_B - q_{AB} \\ 75 &= q_0 + q_A + q_B + q_{AB} \end{aligned}$$

$$y = 40 + 10x_A + 20x_B + 5x_A x_B$$

Qual fator é o de maior **efeito?**

Cálculo dos Efeitos: Sistema Linear

O desempenho da variável resposta pode agora ser ajustado em função de x_A e x_B usando um modelo de regressão

$$y = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

Resolvendo o sistema linear com 4 eq. e 4 incógnitas usando Gauss e substituindo os valores de x_A, x_B e x_{AB} no modelo acima tem-se:

$$\begin{aligned} 15 &= q_0 - q_A - q_B + q_{AB} \\ 25 &= q_0 + q_A - q_B - q_{AB} \\ 45 &= q_0 - q_A + q_B - q_{AB} \\ 75 &= q_0 + q_A + q_B + q_{AB} \end{aligned}$$

$$y = 40 + 10x_A + 20x_B + 5x_A x_B$$

Qual fator é o de maior **efeito?**
O fator B (Quantidade de Dados)

Cálculo dos Efeitos: Sistema Linear

Pode-se usar o conceito de **contrastes** para respostas mais rápidas

- **Contrastes:** Combinações lineares das respostas experimentais que permitem comparar experimentos, fatores ou interações

A soma dos coeficientes de um contraste é sempre zero (exceto para q_0), garantindo que a combinação realmente represente uma comparação

$$q_0 = \frac{1}{4}(y_1 + y_2 + y_3 + y_4)$$

$$q_A = \frac{1}{4}(-y_1 + y_2 - y_3 + y_4)$$

$$q_B = \frac{1}{4}(-y_1 - y_2 + y_3 + y_4)$$

$$q_{AB} = \frac{1}{4}(y_1 - y_2 - y_3 + y_4)$$

Cálculo dos Efeitos: Sistema Linear

Pode-se usar o conceito de **contrastes** para respostas mais rápidas

- **Contrastes:** Combinações lineares das respostas experimentais que permitem comparar experimentos, fatores ou interações

A soma dos coeficientes de um contraste é sempre zero (exceto para q_0), garantindo que a combinação realmente represente uma comparação

$$q_0 = \frac{1}{4}(y_1 + y_2 + y_3 + y_4)$$

$$q_A = \frac{1}{4}(-y_1 + y_2 - y_3 + y_4)$$

$$q_B = \frac{1}{4}(-y_1 - y_2 + y_3 + y_4)$$

$$q_{AB} = \frac{1}{4}(y_1 - y_2 - y_3 + y_4)$$

$$-1 + 1 + (-1) + 1 = 0$$

Cálculo dos Efeitos: Sistema Linear

Pode-se usar o conceito de **contrastes** para respostas mais rápidas

- **Contrastes:** Combinações lineares das respostas experimentais que permitem comparar experimentos, fatores ou interações

A soma dos coeficientes de um contraste é sempre zero (exceto para q_0), garantindo que a combinação realmente represente uma comparação

$$q_0 = \frac{1}{4}(y_1 + y_2 + y_3 + y_4)$$

$$q_A = \frac{1}{4}(-y_1 + y_2 - y_3 + y_4)$$

$$q_B = \frac{1}{4}(-y_1 - y_2 + y_3 + y_4)$$

$$q_{AB} = \frac{1}{4}(y_1 - y_2 - y_3 + y_4)$$

$$-1 + (-1) + 1 + 1 = 0$$

Cálculo dos Efeitos: Sistema Linear

Pode-se usar o conceito de **contrastes** para respostas mais rápidas

- **Contrastes:** Combinações lineares das respostas experimentais que permitem comparar experimentos, fatores ou interações

A soma dos coeficientes de um contraste é sempre zero (exceto para q_0), garantindo que a combinação realmente represente uma comparação

$$q_0 = \frac{1}{4}(y_1 + y_2 + y_3 + y_4)$$

$$q_A = \frac{1}{4}(-y_1 + y_2 - y_3 + y_4)$$

$$q_B = \frac{1}{4}(-y_1 - y_2 + y_3 + y_4)$$

$$q_{AB} = \frac{1}{4}(y_1 - y_2 - y_3 + y_4)$$

$$1 + (-1) + (-1) + 1 = 0$$

Cálculo dos Efeitos: Tabela de Sinais

Usando os **contrastes** para o exemplo anterior:

Classificador	10.000 Exemplos	100.000.000 Exemplos
SVM	15%	45%
Redes Neurais	25%	75%

Representando os dados em uma **Tabela de Sinais**:

I	A (Classificador)	B (Dados)	AB	y (Acurácia %)
1	-1	-1	1	15
1	1	-1	-1	25
1	-1	1	-1	45
1	1	1	1	75

Cálculo dos Efeitos: Tabela de Sinais

Resolução dos efeitos:

- Efeito médio geral:

I	A (Classificador)	B (Dados)	AB	y (Acurácia %)
1	-1	-1	1	15
1	1	-1	-1	25
1	-1	1	-1	45
1	1	1	1	75

Cálculo dos Efeitos: Tabela de Sinais

I	A (Classificador)	B (Dados)	AB	y (Acurácia %)
1	-1	-1	1	15
1	1	-1	-1	25
1	-1	1	-1	45
1	1	1	1	75

Resolução dos efeitos:

- Efeito médio geral:

$$q_0 = \frac{1}{4}(y_1 + y_2 + y_3 + y_4) = \frac{1}{4}(15 + 25 + 45 + 75) = \frac{1}{4}(160) = 40$$

Cálculo dos Efeitos: Tabela de Sinais

I	A (Classificador)	B (Dados)	AB	y (Acurácia %)
1	-1	-1	1	15
1	1	-1	-1	25
1	-1	1	-1	45
1	1	1	1	75

Resolução dos efeitos:

- Efeito médio geral:

$$q_0 = \frac{1}{4}(y_1 + y_2 + y_3 + y_4) = \frac{1}{4}(15 + 25 + 45 + 75) = \frac{1}{4}(160) = 40$$

- Efeito principal do classificador (q_A):

$$q_A = \frac{1}{4}(-y_1 + y_2 - y_3 + y_4) = \frac{1}{4}(-15 + 25 - 45 + 75) = \frac{1}{4}(40) = 10$$

Cálculo dos Efeitos: Tabela de Sinais

I	A (Classificador)	B (Dados)	AB	y (Acurácia %)
1	-1	-1	1	15
1	1	-1	-1	25
1	-1	1	-1	45
1	1	1	1	75

Resolução dos efeitos:

- Efeito médio geral:

$$q_0 = \frac{1}{4}(y_1 + y_2 + y_3 + y_4) = \frac{1}{4}(15 + 25 + 45 + 75) = \frac{1}{4}(160) = 40$$

- Efeito principal do classificador (q_A):

$$q_A = \frac{1}{4}(-y_1 + y_2 - y_3 + y_4) = \frac{1}{4}(-15 + 25 - 45 + 75) = \frac{1}{4}(40) = 10$$

- Efeito principal do dados (q_B):

$$q_B = \frac{1}{4}(-y_1 - y_2 + y_3 + y_4) = \frac{1}{4}(-15 - 25 + 45 + 75) = \frac{1}{4}(80) = 20$$

Cálculo dos Efeitos: Tabela de Sinais

- Efeito entre a Interação entre Classificador e # Exemplos:

$$q_{AB} = \frac{1}{4}(y_1 - y_2 - y_3 + y_4) = \frac{1}{4}(15 - 25 - 45 + 75) = \frac{1}{4}(20) = 5$$

Mesmos resultados obtidos anteriormente!

$$y = 40 + 10x_A + 20x_B + 5x_Ax_B$$

Cálculo dos Efeitos: Tabela de Sinais

A **Tabela de Sinais** também oferece uma representação direta de encontrar os efeitos

- Mais intuitiva e menos custoso do que resolver um sistema linear

Método:

1. Multiplica-se as colunas dos fatores pelos valores das respostas
2. Divide-se pelo número total de experimentos

Cálculo dos Efeitos: Tabela de Sinais

Dados originais:

Classificador	10.000 Exemplos	100.000.000 Exemplos
SVM	15%	45%
Redes Neurais	25%	75%

Tabela de Sinais:

I	A (Classificador)	B (Dados)	AB	y (Acurácia %)
1	-1	-1	1	15
1	1	-1	-1	25
1	-1	1	-1	45
1	1	1	1	75

Cálculo dos Efeitos: Tabela de Sinais

1. Multiplicando cada coluna pela coluna de resposta (y) e somando os resultados

	I	A (Classificador)	B (Dados)	AB	y (Acurácia %)
	1	-1	-1	1	15
	1	1	-1	-1	25
	1	-1	1	-1	45
	1	1	1	1	75
Soma	160	40	80	40	20

Cálculo dos Efeitos: Tabela de Sinais

2. Dividindo os valores somados pelo número total de experimentos (2^2= 4) para obter os coeficientes q_0, q_A, q_B, e q_{AB}:

	I	A (Classificador)	B (Dados)	AB	y (Acurácia %)
	1	-1	-1	1	15
	1	1	-1	-1	25
	1	-1	1	-1	45
	1	1	1	1	75
Soma	160	40	80	40	20
Soma/4	40	10	20	5	

Novamente: $y = 40 + 10x_A + 20x_B + 5x_Ax_B$

Alocação da Variação e Importância dos Fatores

A importância de um fator é medida pela quantidade **de variação** total que ele explica no desempenho do modelo

Fatores que explicam uma alta porcentagem da variação são considerados mais importantes

Vejamos como calcular essa proporção para os fatores Classificador (A) e Quantidade de Dados (B), além da interação AB

- Ou seja, para k=2 ou 2^2

Alocação da Variação e Importância dos Fatores

A **variância amostral** de y é dada por:

$$s_y^2 = \frac{\sum_{i=1}^{2^k}(y_i - \bar{y})^2}{2^k - 1}$$

Onde $\bar{y}$ é a média dos resultados, y dos quatro experimentos e o numerador é **a variação total/soma total dos quadrados (SST)** de y é dada por:

$$SST = \sum_{i=1}^{2^k}(y_i - \bar{y})^2$$

Alocação da Variação e Importância dos Fatores

Decomposição da Variação Total (SST): No projeto 2^2, a variação total pode ser dividida em três partes (Derivação no Livro):

$$SST = 2^2 q_A^2 + 2^2 q_B^2 + 2^2 q_{AB}^2$$

As três partes representam a porção da variação explicada por:

- SSA (Efeito de A - Classificador)
- SSB (Efeito de B - Quantidade Dados)
- SSAB (Interação AB - Classificador x Dados)

Alocação da Variação e Importância dos Fatores

Valores dos coeficientes (efeitos obtidos anteriormente):

$$q_A = 10, \quad q_B = 20, \quad q_{AB} = 5$$

Substituindo na **fórmula da variação total**:

$$SST = 2^2(10)^2 + 2^2(20)^2 + 2^2(5)^2$$

$$SST = 4(100) + 4(400) + 4(25) = 400 + 1600 + 100 = 2100$$

Alocação da Variação e Importância dos Fatores

A porcentagem da variação explicada por cada fator é calculada como a fração entre SSA, SSB, e $SSAB$ e a variação total SST :

- SSA: $\frac{SSA}{SST} = \frac{4(10)^2}{2100} = \frac{400}{2100} \approx 0.1905 \ (19.05\%)$
- SSB: $\frac{SSB}{SST} = \frac{4(20)^2}{2100} = \frac{1600}{2100} \approx 0.7619 \ (76.19\%)$
- SSAB: $\frac{SSAB}{SST} = \frac{4(5)^2}{2100} = \frac{100}{2100} \approx 0.0476 \ (4.76\%)$

Alocação da Variação e Importância dos Fatores

Interpretação dos Resultados:

- 76.19% da variação na acurácia é explicada pela Quantidade de Dados (B), o que significa que esse fator tem o maior impacto no desempenho
- 19.05% da variação é explicada pelo Classificador (A), indicando que a escolha do classificador também influencia o desempenho, mas em menor grau
- 4.76% da variação é explicada pela interação Classificador x Dados (AB), sugerindo que há um efeito combinado moderado entre os dois fatores

A derivação matemática está no Cap. 17 do Livro texto

Exemplo 2:

Suponha um modelo de classificação de e-mails (spam ou não) e temos 3 fatores principais e seus níveis:

- **Classificador (A):** SVM (-1) ou Redes Neurais (1)
- **Quantidade de Dados (B):** 10.000 (-1) ou 100.000 (1) exemplos
- **Pré-processamento (C):** Sem Normalização (-1) ou Com Normalização (1)

Variável resposta: **Acurácia**

Organizando a Tabela de Sinais: Fatores

Exp.	I	A	B	C
1	1	-1	-1	-1
2	1	1	-1	-1
3	1	-1	1	-1
4	1	1	1	-1
5	1	-1	-1	1
6	1	1	-1	1
7	1	-1	1	1
8	1	1	1	1

Organizando a Tabela de Sinais: Interações

Exp.	I	A	B	C	AB	AC	BC	ABC
1	1	-1	-1	-1	1	1	1	-1
2	1	1	-1	-1	-1	-1	1	1
3	1	-1	1	-1	-1	1	-1	1
4	1	1	1	-1	1	-1	-1	-1
5	1	-1	-1	1	1	-1	-1	1
6	1	1	-1	1	-1	1	-1	-1
7	1	-1	1	1	-1	-1	1	-1
8	1	1	1	1	1	1	1	1

Organizando a Tabela de Sinais: Resposta

Exp.	I	A	B	C	AB	AC	BC	ABC	y (Acurácia %)
1	1	-1	-1	-1	1	1	1	-1	50
2	1	1	-1	-1	-1	-1	1	1	55
3	1	-1	1	-1	-1	1	-1	1	60
4	1	1	1	-1	1	-1	-1	-1	70
5	1	-1	-1	1	1	-1	-1	1	65
6	1	1	-1	1	-1	1	-1	-1	75
7	1	-1	1	1	-1	-1	1	-1	80
8	1	1	1	1	1	1	1	1	90

Calculando os Efeitos dos Fatores e Interações

Exp.	I	A	B	C	AB	AC	BC	ABC	y (Acurácia %)
1	1	-1	-1	-1	1	1	1	-1	50
2	1	1	-1	-1	-1	-1	1	1	55
3	1	-1	1	-1	-1	1	-1	1	60
4	1	1	1	-1	1	-1	-1	-1	70
5	1	-1	-1	1	1	-1	-1	1	65
6	1	1	-1	1	-1	1	-1	-1	75
7	1	-1	1	1	-1	-1	1	-1	80
8	1	1	1	1	1	1	1	1	90
Soma	520	35	55	75	5	5	5	-5	
Soma/8	65	4,375	6,875	9,375	0,625	0,625	0,625	-0,625	

Alocação da Variação

A fórmula de SST para 2^3 é:

$$SST = 2^3 q_A^2 + 2^3 q_B^2 + 2^3 q_C^2 + 2^3 q_{AB}^2 + 2^3 q_{AC}^2 + 2^3 q_{BC}^2 + 2^3 q_{ABC}^2$$

Substituindo os valores de q's:

$$SST = 2^3(4.375)^2 + 2^3(6.875)^2 + 2^3(9.375)^2 + 2^3(0.625)^2 + 2^3(0.625)^2 + 2^3(0.625)^2 + 2^3(-0.625)^2$$

$$SST = 8(4.375)^2 + 8(6.875)^2 + 8(9.375)^2 + 8(0.625)^2 + 8(0.625)^2 + 8(0.625)^2 + 8(-0.625)^2$$

$$SST = 153.125 + 378.125 + 703.125 + 3.125 + 3.125 + 3.125 + 3.125$$

$$SST = 1246.875$$

Porcentagem da Variação Explicada por Cada Fator

SSA (Classificador):

$$SSA = \frac{8 \times (4.375)^2}{SST} = \frac{8 \times 19.14}{1246.875} = \frac{153.12}{1246.875} \approx 12.28\%$$

SSB (Quantidade de Dados):

$$SSB = \frac{8 \times (6.875)^2}{SST} = \frac{8 \times 47.27}{1246.875} = \frac{378.16}{1246.875} \approx 30.33\%$$

SSC (Pré-processamento):

$$SSC = \frac{8 \times (9.375)^2}{SST} = \frac{8 \times 87.89}{1246.875} = \frac{703.12}{1246.875} \approx 56.39\%$$

Porcentagem da Variação Explicada por Cada Fator

SSAB (Interação Classificador x Dados):

$$SS_{AB} = \frac{8 \times (0.625)^2}{SST} = \frac{8 \times 0.39}{1246.875} = \frac{3.12}{1246.875} \approx 0.25\%$$

SSBC (Quantidade de Dados x Pré-Processamento):

$$SS_{BC} = \frac{8 \times (0.625)^2}{SST} = \frac{8 \times 0.39}{1246.875} = \frac{3.12}{1246.875} \approx 0.25\%$$

SSAC (Interação Classificador x Pré-processamento):

$$SS_{AC} = \frac{8 \times (0.625)^2}{SST} = \frac{8 \times 0.39}{1246.875} = \frac{3.12}{1246.875} \approx 0.25\%$$

Porcentagem da Variação Explicada por Cada Fator

SABC (Interação Tripla Classificador x Dados x Pré-processamento):

$$SS_{ABC} = \frac{8 \times (-0.625)^2}{SST} = \frac{8 \times 0.39}{1246.875} = \frac{3.12}{1246.875} \approx 0.25\%$$

Interpretações

- O Pré-processamento (C) explica a maior parte da variação, representando aproximadamente 56% da variação total

- A Quantidade de Dados (B) também é um fator relevante, explicando cerca de 30% da variação

- O Classificador (A) explica um valor expressivo, sendo 12%

- As interações são desprezíveis, totalizando aproximadamente 1% de toda a variação

Exercício

Aplique um projeto fatorial 2^3 nos seguintes fatores e níveis:

	A_1		A^2	
	C_1	C_2	C_1	C_2
B_1	100	15	120	10
B_2	40	30	20	50

Fatorial $2^k r$

O projeto fatorial 2^k não permite estimar o erro experimental uma vez que não há **replicações**

Erros experimentais são quantificados por meio da repetição dos experimentos para um mesmo fator e um mesmo nível

Se cada um dos 2^k experimentos for replicados r vezes, tem-se o projeto **fatorial $2^k r$**

- Permite comparar a variação explicada pelos fatores interações e erros experimentais

Fatorial $2^k r$

Considere dois fatores (A e B), o projeto fatorial $2^k r$ assume o seguinte formato:

$$y = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B + e$$

onde:

- os *q's* são os efeitos dos fatores como antes
- e '*e*' é o erro experimental

Fatorial $2^k r$

Considere um experimento com 2 fatores (A e B) e 3 replicações

Exp.	I	A	B	AB
1	1	-1	-1	1
2	1	1	-1	-1
3	1	-1	1	-1
4	1	1	1	1

Fatores e interação, como antes!

Fatorial $2^k r$

Considere um experimento com 2 fatores (A e B) e 3 replicações

Exp.	I	A	B	AB	y (replicações)	y (média)
1	1	-1	-1	1	[15,18,12]	15
2	1	1	-1	-1	[45,48,51]	48
3	1	-1	1	-1	[25,28,19]	24
4	1	1	1	1	[75,75,81]	77

Replicações e média da variável resposta

Fatorial $2^k r$

Considere um experimento com 2 fatores (A e B) e 3 replicações

Exp.	I	A	B	AB	y (replicações)	y (média)
1	1	-1	-1	1	[15,18,12]	15
2	1	1	-1	-1	[45,48,51]	48
3	1	-1	1	-1	[25,28,19]	24
4	1	1	1	1	[75,75,81]	77
Soma	164	86	38	20		
Soma/4	41	21,5	9,5	5		

O cálculo dos efeitos (q's) agora é feito sobre a média das replicações!

Estimativa dos erros experimentais

Considerando o modelo:

$$\hat{y}_i = q_0 + q_{A_i} x_{A_i} + q_{B_i} x_{B_i} + q_{AB} x_{A_i B_i}$$

A diferença entre o valor mensurado e estimado y_{ij} na *j-ésima* replicação do *i-ésimo* experimento representa os erros experimentais

$$e_{ij} = y_{ij} - \hat{y}_i$$

A soma dos erros quadráticos considerando um projeto 2^2 é dada por:

$$SSE = \sum_{i=1}^{2^2} \sum_{j=1}^{r} (e_{ij})^2$$

Estimativa dos erros experimentais

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)	Erros
	41	21.5	9.5	5	y_{i1}, y_{i2}, y_{i3}	y_i	e_{i1}, e_{i2}, e_{i3}
1	1	-1	-1	1	[15, 18, 12]	15	[0, 3, -3]
2	1	1	-1	-1	[45, 48, 51]	48	[-3, 0, 3]
3	1	-1	1	-1	[25, 28, 19]	24	[1, 4, -5]
4	1	1	1	1	[75, 75, 81]	77	[-2, -2, 4

Estimativa dos erros experimentais

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)	Erros
	41	21.5	9.5	5	y_{i1}, y_{i2}, y_{i3}	y_i	e_{i1}, e_{i2}, e_{i3}
1	1	-1	-1	1	[15, 18, 12]	15	[0, 3, -3]
2	1	1	-1	-1	[45, 48, 51]	48	[-3, 0, 3]
3	1	-1	1	-1	[25, 28, 19]	24	[1, 4, -5]
4	1	1	1	1	[75, 75, 81]	77	[-2, -2, 4

Cada experimento e cada replicação possui um erro!

Estimativa dos erros experimentais

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)	Erros
	41	21.5	9.5	5	y_{i1}, y_{i2}, y_{i3}	y_i	e_{i1}, e_{i2}, e_{i3}
1	1	-1	-1	1	[15, 18, 12]	15	[0, 3, -3]
2	1	1	-1	-1	[45, 48, 51]	48	[-3, 0, 3]
3	1	-1	1	-1	[25, 28, 19]	24	[1, 4, -5]
4	1	1	1	1	[75, 75, 81]	77	[-2, -2, 4

O erro experimental é calculado para cada resposta mensurada em relação a média!

Estimativa dos erros experimentais

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)	Erros
	41	21.5	9.5	5	y_{i1}, y_{i2}, y_{i3}	y_i	e_{i1}, e_{i2}, e_{i3}
1	1	-1	-1	1	[15, 18, 12]	15	[0, 3, -3]
2	1	1	-1	-1	[45, 48, 51]	48	[-3, 0, 3]
3	1	-1	1	-1	[25, 28, 19]	24	[1, 4, -5]
4	1	1	1	1	[75, 75, 81]	77	[-2, -2, 4

Assim, o SSE é dado por: $SSE = 0^2 + 3^2 + (-3)^2$

Estimativa dos erros experimentais

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)	Erros
	41	21.5	9.5	5	y_{i1}, y_{i2}, y_{i3}	y_i	e_{i1}, e_{i2}, e_{i3}
1	1	-1	-1	1	[15, 18, 12]	15	[0, 3, -3]
2	1	1	-1	-1	[45, 48, 51]	48	[-3, 0, 3]
3	1	-1	1	-1	[25, 28, 19]	24	[1, 4, -5]
4	1	1	1	1	[75, 75, 81]	77	[-2, -2, 4

Assim, o SSE é dado por: $SSE = 0^2 + 3^2 + (-3)^2 + (-3)^2 + 0^2 + 3^2$

Estimativa dos erros experimentais

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)	Erros
	41	21.5	9.5	5	y_{i1}, y_{i2}, y_{i3}	y_i	e_{i1}, e_{i2}, e_{i3}
1	1	-1	-1	1	[15, 18, 12]	15	[0, 3, -3]
2	1	1	-1	-1	[45, 48, 51]	48	[-3, 0, 3]
3	1	-1	1	-1	[25, 28, 19]	24	[1, 4, -5]
4	1	1	1	1	[75, 75, 81]	77	[-2, -2, 4

Assim, o SSE é dado por:

$$SSE = 0^2 + 3^2 + (-3)^2 + (-3)^2 + 0^2 + 3^2 + 1^2 + 4^2 + (-5)^2 + (-2)^2 + (-2)^2 + 4^2 = 102$$

Alocação da variação

Variação total/Soma Total dos Quadrados SST é dada por:

$$SST = \sum_{i,j}(y_{ij} - \bar{y}_{..})^2 = \sum_{i,j} y_{ij}^2 - \sum_{i,j} \bar{y}_{..}^2$$

Alocação da variação

Variação total/Soma Total dos Quadrados SST é dada por:

$$SST = \sum_{i,j}(y_{ij} - \bar{y}_{..})^2 = \sum_{i,j} y_{ij}^2 - \sum_{i,j} \bar{y}_{..}^2$$

Média (global) da variável resposta para todos os experimentos e replicações

Alocação da variação

Variação total/Soma Total dos Quadrados SST é dada por:

$$SST = \sum_{i,j}(y_{ij} - \bar{y}_{..})^2 = \sum_{i,j} y_{ij}^2 - \sum_{i,j} \bar{y}_{..}^2$$

O SST pode ser dividido nos seguintes termos:

$$SST = \sum_{i,j}(y_{ij} - \bar{y}_{..})^2$$

$$= \sum_{i,j}(y_{ij} - \bar{y}_{..})^2 = 2^2 r q_A^2 + 2^2 r q_B^2 + 2^2 r q_{AB}^2 + \sum_{i,j} e_{ij}^2$$

$$SST = SSA + SSB + SSAB + SSE = SSY - SS0$$

Alocação da variação

SSY: Soma dos quadrados totais, que corresponde à soma dos quadrados dos **valores mensurados**

$$SSY = \sum_{i,j} y_{ij}^2$$

SS0: Soma dos quadrados da média geral, que mede a variação ao redor da **resposta estimada**

$$SS0 = 2^2 r q_0^2$$

Logo, $SST = SSY - SS0$, permitindo avaliar a variação apenas em função dos fatores, interações e erro, isolando a variação da média

Alocação da variação

SSA: Variação explicada pelo fator

$$SSA = 2^2 r q_A^2$$

SSB: Variação explicada pelo fator

$$SSB = 2^2 r q_B^2$$

SSAB: Variação explicada pela interação entre os fatores

$$SSAB = 2^2 r q_{AB}^2$$

SSE: Variação explicada pelo erro, calculada como a variação não explicada pelos fatores

$$SSE = SSY - 2^2 r(q_0^2 + q_A^2 + q_B^2 + q_{AB}^2)$$

Alocação da variação

SST é a soma total da variação, composta pelas parcelas SSA, SSB, SSAB, e SSE

SSY e **SS0** são usados para calcular a variação total (SST) em torno da resposta estimada

Cada componente (**SSA**, **SSB** e **SSAB**) mede a variação explicada por um fator ou interação específica

SSE mede a variação não explicada, ou seja, o erro

Alocação da variação

Para o exemplo anterior:

$$SSY = 15^2 + 18^2 + 12^2 + 45^2 + \cdots + 75^2 + 81^2 = 27,204$$

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)	Erros
	41	21.5	9.5	5	y_{i1}, y_{i2}, y_{i3}	y_i	e_{i1}, e_{i2}, e_{i3}
1	1	-1	-1	1	[15, 18, 12]	15	[0, 3, -3]
2	1	1	-1	-1	[45, 48, 51]	48	[-3, 0, 3]
3	1	-1	1	-1	[25, 28, 19]	24	[1, 4, -5]
4	1	1	1	1	[75, 75, 81]	77	[-2, -2, 4

Alocação da variação

Para o exemplo anterior:

$$SSY = 15^2 + 18^2 + 12^2 + 45^2 + \cdots + 75^2 + 81^2 = 27,204$$

$$SS0 = 2^2 r q_0^2 = 12 \times 41^2 = 20,172$$

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)	Erros
	41	21.5	9.5	5	y_{i1}, y_{i2}, y_{i3}	y_i	e_{i1}, e_{i2}, e_{i3}
1	1	-1	-1	1	[15, 18, 12]	15	[0, 3, -3]
2	1	1	-1	-1	[45, 48, 51]	48	[-3, 0, 3]
3	1	-1	1	-1	[25, 28, 19]	24	[1, 4, -5]
4	1	1	1	1	[75, 75, 81]	77	[-2, -2, 4

Alocação da variação

Para o exemplo anterior:

$$SSY = 15^2 + 18^2 + 12^2 + 45^2 + \cdots + 75^2 + 81^2 = 27,204$$

$$SS0 = 2^2 r q_0^2 = 12 \times 41^2 = 20,172$$

$$SSA = 2^2 r q_A^2 = 12 \times (21.5)^2 = 5547$$

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)	Erros
	41	21.5	9.5	5	y_{i1}, y_{i2}, y_{i3}	y_i	e_{i1}, e_{i2}, e_{i3}
1	1	-1	-1	1	[15, 18, 12]	15	[0, 3, -3]
2	1	1	-1	-1	[45, 48, 51]	48	[-3, 0, 3]
3	1	-1	1	-1	[25, 28, 19]	24	[1, 4, -5]
4	1	1	1	1	[75, 75, 81]	77	[-2, -2, 4

Alocação da variação

Para o exemplo anterior:

$$SSY = 15^2 + 18^2 + 12^2 + 45^2 + \cdots + 75^2 + 81^2 = 27,204$$

$$SS0 = 2^2 r q_0^2 = 12 \times 41^2 = 20,172$$

$$SSA = 2^2 r q_A^2 = 12 \times (21.5)^2 = 5547$$

$$SSB = 2^2 r q_B^2 = 12 \times (9.5)^2 = 1083$$

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)	Erros
	41	21.5	9.5	5	y_{i1}, y_{i2}, y_{i3}	y_i	e_{i1}, e_{i2}, e_{i3}
1	1	-1	-1	1	[15, 18, 12]	15	[0, 3, -3]
2	1	1	-1	-1	[45, 48, 51]	48	[-3, 0, 3]
3	1	-1	1	-1	[25, 28, 19]	24	[1, 4, -5]
4	1	1	1	1	[75, 75, 81]	77	[-2, -2, 4

Alocação da variação

Para o exemplo anterior:

$$SSY = 15^2 + 18^2 + 12^2 + 45^2 + \cdots + 75^2 + 81^2 = 27,204$$

$$SS0 = 2^2 r q_0^2 = 12 \times 41^2 = 20,172$$

$$SSA = 2^2 r q_A^2 = 12 \times (21.5)^2 = 5547$$

$$SSB = 2^2 r q_B^2 = 12 \times (9.5)^2 = 1083$$

$$SSAB = 2^2 r q_{AB}^2 = 12 \times 5^2 = 300$$

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)	Erros
	41	21.5	9.5	5	y_{i1}, y_{i2}, y_{i3}	y_i	e_{i1}, e_{i2}, e_{i3}
1	1	-1	-1	1	[15, 18, 12]	15	[0, 3, -3]
2	1	1	-1	-1	[45, 48, 51]	48	[-3, 0, 3]
3	1	-1	1	-1	[25, 28, 19]	24	[1, 4, -5]
4	1	1	1	1	[75, 75, 81]	77	[-2, -2, 4

Alocação da variação

Para o exemplo anterior:

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)	Erros
	41	21.5	9.5	5	y_{i1}, y_{i2}, y_{i3}	y_i	e_{i1}, e_{i2}, e_{i3}
1	1	-1	-1	1	[15, 18, 12]	15	[0, 3, -3]
2	1	1	-1	-1	[45, 48, 51]	48	[-3, 0, 3]
3	1	-1	1	-1	[25, 28, 19]	24	[1, 4, -5]
4	1	1	1	1	[75, 75, 81]	77	[-2, -2, 4

$$SSY = 15^2 + 18^2 + 12^2 + 45^2 + \cdots$$

$$SS0 = 2^2 r q_0^2 = 12 \times 41^2 = 20,172$$

$$SSA = 2^2 r q_A^2 = 12 \times (21.5)^2 = 5547$$

$$SSB = 2^2 r q_B^2 = 12 \times (9.5)^2 = 1083$$

$$SSAB = 2^2 r q_{AB}^2 = 12 \times 5^2 = 300$$

$$SSE = 27,204 - 2^2 \times 3 \times (41^2 + 21.5^2 + 9.5^2 + 5^2) = 102$$

Alocação da variação

Para o exemplo anterior:

$$SSY = 15^2 + 18^2 + 12^2 + 45^2 + \cdots + 75^2 + 81^2 = 27,204$$

$$SS0 = 2^2 r q_0^2 = 12 \times 41^2 = 20,172$$

$$SSA = 2^2 r q_A^2 = 12 \times (21.5)^2 = 5547$$

$$SSB = 2^2 r q_B^2 = 12 \times (9.5)^2 = 1083$$

$$SSAB = 2^2 r q_{AB}^2 = 12 \times 5^2 = 300$$

$$SSE = 27,204 - 2^2 \times 3 \times (41^2 + 21.5^2 + 9.5^2 + 5^2) = 102$$

$$SST = SSY - SS0 = 27,204 - 20,172 = 7032$$

Alocação da variação

A variação total de 7032 pode ser dividida em quatro partes:

- O fator A explica:

$$\frac{SSA}{SST} = \frac{5547}{7032} = 0.7888 \quad (78.88\%)$$

- O fator B explica:

$$\frac{SSB}{SST} = \frac{1083}{7032} = 0.1540 \quad (15.40\%)$$

- A interação AB:

$$\frac{SSAB}{SST} = \frac{300}{7032} = 0.0427 \quad (4.27\%)$$

- Os restantes não são explicados e são atribuídos a erros experimentais:

$$\frac{SSE}{SST} = \frac{102}{7032} = 0.0145 \quad (1.45\%)$$

Intervalos de confiança para os efeitos

Os efeitos em um projeto fatorial com replicação são calculados por meio de amostras de uma variável aleatória

A **variância dos erros (Mean Square Errors (MSE)** e o **desvio padrão** podem ser estimados a partir do SSE (Soma Quadrática dos Erros):

$$s_e^2 = \frac{SSE}{2^2(r-1)} \qquad s_e = \sqrt{\frac{SSE}{2^2(r-1)}}$$

Onde $2^2(r-1)$ corresponde aos graus de liberdade em função do número de experimentos. Para o exemplo anterior 4*2 =8

Intervalos de confiança para os efeitos

Já o desvio padrão estimado para os efeitos é dado por:

$$S_{q_0} = S_{q_A} = S_{q_B} = S_{q_{AB}} = \frac{s_e}{\sqrt{2^2 r}}$$

Os fatores e suas interações são estruturados de maneira **simétrica** e **equilibrada** em termos de como os dados são distribuídos e coletados

- Logo, o mesmo desvio padrão é aplicado a todos os efeitos estimados

Para o exemplo, os intervalos de confiança dos efeitos são obtidos por:

$$q_i \pm t_{[1-\alpha/2, 2^2(r-1)]} S_{q_i}$$

Intervalos de confiança para os efeitos

Calculando os intervalos de confiança:

1. SSE obtido anteriormente: 102

2. Variância e desvio padrão dos erros:

$$s_e = \sqrt{\frac{SSE}{2^2(r-1)}} = \sqrt{\frac{102}{2^2(3-1)}} = \sqrt{12.75} = 3.57$$

$$s_{q_i} = \frac{s_e}{\sqrt{2^2 r}} = \frac{3.57}{\sqrt{12}} = 1.03$$

Intervalos de confiança para os efeitos

Calculando os intervalos de confiança:

3. Graus de liberdade = 8. Logo distribuição *t*. Assumindo 90% de confiança: 1.86

4. Intervalos de confiança:

$$q_0 : (39.08, 41, 42.91) \qquad q_B : (7.58, 9.5, 11.41)$$

$$q_A : (19.58, 21.5, 23.41) \qquad q_{AB} : (3.08, 5, 6.91)$$

5. Teste da média zero: Algum dos intervalos inclui zero?
   - Não! Logo, todos são significativos!

Intervalos de confiança para respostas

Também é possível estimar a média das respostas obtidas em *m* replicações **futuras** de uma dada combinação de fatores

- Útil para verificar a robustez do modelo

A estimativa da média é dada por:

$$\hat{y} = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

O desvio padrão da estimativa:

$$s_{\hat{y}_m} = s_e \sqrt{\frac{1}{n_{\text{eff}}} + \frac{1}{m}}$$

Intervalos de confiança para respostas

Também é possível estimar a média das respostas obtidas em *m* replicações **futuras** de uma dada combinação de fatores

- Útil para verificar a robustez do modelo

A estimativa da média é dada por:

$$\hat{y} = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

O desvio padrão da estimativa:

$$s_{\hat{y}_m} = s_e \sqrt{\frac{1}{n_{\text{eff}}} + \frac{1}{m}}$$

$$n_{\text{eff}} = \frac{\#\text{ total de observações}}{1 + \text{soma dos DFs dos parâmetros usados em } \hat{y}}$$

Intervalos de confiança para respostas

Também é possível estimar a média das respostas obtidas em *m* replicações **futuras** de uma dada combinação de fatores

- Útil para verificar a robustez do modelo

A estimativa da média é dada por:

$$\hat{y} = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

O desvio padrão da estimativa:

$$s_{\hat{y}_m} = s_e \sqrt{\frac{1}{n_{\text{eff}}} + \frac{1}{m}}$$

experimentos. Ex anterior: $2^2 x 3 = 12$

$$n_{\text{eff}} = \frac{\#\text{ total de observações}}{1 + \text{soma dos DFs dos parâmetros usados em } \hat{y}}$$

Intervalos de confiança para respostas

Também é possível estimar a média das respostas obtidas em *m* replicações **futuras** de uma dada combinação de fatores

- Útil para verificar a robustez do modelo

A estimativa da média é dada por:

$$\hat{y} = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

O desvio padrão da estimativa:

$$s_{\hat{y}_m} = s_e \sqrt{\frac{1}{n_{\text{eff}}} + \frac{1}{m}}$$

4 graus de liberdade
(q_0, q_A, q_B, q_{AB})+1

$$n_{\text{eff}} = \frac{\#\text{ total de observações}}{1 + \text{soma dos DFs dos parâmetros usados em } \hat{y}}$$

Intervalos de confiança para respostas

Também é possível estimar a média das respostas obtidas em *m* replicações **futuras** de uma dada combinação de fatores

- Útil para verificar a robustez do modelo

A estimativa da média é dada por:

$$\hat{y} = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

O desvio padrão da estimativa:

$$s_{\hat{y}_m} = s_e \sqrt{\frac{1}{n_{\text{eff}}} + \frac{1}{m}}$$

replicações futuras!

Intervalos de confiança para respostas

Também é possível estimar a média das respostas obtidas em *m* replicações **futuras** de uma dada combinação de fatores

- Útil para verificar a robustez do modelo

A estimativa da média é dada por:

$$\hat{y} = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B$$

O desvio padrão da estimativa:

$$s_{\hat{y}_m} = s_e \sqrt{\frac{1}{n_{\text{eff}}} + \frac{1}{m}}$$

O intervalo de confiança para o exemplo anterior (2^2) é dado por:

$$\hat{y} \pm t_{[1-\alpha/2, 2^2(r-1)]} s_{\hat{y}_m}$$

Intervalos de confiança para respostas

Desvio padrão para a estimativa para **uma** execução futura:

$$s_{\hat{y}_m} = s_e \sqrt{\frac{5}{2^2 r} + 1}$$

Desvio padrão para a estimativa da **média populacional** (m→∞):

$$s_{\hat{y}_m} = s_e \sqrt{\frac{5}{2^2 r}}$$

Intervalos de confiança para respostas

Considerando o exemplo anterior:

$$\hat{y}_1 = q_0 - q_A - q_B + q_{AB} = 41 - 21.5 - 9.5 + 5 = 15$$

1. **Estimativa para um experimento de confirmação (m=1):**

$$s_{\hat{y}_m} = s_e \sqrt{\frac{1}{n_{eff}} + \frac{1}{m}}$$

$$s_{\hat{y}_m} = 3.57 \sqrt{\frac{1}{2.4} + \frac{1}{1}} = 3.57 \sqrt{0.4167 + 1} = 3.57 \sqrt{1.4167} = 3.57 \times 1.19 = 4.25$$

$$\hat{y} \pm t_{[0.95,8]} \times s_{\hat{y}_m} = 15 \pm 1.86 \times 4.25 = 15 \pm 7.91 \rightarrow (7.09, 22.91)$$

Intervalos de confiança para respostas

2. Para m=5:

$$s_{\hat{y}_m} = 3.57\sqrt{\frac{1}{2.4} + \frac{1}{5}} = 3.57\sqrt{0.4167 + 0.2} = 3.57\sqrt{0.6167} = 3.57 \times 0.785 = 2.80$$

$$\hat{y} \pm t_{[0.95,8]} \times s_{\hat{y}_m} = 15 \pm 1.86 \times 2.80 = 15 \pm 5.21 \rightarrow (9.79, 20.21)$$

Intervalos de confiança para respostas

2. **Para m=5:**

$$s_{\hat{y}_m} = 3.57\sqrt{\frac{1}{2.4} + \frac{1}{5}} = 3.57\sqrt{0.4167 + 0.2} = 3.57\sqrt{0.6167} = 3.57 \times 0.785 = 2.80$$

$$\hat{y} \pm t_{[0.95,8]} \times s_{\hat{y}_m} = 15 \pm 1.86 \times 2.80 = 15 \pm 5.21 \rightarrow (9.79, 20.21)$$

3. **Para m=∞**

$$s_{\hat{y}_m} = s_e\sqrt{\frac{1}{n_{eff}}} = 3.57\sqrt{\frac{1}{2.4}} = 3.57 \times 0.645 = 2.30$$

$$\hat{y} \pm t_{[0.95,8]} \times s_{\hat{y}_m} = 15 \pm 1.86 \times 2.30 = 15 \pm 4.28 \rightarrow (10.72, 19.28)$$

Intervalos de confiança para respostas

4. Resposta média atual: Não é o caso de previsão. Apenas de um I.C. para $\hat{y}_1 = q_0 - q_A - q_B + q_{AB} = 41 - 21.5 - 9.5 + 5 = 15$

$$S_{\hat{y}_1} = \sqrt{\frac{s_e^2 \sum h_i^2}{2^2 r}} = \sqrt{\frac{12.75(1+1+1+1)}{12}} = 2.06$$

$$y_1 \pm t_{[0.95,8]} = 15 \pm 1.86 \times 2.06 = 15 \pm 3.83 = (11.17, 18.83)$$

Intervalos de confiança para respostas

Resumindo:

- Para m=1, I.C.'s: (7.09, 22.91)
- Para m=5, I.C.'s: (9.79, 20.21)
- Para m=∞, I.C.'s: (10.72, 19.28)
- I.C.'s da resposta no experimento: (11.17, 18.83)

Conforme o número de réplicas m aumenta, o I.C. fica mais estreito, indicando maior precisão na estimativa da resposta

Estimativas futuras sempre têm I.C.'s mais largos (ou maior variância) do que a resposta medida diretamente no experimento

- Considera a variabilidade nos futuros experimentos e erros de execução

Premissas

As derivações para os cálculos apresentadas anteriormente assumem as seguintes premissas:

- **Erros estatisticamente independentes:** Gráficos de dispersão: Resíduo x Variável Resposta Predita e Resíduo x # Experimento
- **Erros normalmente distribuídos:** Gráfico Quantil-Quantil ou Testes de Normalidade
- **Desvio padrão dos erros constantes:** Gráfico de dispersão de y para vários níveis do fator
    - Dispersão em um nível significativamente diferente do que em outro indica necessidade de transformação

Modelos multiplicativos

A análise apresentada anteriormente 2^2r, um modelo aditivo foi assumido

$$y_{ij} = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B + e_{ij}$$

O efeito dos fatores, suas interações e os erros são aditivos

Essa premissa precisa ser validada e em muitos casos não é válida

Modelos multiplicativos

Assuma dois fatores A (Algoritmo) e B (Carga de trabalho) com dois níveis cada um

A resposta y_{ij} representa o tempo de execução de w_j operações em um algoritmo capaz de executar v_i operações por segundo

- Uma divisão entre variáveis, o modelo é naturalmente multiplicativo

$$y_{ij} = \frac{w_j}{vi}$$

Típico caso de modelo multiplicativo: Taxas ou desempenhos proporcionais

Modelos multiplicativos

Os efeitos não são aditivos, mas sim multiplicativos. Aplicando *log* e usando a propriedade da divisão logarítmica, tem-se:

$$\log(y_{ij}) = \log(w_j) - \log(v_i)$$

Modelo:

$$y'_{ij} = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B + e_{ij}$$

onde:

$$y'_{ij} = \log(y_{ij})$$

Modelos multiplicativos

Exemplo:

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)
1	1	-1	-1	1	[85.10, 79.50, 147.90]	104,17
2	1	1	-1	-1	[0.891, 1.047, 1.072]	1,003
3	1	-1	1	-1	[0.955, 0.933, 1.122]	1,003
4	1	1	1	1	[0.0148, 0.0126, 0.0118]	0,013
Soma	106,19	-104,15	-104,15	102,17		106,19
Soma/4	26,55	-26,04	-26,04	25,54		26,55

Modelos multiplicativos

Exemplo:

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)
1	1	-1	-1	1	[85.10, 79.50, 147.90]	104,17
2	1	1	-1	-1	[0.891, 1.047, 1.072]	1,003
3	1	-1	1	-1	[0.955, 0.933, 1.122]	1,003
4	1	1	1	1	[0.0148, 0.0126, 0.0118]	0,013
Soma	106,19	-104,15	-104,15	102,17		
Soma/4	26,55	-26,04	-26,04	25,54		

O intervalo de valores mensurados é muito grande: 0.0118 a 147.90

Modelos multiplicativos

Exemplo:

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)
1	1	-1	-1	1	[85.10, 79.50, 147.90]	104,17
2	1	1	-1	-1	[0.891, 1.047, 1.072]	1,003
3	1	-1	1	-1	[0.955, 0.933, 1.122]	1,003
4	1	1	1	1	[0.0148, 0.0126, 0.0118]	0,013
Soma	106,19	-104,15	-104,15	102,17		
Soma/4	26,55	-26,04	-26,04	25,54		

A razão entre o valor máximo (147.90) e mínimo (0.0118) é igual a 12534, que é um valor muito grande. Qualquer coisa maior do que 3, exige log!

Modelos multiplicativos

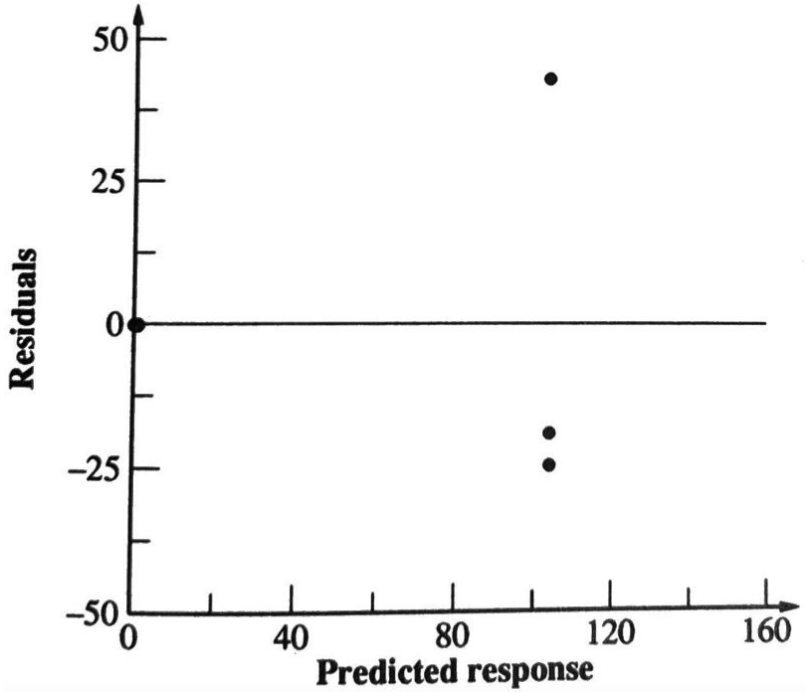
Exemplo:

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)
1	1	-1	-1	1	[85.10, 79.50, 147.90]	104,17
2	1	1	-1	-1	[0.891, 1.047, 1.072]	1,003
3	1	-1	1	-1	[0.955, 0.933, 1.122]	1,003
4	1	1	1	1	[0.0148, 0.0126, 0.0118]	0,013
Soma	106,19	-104,15	-104,15	102,17		106,19
Soma/4	26,55	-26,04	-26,04	25,54		26,55

Os resíduos são pequenos e constantes? Os resíduos seguem uma distribuição normal?

Modelos multiplicativos

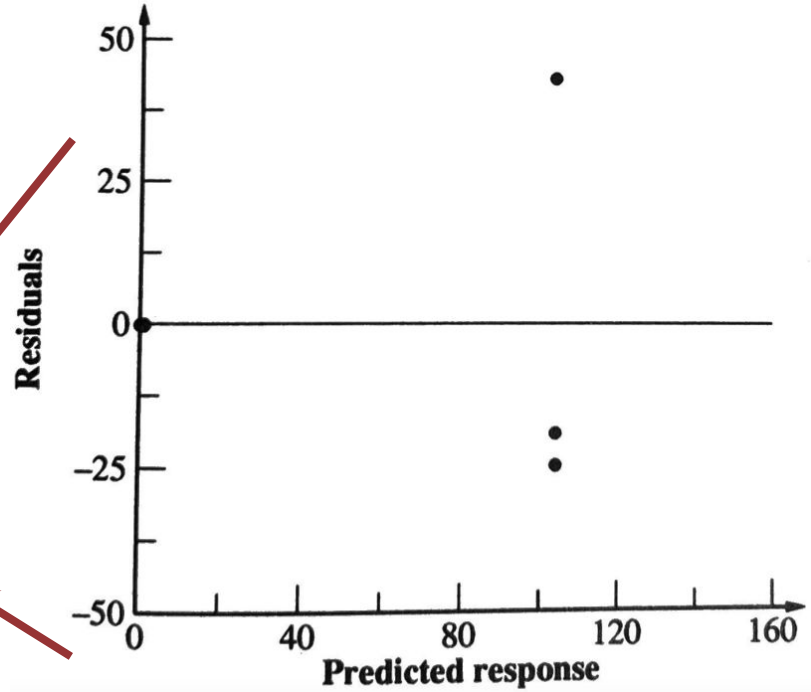
Gráfico de dispersão: Resíduo x Valor Predito



Modelos multiplicativos

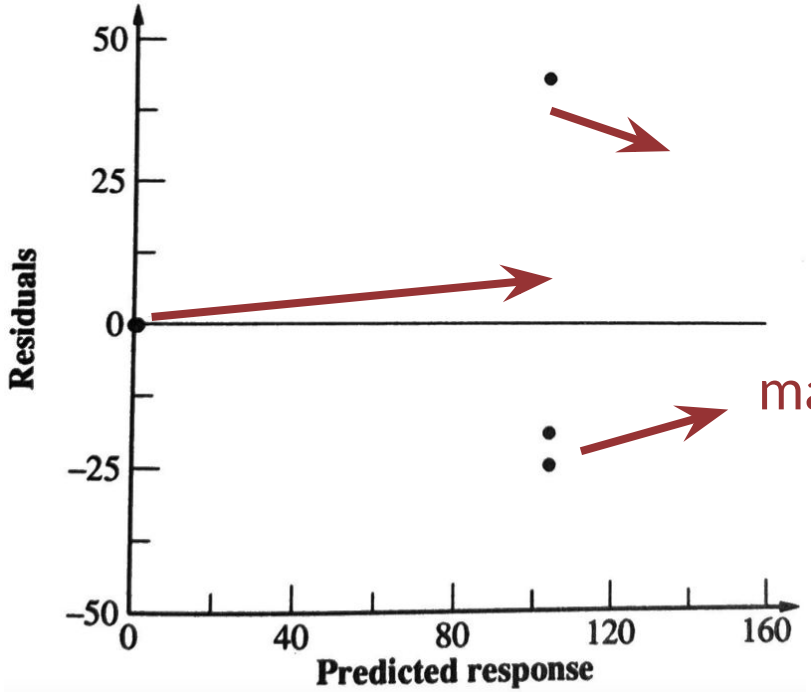
Gráfico de dispersão: Resíduo x Valor Predito

Resíduos não são pequenos comparados a resposta predita



Modelos multiplicativos

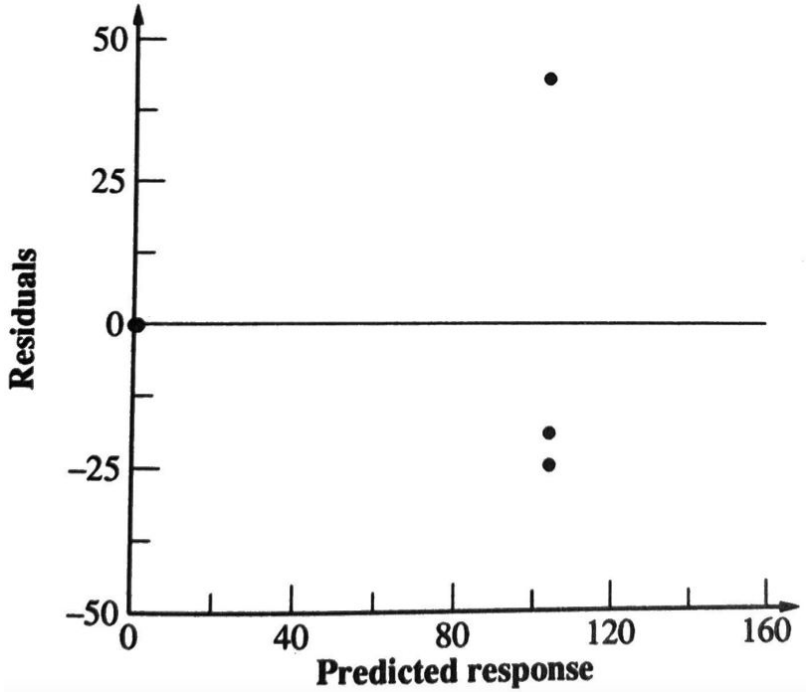
Gráfico de dispersão: Resíduo x Valor Predito



Os resíduos são mais largos para valores maiores e não constantes

Modelos multiplicativos

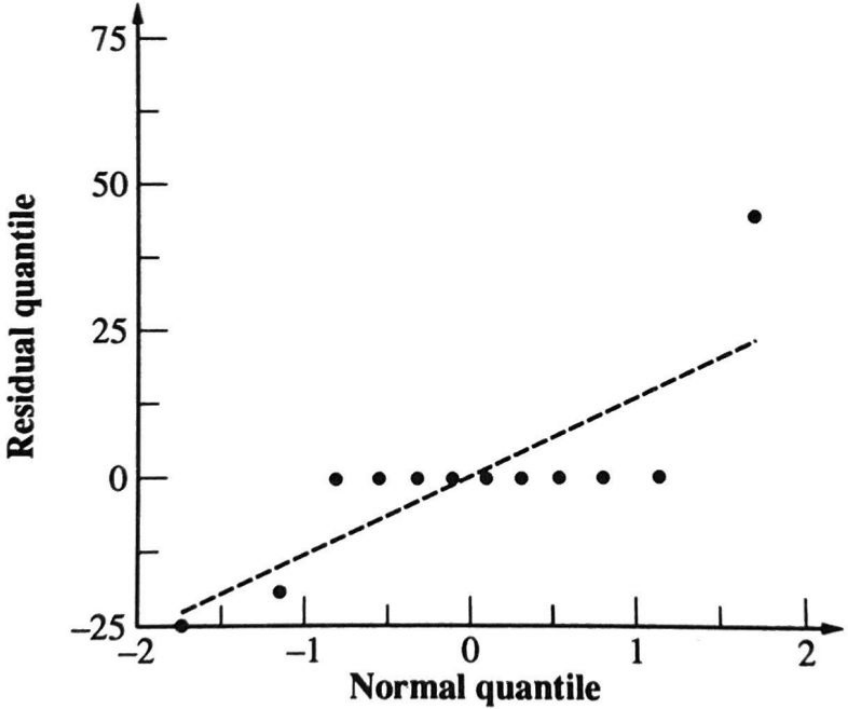
Gráfico de dispersão: Resíduo x Valor Predito



Use uma transformação logarítmica!

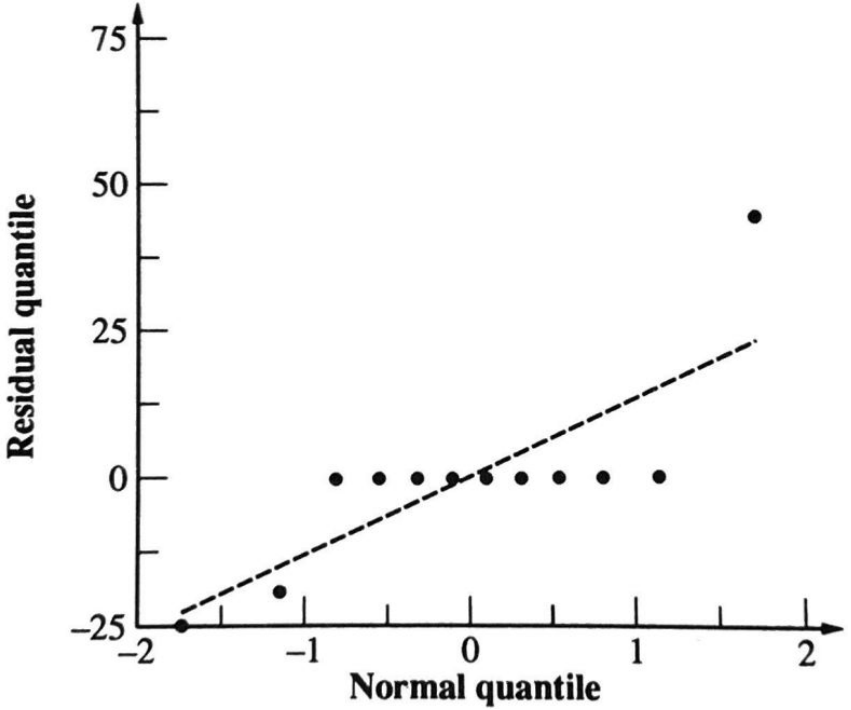
Modelos multiplicativos

Gráfico Quantil-Quantil dos resíduos



Modelos multiplicativos

Gráfico Quantil-Quantil dos resíduos



Não segue uma distribuição normal!

Modelos multiplicativos

E para um modelo multiplicativo?

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)
1	1	-1	-1	1	[1.93, 1.90, 2.17]	2.00
2	1	1	-1	-1	[-0.05, 0.02, 0.03]	0.00
3	1	-1	1	-1	[-0.02,-0.03, 0.05]	0.00
4	1	1	1	1	[-1.83, -1.90, -1.93]	-1.89
Soma	0.11	-3.89	-3.89	0.11		
Soma/4	0.03	-0.97	-0.97	0.03		

Modelos multiplicativos

E para um modelo multiplicativo?

Exp. (i)	I	A	B	AB	Respostas Mensuradas	Resposta Estimada y (média)
1	1	-1	-1	1	[1.93, 1.90, 2.17]	2.00
2	1	1	-1	-1	[-0.05, 0.02, 0.03]	0.00
3	1	-1	1	-1	[-0.02,-0.03, 0.05]	0.00
4	1	1	1	1	[-1.83, -1.90, -1.93]	-1.89
Soma	0.11	-3.89	-3.89	0.11		
Soma/4	0.03	-0.97	-0.97	0.03		

Amplitude nas respostas mensuradas diminuiu bastante!

Modelos multiplicativos

Comparando os dois modelos:

	Additive Model			Multiplicative Model		
Factor	Effect	Percentage of Variation	Confidence Interval	Effect	Percentage of Variation	Confidence Interval
I	26.55		(16.35, 36.74)	0.03		(−0.02, 0.07)[a]
A	−26.04	30.1	(−36.23, −15.84)	−0.97	49.9	(−1.02, −0.93)
B	−26.04	30.1	(−36.23, −15.84)	−0.97	49.9	(−1.02, −0.93)
AB	25.54	29.0	(15.35, 35.74)	0.03	0.0	(−0.02, 0.07)[a]
e		10.8			0.2	

Modelos multiplicativos

Comparando os dois modelos:

	Additive Model			Multiplicative Model		
Factor	Effect	Percentage of Variation	Confidence Interval	Effect	Percentage of Variation	Confidence Interval
I	26.55		(16.35, 36.74)	0.03		$(-0.02, 0.07)^a$
A	−26.04	30.1	(−36.23, −15.84)	−0.97	49.9	(−1.02, −0.93)
B	−26.04	30.1	(−36.23, −15.84)	−0.97	49.9	(−1.02, −0.93)
AB	25.54	29.0	(15.35, 35.74)	0.03	0.0	$(-0.02, 0.07)^a$
e		10.8			0.2	

A significância dos efeitos muda!

Modelos multiplicativos

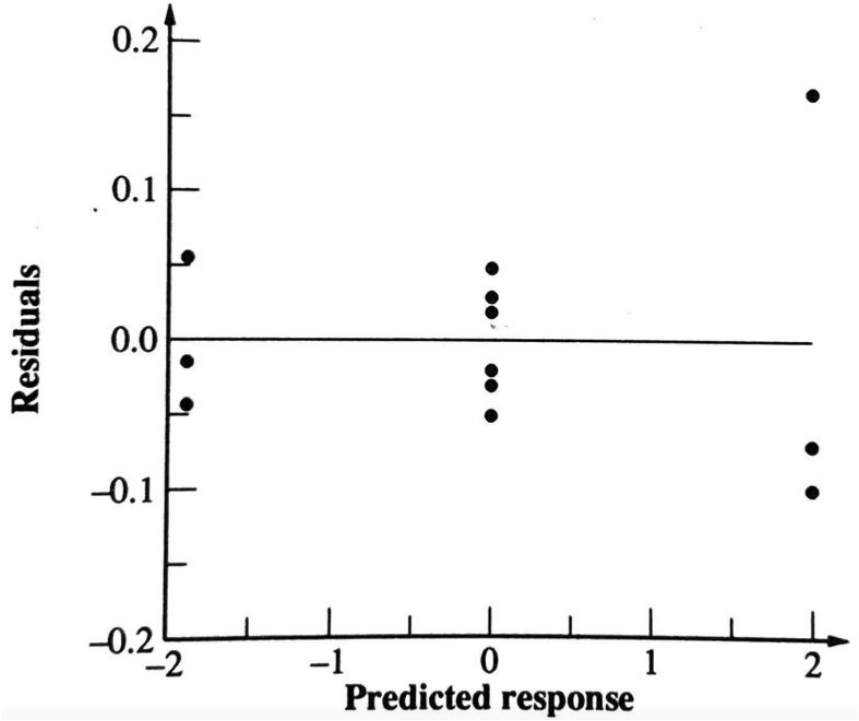
Comparando os dois modelos:

	Additive Model			Multiplicative Model		
Factor	Effect	Percentage of Variation	Confidence Interval	Effect	Percentage of Variation	Confidence Interval
I	26.55		(16.35, 36.74)	0.03		$(-0.02, 0.07)^a$
A	−26.04	30.1	(−36.23, −15.84)	−0.97	49.9	(−1.02, −0.93)
B	−26.04	30.1	(−36.23, −15.84)	−0.97	49.9	(−1.02, −0.93)
AB	25.54	29.0	(15.35, 35.74)	0.03	0.0	$(-0.02, 0.07)^a$
e		10.8			0.2	

A interação entre os fatores não é mais significativa!

Modelos multiplicativos

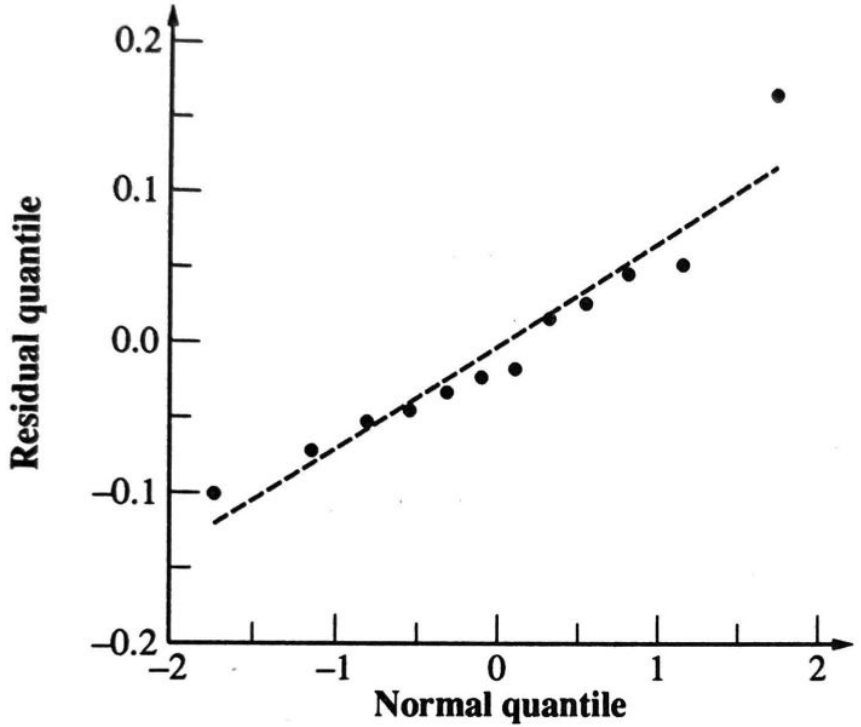
Gráfico de dispersão (Modelo multiplicativo): Resíduo x Valor Predito



Melhorou!

Modelos multiplicativos

Gráfico Quantil-Quantil dos resíduos (Modelo multiplicativo):



Bem mais próximo de uma normal!

Modelos multiplicativos

Modelo final:

$$\log(y) = q_0 + q_A x_A + q_B x_B + q_{AB} x_A x_B + e$$

$$\Rightarrow y = 10^{q_0} 10^{q_A x_A} 10^{q_B x_B} 10^{q_{AB} x_A x_B} 10^{e}$$

$$= 10^{0.03} 10^{-0.97 x_A} 10^{-0.97 x_B} 10^{0.03 x_A x_B} 10^{e}$$

$$= 1.07 \times 0.107^{x_A} \times 0.107^{x_B} \times 1.07^{x_A x_B} 10^{e}$$

Resumindo

Entender se o modelo é multiplicativo ou aditivo na maioria das vezes não é trivial

Visualize a relação entre a variável resposta e os fatores

- Se a relação parecer linear, o modelo aditivo pode ser suficiente
- Se houver curvas ou padrões exponenciais (não linear), o modelo multiplicativo pode ser mais apropriado

Confirme o ajuste: Compare os gráficos antes e depois da transformação para avaliar a melhoria no ajuste do modelo

Resumindo

1. **Modelo:**

$$y_{ij} = q_0 + q_A x_{Ai} + q_B x_{Bi} + q_{AB} x_A x_B i + \cdots + e_{ij}$$

2. **Estimação dos parâmetros:**

$$q_j = \frac{1}{2^k} \sum_{i=1}^{2^k} S_{ij} y_i; \quad S_{ij} = (i, j) \text{ entrada na tabela de sinais.}$$

3. **Soma dos quadrados:**

$$SSY = 2^k \sum_{j=1}^{r} \bar{y}_{ij}$$

$$SSO = 2^k \bar{r} q_0^2$$

$$SST = SSY - SSO$$

$$SS_j = 2^k q_j^2; \quad j = 1, 2, \ldots, 2^k - 1$$

$$SSE = SST - \sum_{j=1}^{2^k - 1} SS_j$$

Resumindo

4. Porcentagem de variação explicada pelo j-ésimo efeito:

$$\frac{SS_j}{SST} \times 100\%$$

5. Desvio padrão dos erros:

$$s_e = \sqrt{\frac{SSE}{2^k(r-1)}}$$

6. Desvio padrão dos efeitos:

$$s_{q_0} = s_q = s_A = s_B = s_{AB} = \frac{s_e}{\sqrt{2^k r}}$$

Resumindo

7. Variância de Contrastes e de Respostas Futuras:

$$\sum h_i q_i, \quad \text{onde} \sum h_i = 0 \text{ é} \frac{s_e^2 \sum h_i^2}{2^k r}$$

8. Desvio-padrão da média de *m* respostas futuras:

$$s\hat{y}_p = s_e \left(1 + \frac{2^k}{2^k r} + \frac{1}{m} \right)^{1/2}$$

9. Intervalos de confiança usando a tabela t:

$$t_{1-\alpha/2^{2^k(r-1)}}$$

Resumindo

10. Premissas do modelo:

- Erros são independentes e identicamente distribuídos com média zero
- Os erros possuem a mesma variância para todos os valores dos preditores
- Os efeitos dos preditores e dos erros são aditivos

11. Testes Visuais

- Gráfico de dispersão: Erros x respostas preditas não deve ter tendência
- O gráfico de quantis normais dos erros deve ser linear
- A dispersão dos valores de y em todos os experimentos deve ser comparável

Se qualquer teste falhar ou se a razão y_{max}/y_{min} for grande, deve-se investigar um modelo multiplicativo

Projetos Fatoriais Fracionários 2^{k-p}

Se o número de fatores é grande, o custo experimental é alto

- Exemplo: 2^7 requer 128 experimentos (sem replicações)

Projetos fracionários podem ser usados para analisar o impacto de *k* fatores (2 níveis) com um número menor 2^{k-r} de experimentos

- Exemplo: 2^{7-1} requer a metade dos experimentos (64), enquanto 2^{7-2} um quarto (32)

Porém não consegue isolar os efeitos de cada fator e de suas interações

Projetos Fatoriais Fracionários 2^{k-p}

Antes da teoria, considere o seguinte exemplo:

I	A	B	C	D	E	F	G	y
1	-1	-1	-1	1	1	1	-1	20
1	1	-1	-1	-1	-1	1	1	35
1	-1	1	-1	-1	1	-1	1	7
1	1	1	-1	1	-1	-1	-1	42
1	-1	-1	1	1	-1	-1	1	36
1	1	-1	1	-1	1	-1	-1	50
1	-1	1	1	-1	-1	1	-1	45
1	1	1	1	1	1	1	1	82

Projetos Fatoriais Fracionários 2^{k-p}

Antes da teoria, considere o seguinte exemplo:

I	A	B	C	D	E	F	G	y
1	-1	-1	-1	1	1	1	-1	20
1	1	-1	-1	-1	-1	1	1	35
1	-1	1	-1	-1	1	-1	1	7
1	1	1	-1	1	-1	-1	-1	42
1	-1	-1	1	1	-1	-1	1	36
1	1	-1	1	-1	1	-1	-1	50
1	-1	1	1	-1	-1	1	-1	45
1	1	1	1	1	1	1	1	82

7 fatores, que implicariam em $2^7 = 128$ experimentos

Projetos Fatoriais Fracionários 2^{k-p}

Antes da teoria, considere o seguinte exemplo:

I	A	B	C	D	E	F	G	y
1	-1	-1	-1	1	1	1	-1	20
1	1	-1	-1	-1	-1	1	1	35
1	-1	1	-1	-1	1	-1	1	7
1	1	1	-1	1	-1	-1	-1	42
1	-1	-1	1	1	-1	-1	1	36
1	1	-1	1	-1	1	-1	-1	50
1	-1	1	1	-1	-1	1	-1	45
1	1	1	1	1	1	1	1	82

Apenas 8 experimentos: 2^{7-4}

Projetos Fatoriais Fracionários 2^{k-p}

Antes da teoria, considere o seguinte exemplo:

I	A	B	C	D	E	F	G	y
1	-1	-1	-1	1	1	1	-1	20
1	1	-1	-1	-1	-1	1	1	35
1	-1	1	-1	-1	1	-1	1	7
1	1	1	-1	1	-1	-1	-1	42
1	-1	-1	1	1	-1	-1	1	36
1	1	-1	1	-1	1	-1	-1	50
1	-1	1	1	-1	-1	1	-1	45
1	1	1	1	1	1	1	1	82

Os níveis devem ser cuidadosamente escolhidos!

Projetos Fatoriais Fracionários 2^{k-p}

Colunas da tabela de experimentos precisam ser mutuamente exclusivas

- A soma dos níveis *i* de cada coluna *j* é zero:

$$\sum_i x_{i,j} = 0 \quad \forall j$$

- A soma dos produtos de quaisquer duas colunas *i* e *j* é zero

$$\sum_i x_{i,j} x_{i,l} = 0 \quad \forall j \neq l$$

- A soma dos quadrados de cada coluna *j* é 2^{k-p}

$$\sum_i x_{i,j}^2 = 2^{k-p}$$

Projetos Fatoriais Fracionários 2^{k-p}

A ortogonalidade permite calcular os efeitos e as suas contribuições para a variação dos valores de *y*

Considerando o exemplo anterior, tem-se o seguinte modelo:

$$y = q_0 + q_A x_A + q_B x_B + q_C x_C + q_D x_D + q_E x_E + q_F x_F + q_G x_G$$

O efeito para cada fator pode ser calculados como antes. Ex. para A:

$$q_A = \sum_i y_i x_{A_i} \qquad q_A = \frac{-y_1 + y_2 - y_3 + y_4 - y_5 + y_6 - y_7 + y_8}{8}$$

A mesma coisa para o desvio padrão, Intervalos de confiança, etc …

Projetos Fatoriais Fracionários 2^{k-p}

Para o exemplo anterior:

I	A	B	C	D	E	F	G	y
1	-1	-1	-1	1	1	1	-1	20
1	1	-1	-1	-1	-1	1	1	35
1	-1	1	-1	-1	1	-1	1	7
1	1	1	-1	1	-1	-1	-1	42
1	-1	-1	1	1	-1	-1	1	36
1	1	-1	1	-1	1	-1	-1	50
1	-1	1	1	-1	-1	1	-1	45
1	1	1	1	1	1	1	1	82
317	101	35	109	43	1	47	3	Total
39.62	12.62	4.37	13.62	5.37	0.125	5.87	0.37	Total/8

Projetos Fatoriais Fracionários 2^{k-p}

Para o exemplo anterior:

I	A	B	C	D	E	F	G	y
1	-1	-1	-1	1	1	1	-1	20
1	1	-1	-1	-1	-1	1	1	35
1	-1	1	-1	-1	1	-1	1	7
1	1	1	-1	1	-1	-1	-1	42
1	-1	-1	1	1	-1	-1	1	36
1	1	-1	1	-1	1	-1	-1	50
1	-1	1	1	-1	-1	1	-1	45
1	1	1	1	1	1	1	1	82
317	101	35	109	43	1	47	3	Total
39.62	12.62	4.37	13.62	5.37	0.125	5.87	0.37	Total/8

Fator A e C possuem os maiores efeitos: Refaça o experimento com foco neles!

Projetos Fatoriais Fracionários 2^{k-p}

Para o exemplo anterior:

I	A	B	C	D	E	F	G	y
1	-1	-1	-1	1	1	1	-1	20
1	1	-1	-1	-1	-1	1	1	35
1	-1	1	-1	-1	1	-1	1	7
1	1	1	-1	1	-1	-1	-1	42
1	-1	-1	1	1	-1	-1	1	36
1	1	-1	1	-1	1	-1	-1	50
1	-1	1	1	-1	-1	1	-1	45
1	1	1	1	1	1	1	1	82
317	101	35	109	43	1	47	3	Total
39.62	12.62	4.37	13.62	5.37	0.125	5.87	0.37	Total/8

Interações foram ignoradas porque são pequenas. No entanto, deve-se testar!

Preparando a tabela de sinais: Projetos 2^{k-p}

1. **Escolha *k-p* fatores e prepare uma tabela de sinais completa para o projeto fatorial completo com *k-p* fatores**
   a. Resulta em uma tabela com 2^{k-p} linhas e 2^{k-p} colunas
   b. A primeira coluna, marcada como I, contém somente 1's
   c. As próximas *k–p* colunas serão marcadas com os *k-p* fatores escolhidos. As colunas restantes são produtos desses fatores

2. **Das 2^{k-p}–(*k-p*)–1 colunas que restaram a direita da tabela:**
   a. Escolha *p* colunas e marque-as como os *p* fatores **que não foram escolhidos no passo 1**

Preparando a tabela de sinais: Projetos 2^{k-p}

Passo 1: Criação da tabela e escolha dos fatores: A, B e C

Expt N.	I	A	B	C	AB	AC	BC	ABC
1	1	-1	-1	-1	1	1	1	-1
2	1	1	-1	-1	-1	-1	1	1
3	1	-1	1	-1	-1	1	-1	1
4	1	1	1	-1	1	-1	-1	-1
5	1	-1	-1	1	1	-1	-1	1
6	1	1	-1	1	-1	1	-1	-1
7	1	-1	1	1	-1	-1	1	-1
8	1	1	1	1	1	1	1	1

Preparando a tabela de sinais: Projetos 2^{k-p}

Passo 2: Escolha das $2^{k-p}-(k-p)-1=8-(7-4)-1=4$ para os fatores faltantes

Expt N.	I	A	B	C	AB	AC	BC	ABC
1	1	-1	-1	-1	1	1	1	-1
2	1	1	-1	-1	-1	-1	1	1
3	1	-1	1	-1	-1	1	-1	1
4	1	1	1	-1	1	-1	-1	-1
5	1	-1	-1	1	1	-1	-1	1
6	1	1	-1	1	-1	1	-1	-1
7	1	-1	1	1	-1	-1	1	-1
8	1	1	1	1	1	1	1	1

Preparando a tabela de sinais: Projetos 2^{k-p}

Passo 2: Escolha das $2^{k-p}-(k-p)-1=8-(7-4)-1=4$

Expt N.	I	A	B	C	D	E	F	G
1	1	-1	-1	-1	1	1	1	-1
2	1	1	-1	-1	-1	-1	1	1
3	1	-1	1	-1	-1	1	-1	1
4	1	1	1	-1	1	-1	-1	-1
5	1	-1	-1	1	1	-1	-1	1
6	1	1	-1	1	-1	1	-1	-1
7	1	-1	1	1	-1	-1	1	-1
8	1	1	1	1	1	1	1	1

Preparando a tabela de sinais: Projetos 2^{k-p}

Outro exemplo: **Passo 1**

Expt N.	I	A	B	C	AB	AC	BC	ABC
1	1	-1	-1	-1	1	1	1	-1
2	1	1	-1	-1	-1	-1	1	1
3	1	-1	1	-1	-1	1	-1	1
4	1	1	1	-1	1	-1	-1	-1
5	1	-1	-1	1	1	-1	-1	1
6	1	1	-1	1	-1	1	-1	-1
7	1	-1	1	1	-1	-1	1	-1
8	1	1	1	1	1	1	1	1

Preparando a tabela de sinais: Projetos 2^{k-p}

Passo 2: Arbitrariamente, uma coluna foi escolhida para o fator D

Expt N.	I	A	B	C	AB	AC	BC	D
1	1	-1	-1	-1	1	1	1	-1
2	1	1	-1	-1	-1	-1	1	1
3	1	-1	1	-1	-1	1	-1	1
4	1	1	1	-1	1	-1	-1	-1
5	1	-1	-1	1	1	-1	-1	1
6	1	1	-1	1	-1	1	-1	-1
7	1	-1	1	1	-1	-1	1	-1
8	1	1	1	1	1	1	1	1

Preparando a tabela de sinais: Projetos 2^{k-p}

Resumo: Projeto que permite analisar 4 fatores e 3 interações

Expt N.	I	A	B	C	AB	AC	BC	D
1	1	-1	-1	-1	1	1	1	-1
2	1	1	-1	-1	-1	-1	1	1
3	1	-1	1	-1	-1	1	-1	1
4	1	1	1	-1	1	-1	-1	-1
5	1	-1	-1	1	1	-1	-1	1
6	1	1	-1	1	-1	1	-1	-1
7	1	-1	1	1	-1	-1	1	-1
8	1	1	1	1	1	1	1	1

Confounding

Um problema do fatorial fracionário é que alguns efeitos não podem ser determinados

Confounding: Apenas a influência combinada de dois ou mais efeitos pode ser computada

Considere o exemplo anterior

Confounding

Expt No.	I	A	B	C	AB	AC	BC	D
1	1	-1	-1	-1	1	1	1	-1
2	1	1	-1	-1	-1	-1	1	1
3	1	-1	1	-1	-1	1	-1	1
4	1	1	1	-1	1	-1	-1	-1
5	1	-1	-1	1	1	-1	-1	1
6	1	1	-1	1	-1	1	-1	-1
7	1	-1	1	1	-1	-1	1	-1
8	1	1	1	1	1	1	1	1

$$q_D = \sum_i y_i x_{D_i} = \frac{-y_1 + y_2 + y_3 - y_4 + y_5 - y_6 - y_7 + y_8}{8}$$

Confounding

Expt No.	I	A	B	C	AB	AC	BC	ABC
1	1	-1	-1	-1	1	1	1	-1
2	1	1	-1	-1	-1	-1	1	1
3	1	-1	1	-1	-1	1	-1	1
4	1	1	1	-1	1	-1	-1	-1
5	1	-1	-1	1	1	-1	-1	1
6	1	1	-1	1	-1	1	-1	-1
7	1	-1	1	1	-1	-1	1	-1
8	1	1	1	1	1	1	1	1

$$q_{ABC} = \sum_i y_i x_{D_i} = \frac{-y_1 + y_2 + y_3 - y_4 + y_5 - y_6 - y_7 + y_8}{8}$$

Confounding

Expt N.	I	A	B	C	AB	AC	BC	ABC + D
1	1	-1	-1	-1	1	1	1	-1
2	1	1	-1	-1	-1	-1	1	1
3	1	-1	1	-1	-1	1	-1	1
4	1	1	1	-1	1	-1	-1	-1
5	1	-1	-1	1	1	-1	-1	1
6	1	1	-1	1	-1	1	-1	-1
7	1	-1	1	1	-1	-1	1	-1
8	1	1	1	1	1	1	1	1

$$q_D + q_{ABC} = \sum_i y_i x_{A_i} x_{B_i} x_{C_i} = \frac{-y_1 + y_2 + y_3 - y_4 + y_5 - y_6 - y_7 + y_8}{8}$$

Sem o fatorial completo, não é possível separar os efeitos!

Confounding

Expt No.	I	A	B	C	AB	AC	BC	ABC + D
1	1	-1	-1	-1	1	1	1	-1
2	1	1	-1	-1	-1	-1	1	1
3	1	-1	1	-1	-1	1	-1	1
4	1	1	1	-1	1	-1	-1	-1
5	1	-1	-1	1	1	-1	-1	1
6	1	1	-1	1	-1	1	-1	-1
7	1	-1	1	1	-1	-1	1	-1
8	1	1	1	1	1	1	1	1

$$q_D + q_{ABC} = \sum_i y_i x_{A_i} x_{B_i} x_{C_i} = \frac{-y_1 + y_2 + y_3 - y_4 + y_5 - y_6 - y_7 + y_8}{8}$$

Logo, ABC e D são ditos efeitos ***cofounded!***

Confounding

Se o efeito de *ABC* for pequeno comparado ao efeito *D*, isso não é um problema

- Neste caso, a expressão do efeito anterior representa melhor *D*

Representação do *confounding*: *ABC=D*

Outros *confoundings* no exemplo anterior:

$$A = BCD \qquad AB = CD \qquad ABC = D$$
$$B = ACD \qquad AC = BD \qquad I = ABCD$$
$$C = ABD \qquad BC = AD$$

Confounding

Expt N.	I	A	B	C	D	AC	BC	ABC
1	1	-1	-1	-1	1	1	1	-1
2	1	1	-1	-1	-1	-1	1	1
3	1	-1	1	-1	-1	1	-1	1
4	1	1	1	-1	1	-1	-1	-1
5	1	-1	-1	1	1	-1	-1	1
6	1	1	-1	1	-1	1	-1	-1
7	1	-1	1	1	-1	-1	1	-1
8	1	1	1	1	1	1	1	1

Um projeto 2^{4-1} alternativo

Confounding

Confoundings do projeto alternativo:

$$I = ABD \qquad D = AB$$
$$A = BD \qquad AC = BCD$$
$$B = AD \qquad BC = ACD$$
$$C = ABCD \qquad ABC = CD$$

Esse projeto não é tão bom quanto o outro

- No outro projeto, a média (*I*) foi misturado com as interações de quarta ordem
- Neste aqui, interações de 2ª (ex., AC, BC e CD) se misturam com as de 3ª ordem (BCD, ACD e ABC)

Algebra de *confounding*

Os projetos exemplificados anteriormente são chamados de *I=ABCD* e *I=ABD*

Eles recebem esses nomes em função de ser o **polinômio gerador**

É possível obter todos os outros *confoundings* multiplicando os dois lados do polinômio gerador por termos diferentes usando as seguintes regras:

- A média *(I)* é tratada como unidade. Ex: $IA = A$
- Qualquer termo elevado a potência de 2 é apagado. Ex: $AB^2C = AC$

Algebra de *confounding*

Alguns exemplos de *confoundings* para o projeto *I=ABCD*:

- $AI = A^2BCD \Rightarrow A = BCD$
- $BI = AB^2CD \Rightarrow B = ACD$

Algebra de *confounding*

Alguns exemplos de *confoundings* para o projeto *I=ABCD*:

- $AI = A^2BCD \Rightarrow A = BCD$
- $BI = AB^2CD \Rightarrow B = ACD$

$$
\begin{array}{lll}
A = BCD & AB = CD & ABC = D \\
B = ACD & AC = BD & I = ABCD \\
C = ABD & BC = AD &
\end{array}
$$

Em um projeto 2^{k-p}, 2^p efeitos são *confounded* e, por definição, o polinômio gerador tem 2^p termos

- Veja a derivação no livro

Exemplo

Considere o seguinte projeto:

- Fatores: A, B, C, D e E, cada um com dois níveis

Assuma um projeto de experimentos fracionário 2^{5-1} com gerador I = ABCDE

Três variáveis de resposta: V1, V2 e V3

Exemplo

Exp.	A	B	C	D	E	V1	V2	V3
1	-1	-1	-1	-1	1	15	25	15,2
2	1	-1	-1	-1	-1	11	41	3
3	-1	1	-1	-1	-1	25	36	21
4	1	1	-1	-1	1	10	15,7	8,6
5	-1	-1	1	-1	-1	14	63,9	7,5
6	1	-1	1	-1	1	10	13,2	7,5
7	-1	1	1	1	1	28	36,3	20,2
8	1	1	1	1	-1	11	23	3
9	-1	-1	-1	-1	-1	14	66,1	6,4
10	1	-1	-1	-1	1	10	9,1	8,4
11	-1	1	-1	-1	1	27	34,6	15,7
12	1	1	-1	-1	-1	11	23	3
13	-1	-1	1	1	1	14	26	12
14	1	-1	1	1	-1	11	38	2
15	-1	1	1	1	-1	25	35	17,2
16	1	1	1	1	1	11	22	2

Exemplo

Confounded Effects 1	Confounded Effects 2	V1 Estim.	V1 %var
I	ABCDE	15,44	31,74
A	BCDE	**-4,81**	**55,5**
B	ACDE	**3,06**	**22,5**
C	ABDE	0,06	0
D	ABCE	-0,06	0
AB	CDE	**-2,94**	**20,7**
AC	BDE	0,06	0
AD	BCE	0,19	0,1
BC	ADE	0,19	0,1
BD	ACE	0,06	0
CD	ABE	-0,19	0,1
DE	ABC	-0,06	0
CE	ABD	0,06	0
BE	ACD	0,31	0,2
AE	BCD	-0,56	0,8
E	ABCD	0,19	0,1

Exemplo

Confounded Effects 1	Confounded Effects 2	V1 Estim.	V1 %var	V2 Estim.	V2 %var
I	ABCDE	15,44	31,74	31,74	9,54
A	BCDE	**-4,81**	**55,5**	**-8,62**	**31**
B	ACDE	**3,06**	**22,5**	**-3,54**	**5,2**
C	ABDE	0,06	0	0,43	0,1
D	ABCE	-0,06	0	-0,02	0
AB	CDE	**-2,94**	**20,7**	1,34	0,8
AC	BDE	0,06	0	0,49	0,1
AD	BCE	0,19	0,1	-0,08	0,1
BC	ADE	0,19	0,1	0,44	0,1
BD	ACE	0,06	0	0,47	0,1
CD	ABE	-0,19	0,1	-1,91	1,5
DE	ABC	-0,06	0	0,21	0,1
CE	ABD	0,06	0	1,21	0,6
BE	ACD	0,31	0,2	**7,96**	**26,4**
AE	BCD	-0,56	0,8	0,88	3
E	ABCD	0,19	0,1	**-9,01**	**33,8**

Exemplo

Confounded Effects 1	Confounded Effects 2	V1 Estim.	V1 %var	V2 Estim.	V2 %var	V3 Estim.	V3 %var
I	ABCDE	15,44	31,74	31,74	9,54	9,54	15,44
A	BCDE	**-4,81**	**55,5**	**-8,62**	**31**	**-4,86**	**58,8**
B	ACDE	**3,06**	**22,5**	**-3,54**	**5,2**	**1,79**	**8**
C	ABDE	0,06	0	0,43	0,1	-0,62	1
D	ABCE	-0,06	0	-0,02	0	-1,21	3,6
AB	CDE	**-2,94**	**20,7**	1,34	0,8	**-2,33**	**13,5**
AC	BDE	0,06	0	0,49	0,1	-0,44	0,5
AD	BCE	0,19	0,1	-0,08	0,1	0,37	0,3
BC	ADE	0,19	0,1	0,44	0,1	-0,12	0
BD	ACE	0,06	0	0,47	0,1	-0,66	1,1
CD	ABE	-0,19	0,1	-1,91	1,5	0,58	0,5
DE	ABC	-0,06	0	0,21	0,1	-0,47	0,5
CE	ABD	0,06	0	1,21	0,6	-0,16	0,1
BE	ACD	0,31	0,2	**7,96**	**26,4**	-1,37	4,7
AE	BCD	-0,56	0,8	0,88	3	0,28	0,2
E	ABCD	0,19	0,1	**-9,01**	**33,8**	**1,66**	**6,8**

Exemplo

Os valores ideais para os parâmetros são diferentes para as três variáveis respostas

Observando os percentuais de variação explicadas, nota-se que os fatores com maior impacto são:

- Variável V1: A, B e AB
- Variável V2: A, B, E e EB
- Variável V3: A, B, E e AB

Erros comuns em experimentação

1. Ignorar a variação por erro experimental

A variação por **erro experimental** refere-se às flutuações naturais que ocorrem nos resultados de um experimento

- Mesmo quando as condições (fatores/níveis) são mantidas constantes

Surgem a partir de fatores aleatórios, como a divisão dos dados, variações no *hardware* ou *software*, ou outros fatores não controláveis

É importante repetir o experimento várias vezes e calcular a variação

Erros comuns em experimentação

1. Ignorar a variação por erro experimental (Cont.)

Exemplo: Você treina o mesmo classificador (ex.: SVM) com o mesmo conjunto de dados e diferentes divisões de dados:

- 1º execução: Acurácia de 85%
- 2º execução: Acurácia de 84%
- 3º execução: Acurácia de 80%

Essas pequenas diferenças são devidas ao erro experimental

- Ignorar a variação pode levar a falsas conclusões, confundindo flutuações normais com fatores importantes

Erros comuns em experimentação

2. Ignorar a variação por erro experimental

Parâmetros não controlados podem causar variação e levar a conclusões erradas

Controlá-los é crucial para garantir que os resultados sejam atribuídos corretamente aos fatores estudados e não a fatores externos

Erros comuns em experimentação

2. Ignorar a variação por erro experimental

Exemplo: Você está comparando diferentes algoritmos de classificação (ex.: SVM, redes neurais, árvores de decisão)

- Mas não controla adequadamente a distribuição dos dados (ex.: balanceamento entre as classes "spam" e "não spam")

As diferenças na acurácia podem ser causadas pela distribuição desequilibrada dos dados, e não pelo classificador em si

Isso pode distorcer os resultados, levando a uma interpretação incorreta sobre qual classificador é melhor

Erros comuns em experimentação

3. Efeitos de diferentes fatores não são isolados

Múltiplos fatores são alterados simultaneamente, pode tornar difícil atribuir as mudanças observadas no desempenho a um fator específico

Ocorre porque os efeitos de diferentes fatores estão "misturados", tornando impossível identificar qual fator causou a mudança

Erros comuns em experimentação

3. Efeitos de diferentes fatores não são isolados

Exemplo: Você decide variar simultaneamente o algoritmo de classificação (SVM, árvore de decisão) e a quantidade de dados (10k e 100k amostras)

- Se a acurácia melhorar, não será claro se isso ocorreu devido ao classificador ou à quantidade de dados

Sem isolar os fatores, fica difícil entender a contribuição de cada um no desempenho do modelo

Erros comuns em experimentação

4. Uso de projeto simples de um fator por vez

Alterar apenas um fator por vez em um experimento pode levar ao uso ineficiente dos recursos

- E exigir mais experimentos para obter as mesmas informações

Projetos experimentais mais avançados permitem avaliar múltiplos fatores simultaneamente de forma mais eficiente

Erros comuns em experimentação

4. Uso de projeto simples de um fator por vez

Exemplo: Testar individualmente cada classificador (SVM, redes neurais, árvores de decisão) com diferentes tamanhos de dados (10k, 50k, 100k exemplos) exige muitos experimentos

Em vez de realizar experimentos para cada combinação de fatores individualmente, seria mais eficiente usar um projeto diferente

- Pode-se combinar diferentes fatores e níveis de uma só vez, reduzindo o número total de experimentos

Erros comuns em experimentação

5. Ignorar interações entre fatores

A interação entre fatores ocorre quando o efeito de um fator depende do nível de outro fator

Ignorar essas interações pode levar a uma compreensão incompleta ou incorreta dos resultados experimentais

Erros comuns em experimentação

5. Ignorar interações entre fatores

Exemplo: O impacto de aumentar a quantidade de dados (10k, 50k, 100k exemplos) pode depender do classificador usado

- Um classificador mais simples, como a regressão logística, pode se beneficiar significativamente de mais dados
- Enquanto uma rede neural pode já estar saturada em termos de desempenho com menos dados

Se você ignorar a interação entre o algoritmo e a quantidade de dados, pode perder essas nuances importantes

Erros comuns em experimentação

6. Realização de muitos experimentos

Realizar um número excessivo de experimentos com muitos fatores e níveis pode ser ineficiente e difícil de interpretar

É melhor dividir o projeto em etapas, começando com poucos fatores e níveis, para depurar o processo e identificar fatores irrelevantes

Erros comuns em experimentação

6. Realização de muitos experimentos

Exemplo: Você decide testar:

- 5 algoritmos de classificação (SVM, redes neurais, KNN, etc.)
- 3 quantidades de dados (10k, 50k, 100k exemplos)
- 4 tipos de pré-processamento (normalização, padronização, sem pré-processamento, etc)
- 3 métodos de validação (holdout, k-fold, leave-one-out)

Isso resultaria em 5*3*4*3 = 180 experimentos (sem replicação)

Comece com menos fatores e níveis, identifique os mais importantes, e só então expanda o estudo com base nos resultados iniciais

Dúvidas?

Créditos

Este material é baseado nos livros textos da disciplina em questão e foi desenvolvido pelo professor Carlos Henrique Gomes Ferreira. Além disso, ele está licenciado sob uma **Licença Creative Commons Atribuição 4.0 Internacional (CC BY 4.0)**. Versão 1.0. 09/2024.