# Impacto do uso passivo vs. ativo de IA generativa no $\Delta$GPA: Experimento fatorial $2^3r$ com bootstrap estratificado

Relatório da Entrega 2 – Resultados preliminares

Wagner Tironi Pinto

Orientador: Prof. Dr. Carlos H. G. Ferreira

PCC170 – Projeto e Análise de Experimentos Computacionais

**Resumo**

Este relatório apresenta a Entrega 2 do projeto de PCC170. Avalia-se se o modo de uso de IA generativa (*passivo*: gerar texto/resposta pronta; *ativo*: idear, resumir, depurar) afeta a variação de desempenho acadêmico ($\Delta$GPA = GPA pós − GPA pré), em interação com a ansiedade em exames e as horas de estudo. O recorte é único (STEM + *Junior*, $n = 3.279$) e os níveis dos fatores são definidos pela mediana ($Q_2$): *baixo* $\leq Q_2$ e *alto* $> Q_2$, o que aproveita todos os alunos do recorte (menor célula com 181 alunos). Utiliza-se um projeto fatorial $2^3$ com $r = 30$ réplicas obtidas por bootstrap estratificado (semente 42, $m = 36$ alunos por célula), e um segundo ciclo de bootstrap (5.000 reamostras) para intervalos de confiança dos efeitos. O efeito das horas de estudo é dominante (+0,121; 61,7% da variância); o uso passivo reduz o $\Delta$GPA em 0,077 (IC95% [−0,092; −0,062]) e interage negativamente com a ansiedade (−0,023). A regra por quartis extremos ($< Q_1/\geq Q_3$) é mantida como análise de sensibilidade e leva às mesmas conclusões qualitativas. Os resultados são preliminares e observacionais, e as limitações são discutidas.

## Sumário

**1 Introdução** **3**

**2 Análise Exploratória dos Dados** **3**

2.1 Base de dados . . . . . 3

2.2 Recorte e estatísticas descritivas . . . . . 3

2.3 Definição dos níveis pela mediana . . . . . 4

2.4 Distribuição acumulada (CDF) . . . . . 4

2.5 Resposta bruta por célula . . . . . 6

**3 Materiais e Métodos** **6**

3.1 Ambiente . . . . . 6

3.2 Unidade experimental, fatores, níveis e resposta . . . . . 7

3.3 Quadro das combinações de teste . . . . . 7

3.4 Modelo principal: ANOVA $2^3$ sobre os dados brutos . . . . . 8

3.5 Efeitos e intervalos de confiança (bootstrap estratificado) . . . . . 9

3.6 Réplicas bootstrap: papel apenas ilustrativo . . . . . 9

3.7 Critérios de validação e decisão . . . . . 9

**4 Resultados Experimentais** **9**

4.1 Visão geral das respostas (cubo) . . . . . 9

4.2 ANOVA do fatorial $2^3$ sobre os dados brutos (HC3) . . . . . 10

4.3 Efeitos e intervalos de confiança . . . . . 11

4.4 Diagnóstico dos resíduos e heterocedasticidade . . . . . 14

**5 Caracterização e Análises Finais** **14**

**6 Discussão** **15**

**7 Conclusões e Trabalhos Futuros** **16**

**A Análise de Sensibilidade e Réplicas Ilustrativas** **16**

A.1 Normalização das médias pelo bootstrap (ilustrativo) . . . . . 16

A.2 ANOVA sobre as réplicas bootstrap (descritiva) . . . . . 18

A.3 Diagnóstico dos resíduos das réplicas . . . . . 18

A.4 Estabilidade entre sementes . . . . . 19

A.5 Sensibilidade à definição dos níveis, ANCOVA e regressão contínua . . . . 19

A.6 Balanceamento, permutação e teto de GPA . . . . . 20

**B Reprodutibilidade** **22**

# 1 Introdução

**Contexto.** A adoção de IA generativa por estudantes universitários cresceu rapidamente, mas há dúvida sobre se seus benefícios dependem da *forma* de uso. Usos que substituem o esforço cognitivo (obter respostas prontas, redigir textos) tendem a ser distintos de usos que o ampliam (gerar ideias, resumir leituras, depurar código).

**Motivação e problema.** Na Entrega 1 foi estimado, por *propensity score matching*, um efeito médio do uso passivo de ATE = $-0{,}072$ (IC95% $[-0{,}092; -0{,}053]$). Após orientação do professor, o problema foi reformulado: (i) adotar um único recorte (STEM + *Junior*) para evitar viés de composição; (ii) usar bootstrap e um projeto fatorial para normalizar os dados e quantificar efeitos e interações.

**Objetivo.** Quantificar o efeito do modo de uso da IA (A), da ansiedade em exames (B) e das horas de estudo tradicionais (C), e suas interações, sobre o $\Delta$GPA.

**Hipótese geral (definida antes do experimento).** $H_0$: nenhum dos efeitos principais ou de interação sobre o $\Delta$GPA é diferente de zero. $H_1$: o uso passivo reduz o $\Delta$GPA em relação ao uso ativo, e esse efeito depende (interage) do nível de ansiedade e/ou das horas de estudo.

# 2 Análise Exploratória dos Dados

Esta seção apenas caracteriza os dados; a avaliação da hipótese ocorre nas seções seguintes.

## 2.1 Base de dados

A base `ai_student_impact_dataset.csv` possui 50.000 registros e 16 variáveis, sem valores nulos. Trata-se de dados tabulares (não simulados pelo autor) cuja origem exata (provavelmente um conjunto público sintético do Kaggle) deve ser citada na versão final. Variáveis usadas: `Primary_Use_Case`, `Anxiety_Level_During_Exams` (1–10), `Traditional_Study_Hours`, `Pre_Semester_GPA`, `Post_Semester_GPA`, `Major_Category` e `Year_of_Study`. A resposta é $\Delta\text{GPA} = \text{GPA}_{pós} - \text{GPA}_{pré}$.

## 2.2 Recorte e estatísticas descritivas

O recorte STEM + *Junior* contém $n = 3.279$ alunos (813 passivos e 2.466 ativos).

**Tabela 1:** Estatísticas descritivas (base completa e recorte STEM + *Junior*).

| Variável | Base completa | | STEM + Junior | |
|---|---|---|---|---|
| | Média | DP | Média | DP |
| $\Delta$GPA | 0,20 | 0,19 | 0,24 | 0,19 |
| Ansiedade (1–10) | 4,27 | 2,14 | 4,42 | 2,23 |
| Horas de estudo | 11,21 | 5,16 | 11,04 | 5,29 |

## 2.3 Definição dos níveis pela mediana

No recorte, as medianas ($Q_2$) são: ansiedade $Q_2 = 4$ e horas de estudo $Q_2 = 10{,}91$. Nível *baixo* $\leq Q_2$ e nível *alto* $> Q_2$. Todos os 3.279 alunos entram no experimento (nenhuma faixa é descartada). Como a ansiedade é discreta, 53,4% dos alunos têm ansiedade $\leq Q_2$ (horas: 50,0%). A regra anterior ($< Q_1$ baixo, $\geq Q_3$ alto, com $Q_1 = 3$, $Q_3 = 6$ para ansiedade e $Q_1 = 7{,}33$, $Q_3 = 14{,}475$ para horas) descartava 74% do recorte e fica como análise de sensibilidade. As Figuras 1 e 2 mostram as distribuições, os pontos de corte e o tamanho das células.

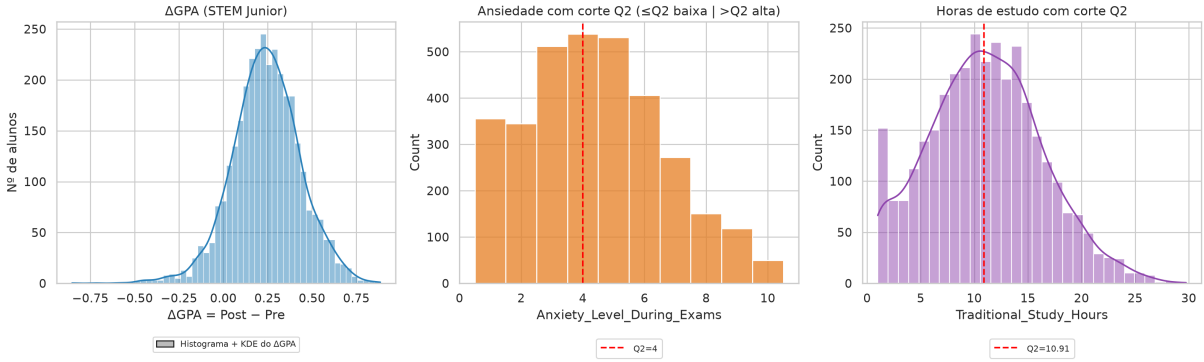



**Figura 1:** Distribuições de ansiedade, horas de estudo e ΔGPA com o corte pela mediana ($Q_2$).

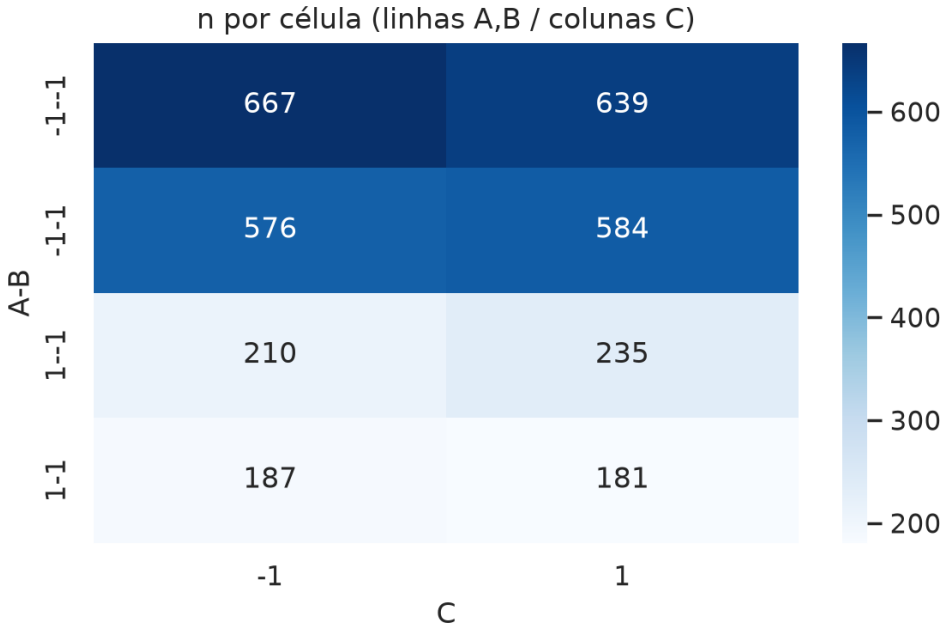



**Figura 2:** Número de alunos por célula do fatorial. A menor célula tem $n = 181$ (passivo, ansiedade alta, muito estudo).

## 2.4 Distribuição acumulada (CDF)

As CDFs empíricas permitem comparar os grupos sem depender de agrupamento (*bins*). A Figura 3 mostra que a curva do ΔGPA de usuários passivos está deslocada à esquerda,

e que a curva de horas altas está deslocada à direita (maior ΔGPA). A Figura 4 compara as oito células e o recorte completo com o subconjunto de extremos $Q_1/Q_3$ (analíse de sensibilidade). A Figura 5 mostra as variáveis contínuas com o corte $Q_2$ (e $Q_1$, $Q_3$ como referência).

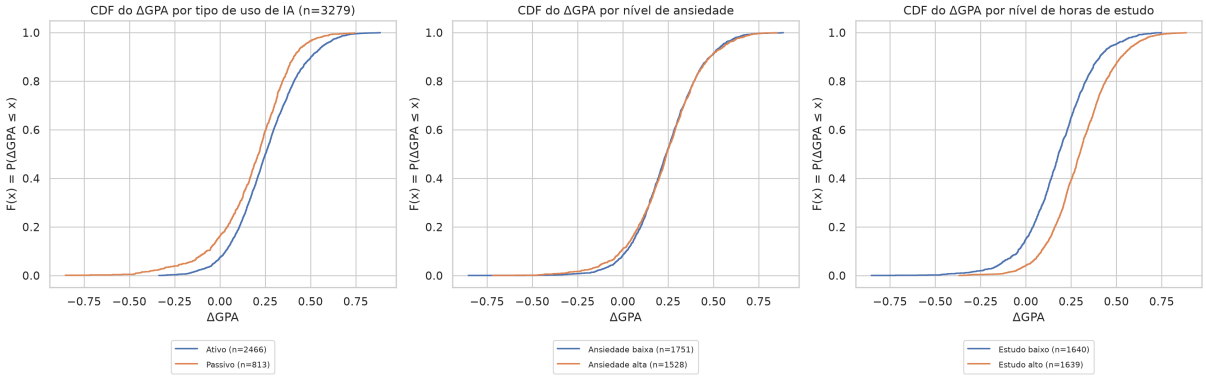



**Figura 3:** CDF do ΔGPA segundo cada fator (A, B e C).

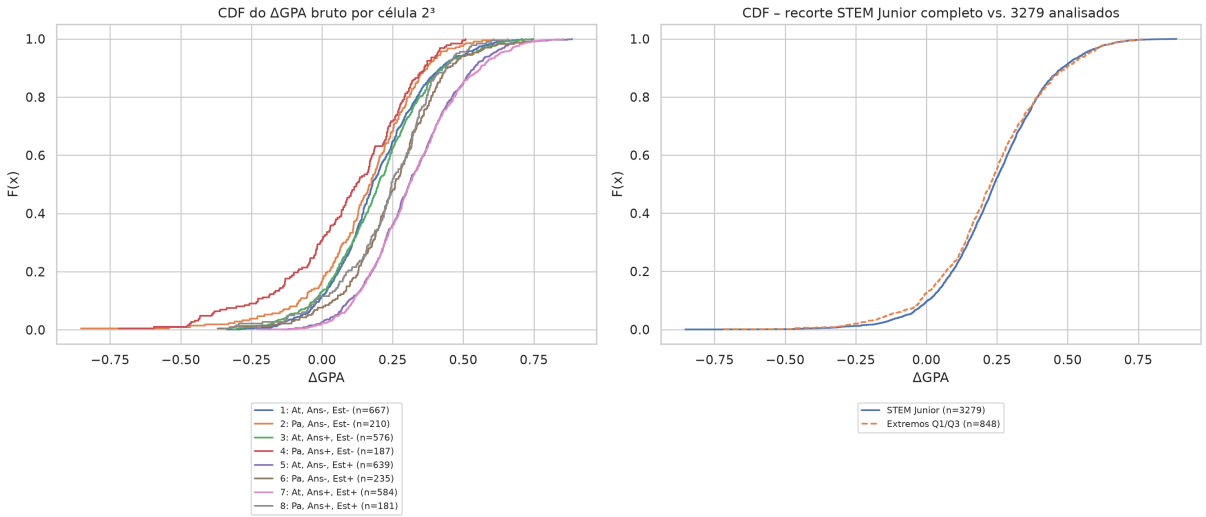



**Figura 4:** CDF do ΔGPA por célula e comparação do recorte analisado (n=3.279) com o subconjunto de extremos $Q_1/Q_3$.

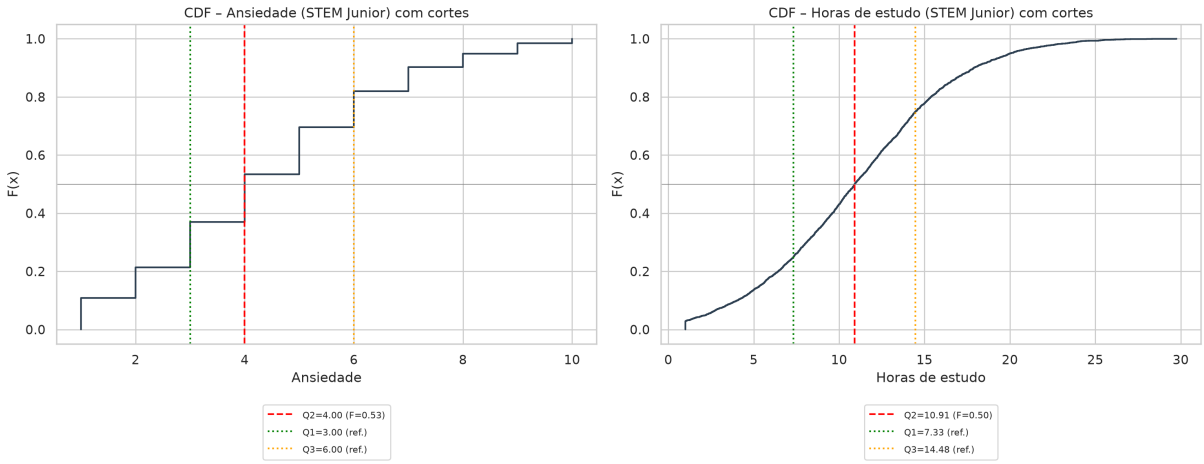



**Figura 5:** CDF de ansiedade e horas de estudo com marcação de $Q_2$ (corte) e de $Q_1$, $Q_3$ (referência).

## 2.5 Resposta bruta por célula

A Figura 6 exibe o ΔGPA bruto por célula. As células passivas têm assimetria negativa (de −0,72 a −1,13; Shapiro–Wilk $p < 0{,}001$ nas células 2, 4 e 8), em parte pelo teto de GPA 4,0, o que motiva a normalização via bootstrap. As células passivas também têm maior dispersão (DP até 0,236 contra cerca de 0,17). O balanceamento da covariável `Pre_Semester_GPA` entre as células é adequado (ANOVA, $p = 0{,}89$).

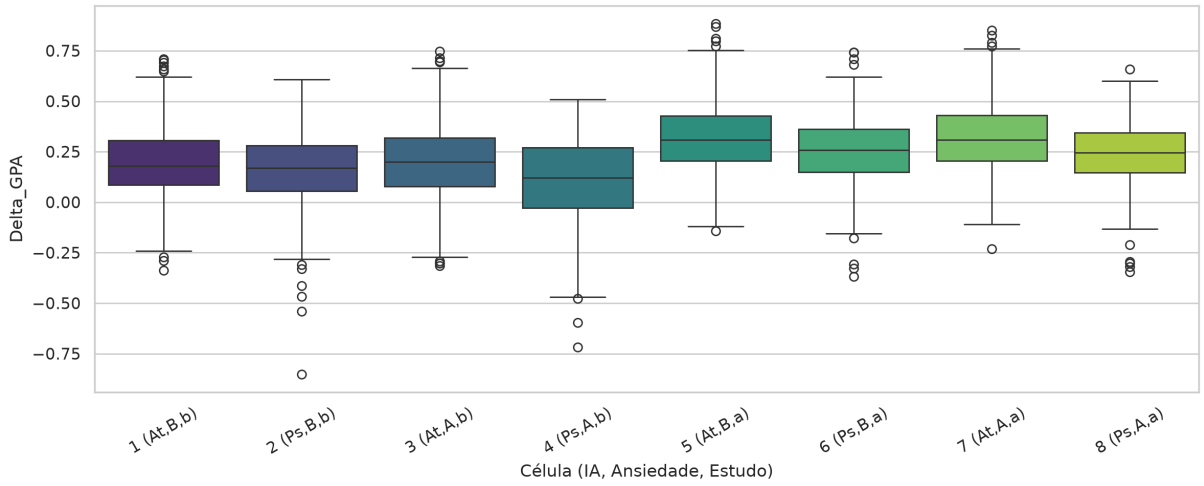



**Figura 6:** ΔGPA bruto por célula experimental.

# 3 Materiais e Métodos

## 3.1 Ambiente

Python 3.12.3, NumPy 2.5.4, pandas 3.1.0, SciPy 1.18.1, statsmodels 1.18.1, Matplotlib 3.11.2 e seaborn 0.15.0. O código (`pcc170_entrega02.py`) e o notebook executado

(`.ipynb`) acompanham o relatório. Sementes: 42 (principal) e outras nove para checar estabilidade.

## 3.2 Unidade experimental, fatores, níveis e resposta

**Unidade experimental:** aluno de STEM no 3.º ano (*Junior*). **Resposta:** ΔGPA. **Condições controladas:** área (STEM) e ano de estudo fixos; `Pre_GPA` verificado como balanceado. Os fatores B e C são dicotomizados pela mediana; essa escolha é comparada com a regra por quartis extremos e com um modelo contínuo na análise de sensibilidade.

**Tabela 2:** Fatores e níveis.

| Fator | Nome | Nível −1 | Nível +1 |
|---|---|---|---|
| A | Modo de uso da IA | Ativo (Ideation, Summarizing, Debugging) | Passivo (Copywriting/Drafting, Direct Answer) |
| B | Ansiedade em exames | Baixa ($\leq 4$) | Alta ($> 4$) |
| C | Horas de estudo | Baixas ($\leq 10{,}91$) | Altas ($> 10{,}91$) |

## 3.3 Quadro das combinações de teste

Os 8 ensaios seguem a ordem de Yates (A varia mais rápido). A Tabela 3 apresenta as combinações, os tamanhos de célula e as estatísticas da resposta; a Tabela 4 traz a matriz de sinais com colunas A, B, C, AB, AC, BC e ABC (produto dos sinais), usada para calcular os efeitos. A Figura 7 reproduz ambos os quadros.

**Tabela 3:** Combinações de teste (ordem de Yates).

| Ensaio | A | B | C | $n$ | Média ΔGPA | DP |
|---|---|---|---|---|---|---|
| (1) | − | − | − | 667 | 0,196 | 0,172 |
| a | + | − | − | 210 | 0,152 | 0,198 |
| b | − | + | − | 576 | 0,201 | 0,184 |
| ab | + | + | − | 187 | 0,091 | 0,236 |
| c | − | − | + | 639 | 0,317 | 0,170 |
| ac | + | − | + | 235 | 0,252 | 0,176 |
| bc | − | + | + | 584 | 0,323 | 0,173 |
| abc | + | + | + | 181 | 0,233 | 0,179 |

**Tabela 4:** Matriz de sinais dos efeitos.

| Ensaio | A | B | C | AB | AC | BC | ABC |
|---|---|---|---|---|---|---|---|
| (1) | − | − | − | + | + | + | − |
| a | + | − | − | − | − | + | + |
| b | − | + | − | − | + | − | + |
| ab | + | + | − | + | − | − | − |
| c | − | − | + | + | − | − | + |
| ac | + | − | + | − | + | − | − |
| bc | − | + | + | − | − | + | − |
| abc | + | + | + | + | + | + | + |

**Quadro das combinações de teste (8 tratamentos × r = 30 réplicas)**

| Ensaio | Yates | A (IA) | B (Ansiedade) | C (Estudo) | n alunos | ΔGPA médio | DP | Réplicas (r) | m por réplica | Observações |
|---|---|---|---|---|---|---|---|---|---|---|
| 1 | (1) | -1 Ativo | -1 Baixa (≤Q2) | -1 Baixas (≤Q2) | 667 | 0.196 | 0.172 | 30 | 36 | 30 |
| 2 | a | +1 Passivo | -1 Baixa (≤Q2) | -1 Baixas (≤Q2) | 210 | 0.152 | 0.198 | 30 | 36 | 30 |
| 3 | b | -1 Ativo | +1 Alta (>Q2) | -1 Baixas (≤Q2) | 576 | 0.201 | 0.184 | 30 | 36 | 30 |
| 4 | ab | +1 Passivo | +1 Alta (>Q2) | -1 Baixas (≤Q2) | 187 | 0.091 | 0.236 | 30 | 36 | 30 |
| 5 | c | -1 Ativo | -1 Baixa (≤Q2) | +1 Altas (>Q2) | 639 | 0.317 | 0.17 | 30 | 36 | 30 |
| 6 | ac | +1 Passivo | -1 Baixa (≤Q2) | +1 Altas (>Q2) | 235 | 0.252 | 0.176 | 30 | 36 | 30 |
| 7 | bc | -1 Ativo | +1 Alta (>Q2) | +1 Altas (>Q2) | 584 | 0.323 | 0.173 | 30 | 36 | 30 |
| 8 | abc | +1 Passivo | +1 Alta (>Q2) | +1 Altas (>Q2) | 181 | 0.233 | 0.179 | 30 | 36 | 30 |

Nível +1 (alto/passivo) Nível −1 (baixo/ativo)

**Figura 7:** Quadro das combinações de teste.

**Matriz de sinais dos contrastes (efeito = Σ sinal·Y / 4)**

| Ensaio | Yates | I | A | B | C | AB | AC | BC | ABC | Y_média_obs |
|---|---|---|---|---|---|---|---|---|---|---|
| 1 | (1) | 1 | -1 | -1 | -1 | 1 | 1 | 1 | -1 | 0.196 |
| 2 | a | 1 | 1 | -1 | -1 | -1 | -1 | 1 | 1 | 0.152 |
| 3 | b | 1 | -1 | 1 | -1 | -1 | 1 | -1 | 1 | 0.201 |
| 4 | ab | 1 | 1 | 1 | -1 | 1 | -1 | -1 | -1 | 0.091 |
| 5 | c | 1 | -1 | -1 | 1 | 1 | -1 | -1 | 1 | 0.317 |
| 6 | ac | 1 | 1 | -1 | 1 | -1 | 1 | -1 | -1 | 0.252 |
| 7 | bc | 1 | -1 | 1 | 1 | -1 | -1 | 1 | -1 | 0.323 |
| 8 | abc | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 0.233 |

Sinal +1 Sinal −1

**Figura 8:** Matriz de sinais dos contrastes.

## 3.4 Modelo principal: ANOVA $2^3$ sobre os dados brutos

Os alunos são as unidades experimentais e as $n = 3.279$ observações brutas são o "experimento" (fatorial $2^3$ observacional e não balanceado, com $n_c = 181$–$667$ por célula). Ajusta-se $\Delta\texttt{GPA} \sim \texttt{A*B*C}$ com codificação $\pm 1$, SQ tipo III (testa exatamente o contraste de efeito, mesmo com $n$ desigual) e erros-padrão robustos à heterocedasticidade (HC3). Essa é a única fonte de $p$-valores da decisão.

### 3.5 Efeitos e intervalos de confiança (bootstrap estratificado)

O efeito de cada termo é

$$\text{efeito} = \frac{1}{4}\sum_{c=1}^{8} s_c\,\overline{Y}_c,$$

onde $s_c$ é o sinal da coluna correspondente (Tabela 4) e $\overline{Y}_c$ a média bruta da célula; equivale ao dobro do coeficiente da regressão com variáveis codificadas em $\pm 1$. O bootstrap é usado *exclusivamente* para os ICs: 5.000 reamostras estratificadas (tamanho $n_c$ completo de cada célula), recalculando os sete efeitos e obtendo ICs de 95% pelo método percentil, que não assumem variâncias iguais.

### 3.6 Réplicas bootstrap: papel apenas ilustrativo

Sortear $m = 36$ alunos *com reposição* de cada célula $r = 30$ vezes (240 médias) ilustra o balanceamento e a normalização das médias pelo Teorema Central do Limite, mas **não constitui replicação experimental**: as réplicas reamostram os mesmos alunos (pseudo-replicação) e medem a variabilidade do estimador, não o erro experimental. Por isso a ANOVA sobre essas médias tem $p$-valores otimistas e não é usada para decidir (Apêndice A).

### 3.7 Critérios de validação e decisão

- Diagnóstico dos resíduos do modelo bruto: Shapiro–Wilk, Levene e gráfico resíduos $\times$ ajustados. Em caso de heterocedasticidade, o modelo adota HC3 e confere-se o IC bootstrap.
- Estabilidade: desvio-padrão do efeito entre 10 sementes $< 0{,}01$ (Apêndice A).
- Balanceamento de `Pre_GPA` (ANOVA, $p > 0{,}05$).
- Decisão: efeito *significativo* se o IC95% bootstrap exclui 0 **e** o $p$ (HC3) do modelo bruto $< 0{,}05$; *fraco* se apenas um dos critérios é atendido; *não significativo* caso contrário.

## 4 Resultados Experimentais

### 4.1 Visão geral das respostas (cubo)

A Figura 9 apresenta o $\Delta$GPA médio nos oito vértices. O pior vértice é *passivo + ansiedade alta + pouco estudo* (0,091); o melhor, *ativo + ansiedade alta + muito estudo* (0,323), praticamente empatado com *ativo + ansiedade baixa + muito estudo* (0,317).

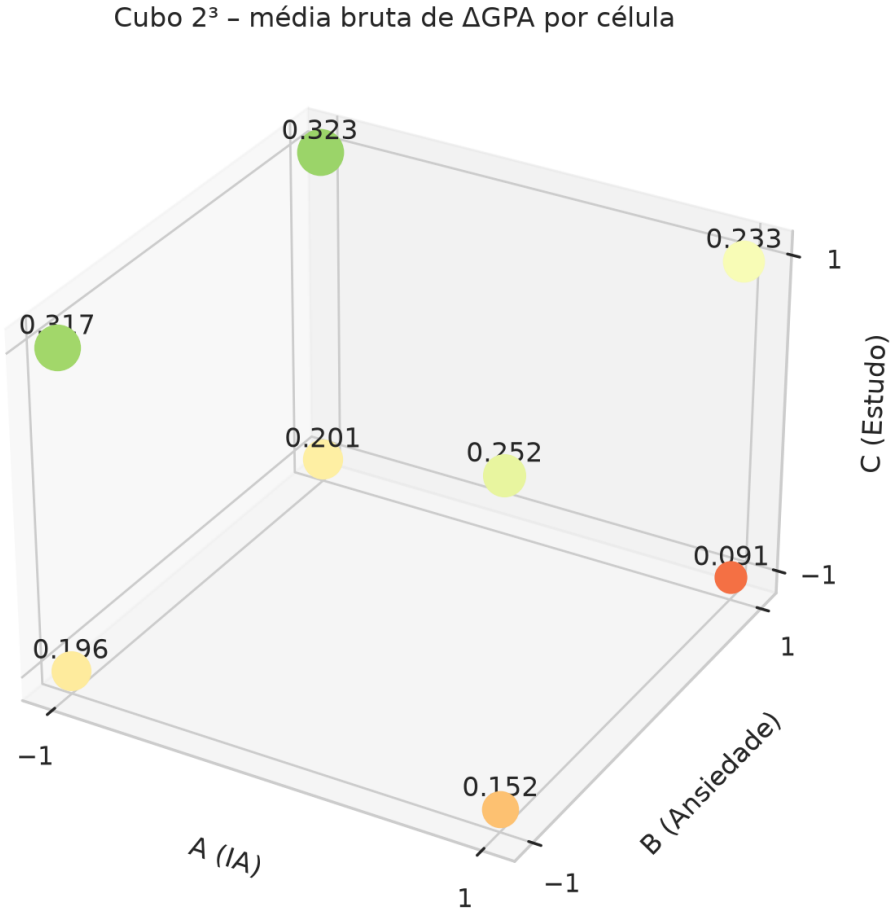



**Figura 9:** ΔGPA médio por vértice do cubo $2^3$.

## 4.2 ANOVA do fatorial $2^3$ sobre os dados brutos (HC3)

**Tabela 5:** ANOVA $2^3$ não balanceada ($n = 3.279$; SQ tipo III; $p$ clássico e com erros-padrão HC3). Resíduo: 89,0% da SQ total ($R^2 = 0{,}129$).

| Fonte | SQ | $F$ (clássico) | $p$ clássico | $p$ (HC3) | % da SQ total |
|---|---|---|---|---|---|
| A | 3,608 | 110,7 | $< 0{,}001$ | $< 0{,}001$ | 3,01 |
| B | 0,185 | 5,69 | 0,017 | 0,027 | 0,15 |
| C | 8,894 | 272,9 | $< 0{,}001$ | $< 0{,}001$ | 7,43 |
| AB | 0,311 | 9,54 | 0,002 | 0,004 | 0,26 |
| AC | 0,0001 | 0,004 | 0,947 | 0,951 | $< 0{,}01$ |
| BC | 0,069 | 2,12 | 0,146 | 0,177 | 0,06 |
| ABC | 0,057 | 1,76 | 0,185 | 0,218 | 0,05 |
| Resíduo | 106,589 | – | – | – | 89,0 |

Os fatores explicam 11% da variabilidade individual do ΔGPA, quase toda devida a C (7,4%) e A (3,0%); o restante é variabilidade entre alunos não explicada pelos três fatores (Figura 10).

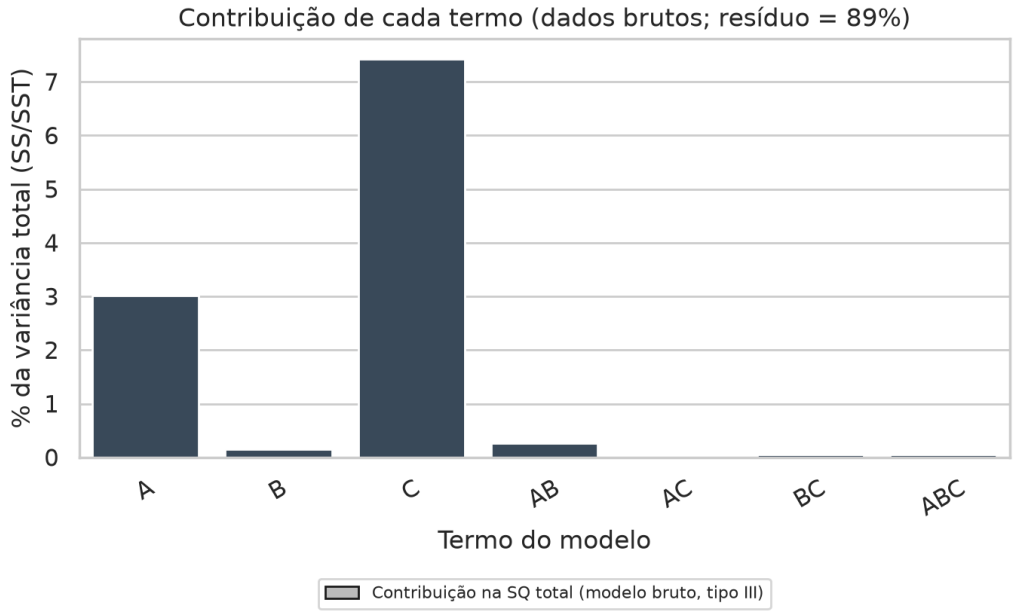



**Figura 10:** Percentual da soma de quadrados total por termo (dados brutos).

## 4.3 Efeitos e intervalos de confiança

**Tabela 6:** Efeitos estimados (médias brutas), IC95% bootstrap, $p$ (HC3) e veredito.

| Efeito | Valor | IC95% | $p$ (HC3) | Veredito |
|---|---|---|---|---|
| A (modo de uso) | −0,0772 | [−0,0920; −0,0621] | $<$ 0,001 | significativo |
| B (ansiedade) | −0,0175 | [−0,0329; −0,0019] | 0,027 | signif. (marginal) |
| C (horas) | +0,1211 | [+0,1058; +0,1364] | $<$ 0,001 | significativo |
| AB | −0,0226 | [−0,0384; −0,0074] | 0,004 | significativo |
| AC | −0,0005 | [−0,0156; +0,0148] | 0,951 | não signif. |
| BC | +0,0107 | [−0,0051; +0,0263] | 0,177 | não signif. |
| ABC | +0,0097 | [−0,0063; +0,0253] | 0,218 | não signif. |

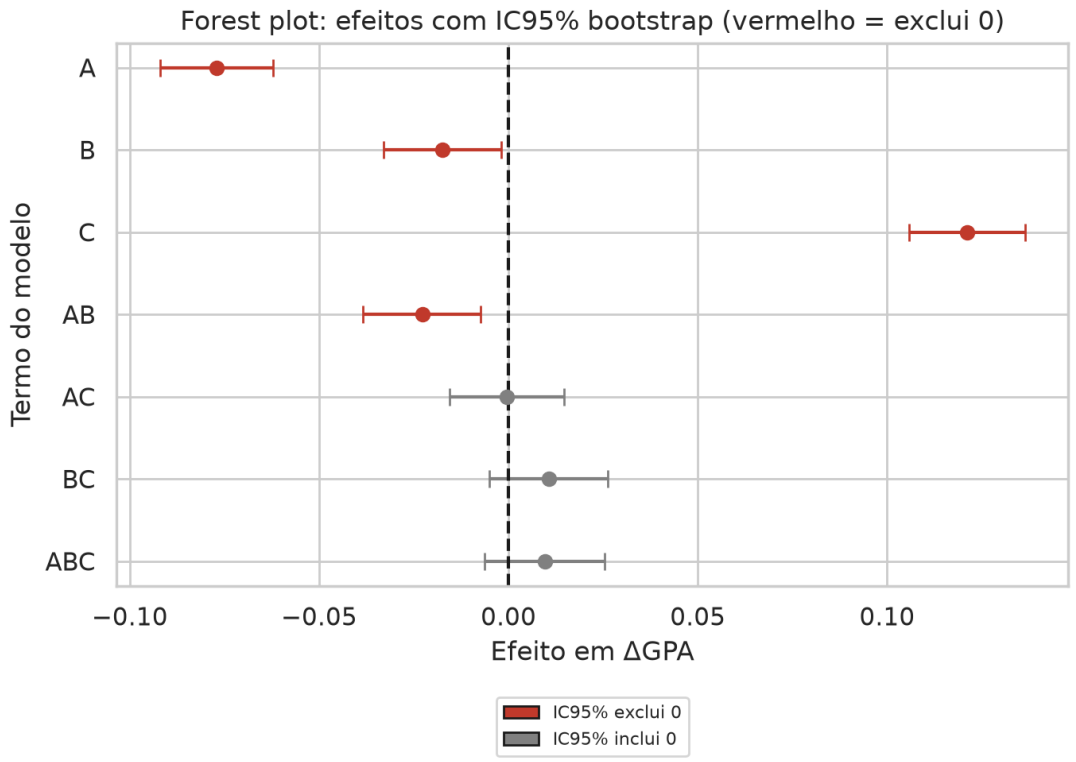



**Figura 11:** *Forest plot* dos efeitos com IC95% bootstrap.

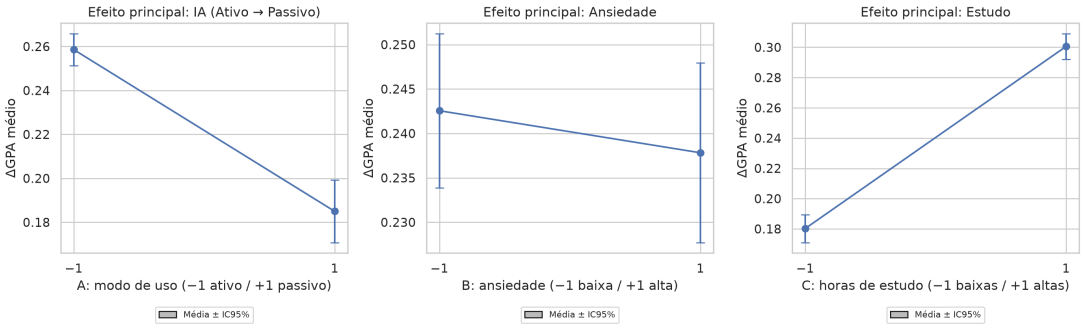



**Figura 12:** Efeitos principais sobre o ΔGPA.

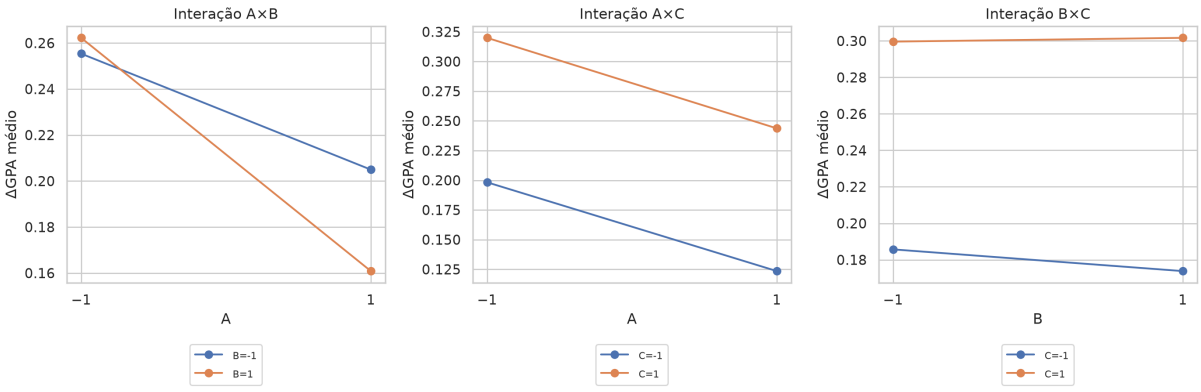



**Figura 13:** Gráficos de interação entre os fatores.

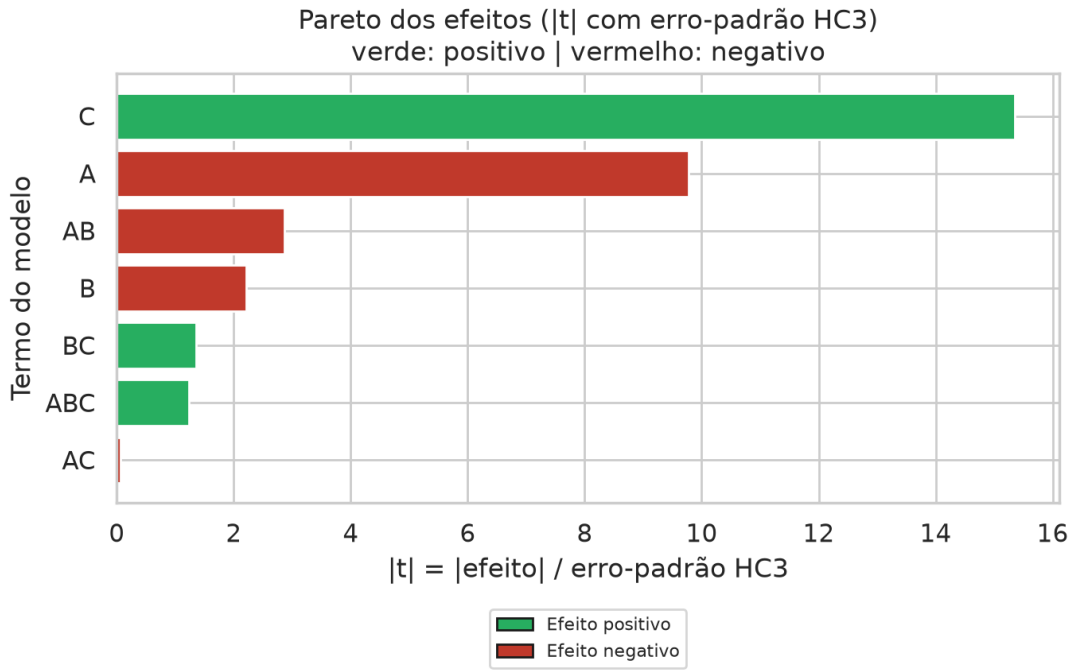



**Figura 14:** Diagrama de Pareto dos efeitos ($|t|$ com erro-padrão HC3).

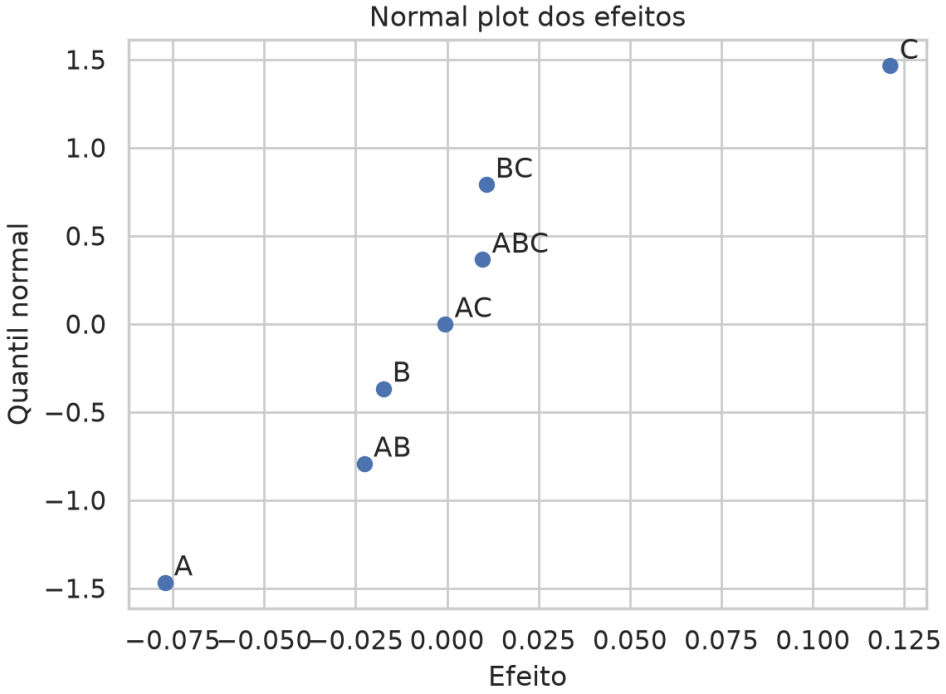



**Figura 15:** Gráfico normal dos efeitos: pontos afastados da reta são efeitos ativos (C, A, AB e B).

## 4.4 Diagnóstico dos resíduos e heterocedasticidade

**Tabela 7:** Checagens de validação do modelo principal.

| Checagem | Atendida | Detalhe |
|---|---|---|
| Levene entre células, dados brutos ($p > 0{,}05$) | **Não** | $p = 2{,}6 \times 10^{-5} \rightarrow$ HC3 + IC bootstrap |
| Concordância IC bootstrap × HC3 | Sim | os sete termos coincidem |
| Estabilidade entre sementes (DP $< 0{,}01$) | Sim | DP máx. $= 0{,}0056$ |
| Balanceamento de Pre_GPA ($p > 0{,}05$) | Sim | $p = 0{,}89$ |

**Heterocedasticidade.** O teste de Levene rejeita a homocedasticidade nos dados brutos ($p < 0{,}001$): o DP por célula varia de 0,170 a 0,236 e as células passivas têm DP médio maior (0,197) que as ativas (0,175), com o máximo na célula 4 (passivo, ansiedade alta, pouco estudo). Os resíduos são aproximadamente simétricos, com cauda inferior (teto de GPA), e o gráfico resíduos × ajustados (Figura 16) mostra dispersão parecida entre células, com pequenas diferenças. Em vez de transformar a resposta (a transformação $\log Y$ da Aula 7 não se aplica, pois o $\Delta$GPA assume valores $\leq 0$), adotam-se estimadores robustos: ANOVA com matriz de covariância HC3 e ICs bootstrap, que não assumem variâncias iguais. As duas abordagens concordam em todos os efeitos.

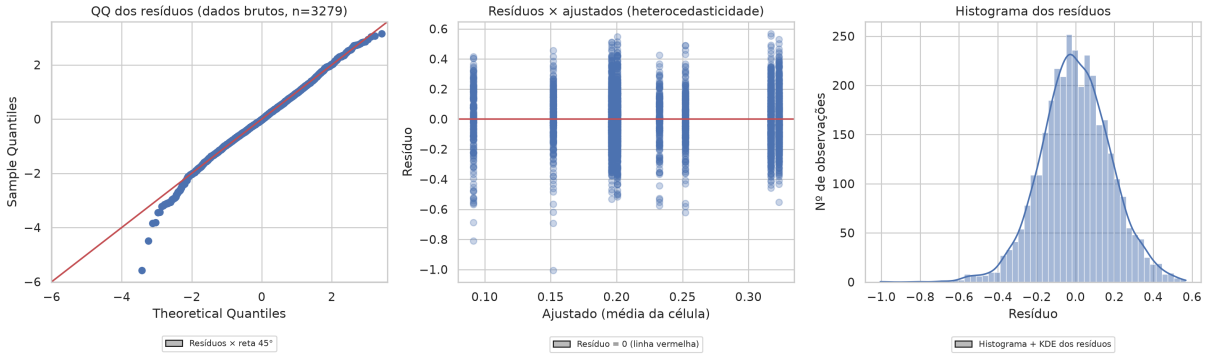



**Figura 16:** Diagnóstico dos resíduos do modelo bruto ($n = 3.279$): normalidade (QQ), resíduos × ajustados e histograma.

# 5 Caracterização e Análises Finais

Interpretando os efeitos em unidades de GPA (média de + menos média de −):

- **C (horas de estudo):** estudar acima da mediana acrescenta cerca de 0,121 ponto em relação a estudar até a mediana; é o fator dominante (7,4% da SQ total, contra 3,0% de A).
- **A (modo de uso):** o uso passivo reduz o $\Delta$GPA em cerca de 0,077 em média (IC95% $[-0{,}092; -0{,}062]$).
- **AB:** a penalização do uso passivo é maior sob ansiedade alta: com pouco estudo, $-0{,}110$ ($ab$ 0,091 vs. $b$ 0,201) contra $-0{,}044$ com ansiedade baixa ($a$ 0,152 vs. (1)

0,196); com muito estudo, −0,090 contra −0,065. Isso sugere que a ansiedade amplifica o dano do uso passivo; a regressão contínua confirma a interação.

- **AC:** não significativa (−0,0005): a perda do uso passivo é semelhante com pouco estudo (média das duas ansiedades −0,077) e com muito estudo (−0,078).
- **B:** efeito principal marginal e pequeno (−0,0175; IC exclui 0 por pouco; $p_{\text{HC3}} = 0{,}027$; 0,15% da SQ total).

Recomendação prática preliminar: priorizar usos ativos da IA, especialmente em estudantes ansiosos; o ganho por estudar mais supera o de qualquer escolha de modo de uso.

# 6 Discussão

**Avaliação preliminar da hipótese.** Rejeita-se $H_0$ para A, C e AB (e, marginalmente, B), em consistência com $H_1$: o uso passivo reduz o ΔGPA e o efeito depende da ansiedade. Não há evidência de interação com horas de estudo (AC, BC, ABC) nesta amostra. O resultado é coerente com a Entrega 1 (ATE = −0,072), embora a PSM tenha mudado pouco o resultado porque as covariáveis já estavam balanceadas ($|\text{SMD}| < 0{,}05$).

**Limitações.**

- *Pseudo-replicação:* as réplicas bootstrap reusam os mesmos alunos e não são replicação experimental; por isso a ANOVA principal é ajustada aos 3.279 dados brutos com HC3, e o bootstrap serve apenas para os ICs.
- *Definição de "passivo":* inclui *Copywriting*, cujo ΔGPA (0,200) é igual ao de *Ideation*; o efeito vem quase todo de *Direct Answer Generation* (0,133). Com a regra de extremos $Q_1/Q_3$, restringir a esse uso deixava as células inviáveis ($n = 17$–$31$); com a mediana essa análise passa a ser possível e está prevista como próximo passo.
- *Teto de GPA 4,0:* afeta cerca de 12% do recorte, gera assimetria nas células passivas e pode subestimar ganhos.
- *Heterocedasticidade:* as células passivas têm maior dispersão (Levene $p < 0{,}001$ nos dados brutos); tratada com ANOVA robusta (HC3) e IC bootstrap, que não assumem variâncias iguais.
- *Dicotomização pela mediana:* perde informação de variáveis contínuas ($R^2$ 0,129 vs. 0,181 no modelo contínuo) e, na ansiedade (discreta), a mediana 4 deixa 53,4% no nível baixo; por isso o efeito de B é pequeno e o contraste é "acima vs. abaixo da mediana", não "muito vs. pouco".
- *Dados observacionais:* não há atribuição aleatória do modo de uso; não se estabelece causalidade. A base provavelmente é sintética, limitando a generalização.

**Mediana × quartis extremos.** A mediana usa 100% do recorte (menor célula 181 contra 36), reduz pela metade a largura dos ICs, evita exclusão de alunos e tem regra simples e replicável; por isso foi adotada como análise principal. A regra de extremos

produz efeitos maiores (C +0,195) por comparar grupos mais distantes, mas com poucos alunos e descartando 74% dos dados. Ambas levam às mesmas conclusões qualitativas.

**Correções à Entrega 1.** A reavaliação dos dados mostrou que: a base tem 50.000 registros reais (não 10.000 simulados); a tabela descritiva anterior estava incorreta (valores corretos na Tabela 1); a ansiedade não se concentra em 7–10 (moda = 4); e a narrativa de confusão não era sustentada pelos dados.

# 7 Conclusões e Trabalhos Futuros

O fatorial $2^3$ sobre os dados brutos, com erros robustos (HC3) e ICs por bootstrap estratificado, é viável com os níveis definidos pela mediana (menor célula $n = 181$) e produz resultados estáveis entre sementes. As horas de estudo são o principal determinante do $\Delta$GPA; o uso passivo de IA reduz o $\Delta$GPA em cerca de 0,08 e interage negativamente com a ansiedade alta. A heterocedasticidade das células passivas é tratada por HC3 e IC bootstrap e permanece como limitação declarada.

**Ajustes planejados para a entrega final:**

- Citar a fonte e versão do conjunto de dados e documentar sua natureza.
- Testar definições alternativas de "passivo" (por exemplo, somente *Direct Answer*) com células maiores ou outros recortes.
- Se necessário, aprofundar o tratamento do teto de GPA (por exemplo, regressão censurada), hoje apenas na análise de sensibilidade (Apêndice A).
- Replicar em outros recortes (por exemplo, outras áreas e anos) para avaliar generalização.

# A Análise de Sensibilidade e Réplicas Ilustrativas

Este apêndice reúne as técnicas complementares, que não entram na decisão: normalização das médias por bootstrap, ANOVA das réplicas, estabilidade entre sementes, regras de corte alternativas, ANCOVA, regressão contínua, varredura de $m$, permutação e tratamento do teto de GPA (reflexão+raiz e regressão quantílica).

## A.1 Normalização das médias pelo bootstrap (ilustrativo)

Os dados brutos das células passivas são assimétricos (com $n$ grande, o Shapiro–Wilk rejeita normalidade em 5 das 8 células); as médias bootstrap tornam-se normais ($p \geq 0{,}077$ em todas as células). As Figuras 17, 18 e 19 ilustram a normalização.

**Tabela 8:** Assimetria e Shapiro–Wilk por célula (bruto vs. médias bootstrap).

| Célula | $n$ | Assim. bruta | $p$ bruto | Assim. boot. | $p$ boot. |
|---|---|---|---|---|---|
| 1 | 667 | 0,224 | 0,012 | $-0,125$ | 0,944 |
| 2 | 210 | $-1,127$ | $< 0,001$ | 0,239 | 0,593 |
| 3 | 576 | 0,056 | 0,224 | 0,288 | 0,726 |
| 4 | 187 | $-0,798$ | $< 0,001$ | 0,343 | 0,464 |
| 5 | 639 | 0,167 | 0,350 | 0,355 | 0,509 |
| 6 | 235 | $-0,299$ | 0,008 | 0,704 | 0,077 |
| 7 | 584 | 0,259 | 0,021 | $-0,145$ | 0,371 |
| 8 | 181 | $-0,719$ | $< 0,001$ | 0,200 | 0,854 |

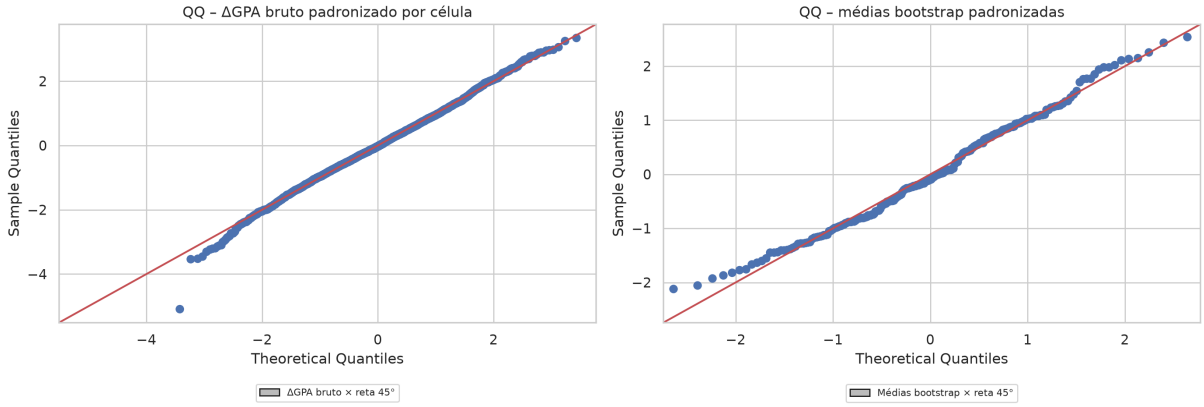



**Figura 17:** Gráficos Q-Q antes (dados brutos) e depois (médias bootstrap).

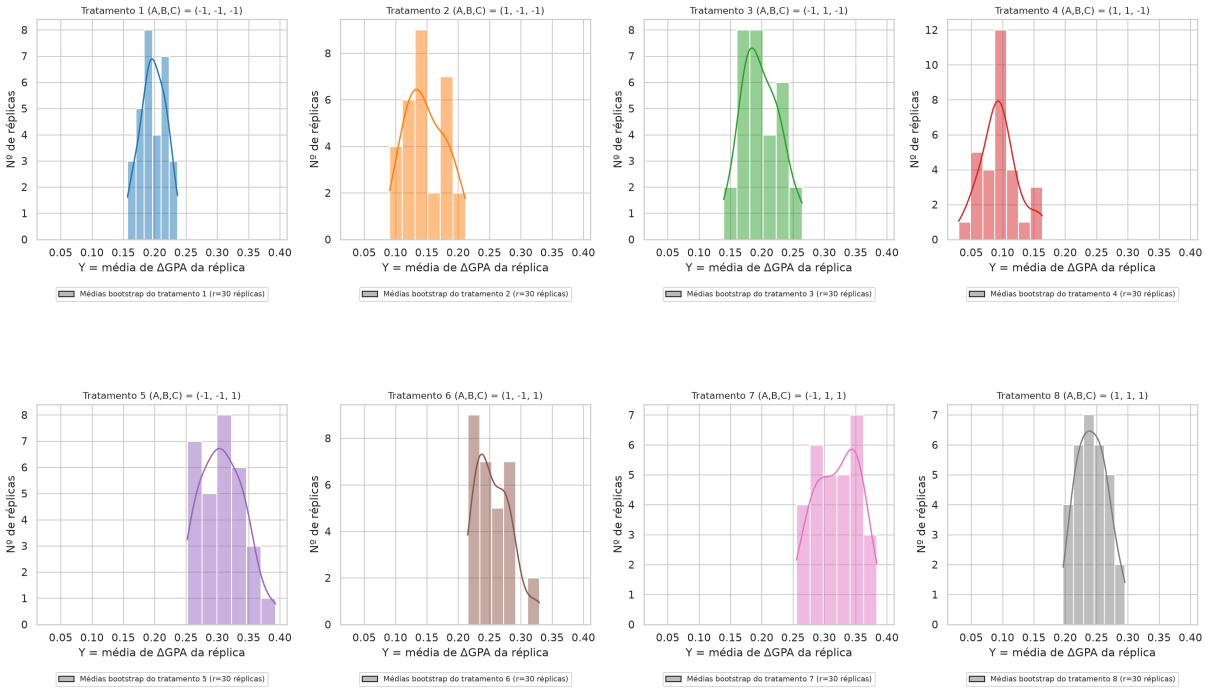



**Figura 18:** Histogramas das médias bootstrap por célula.

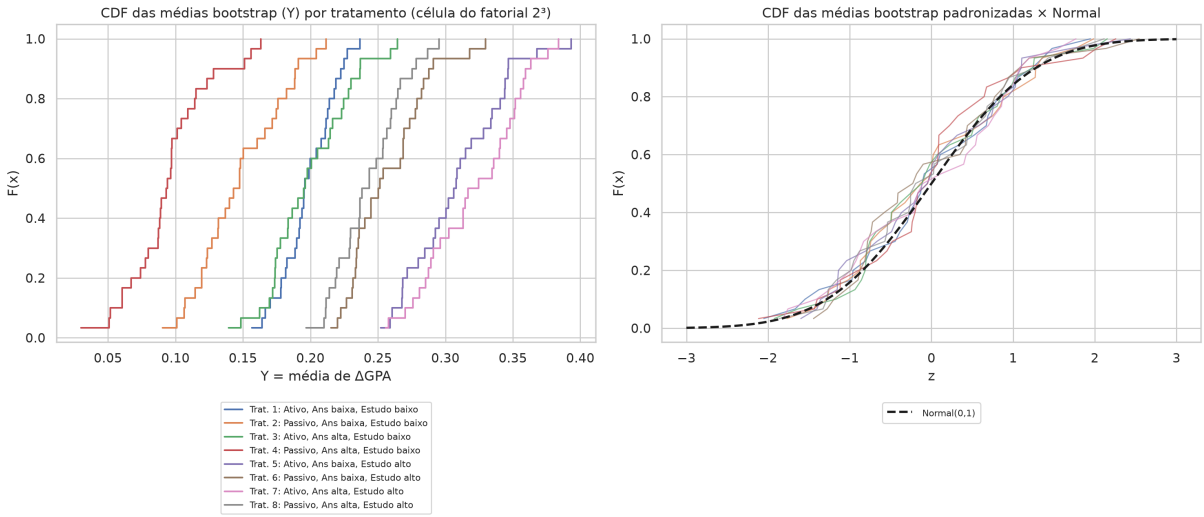



**Figura 19:** CDF das médias bootstrap versus CDF normal teórica.

## A.2 ANOVA sobre as réplicas bootstrap (descritiva)

**Tabela 9:** ANOVA sobre as 240 observações bootstrap.

| Fonte | SQ | GL | $F$ | $p$ | % var. |
|---|---|---|---|---|---|
| A | 0,3005 | 1 | 331,6 | $< 0{,}001$ | 20,6 |
| B | 0,0107 | 1 | 11,8 | $< 0{,}001$ | 0,7 |
| C | 0,9016 | 1 | 994,8 | $< 0{,}001$ | 61,7 |
| AB | 0,0241 | 1 | 26,5 | $< 0{,}001$ | 1,6 |
| AC | 0,0024 | 1 | 2,6 | 0,108 | 0,2 |
| BC | 0,0097 | 1 | 10,8 | 0,001 | 0,7 |
| ABC | 0,0028 | 1 | 3,1 | 0,078 | 0,2 |
| Resíduo | 0,2103 | 232 | – | – | 14,4 |

**Atenção:** os $p$-valores desta ANOVA são otimistas (até BC, nulo, aparece com $p = 0{,}001$), pois as réplicas reutilizam os mesmos alunos. Por isso ela *não* é usada na decisão (a inferência é feita pelo modelo bruto com HC3 e pelo IC bootstrap), e o % de variância desta tabela (C = 61,7%) é inflado pela remoção da variabilidade entre alunos.

## A.3 Diagnóstico dos resíduos das réplicas

Nas réplicas, o Shapiro–Wilk dos resíduos dá $p = 0{,}115$ (normalidade aceita) e o Levene $p = 0{,}044$ (no limiar), reflexo da maior dispersão das células passivas.

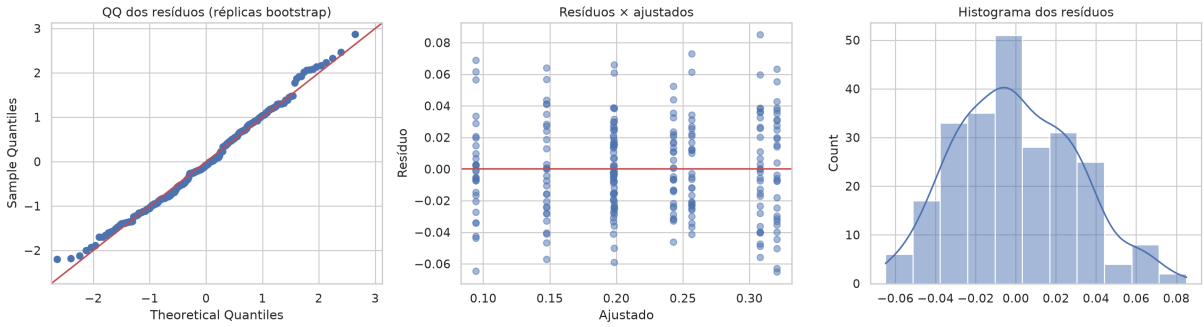



**Figura 20:** Diagnóstico dos resíduos da ANOVA das réplicas bootstrap.

## A.4 Estabilidade entre sementes

Repetindo o procedimento com 10 sementes, o desvio-padrão dos efeitos fica entre 0,0027 e 0,0056 (A: $-0{,}0772 \pm 0{,}0056$; C: $+0{,}1228 \pm 0{,}0029$; AB: $-0{,}0220 \pm 0{,}0027$), de modo que as conclusões não dependem da semente.

## A.5 Sensibilidade à definição dos níveis, ANCOVA e regressão contínua

**Tabela 10:** Efeitos sob definições alternativas de nível (* = IC95% exclui 0).

| Definição | $n$ | A | B | C | AB | AC | BC | ABC |
|---|---|---|---|---|---|---|---|---|
| Mediana (principal) | 3.279 | $-0{,}077^*$ | $-0{,}017^*$ | $+0{,}121^*$ | $-0{,}023^*$ | 0,000 | $+0{,}011$ | $+0{,}010$ |
| $< Q_1 / \geq Q_3$ (versão anterior) | 848 | $-0{,}067^*$ | $-0{,}043^*$ | $+0{,}195^*$ | $-0{,}046^*$ | $+0{,}022$ | $+0{,}004$ | $-0{,}006$ |
| $\leq Q_1 / \geq Q_3$ | 1.101 | $-0{,}080^*$ | $-0{,}038^*$ | $+0{,}193^*$ | $-0{,}033^*$ | $+0{,}011$ | $+0{,}006$ | $+0{,}005$ |

Os sinais, a significância de A, C e AB e a ordem de importância se mantêm nas três regras; mudam as magnitudes de B, C e AB, que caem cerca de 40–50% com a mediana porque o contraste deixa de ser "extremo × extremo" e passa a "acima × abaixo da mediana". Uma ANCOVA com `Pre_GPA` como covariável dá A = −0,076, B = −0,018, C = +0,121 e AB = −0,022, praticamente idênticos aos principais. Uma regressão contínua (sem dicotomizar B e C; $R^2 = 0{,}181$, contra 0,129 do modelo dicotomizado) confirma: cada hora de estudo adiciona +0,014 ($p < 0{,}001$), cada ponto de ansiedade reduz 0,005 ($p = 0{,}002$) e a interação uso passivo × ansiedade é −0,0064 por ponto ($p < 0{,}001$).

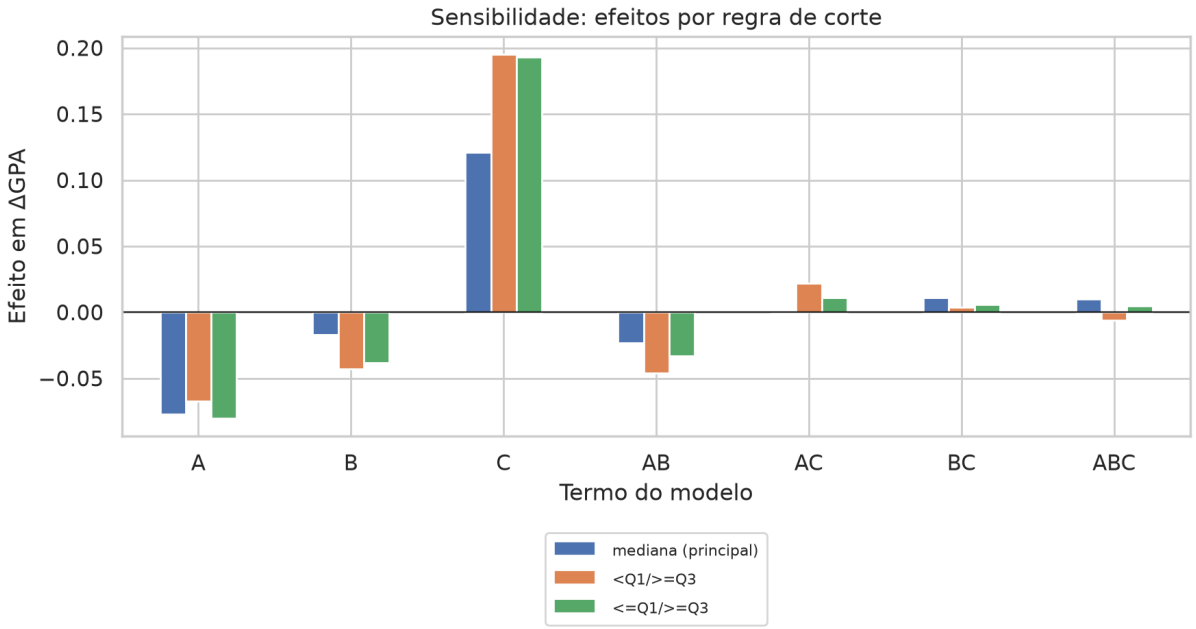



**Figura 21:** Sensibilidade dos efeitos à definição dos níveis.

## A.6 Balanceamento, permutação e teto de GPA

O desbalanceamento ($n = 181$–$667$) não enviesa as estimativas, mas elimina a ortogonalidade dos contrastes e torna desigual a precisão por célula; a amostragem com $m$ igual por célula restaura o balanceamento. O bootstrap, entretanto, *não normaliza* o ΔGPA bruto (assimetria por causa do teto 4,0): apenas aproxima a distribuição das médias. A Tabela 11 compara esquemas de réplica ($r = 300$).

| Esquema | $A$ | $C$ | $AB$ |
|---|---|---|---|
| bootstrap $m = 36$ (atual) | −0,075 | +0,121 | −0,023 |
| bootstrap $m = 150$ | −0,077 | +0,121 | −0,023 |
| sem reposição $m = 150$ | −0,078 | +0,121 | −0,023 |
| sem reposição $m = 181$ | −0,077 | +0,121 | −0,023 |

**Tabela 11:** Efeitos médios por esquema de réplica.

Os efeitos são idênticos (±0,003): a estimativa não depende de $m$ nem da reposição (Fig. 22). O desvio-padrão entre réplicas sem reposição diminui com $m$ por efeito de população finita ($\approx 0{,}021$ em $m = 36$ e $\approx 0{,}006$ em $m = 181$) e não representa o erro do estimador; por isso Shapiro e Levene das réplicas sem reposição falham por construção, e o IC de inferência permanece o do bootstrap completo.

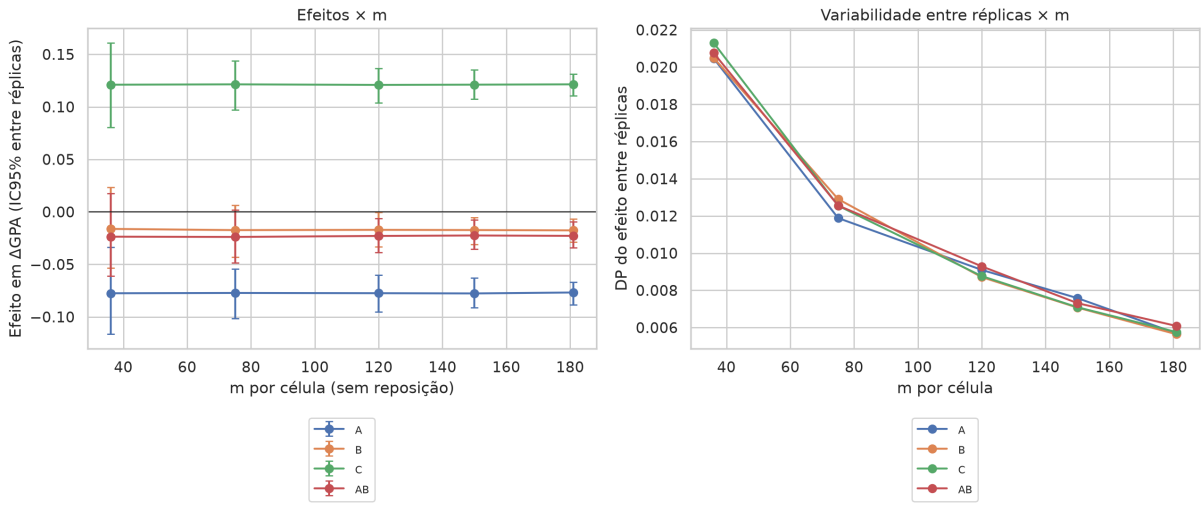



**Figura 22:** Efeitos e variabilidade entre réplicas em função de $m$ (sem reposição).

O teste de permutação (5.000, resíduos do modelo reduzido) fornece $p = 0{,}0002$ (A), 0,0002 (C), 0,0016 (AB), 0,95 (AC), 0,145 (BC) e 0,18 (ABC), concordando com IC bootstrap e HC3. Para B, $p = 0{,}019$, em linha com HC3 (0,027) e ANOVA bruta (0,017): efeito marginal e de magnitude desprezível (0,15% da SQ total). Com transformação (reflexão + raiz) e regressão quantílica para o teto de GPA (12,1% no valor 4,0), os sinais se mantêm (A −0,051, C +0,114 na mediana).

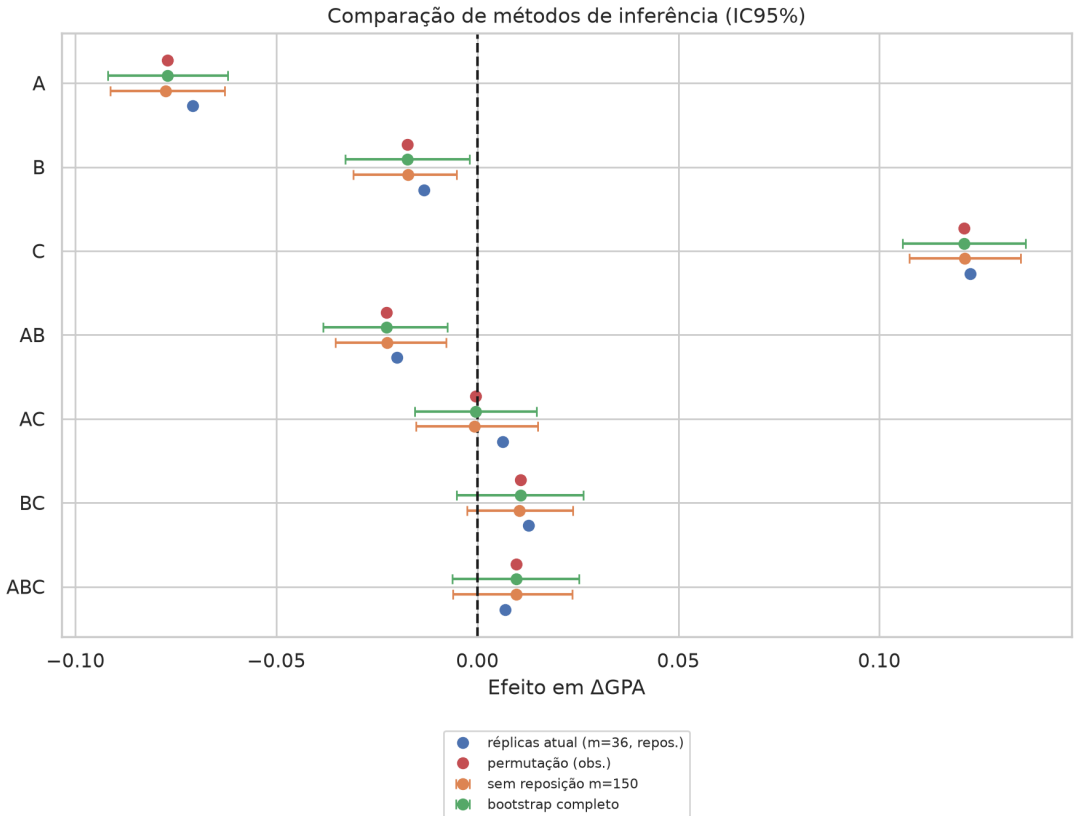



**Figura 23:** Efeitos e IC95% por método de inferência.

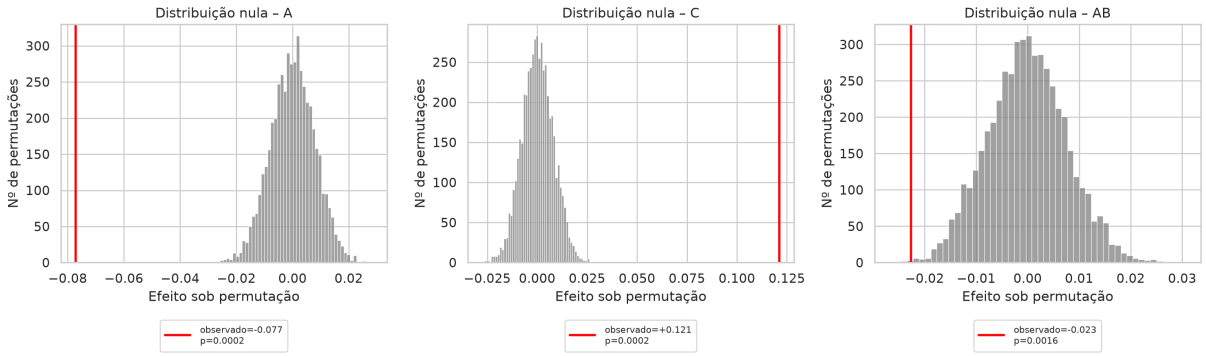



**Figura 24:** Distribuição nula da permutação e efeito observado (A, C, AB).

Conclusão: os métodos concordam; a análise principal permanece o modelo bruto com HC3 e IC bootstrap, e as demais técnicas servem apenas de verificação.

# B Reprodutibilidade

- Parâmetros: `SEED`=42, $r = 30$, $m = 36$, `NBOOT`=5.000, `REGRA`="mediana" ("quartis" reproduz a versão anterior, arquivada em `entrega2/dados/quartis/`).
- Código: `entrega2/pcc170_entrega02.py` (fonte única) e `pcc170_entrega02.ipynb`.
- Figuras: `entrega2/figuras/` (24 arquivos + `separados/`); tabelas CSV: `entrega2/dados/`.
- Dados: `csv/ai_student_impact_dataset.csv`.