Impacto do uso passivo vs. ativo de IA generativa no ΔGPA: Experimento fatorial $2^3 r$ com bootstrap estratificado

Relatório da Entrega 2 – Resultados preliminares

Wagner Tironi Pinto

Orientador: Prof. Dr. Carlos H. G. Ferreira

PCC170 – Projeto e Análise de Experimentos Computacionais

Resumo

Este relatório apresenta a Entrega 2 do projeto de PCC170. Avalia-se se o modo de uso de IA generativa (*passivo*: gerar texto/resposta pronta; *ativo*: idear, resumir, depurar) afeta a variação de desempenho acadêmico (ΔGPA = GPA pós − GPA pré), em interação com a ansiedade em exames e as horas de estudo. O recorte é único (STEM + *Junior*, $n = 3.279$) e os níveis dos fatores sáo definidos por quartis: *alto* $\geq Q_3$ e *baixo* $< Q_1$, restando 848 alunos. Utiliza-se um projeto fatorial 2^3 com $r = 30$ réplicas obtidas por bootstrap estratificado (semente 42, $m = 36$ alunos por célula), e um segundo ciclo de bootstrap (5.000 reamostras) para intervalos de confiança dos efeitos. O efeito da horas de estudo é dominante (+0,195; 74,7% da variância); o uso passivo reduz o ΔGPA em 0,067 (IC95% $[-0{,}097; -0{,}038]$) e interage negativamente com a ansiedade ($-0{,}046$). Os resultados são preliminares e observacionais, e as limitações são discutidas.

Sumário

1 Introdução **3**

2 Análise Exploratória dos Dados **3**

2.1 Base de dados 3

2.2 Recorte e estatísticas descritivas 3

2.3 Definição dos níveis por quartis 4

2.4 Distribuição acumulada (CDF) 4

2.5 Resposta bruta por célula 5

3 Materiais e Métodos **6**

3.1 Ambiente 6

3.2 Unidade experimental, fatores, níveis e resposta 6

3.3 Quadro das combinações de teste 6

3.4 Aleatorização e réplicas (Ciclo 1) 8

3.5 Efeitos e intervalos de confiança (Ciclo 2) 8

3.6 Critérios de validação e decisão 9

4 Resultados Experimentais **9**

4.1 Normalização pelo bootstrap 9

4.2 Visão geral das respostas (cubo) 10

4.3 ANOVA do fatorial 2^3r 11

4.4 Efeitos e intervalos de confiança 12

4.5 Diagnóstico dos resíduos e validação 15

4.6 Estabilidade entre sementes 15

4.7 Análise de sensibilidade 15

5 Caracterização e Análises Finais **16**

6 Discussão **16**

7 Conclusões e Trabalhos Futuros **17**

A Reprodutibilidade **18**

1 Introdução

Contexto. A adoção de IA generativa por estudantes universitários cresceu rapidamente, mas há dúvida sobre se seus benefícios dependem da *forma* de uso. Usos que substituem o esforço cognitivo (obter respostas prontas, redigir textos) tendem a ser distintos de usos que o ampliam (gerar ideias, resumir leituras, depurar código).

Motivação e problema. Na Entrega 1 foi estimado, por *propensity score matching*, um efeito médio do uso passivo de ATE = $-0{,}072$ (IC95% $[-0{,}092; -0{,}053]$). Após orientação do professor, o problema foi reformulado: (i) adotar um único recorte (STEM + *Junior*) para evitar viés de composição; (ii) usar bootstrap e um projeto fatorial para normalizar os dados e quantificar efeitos e interações.

Objetivo. Quantificar o efeito do modo de uso da IA (A), da ansiedade em exames (B) e das horas de estudo tradicionais (C), e suas interações, sobre o ΔGPA.

Hipótese geral (definida antes do experimento). H_0: nenhum dos efeitos principais ou de interação sobre o ΔGPA é diferente de zero. H_1: o uso passivo reduz o ΔGPA em relação ao uso ativo, e esse efeito depende (interage) do nível de ansiedade e/ou das horas de estudo.

2 Análise Exploratória dos Dados

Esta seção apenas caracteriza os dados; a avaliação da hipótese ocorre nas seções seguintes.

2.1 Base de dados

A base `ai_student_impact_dataset.csv` possui 50.000 registros e 16 variáveis, sem valores nulos. Trata-se de dados tabulares (não simulados pelo autor) cuja origem exata (provavelmente um conjunto público sintético do Kaggle) deve ser citada na versão final. Variáveis usadas: `Primary_Use_Case`, `Anxiety_Level_During_Exams` (1–10), `Traditional_Study_Hours`, `Pre_Semester_GPA`, `Post_Semester_GPA`, `Major_Category` e `Year_of_Study`. A resposta é $\Delta\text{GPA} = \text{GPA}_{pós} - \text{GPA}_{pré}$.

2.2 Recorte e estatísticas descritivas

O recorte STEM + *Junior* contém $n = 3.279$ alunos (813 passivos e 2.466 ativos).

Tabela 1: Estatísticas descritivas (base completa e recorte STEM + *Junior*).

Variável	Base completa		STEM + Junior	
	Média	DP	Média	DP
ΔGPA	0,20	0,19	0,24	0,19
Ansiedade (1–10)	4,27	2,14	4,42	2,23
Horas de estudo	11,21	5,16	11,04	5,29

2.3 Definição dos níveis por quartis

No recorte, os quartis são: ansiedade $Q_1 = 3$, $Q_3 = 6$; horas de estudo $Q_1 = 7{,}33$, $Q_3 = 14{,}475$. Nível *baixo* $< Q_1$ e nível *alto* $\geq Q_3$. Alunos em faixas intermediárias são excluídos do experimento, restando 848 (25,9% do recorte). As Figuras 1 e 2 mostram as distribuições, os pontos de corte e o tamanho das células.

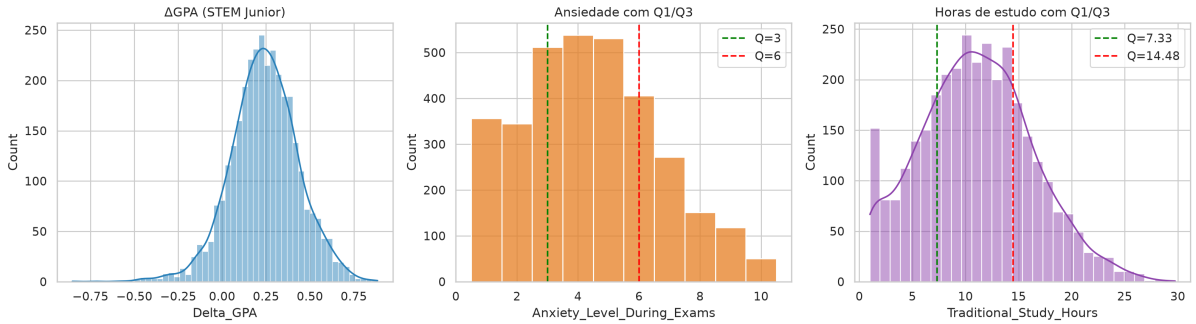


Figura 1: Distribuições de ansiedade, horas de estudo e ΔGPA com os quartis de corte.

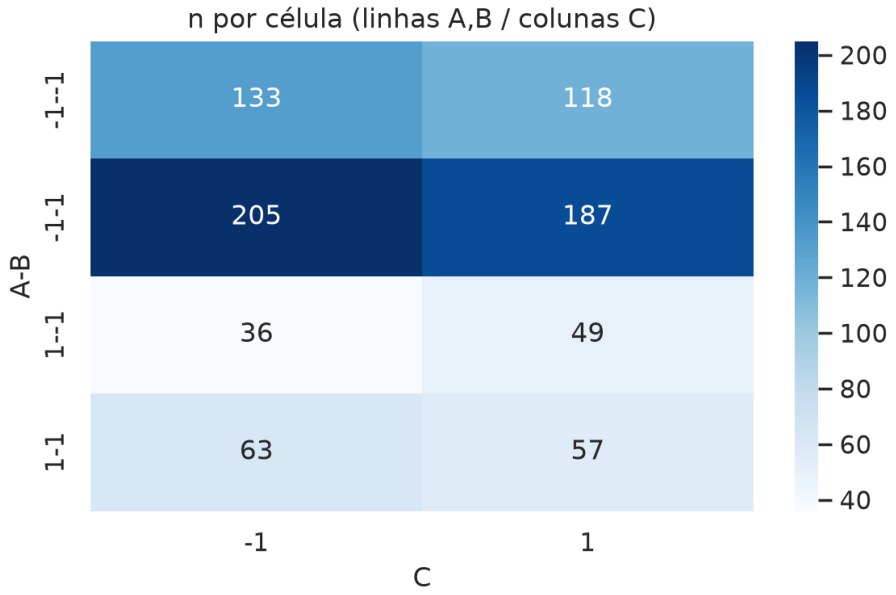


Figura 2: Número de alunos por célula do fatorial. A menor célula tem $n = 36$ (passivo, ansiedade baixa, pouco estudo).

2.4 Distribuição acumulada (CDF)

As CDFs empíricas permitem comparar os grupos sem depender de agrupamento (*bins*). A Figura 3 mostra que a curva do ΔGPA de usuários passivos está deslocada à esquerda, e que a curva de horas altas está deslocada à direita (maior ΔGPA). A Figura 4 compara as oito células e o efeito do recorte. A Figura 5 mostra as variáveis contínuas com os quartis.

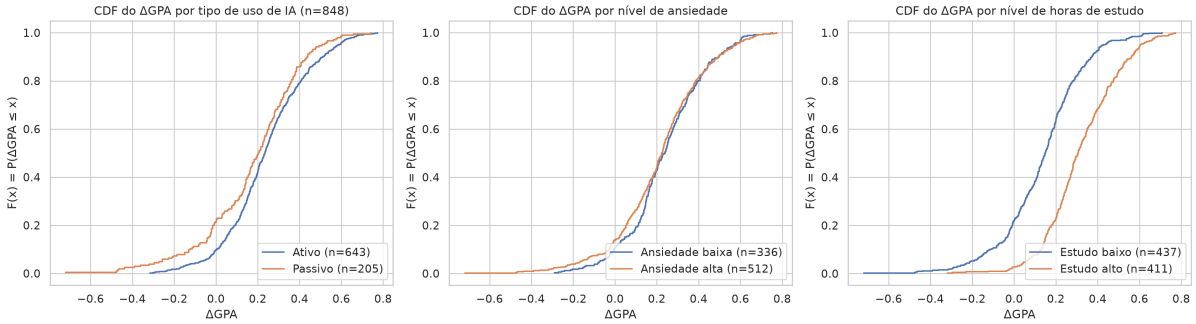


Figura 3: CDF do ΔGPA segundo cada fator (A, B e C).

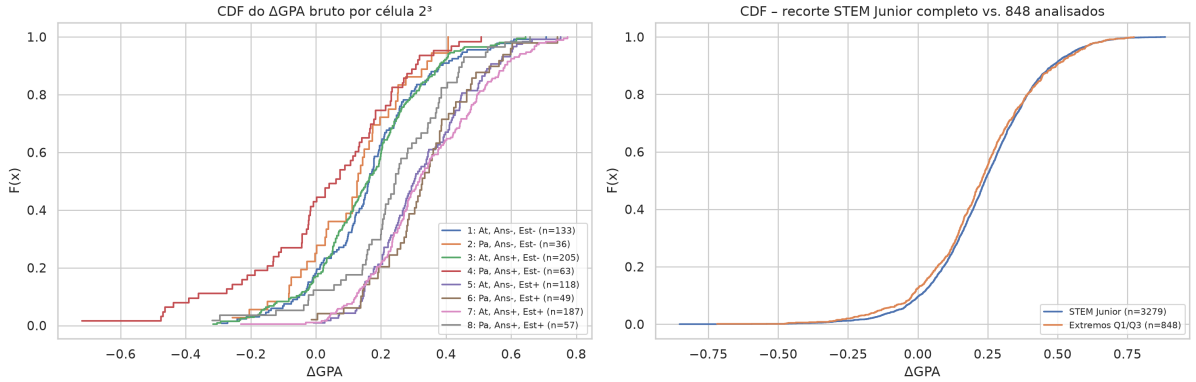


Figura 4: CDF do ΔGPA por célula e por recorte (base completa, STEM + Junior e níveis extremos).

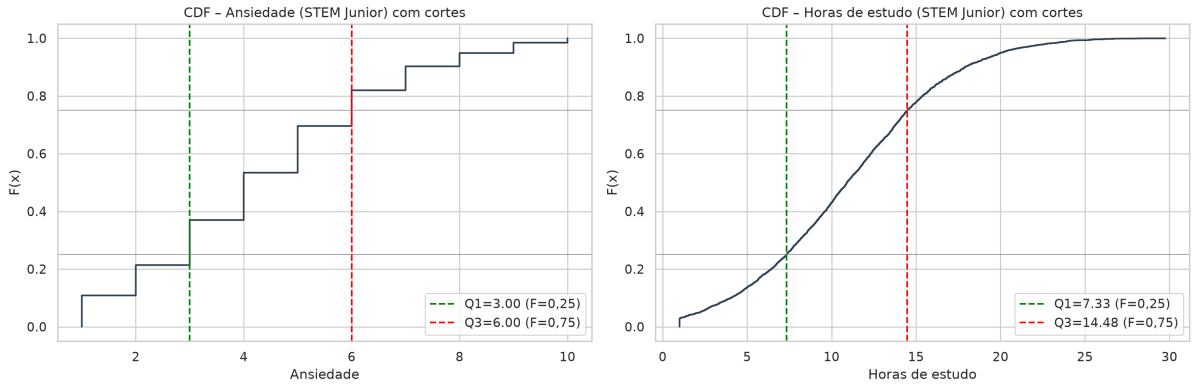


Figura 5: CDF de ansiedade e horas de estudo com marcação de Q_1 e Q_3.

2.5 Resposta bruta por célula

A Figura 6 exibe o ΔGPA bruto por célula. As células passivas têm assimetria negativa (aprox. $-0{,}68$; Shapiro–Wilk $p = 0{,}067$ e $0{,}052$), o que motiva a normalização via bootstrap. O balanceamento da covariável `Pre_Semester_GPA` entre as células é adequado (ANOVA, $p = 0{,}61$).

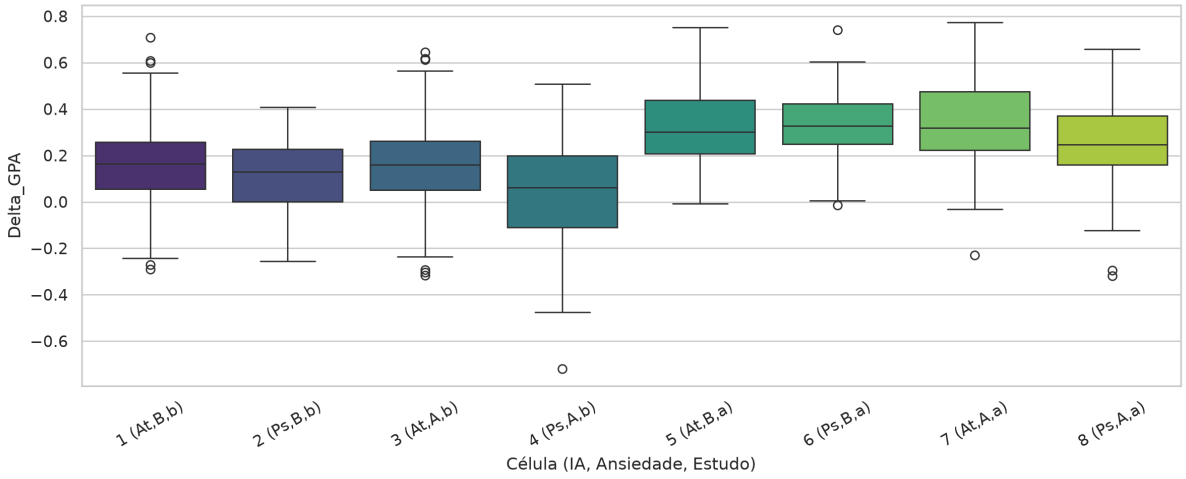


Figura 6: ΔGPA bruto por célula experimental.

3 Materiais e Métodos

3.1 Ambiente

Python 3.12.3, NumPy 2.5.4, pandas 3.1.0, SciPy 1.18.1, statsmodels 1.18.1, Matplotlib 3.11.2 e seaborn 0.15.0. O código (`pcc170_entrega02.py`) e o notebook executado (`.ipynb`) acompanham o relatório. Sementes: 42 (principal) e outras nove para checar estabilidade.

3.2 Unidade experimental, fatores, níveis e resposta

Unidade experimental: aluno de STEM no 3.º ano (*Junior*). **Resposta:** ΔGPA. **Condições controladas:** área (STEM) e ano de estudo fixos; `Pre_GPA` verificado como balanceado.

Tabela 2: Fatores e níveis.

Fator	Nome	Nível −1	Nível +1
A	Modo de uso da IA	Ativo (Ideation, Summarizing, Debugging)	Passivo (Copywriting/Drafting, Direct Answer)
B	Ansiedade em exames	Baixa (< 3)	Alta (≥ 6)
C	Horas de estudo	Baixas ($< 7{,}33$)	Altas ($\geq 14{,}475$)

3.3 Quadro das combinações de teste

Os 8 ensaios seguem a ordem de Yates (A varia mais rápido). A Tabela 3 apresenta as combinações, os tamanhos de célula e as estatísticas da resposta; a Tabela 4 traz a matriz

de sinais com colunas A, B, C, AB, AC, BC e ABC (produto dos sinais), usada para calcular os efeitos. A Figura 7 reproduz ambos os quadros.

Tabela 3: Combinações de teste (ordem de Yates).

Ensaio	A	B	C	n	Média ΔGPA	DP
(1)	−	−	−	133	0,164	0,180
a	+	−	−	36	0,114	0,165
b	−	+	−	205	0,157	0,180
ab	+	+	−	63	0,028	0,250
c	−	−	+	118	0,326	0,155
ac	+	−	+	49	0,334	0,155
bc	−	+	+	187	0,340	0,178
abc	+	+	+	57	0,243	0,189

Tabela 4: Matriz de sinais dos efeitos.

Ensaio	A	B	C	AB	AC	BC	ABC
(1)	−	−	−	+	+	+	−
a	+	−	−	−	−	+	+
b	−	+	−	−	+	−	+
ab	+	+	−	+	−	−	−
c	−	−	+	+	−	−	+
ac	+	−	+	−	+	−	−
bc	−	+	+	−	−	+	−
abc	+	+	+	+	+	+	+

Quadro das combinações de teste (8 tratamentos × r = 30 réplicas)

Ensaio	Yates	A (IA)	B (Ansiedade)	C (Estudo)	n alunos	ΔGPA médio	DP	Réplicas (r)	m por réplica	Observações
1	(1)	-1 Ativo	-1 Baixa (<Q1)	-1 Baixas (<Q1)	133	0.164	0.18	30	36	30
2	a	+1 Passivo	-1 Baixa (<Q1)	-1 Baixas (<Q1)	36	0.114	0.165	30	36	30
3	b	-1 Ativo	+1 Alta (≥Q3)	-1 Baixas (<Q1)	205	0.157	0.18	30	36	30
4	ab	+1 Passivo	+1 Alta (≥Q3)	-1 Baixas (<Q1)	63	0.028	0.25	30	36	30
5	c	-1 Ativo	-1 Baixa (<Q1)	+1 Altas (≥Q3)	118	0.326	0.155	30	36	30
6	ac	+1 Passivo	-1 Baixa (<Q1)	+1 Altas (≥Q3)	49	0.334	0.155	30	36	30
7	bc	-1 Ativo	+1 Alta (≥Q3)	+1 Altas (≥Q3)	187	0.34	0.178	30	36	30
8	abc	+1 Passivo	+1 Alta (≥Q3)	+1 Altas (≥Q3)	57	0.243	0.189	30	36	30

Matriz de sinais dos contrastes (efeito = Σ sinal·Y / 4)

Ensaio	Yates	I	A	B	C	AB	AC	BC	ABC	Y_média_obs
1	(1)	1	-1	-1	-1	1	1	1	-1	0.164
2	a	1	1	-1	-1	-1	-1	1	1	0.114
3	b	1	-1	1	-1	-1	1	-1	1	0.157
4	ab	1	1	1	-1	1	-1	-1	-1	0.028
5	c	1	-1	-1	1	1	-1	-1	1	0.326
6	ac	1	1	-1	1	-1	1	-1	-1	0.334
7	bc	1	-1	1	1	-1	-1	1	-1	0.34
8	abc	1	1	1	1	1	1	1	1	0.243

Figura 7: Quadros das combinações de teste e da matriz de sinais.

3.4 Aleatorização e réplicas (Ciclo 1)

Para cada célula c e réplica $j = 1, \ldots, r$ ($r = 30$), sorteiam-se $m = 36$ alunos *com reposição* dentro da célula (36 é o tamanho da menor célula, o que equilibra o desenho). A resposta da réplica é $Y_{cj} = \overline{\Delta\text{GPA}}$ da amostra, resultando em $8 \times 30 = 240$ observações. Cada réplica é uma nova execução com sorteio independente (gerador com semente fixa para reprodutibilidade). O Teorema Central do Limite faz com que as médias amostrais sejam aproximadamente normais mesmo com células assimétricas. Ajusta-se então a ANOVA 2^3 (`Y ~ A*B*C`, SQ tipo II) e verificam-se as premissas (normalidade e homocedasticidade dos resíduos).

3.5 Efeitos e intervalos de confiança (Ciclo 2)

O efeito de cada termo é

$$\text{efeito} = \frac{1}{4} \sum_{c=1}^{8} s_c \, \overline{Y}_c,$$

onde s_c é o sinal da coluna correspondente (Tabela 4); equivale ao dobro do coeficiente da regressão com variáveis codificadas em ± 1. Realizam-se 5.000 reamostras bootstrap estratificadas (tamanho n_c completo de cada célula), recalculando os sete efeitos em cada uma e obtendo ICs de 95% pelo método percentil.

3.6 Critérios de validação e decisão

- Shapiro–Wilk dos resíduos com $p > 0{,}05$ e Levene entre células com $p > 0{,}05$.
- Estabilidade: desvio-padrão do efeito entre 10 sementes $< 0{,}01$.
- Balanceamento de `Pre_GPA` (ANOVA, $p > 0{,}05$).
- Decisão: efeito *significativo* se o IC95% exclui 0 **e** o p da ANOVA sobre os dados brutos ($n = 848$, desbalanceada) $< 0{,}05$; *fraco* se apenas um dos critérios é atendido; *não significativo* caso contrário.

4 Resultados Experimentais

4.1 Normalização pelo bootstrap

Os dados brutos das células passivas são assimétricos; as médias bootstrap tornam-se normais ($p \geq 0{,}10$ em todas as células). As Figuras 8, 9 e 10 ilustram a normalização.

Tabela 5: Assimetria e Shapiro–Wilk por célula (bruto vs. médias bootstrap).

Célula	n	Assim. bruta	p bruto	Assim. boot.	p boot.
1	133	0,164	0,223	0,092	0,929
2	36	$-0,221$	0,799	$-0,274$	0,804
3	205	0,003	0,297	$-0,395$	0,461
4	63	$-0,677$	0,067	$-0,050$	0,902
5	118	0,330	0,103	0,018	0,614
6	49	0,119	0,949	0,535	0,101
7	187	0,126	0,139	$-0,079$	0,755
8	57	$-0,686$	0,052	0,299	0,683

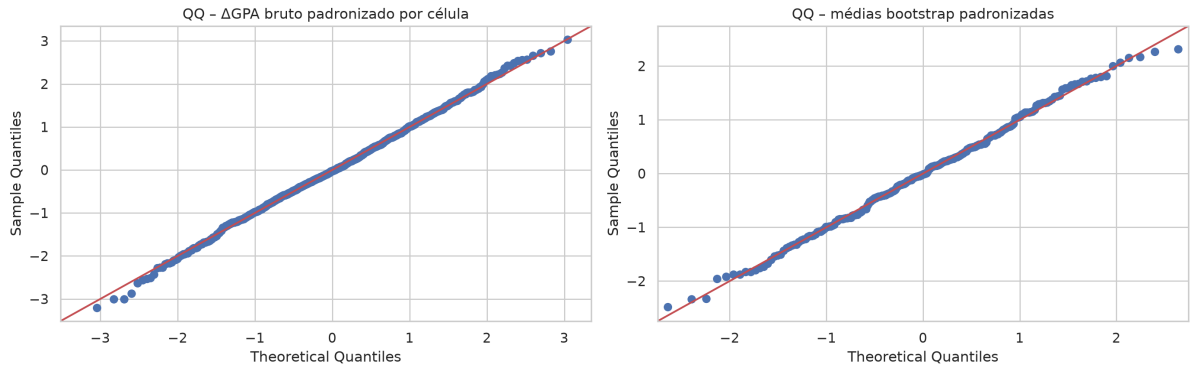


Figura 8: Gráficos Q-Q antes (dados brutos) e depois (médias bootstrap).

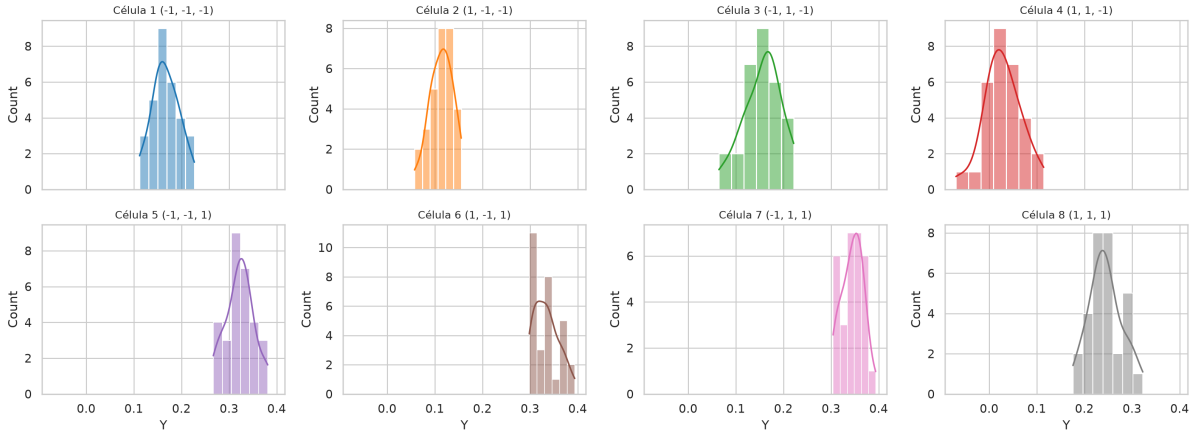


Figura 9: Histogramas das médias bootstrap por célula.

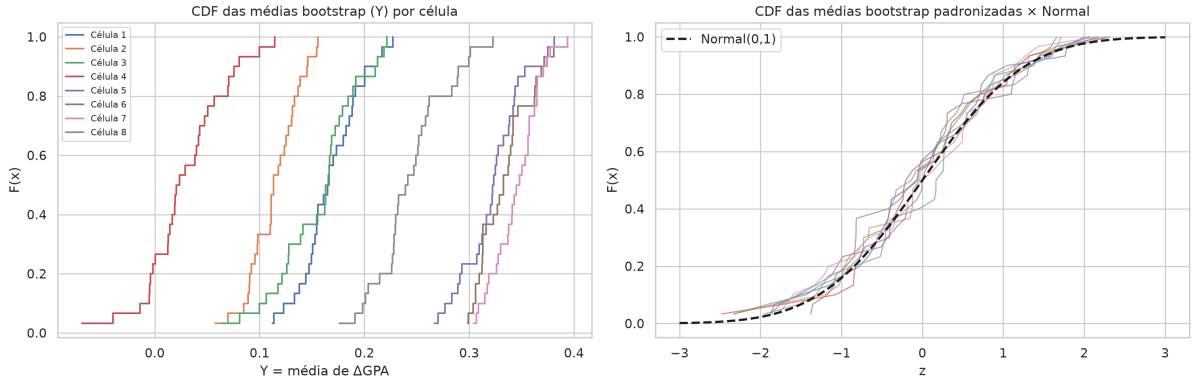


Figura 10: CDF das médias bootstrap versus CDF normal teórica.

4.2 Visão geral das respostas (cubo)

A Figura 11 apresenta o ΔGPA médio nos oito vértices. O pior vértice é *passivo + ansiedade alta + pouco estudo* (0,028); o melhor, *ativo + ansiedade alta + muito estudo* (0,340).

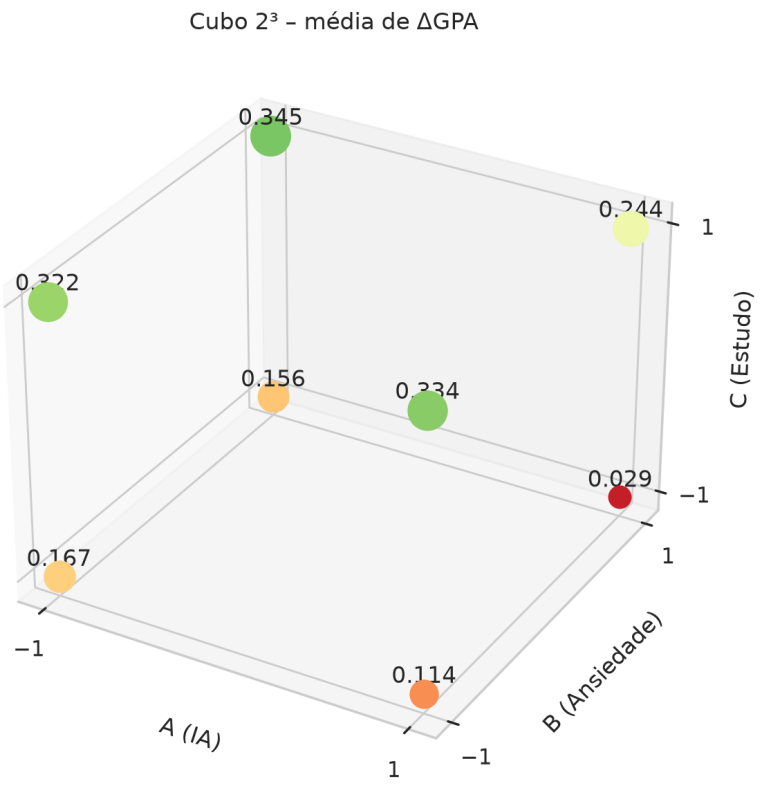


Figura 11: ΔGPA médio por vértice do cubo 2^3.

4.3 ANOVA do fatorial 2^3r

Tabela 6: ANOVA sobre as 240 observações bootstrap.

Fonte	SQ	GL	F	p	% var.
A	0,2727	1	279,8	$< 0{,}001$	8,9
B	0,1001	1	102,7	$< 0{,}001$	3,3
C	2,2779	1	2337,0	$< 0{,}001$	74,7
AB	0,1321	1	135,6	$< 0{,}001$	4,3
AC	0,0313	1	32,1	$< 0{,}001$	1,0
BC	0,0031	1	3,2	0,077	0,1
ABC	0,0054	1	5,6	0,019	0,2
Resíduo	0,2261	232	–	–	7,4

Atenção: os p-valores desta ANOVA são otimistas, pois as réplicas reutilizam os mesmos 848 alunos. Por isso ela é usada para decompor a variância (Figura 12); a inferência é feita pelo IC bootstrap e pela ANOVA bruta.

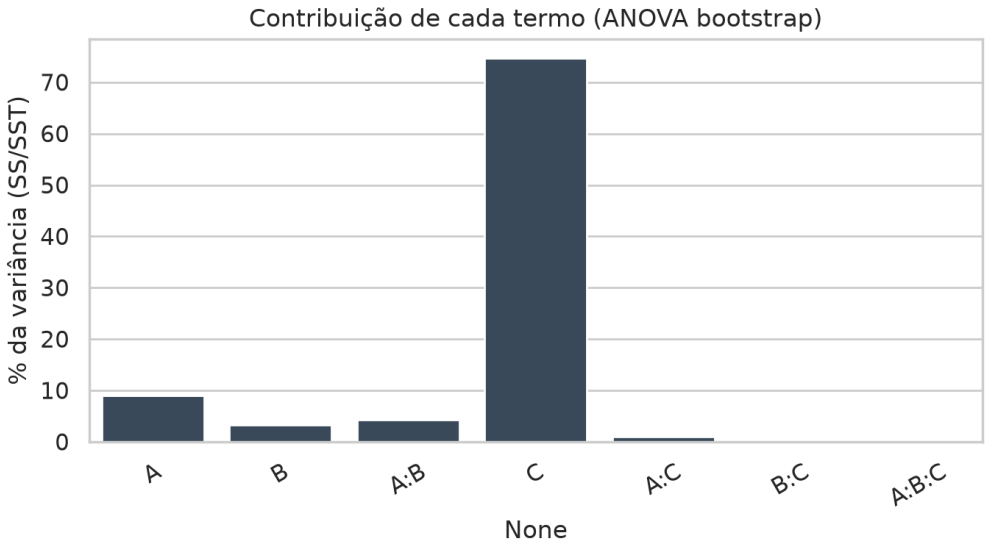


Figura 12: Percentual da variância explicado por cada termo.

4.4 Efeitos e intervalos de confiança

Tabela 7: Efeitos estimados, IC95% bootstrap, p da ANOVA bruta e veredito.

Efeito	Valor	IC95%	p bruto	Veredito
A (modo de uso)	−0,0672	[−0,0971; −0,0380]	$< 0{,}001$	significativo
B (ansiedade)	−0,0426	[−0,0710; −0,0133]	0,127	fraco
C (horas)	+0,1952	[+0,1673; +0,2246]	$< 0{,}001$	significativo
AB	−0,0460	[−0,0759; −0,0172]	0,0019	significativo
AC	+0,0222	[−0,0067; +0,0523]	0,152	não signif.
BC	+0,0040	[−0,0253; +0,0343]	0,565	não signif.
ABC	−0,0065	[−0,0345; +0,0235]	0,663	não signif.

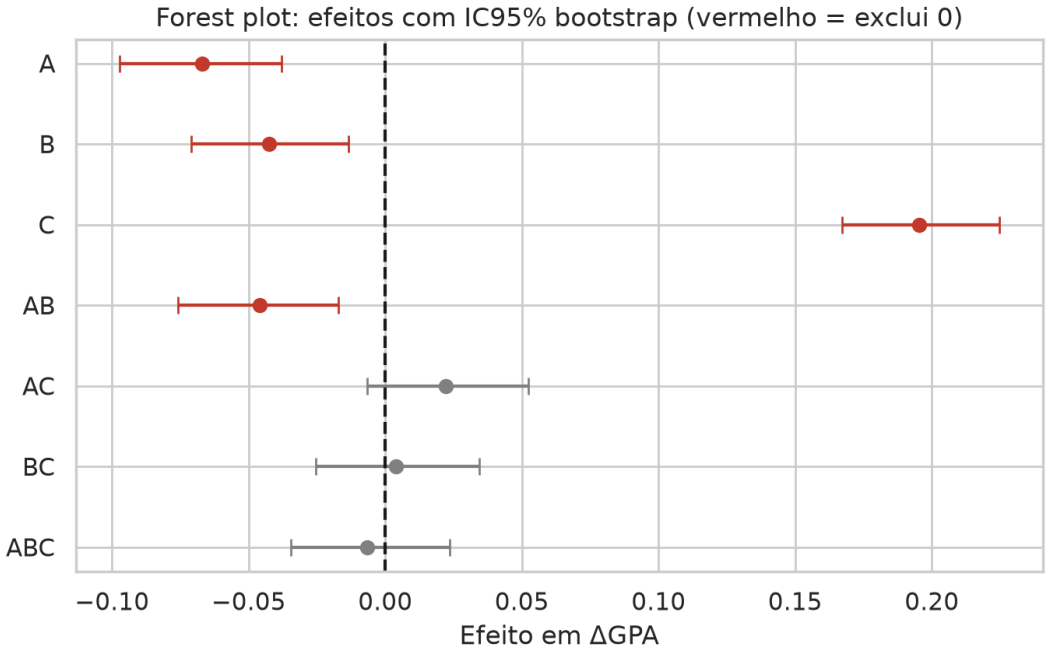


Figura 13: *Forest plot* dos efeitos com IC95% bootstrap.

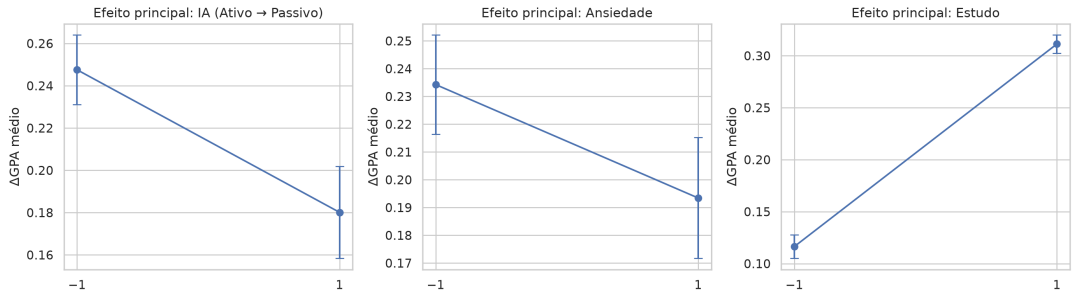


Figura 14: Efeitos principais sobre o ΔGPA.

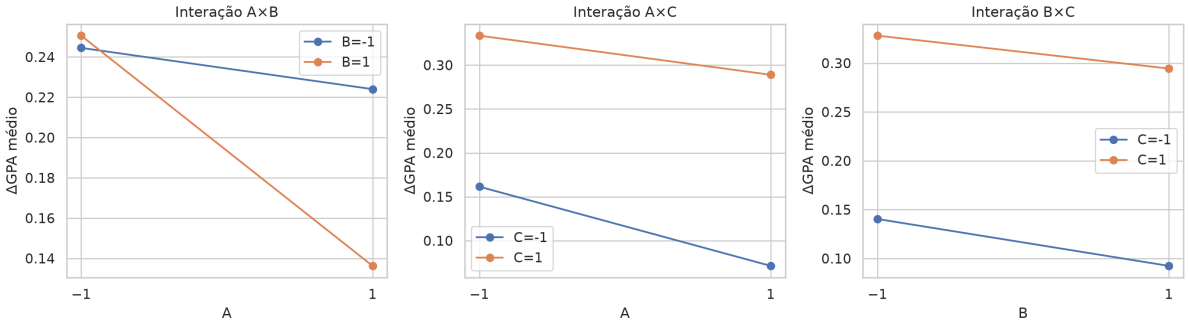


Figura 15: Gráficos de interação entre os fatores.

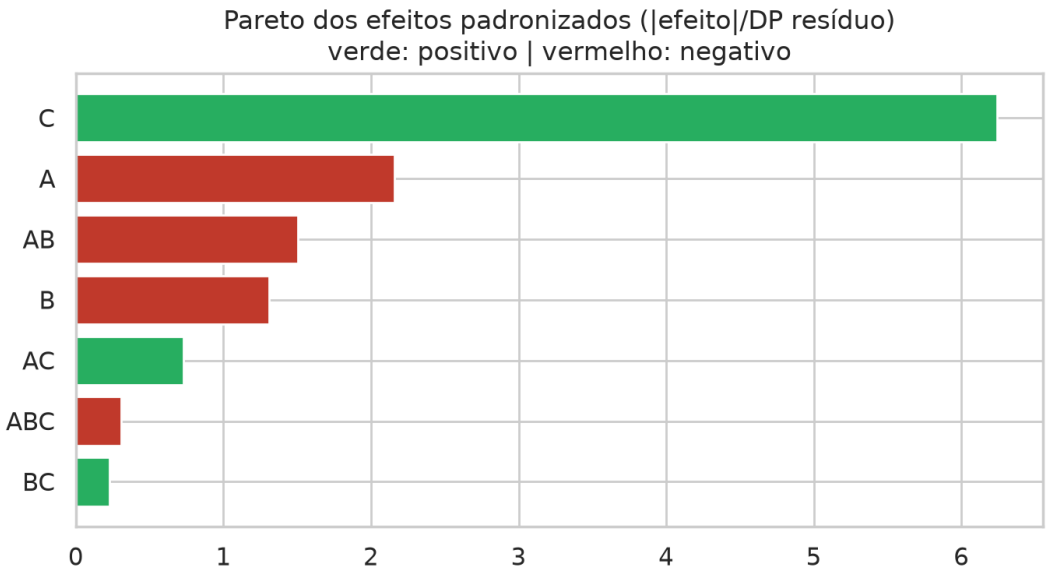


Figura 16: Diagrama de Pareto dos efeitos absolutos.

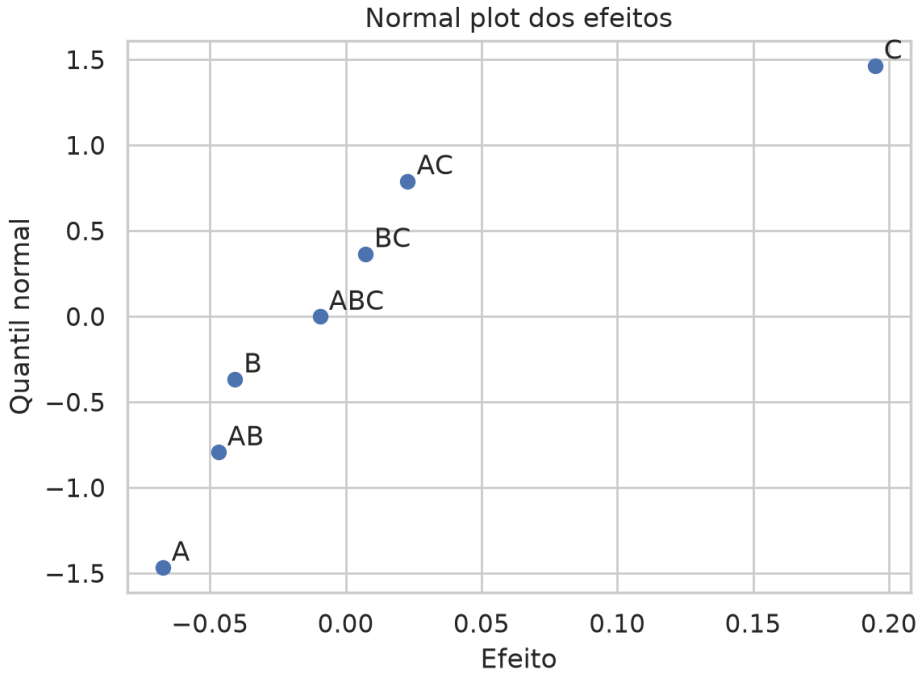


Figura 17: Gráfico normal dos efeitos: pontos afastados da reta são efeitos ativos (C, A, AB e B).

4.5 Diagnóstico dos resíduos e validação

Tabela 8: Checagens de validação.

Checagem	Atendida	Detalhe
Shapiro dos resíduos ($p > 0{,}05$)	Sim	$p = 0{,}807$
Levene entre células ($p > 0{,}05$)	Sim	$p = 0{,}119$
Estabilidade entre sementes (DP $< 0{,}01$)	Sim	DP máx. $= 0{,}0055$
Concordância IC × ANOVA bruta	Não	efeito B "fraco"
Balanceamento de Pre_GPA ($p > 0{,}05$)	Sim	$p = 0{,}61$

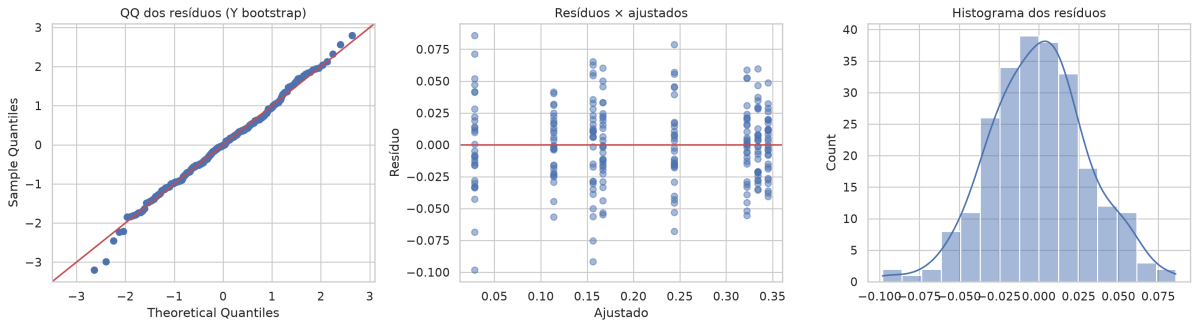


Figura 18: Diagnóstico dos resíduos da ANOVA (normalidade e variância).

4.6 Estabilidade entre sementes

Repetindo o procedimento com 10 sementes, o desvio-padrão dos efeitos fica entre 0,0013 e 0,0055 (A: $-0{,}0674 \pm 0{,}0032$; C: $+0{,}1951 \pm 0{,}0049$; AB: $-0{,}0457 \pm 0{,}0013$), de modo que as conclusões não dependem da semente.

4.7 Análise de sensibilidade

Tabela 9: Efeitos sob definições alternativas de nível (* = IC95% exclui 0).

Definição	n	A	B	C	AB	AC	BC	ABC
$< Q_1 / \geq Q_3$ (principal)	848	$-0{,}067^*$	$-0{,}043^*$	$+0{,}195^*$	$-0{,}046^*$	$+0{,}022$	$+0{,}004$	$-0{,}006$
$\leq Q_1 / \geq Q_3$	1.101	$-0{,}080^*$	$-0{,}038^*$	$+0{,}193^*$	$-0{,}033^*$	$+0{,}011$	$+0{,}006$	$+0{,}005$
Mediana	3.279	$-0{,}077^*$	$-0{,}017^*$	$+0{,}121^*$	$-0{,}023^*$	0,000	$+0{,}011$	$+0{,}010$

Uma ANCOVA com `Pre_GPA` como covariável dá A $= -0{,}065$, B $= -0{,}041$, C $= +0{,}196$ e AB $= -0{,}048$, praticamente idênticos aos principais.

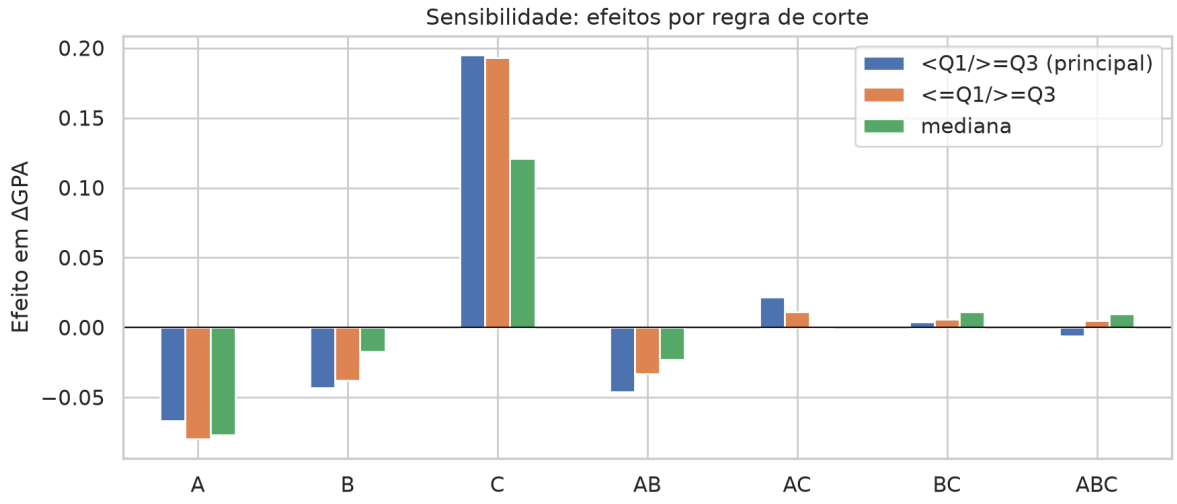


Figura 19: Sensibilidade dos efeitos à definição dos níveis.

5 Caracterização e Análises Finais

Interpretando os efeitos em unidades de GPA (média de + menos média de −):

- **C (horas de estudo):** estudar muito (acima de Q_3) acrescenta cerca de 0,195 ponto em relação a estudar pouco; é o fator dominante (74,7% da variância).
- **A (modo de uso):** o uso passivo reduz o ΔGPA em cerca de 0,067 em média (IC95% $[-0{,}097; -0{,}038]$).
- **AB:** a penalização do uso passivo é maior sob ansiedade alta (célula ab: 0,028 contra 0,114 em a), sugerindo que a ansiedade amplifica o dano do uso passivo.
- **AC:** não significativa; com muitas horas de estudo o efeito do uso passivo se atenua (célula ac: 0,334 vs. c: 0,326), mas a diferença não é distinguível de zero.
- **B:** efeito principal fraco (IC exclui 0, mas p bruto = 0,127).

Recomendação prática preliminar: priorizar usos ativos da IA, especialmente em estudantes ansiosos; o ganho por estudar mais supera o de qualquer escolha de modo de uso.

6 Discussão

Avaliação preliminar da hipótese. Rejeita-se H_0 para A, C e AB, em consistência com H_1: o uso passivo reduz o ΔGPA e o efeito depende da ansiedade. Não há evidência de interação com horas de estudo (AC, BC, ABC) nesta amostra. O resultado é coerente com a Entrega 1 (ATE = −0,072), embora a PSM tenha mudado pouco o resultado porque as covariáveis já estavam balanceadas ($|\text{SMD}| < 0{,}05$).

Limitações.

- *Inflação da ANOVA bootstrap:* as réplicas reusam as mesmas 848 pessoas, logo os p são otimistas; mitigado pelo uso do IC bootstrap e da ANOVA bruta.
- *Definição de "passivo":* inclui *Copywriting*, cujo ΔGPA (0,200) é igual ao de *Ideation*; o efeito vem quase todo de *Direct Answer Generation* (0,133). Restringir a esse uso deixa as células inviáveis ($n = 17$–31).
- *Teto de GPA 4,0:* afeta cerca de 12% do recorte e pode subestimar ganhos.
- *Células passivas pequenas* (36–63 alunos) e desbalanceamento entre células.
- *Dados observacionais:* não há atribuição aleatória do modo de uso; não se estabelece causalidade. A base provavelmente é sintética, limitando a generalização.
- *Exclusão das faixas intermediárias:* 74% do recorte não entra no experimento principal (a sensibilidade pela mediana mostra os mesmos sinais, com efeitos menores).

Correções à Entrega 1. A reavaliação dos dados mostrou que: a base tem 50.000 registros reais (não 10.000 simulados); a tabela descritiva anterior estava incorreta (valores corretos na Tabela 1); a ansiedade não se concentra em 7–10 (moda = 4); e a narrativa de confusão não era sustentada pelos dados.

7 Conclusões e Trabalhos Futuros

O fatorial 2^3r com bootstrap estratificado é viável com os níveis definidos por quartis (menor célula $n = 36$), produz respostas aproximadamente normais, resíduos válidos e resultados estáveis entre sementes. As horas de estudo são o principal determinante do ΔGPA; o uso passivo de IA reduz o ΔGPA em cerca de 0,07 e interage negativamente com a ansiedade alta.

Ajustes planejados para a entrega final:

- Citar a fonte e versão do conjunto de dados e documentar sua natureza.
- Testar definições alternativas de "passivo" (por exemplo, somente *Direct Answer*) com células maiores ou outros recortes.
- Utilizar um esquema de réplicas com subamostras disjuntas (sem reposição) ou validação cruzada para evitar inflação dos p-valores.
- Incluir modelos que tratem o teto de GPA (por exemplo, regressão censurada) e ANCOVA como análise principal.
- Replicar em outros recortes (por exemplo, outras áreas e anos) para avaliar generalização.

A Reprodutibilidade

- Parâmetros: `SEED`=42, $r = 30$, $m = 36$, `NBOOT`=5.000.
- Código: `entrega2/pcc170_entrega02.py` (fonte única) e `pcc170_entrega02.ipynb`.
- Figuras: `entrega2/figuras/` (19 arquivos); tabelas CSV: `entrega2/dados/`.
- Dados: `csv/ai_student_impact_dataset.csv`.