Projeto da disciplina

Projeto e Análise de Experimentos

Prof. Carlos Henrique Gomes Ferreira

UFOP

decom
departamento
de computação

Objetivos

Aplicação Prática de Conceitos:

- Implementar na prática os conceitos da disciplina, sob orientação do professor

Exploração de Temas Avançados:

- Trabalhar com técnicas e áreas que representam o estado da arte em computação relacionados a sua graduação/mestrado/doutorado

Diversificação e Aprofundamento do Conhecimento:

- Ampliar os conhecimentos dos alunos, aprofundando em temas relevantes e diversificando a formação acadêmica

Marco 0: Análise Exploratória dos Dados

A Análise Exploratória dos Dados (AED) é o primeiro contato com os dados do projeto

Esta etapa é fundamental e obrigatória em todos os trabalhos, pois permite

- Caracterização dos dados usando visualizações gráficas e estatísticas
- Essencial para entender a qualidade dos dados
- Orientação das próximas etapas

Obrigatória em todos os trabalhos

Técnica 1: Projeto Fatorial

Os projetos fatoriais permitem analisar simultaneamente os efeitos de vários fatores afetando as métricas de interesse

Capacidade de identificar os efeitos principais de cada fator bem como as interações entre eles

- Possibilita uma compreensão detalhada de como os fatores influenciam conjuntamente a variável resposta

Sobretudo, traz significância estatística para a análise para ignorar erros de medição e fatores não controlados

Técnica 2: Comparação entre sistemas

Uso de intervalos de confiança variados para comparar algoritmos/métodos/plataformas/modelos, etc

Exige hipóteses e cenários de aplicação mais bem definidos e de maior interesse

Por ex.: *"Comparar o tempo de processamento de um processador Intel i3 e um Intel i9 da mesma geração!"*

- Para quê? Por quê? O que te leva a pensar que o i3 será mais rápido?

Alguns exemplos de projetos

Exemplo 1: Virtualizadores em Nuvem

Um virtualizador é um software que cria e gerencia ambientes virtuais

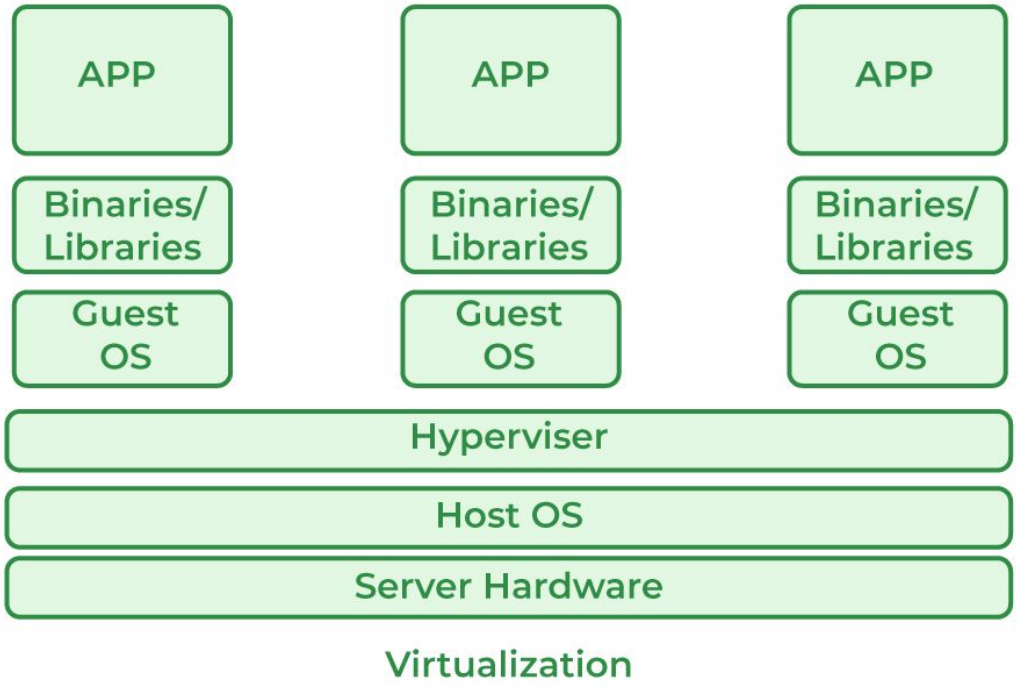
- A escolha do virtualizador pode afetar o desempenho e o aproveitamento dos recursos de uma infraestrutura em nuvem

Problema (Estudo de 2014): Como Xen e KVM respondem a cargas Web e de E/S sob diferentes configurações de memória, vCPU e número de máquinas virtuais?

Hipótese: "*O efeito do virtualizador sobre o desempenho depende da carga de trabalho e da configuração dos recursos da máquina virtual*"

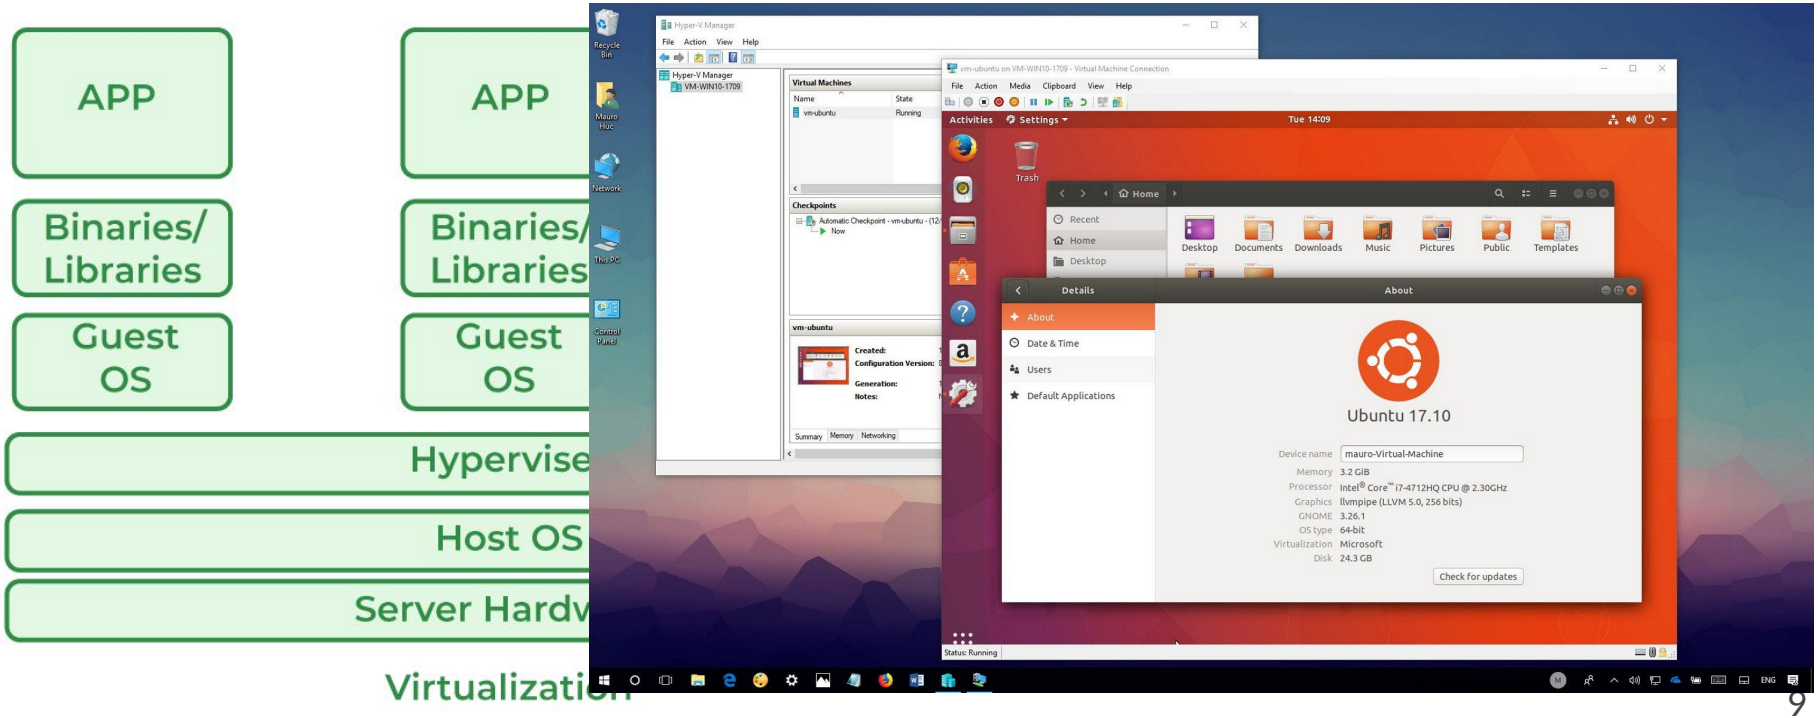
Exemplo 1: Virtualizadores em Nuvem

Ideia geral de um virtualizador:



Exemplo 1: Virtualizadores em Nuvem

Ideia geral de um virtualizador:



Exemplo 1: Virtualizadores em Nuvem

Objetivo: Quantificar os efeitos do virtualizador, da memória, do número de vCPUs e do número de máquinas virtuais sobre o desempenho do sistema

Fatores e níveis:

Fator	Níveis	
Virtualizador	XEN	KVM
Memória	512MB	1024MB
vCPU	1	2
Número de MVs	3	6

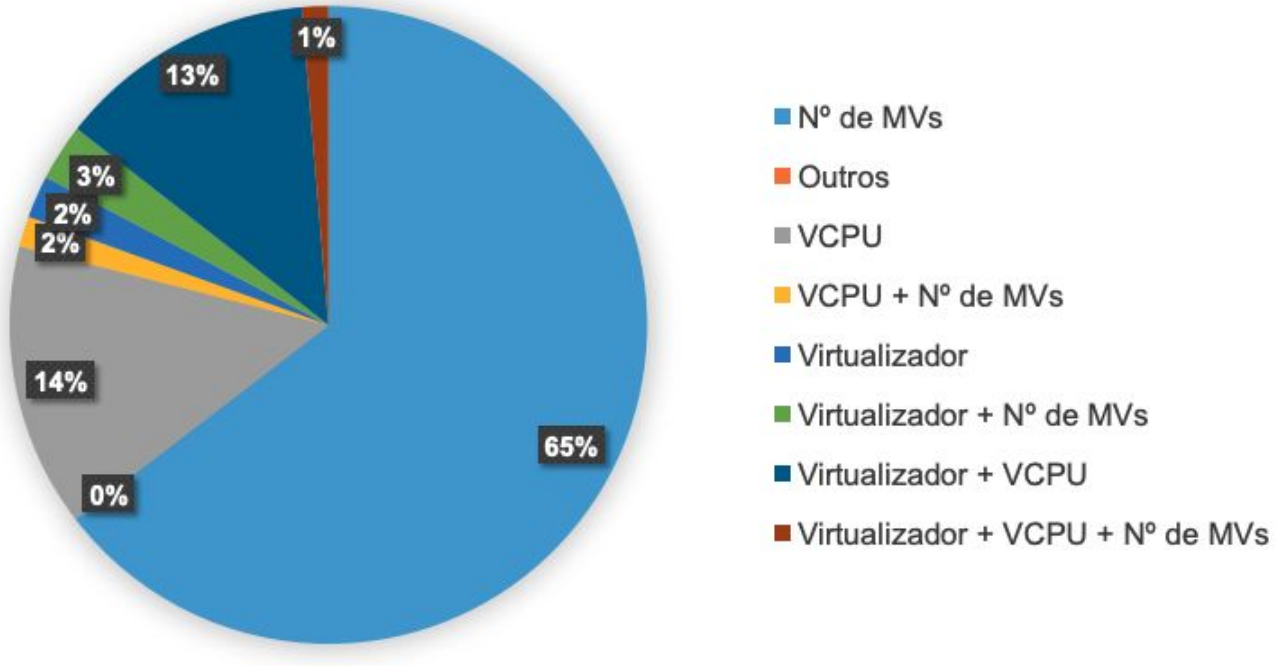
Variáveis resposta: Número de requisições atendidas (Servidor Web Apache), Número de arquivos transferidos (Operações de E/S Postmark)

Projeto Fatorial

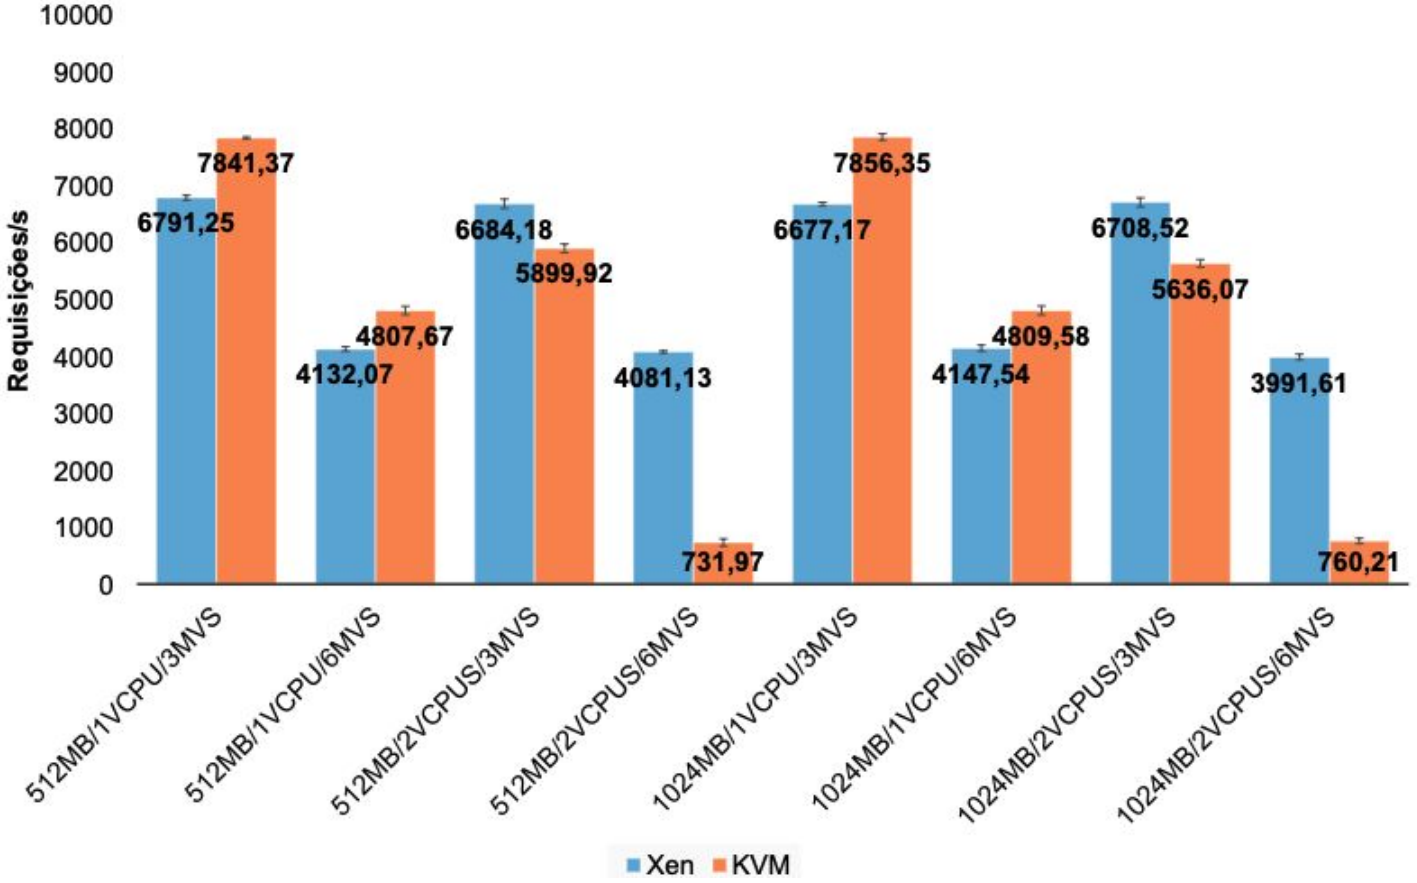
Tabela 2. Combinação dos Fatores e Níveis

Exp.	Virtualizador	Memória MV	vCPU MV	Nº MVs
1	Xen	512 MB	1	3
2	Xen	512 MB	1	6
3	Xen	512 MB	2	3
4	Xen	512 MB	2	6
5	Xen	1024 MB	1	3
6	Xen	1024 MB	1	6
7	Xen	1024 MB	2	3
8	Xen	1024 MB	2	6
9	KVM	512 MB	1	3
10	KVM	512 MB	1	6
11	KVM	512 MB	2	3
12	KVM	512 MB	2	6
13	KVM	1024 MB	1	3
14	KVM	1024 MB	1	6
15	KVM	1024 MB	2	3
16	KVM	1024 MB	2	6

Resultados: Alocação da variação explicada



Servidor Web: Média com 95% de confiança



Resultados: Alocação da variação explicada

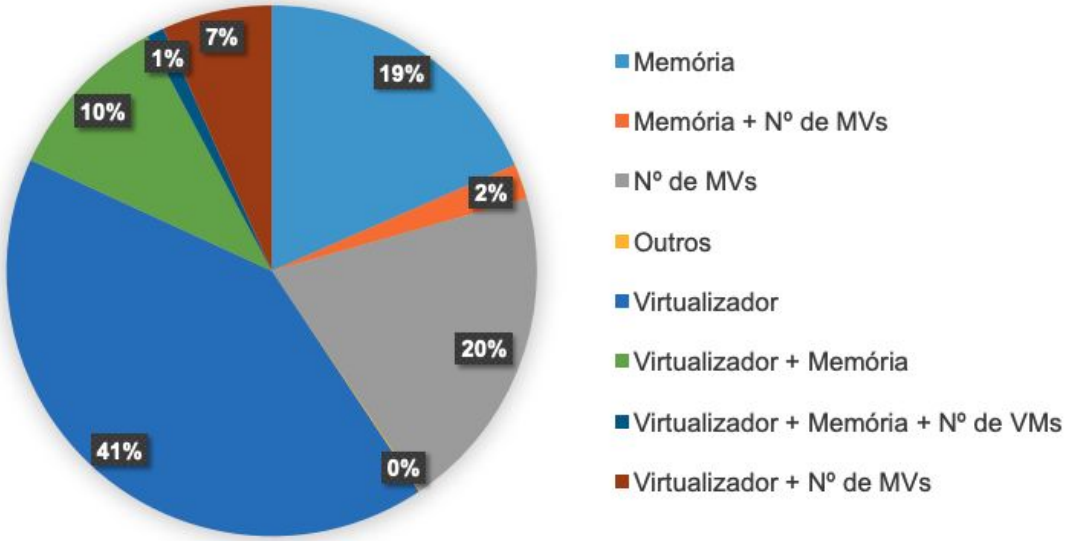
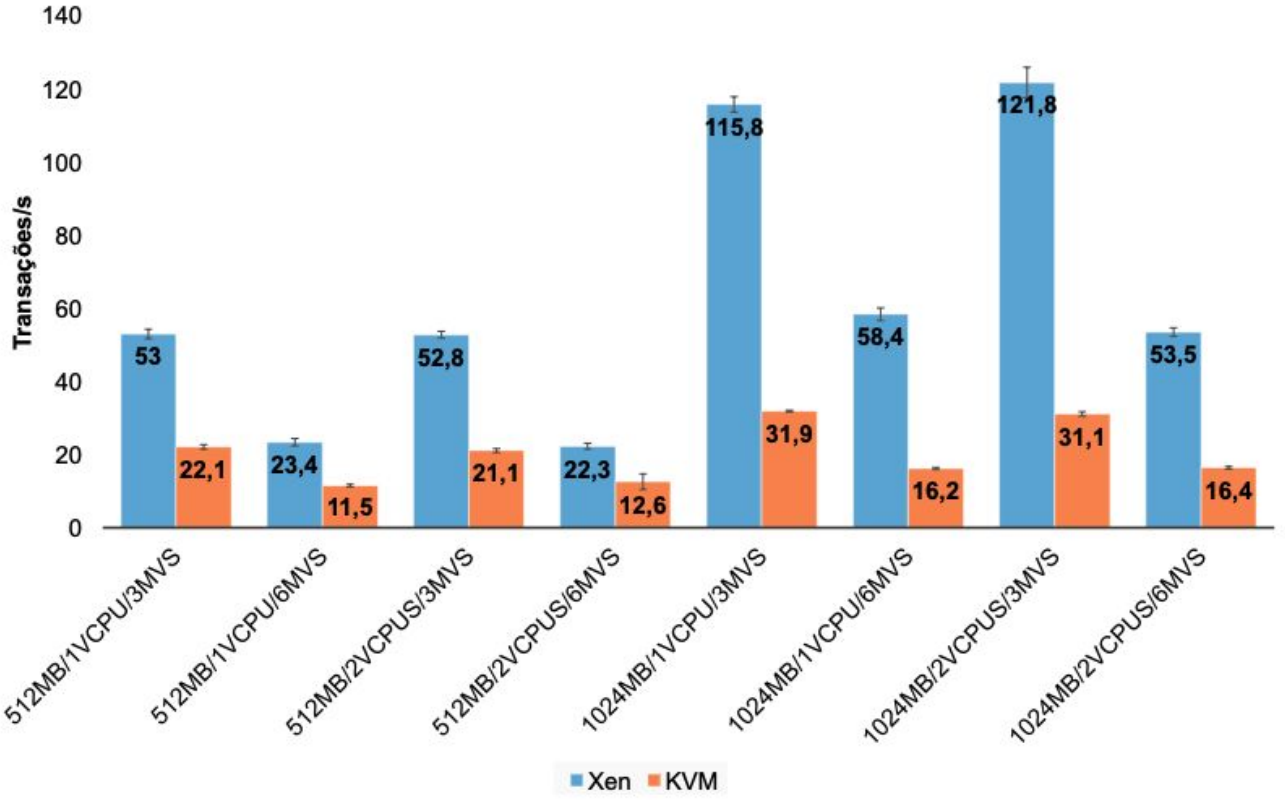


Figura 3. Influência E/S

Servidor de E/S: Média com 95% de confiança



Exemplo 2: Classificação automática de texto

Motivação: A rotulação manual de comentários é cara e precisa ser repetida para cada idioma

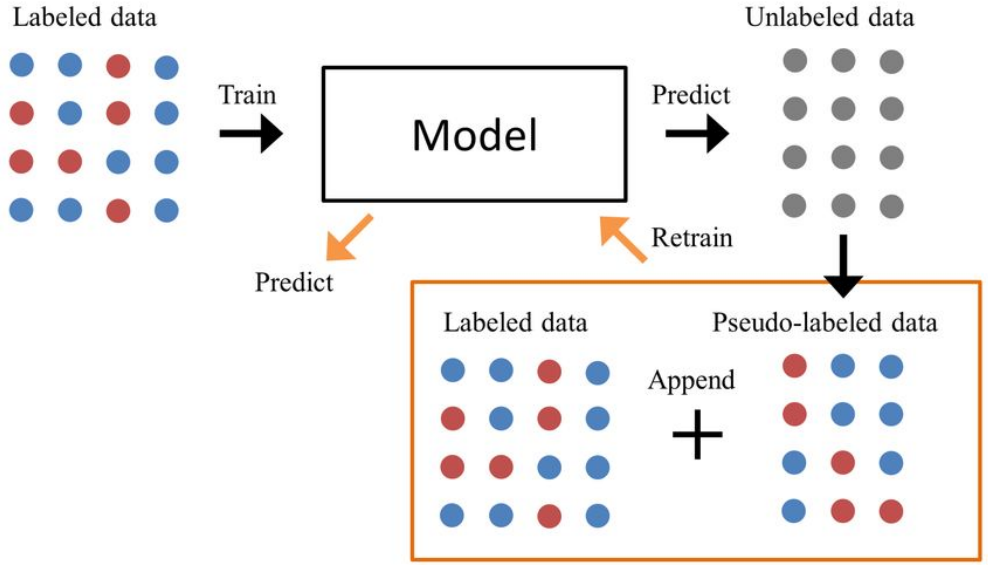
Tarefa: Classificação de um comentário do YouTube em 3 possíveis classes: Favorável, Contrário e Inconclusivo

Problema: Qual estratégia de seleção de pseudo rótulos reduz o custo de rotulação sem comprometer o desempenho do classificador?

Objetivo: Comparar o desempenho das duas estratégias de seleção de pseudorrótulos nos dois idiomas e gerar um modelo final para caracterização

Exemplo 2: Classificação automática de texto

Tarefa: Adotar uma estratégia de *self-labeling*:



Hipótese: *"A seleção por baixa entropia produz maior precisão, revocação e F1-score do que a seleção aleatória, independente do idioma."*

Exemplo 2: Classificação automática de texto

Fatores e Níveis:

Self-training: *Low Entropy* e *Random Sampling*.

Idioma: *Português* e *Inglês*.

A (Idioma)	B (Sampling)	AB (Interação)
1	1	1
1	-1	-1
-1	1	-1
-1	-1	1

Replicações: Validação cruzada 5 folds.

Variáveis Respostas:

Precisão e Recall por Classe: Identifica quais classes o modelo entende melhor ou pior.

F1-Score: Considera a proporção de classes na análise.

Exemplo 2: Classificação automática de texto

Fatores e Níveis:
Self-training: *Low Entropy* e *Random Sampling*.
Idioma: *Português* e *Inglês*.

A (Idioma)	B (Sampling)	AB (Interação)
1	1	1
1	-1	-1
-1	1	-1
-1	-1	1

Replicações: Validação cruzada 5 folds.

Variáveis Respostas:
Precisão e Recall por Classe: Identifica quais classes o modelo entende melhor ou pior.

F1-Score:
Considera a proporção de classes na análise.

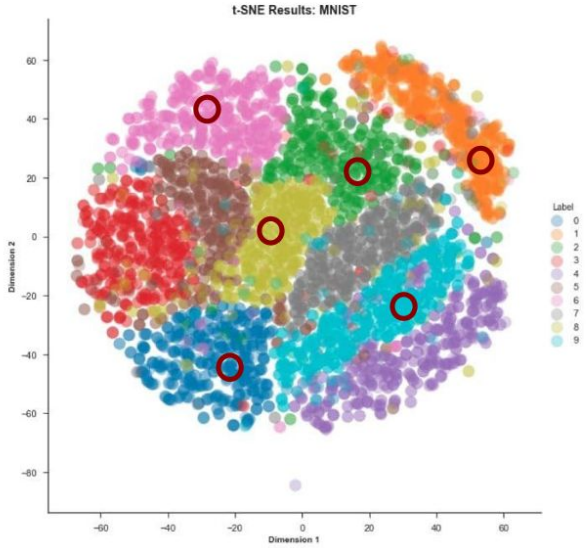
Lhama: meta-llama/Meta-Llama-3.1-8B

Eficiente e com bom desempenho em análise de texto.

Suporta longos contextos e múltiplos idiomas.

Exemplo 2: Classificação automática de texto

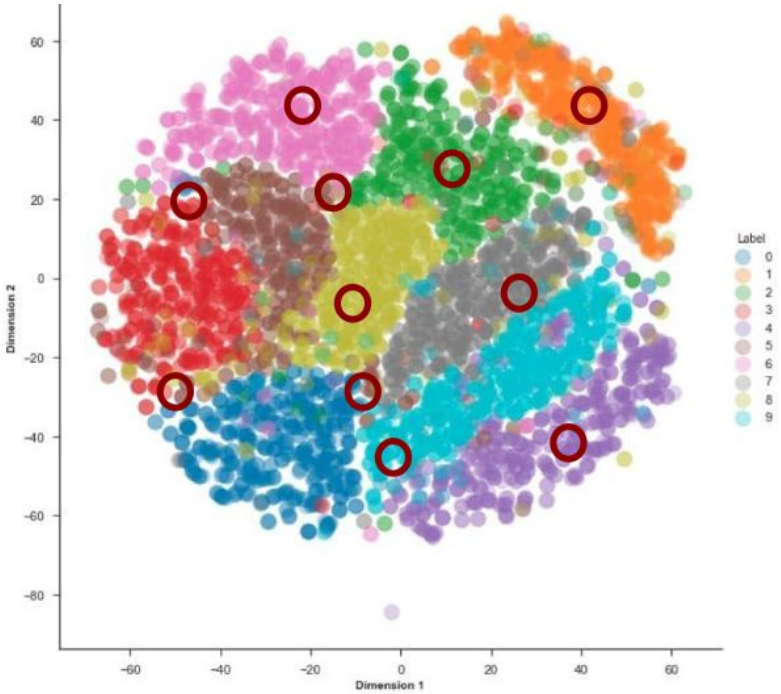
Ex: Seleção de pseudo rótulos usando a abordagem de *"Low Entropy"*



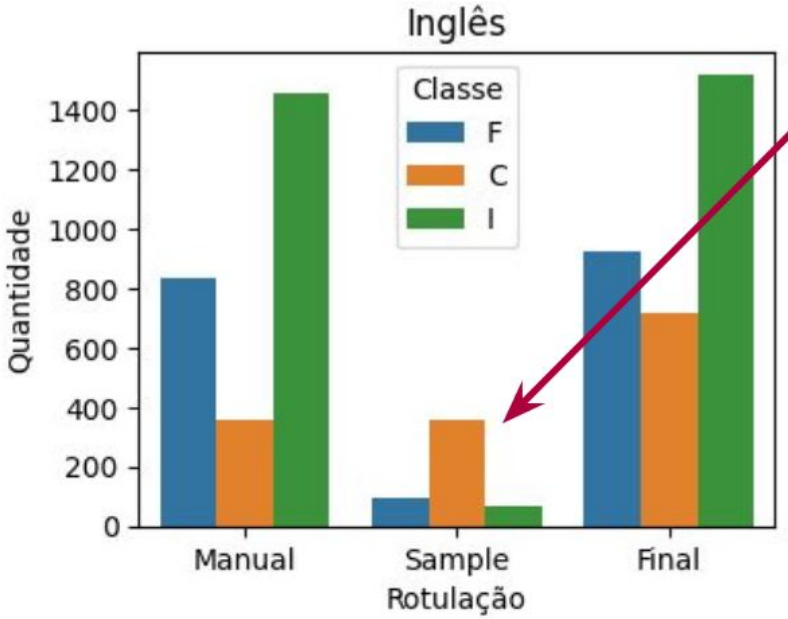
Comentário	F	C	I
Comecei a usar cigarros eletrônicos e desenvolvi problemas respiratórios.	0.2983	0.2905	**0.4111**
I don't trust these vaping gadgets	0.1881	0.3608	**0.4507**
Tried vaping to quit smoking but relapsed to proper cigarettes	0.212	**0.7124**	0.0756
Switched from cigarettes to vape and feel much better	**0.4983**	0.3547	0.1467

Exemplo 2: Classificação automática de texto

Ex: Seleção de *pseudo rótulos* usando a abordagem aleatória:



Exemplo 2: Classificação automática de texto



A quantidade de amostras por classe é inversamente proporcional à sua quantidade inicial

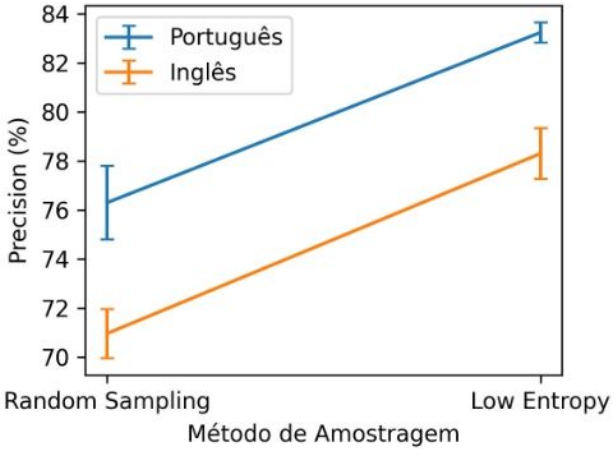
Exemplo 2: Classificação automática de texto

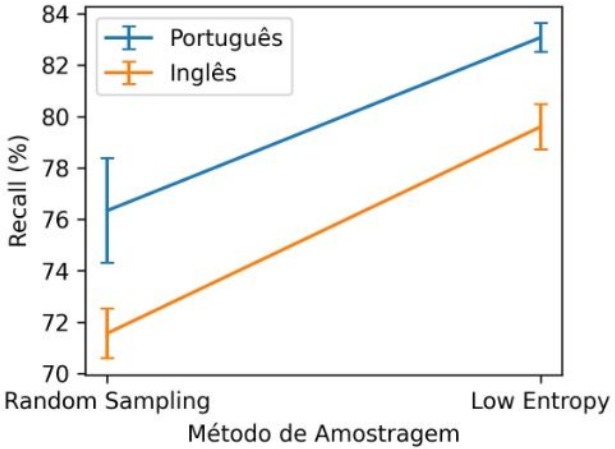
Variação explicada:

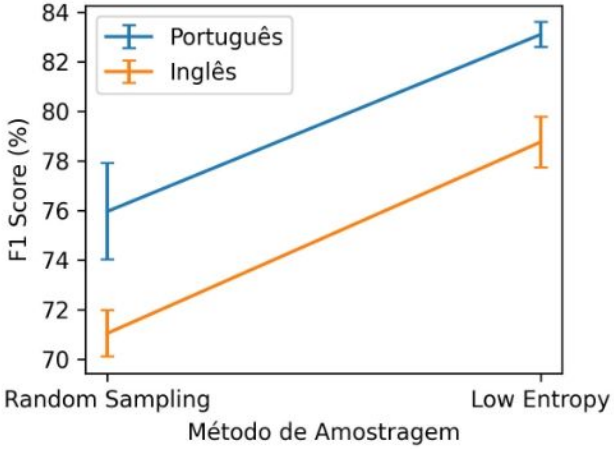
	Idioma	Amostragem	Iteração	Residual
recall	22,42%	71,79%	0.66%	5,23%
precision	32,87%	63,43%	0,05%	3,64%
f1-score	26,60%	68,34%	0,10%	4,80%

Exemplo 2: Classificação automática de texto

Análise do impacto do método de amostragem nas variáveis respostas:

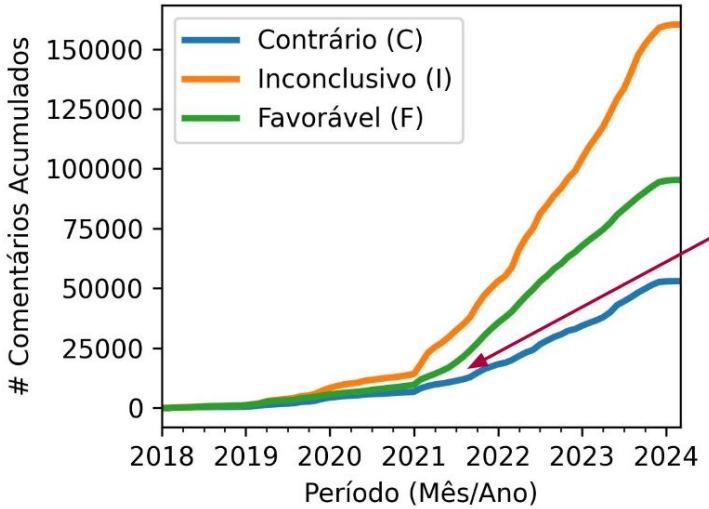






Exemplo 2: Classificação automática de texto

Definição de um classificador final caracterização de toda a base:



É possível notar um aumento no número de comentários a partir de 2021

Exemplo 2: Classificação automática de texto

Posteriormente, uma nova abordagem mista foi proposta e usada para um trabalho final submetido ao BMC Digital Health:

Convergent content, divergent audiences: a multilingual temporal analysis of e-cigarette discourse on YouTube

Aline Martins[1], Lucas Camelo[2], Richardy Tanure[2], Mauro Farina[3], Damiano Ravalico[3], Martino Trevisan[3], Marco A. Romano-Silva[4], Débora M. de Miranda[4], Jussara Almeida[5], Marcos Gonçalves[5], Helen Lima[2], Carlos H. G. Ferreira[6*]

[1]Postgraduate Program in Computer Science, Federal University of Ouro Preto, Ouro Preto, Minas Gerais, Brazil.
[2]Department of Computing and Systems, Federal University of Ouro Preto, João Monlevade, Minas Gerais, Brazil.
[3]Dipartimento di Ingegneria e Architettura, Università degli Studi di Trieste, Trieste, Italy.
[4]Faculty of Medicine, Federal University of Minas Gerais, Belo Horizonte, Minas Gerais, Brazil.
[5]Department of Computer Science, Federal University of Minas Gerais, Belo Horizonte, Minas Gerais, Brazil.
[6*]Department of Computing, Federal University of Ouro Preto, João Monlevade, Minas Gerais, Brazil.

Exemplo 3: Modelagem do perfil da NBA

Motivação: Os estilos de jogo da NBA mudam ao longo do tempo, mas estatísticas isoladas não revelam claramente a evolução dos perfis dos jogadores

Problema: Como identificar perfis consistentes de jogadores e acompanhar suas transições ao longo das temporadas em um conjunto de dados de alta dimensionalidade?

- Técnicas como do estado da arte, como o UMAP, dependem fortemente da parametrização
- Como escolher melhor esses parâmetros?

Exemplo 3: Modelagem do perfil da NBA

Hipótese: *"A parametrização do UMAP, afetam significativamente a qualidade e a estabilidade dos agrupamentos"*

Tarefa: Agrupamento e mapeamento temporal da mudança dos grupos

A configuração selecionada produziu seis perfis interpretáveis. A participação desses perfis e as transições entre eles mudaram ao longo das temporadas

Exemplo 3: Modelagem do perfil da NBA

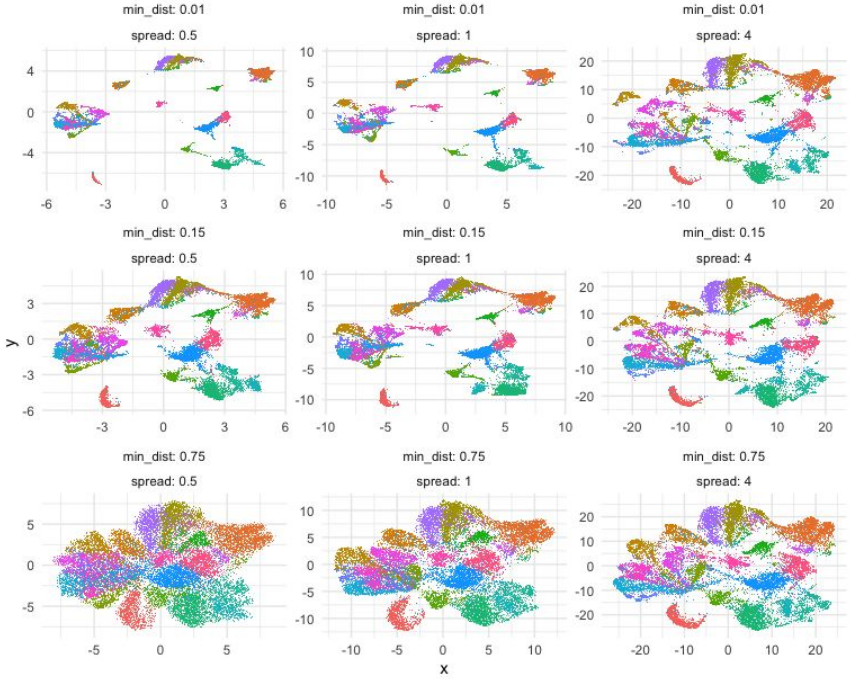
Sugestão para os alunos da pós: Apoiem-se na literatura!!!

Table 1: Summary of representative related work. **RL**: Research Line (**PC** = Player Clustering; **GOP** = Game Outcome Prediction; **PP** = Performance Prediction; **II** = Injury Impact; **LP** = Longitudinal Profiling). **TS**: Temporal Scope (seasons). **Focus / Outcome**: primary analytical objective and modeled output. **LT**: Longitudinal Transitions modeled. Additional abbreviations: EoCC: Effectiveness on Clutch Competency; LMT: Logistic Model Tree; LR: Logistic Regression; RF: Random Forest; ARM: Association Rule Mining; SE: Stacked Ensemble; RTP: Return-to-Play; TDA: Topological Data Analysis.

Study	RL	TS	Focus / Outcome	LT
Alagappan (2012)	PC	1	Topological redefinition of positions; 13 roles via TDA	No
Zhang et al. (2018)	PC	1	Line-up composition; 4 profiles via anthropometric attrs.	No
Osken and Onay (2022)	PC	6	Role typology; clusters via K-Means and C-Means	No
Duman and Sennaroğlu (2024)	PC	15	Position-specific sub-roles; 4–6 per position via AHC	No
Ke et al. (2024)	PC	22	Roster construction; 10 types via PCA + K-Means/AHC	No
Yamada and Fujii (2024)	PC	1	Shooting style and offensive role; tracking-based clusters	No
Thabtah et al. (2019)	GOP	37	Finals outcome forecasting; game winner (83% acc., LMT)	No
Ma (2021)	GOP	24	Playoff qualification; 91.4% acc. (LR)	No
Yao (2023)	GOP	19	Match result with Elo metric; 67% acc. (RF)	No
Horvat et al. (2023)	GOP	5	Efficiency-index prediction; ∼66% acc.	No
He and Choi (2025)	GOP	3	Stacked ensemble + SHAP; game winner	No
Oughali et al. (2019)	PP	1	Shot success from spatial features; 68% acc. (XGBoost)	No
Chen and Chen (2020)	PP	4	MVP prediction; awardee classification (neural network)	No
Vaci et al. (2019)	PP	50	Aging curves; development/decline factors (Bayesian)	No
Iatropoulos et al. (2025)	PP	20	Intra-game patterns by quarter; rules via ARM	No
Sarlis et al. (2024)	PP	21	Clutch performance; EoCC metric	No
DeFroda et al. (2021)	II	9	ACL recovery; performance decline (84% RTP)	No
Tummala et al. (2023)	II	6	Ankle injury risk; recurrence and recovery duration	No
Nosrat et al. (2025)	II	–	Meniscal tear surgery; RTP and post-surgery performance	No
Sarlis et al. (2025)	II	23	Multi-injury impact; performance across post-injury windows	No
TeMPO (ours)	**LP**	**27**	**Longitudinal role evolution; clusters + inter-season transitions**	**Yes**

Exemplo 3: Modelagem do perfil da NBA

Riscos de uma má parametrização do UMAP



Exemplo 3: Modelagem do perfil da NBA

Fatores e níveis:

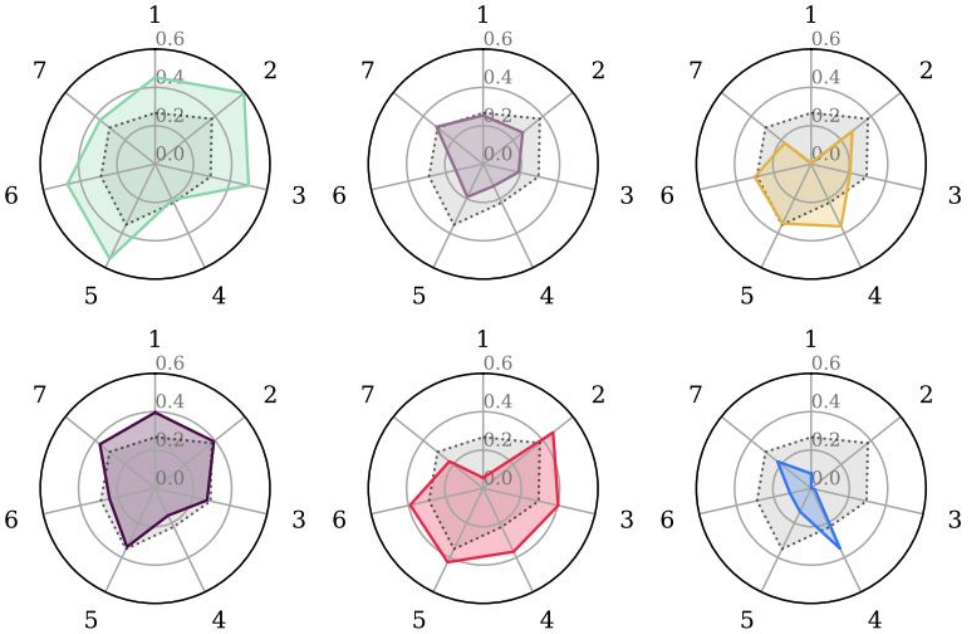
- **# Vizinhos:** 15 vs 30
- **# Componentes:** 15 vs 30
- **Tipo de normalização dos dados:** Robusta vs Min-Max
- ***Features:*** Features selecionadas (com base na literatura e análise de correlação-PCA) e todas as features do conjunto de dados

Variável resposta: Silhouette Score

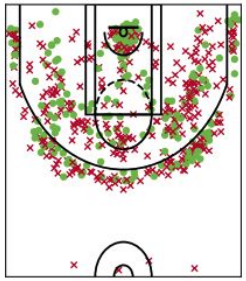
Replicações: 10

Exemplo 3: Resultados

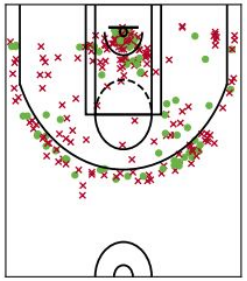
ID	Attribute	Gini Index
1	Three-point field goals made (FG3M)	0.52
2	Long mid-range shots pct (LONG MID RANGE SHOT PCT)	0.41
3	Long mid-range shots missed (LONG MID RANGE SHOT U)	0.36
4	Blocks (BLK)	0.33
5	Mid-range shots missed (MID RANGE SHOT U)	0.29
6	Mid-range shots pct (MID RANGE SHOT PCT)	0.29
7	Assists Ratio (AST RATIO)	0.27



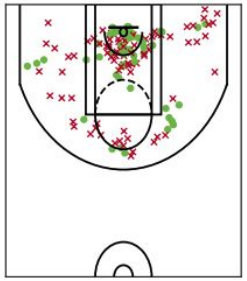
Exemplo 3: Resultados



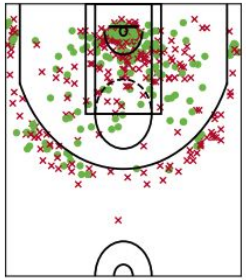
(a) Cluster 1: Balanced offensive activity with moderate efficiency.



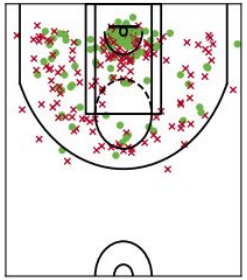
(b) Cluster 2: Minimal shot attempts, likely tactical spacing roles.



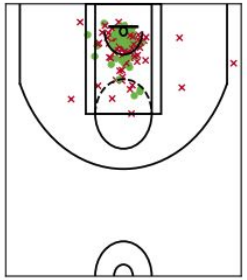
(c) Cluster 3: Near-rim attempts, strong defensive presence.



(d) Cluster 4: High-volume scorers across all court areas.

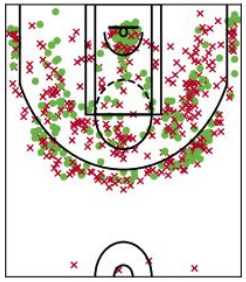


(e) Cluster 5: Interior-focused scorers with defensive roles.

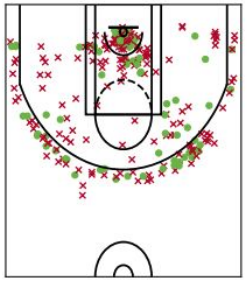


(f) Cluster 6: Near-rim attempts.

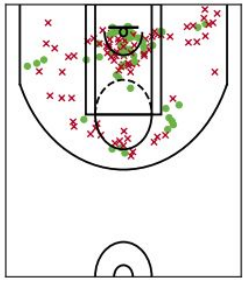
Exemplo 3: Resultados



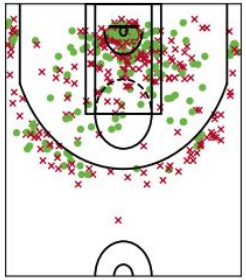
(a) Cluster 1: Balanced offensive activity with moderate efficiency.



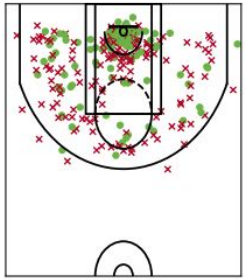
(b) Cluster 2: Minimal shot attempts, likely tactical spacing roles.



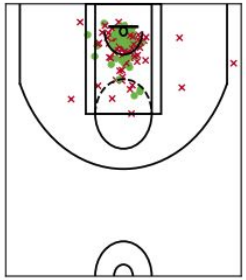
(c) Cluster 3: Near-rim attempts, strong defensive presence.



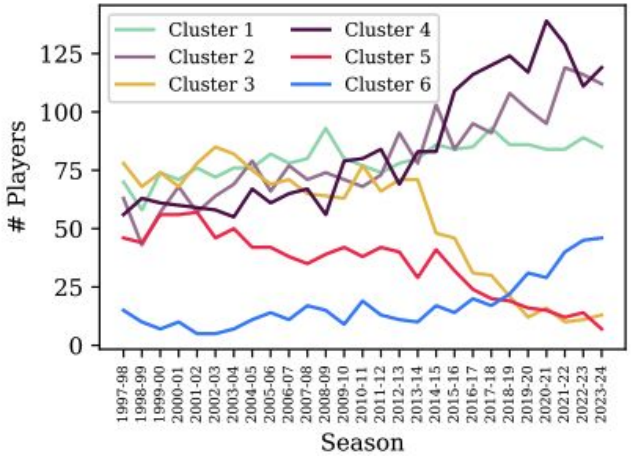
(d) Cluster 4: High-volume scorers across all court areas.



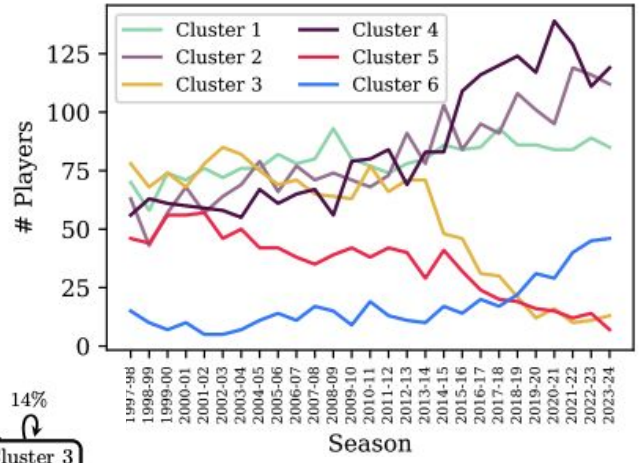
(e) Cluster 5: Interior-focused scorers with defensive roles.

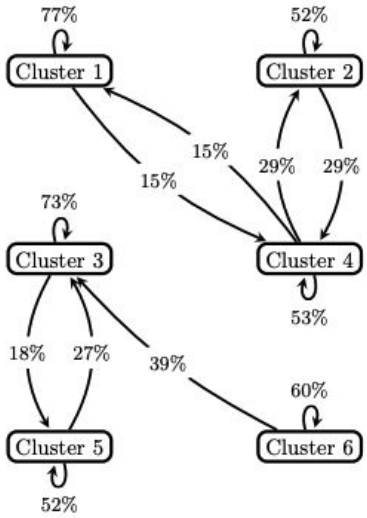


(f) Cluster 6: Near-rim attempts.

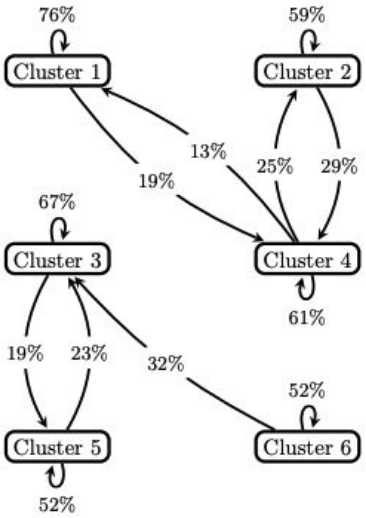


Exemplo 3: Resultados

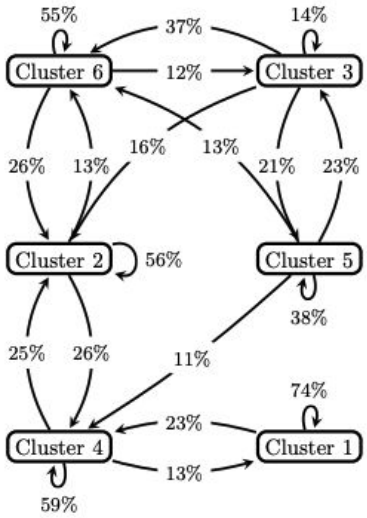




(a) 1997 - 2007.

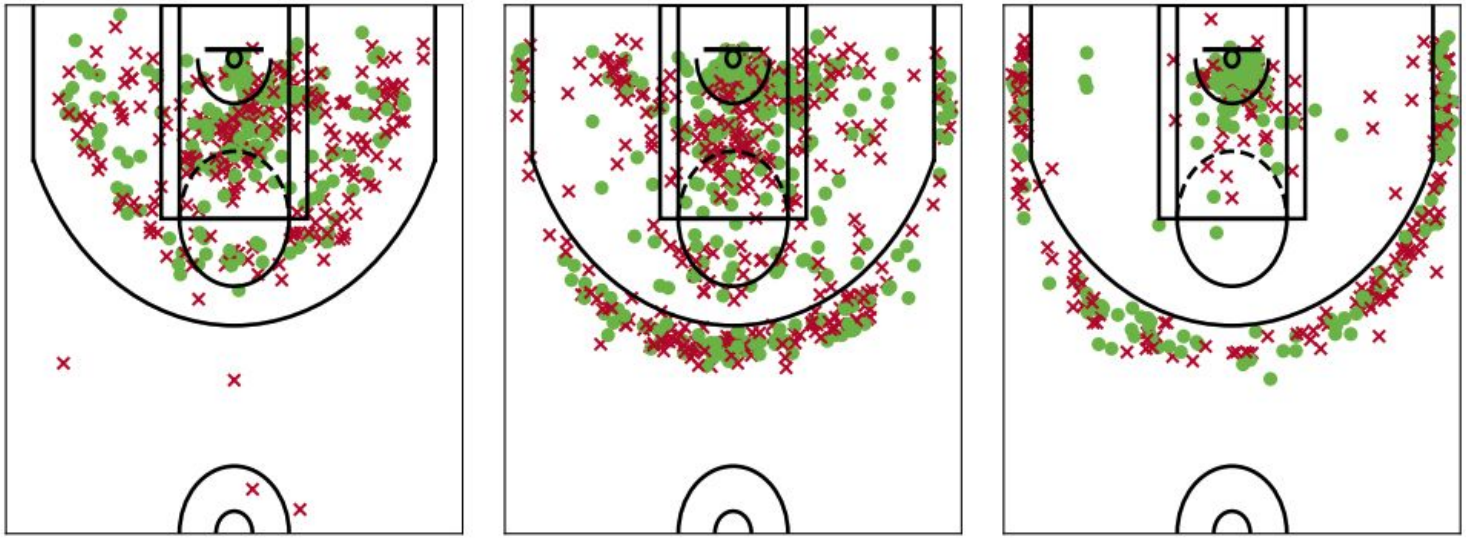


(b) 2008 - 2018.



(c) 2019 - 2024.

Exemplo 3: Resultados



(a) Shot chart in 2007. (b) Shot chart in 2017. (c) Shot chart in 2023.

Fig. 12: Shot maps for Al Horford across three key seasons (2007, 2017, 2023).

Exemplo 3: Resultados



Home > Journal of Big Data > Article

TeMPO: A framework for longitudinal mapping of NBA player profiles

Research | Open access | Published: 16 July 2026

Cite this article

You have full access to this open access article

Download PDF | Save article

Journal of Big Data

Aims and scope →

Submit manuscript →

Marco Túlio M. Madeira, Luca Vassio, Alexandre M. de Sousa & Carlos H. G. Ferreira

89 Accesses Explore all metrics →

We're sharing this article early to provide faster access to peer-reviewed, accepted research. It is citable and carries a permanent DOI. This version is subject to further edits and will be replaced automatically by the final Version of Record. All legal disclaimers apply.

Abstract

Part of a collection:
Big Data and Data-driven in Sports

Sections | Figures

Abstract

Acknowledgements

Funding

Author information

Exemplo 4: FOG em indivíduos com Parkinson

Motivação: A detecção automática do congelamento da marcha pode apoiar o monitoramento por dispositivos vestíveis, que possuem recursos computacionais limitados

Problema: Qual combinação de janela, quantidade de dados e representação dos atributos oferece o melhor desempenho para detectar episódios de FOG?

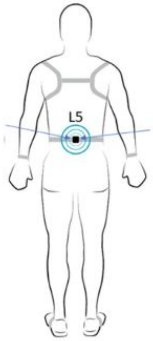
Hipótese: *"A engenharia de features sobre o sinal do dispositivo pode afetar significativamente o desempenho."*

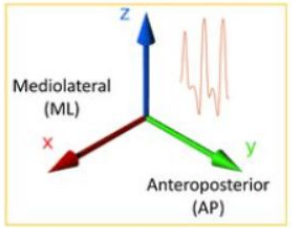
Exemplo 4: FOG em indivíduos com Parkinson

Objetivo: Quantificar os efeitos de parâmetros do modelo para identificar uma configuração eficiente para a detecção de FOG

Tarefa: Aprendizado de máquina - Classificação

Aspecto interessante: Dados de um estudo anterior da literatura





Aceleração de um sensor lombar em três eixos:
Z - vertical
ML – médio lateral
AP - anteroposterior

Exemplo 4: FOG em indivíduos com Parkinson

Projeto Experimental com algoritmo *Light GBM* fixo:

Tamanho da Janela	Tamanho da Base	Engenharia de Features
100	0.5	4 Momentos Distribuição
100	0.5	Medidas Descritivas
100	1	4 Momentos Distribuição
100	1	Medidas Descritivas
200	0.5	4 Momentos Distribuição
200	0.5	Medidas Descritivas
200	1	4 Momentos Distribuição
200	1	Medidas Descritivas

Variáveis resposta: Acurácia, Precisão, Revocação, F1-Score

Replicações: 10 treinamentos com amostras distintas

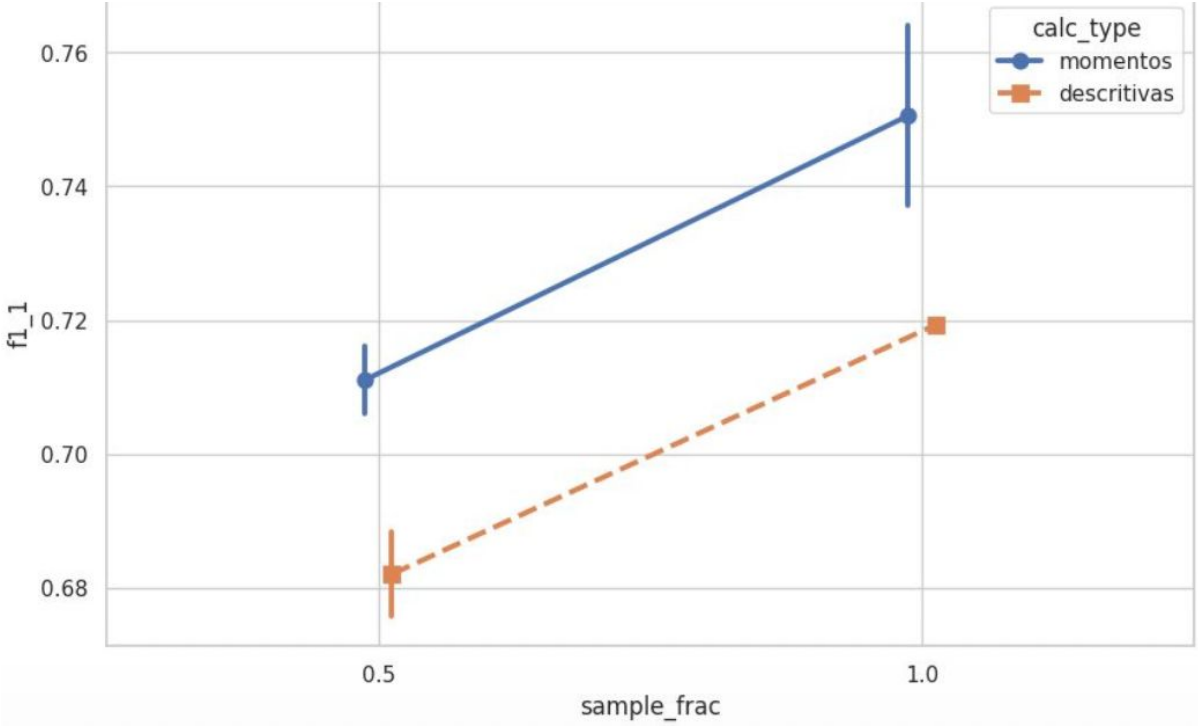
Resultados

Alocação da Variação:

Fator	Efeito	Variação	Intervalo Confiança
window_size	0.0073	8.01%	[-0.0027, 0.0073, 0.0173]
sample_frac	0.0179	47.98%	[0.0079, 0.0179, 0.0279]
calc_type	-0.0155	36.23%	[-0.0103, -0.0057, -0.0012]
window_size sample_frac	0.0009	0.13%	[-0.0091, 0.0009, 0.0110]
window_size calc_type	-0.0054	4.39%	[-0.0154, -0.0054, 0.0046]
sample_frac calc_type	0.0014	0.31%	[-0.0086, 0.0014, 0.0115]
window_size sample_frac_calc_type	0.0001	0.0001%	[-0.0099, 0.0001, 0.0101]
Erro		2.94%	

Resultados

Alocação da Variação:



Dúvidas?

Créditos

Este material é baseado nos livros textos da disciplina em questão e foi desenvolvido pelo professor Carlos Henrique Gomes Ferreira. Além disso, ele está licenciado sob uma **Licença Creative Commons Atribuição 4.0 Internacional (CC BY 4.0)**. Versão 1.0. 02/2024.