Comparação entre experimentos

Projeto e Análise de Experimentos

Prof. Carlos Henrique Gomes Ferreira



UFOP

DECSI

DEPARTAMENTO DE COMPUTAÇÃO E SISTEMAS

“It is easy to lie with statistics. It is hard to tell the truth without statistics.” — Andrejs Dunkels (1939–1998)

Motivação

Uma amostra de dados, tipicamente, não é suficiente para fazer uma definição final sobre um sistema, algoritmo, ou coisa qualquer

- Por exemplo, comparamos dois algoritmos com 5 ou 10 conjuntos de dados e então dizemos que um é melhor do que o outro

Não podemos fazer essa afirmação definitivamente

- Mas podemos fazer uma afirmação probabilística sobre a faixa em que as características da maioria dos experimentos se encontram

Foco: Vamos entender os conceitos fundamentais para comparar experimentos a partir de dados

População vs. Amostra

Definições Básicas:

- **População:** Conjunto completo de dados (números)
- **Amostra:** Subconjunto de dados retirados da população

Média Populacional vs. Média Amostral:

- **Média Populacional (μ):** Média de todos os dados na população.
- **Média Amostral ($\bar{x}$):** Média dos dados na amostra

Exemplo:

- População tem média μ e desvio padrão σ
- Amostra {x1, x2, ..., xn} tem média amostral $\bar{x}$
- $\bar{x}$ é uma estimativa de μ, mas pode diferir de μ

Parâmetros vs. Estatísticas

Diferenças Cruciais:

- **Parâmetros:** Características fixas da população (ex: μ e σ)
  - São fixos e desconhecidos
- **Estatísticas:** Estimativas calculadas a partir da amostra (ex: $\bar{x}$ e s)
  - São variáveis e dependem da amostra

Notação:

- **Parâmetros:** Letras gregas (ex: μ para média, σ para desvio padrão)
- **Estatísticas:** Letras latinas (ex: $\bar{x}$ para média amostral, s para desvio padrão amostral)

Ex 1: Tempo de Execução de Algoritmos

Contexto: Avaliamos o tempo de execução de dois algoritmos: A e B

- **População:** Todos os possíveis tempos de execução dos algoritmos em todos os conjuntos de dados (Não temos)
- **Amostra:** Medimos o tempo de execução em 10 conjuntos de dados diferentes para cada algoritmo

Média Populacional vs. Média Amostral:

- **Média Populacional (μ):** Tempo de execução médio verdadeiro para cada algoritmo em todos os conjuntos de dados possíveis
- **Média Amostral ($\bar{x}$):** Tempo de execução médio calculado a partir dos 10 conjuntos de dados amostrados

Ex 1: Tempo de Execução de Algoritmos

Resultados:

- Algoritmo A: Média amostral $\bar{x}_A = 2.3$ segundos
- Algoritmo B: Média amostral $\bar{x}_B = 2.7$ segundos

Conclusão: As médias amostrais sugerem que o Algoritmo A pode ser mais rápido, mas precisamos considerar a variabilidade amostral

Ex 2: Desempenho de Modelos de M.L.

Contexto: Avaliamos a acurácia de dois modelos de classificação: Modelo X e Modelo Y

- **População:** Todos os possíveis valores de acurácia dos modelos em todos conjuntos de dados aplicáveis ao modelo
- **Amostra:** Testamos os modelos em 10 conjuntos de dados diferentes

Ex 2: Precisão de Modelos de M.L.

Acurácia: Métrica de desempenho de um modelo de classificação que indica a proporção de previsões corretas em relação ao total de previsões feitas pelo modelo:

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN}$$

VP (Verdadeiros Positivos): Número de previsões corretas onde o modelo previu a classe positiva corretamente

VN (Verdadeiros Negativos): Número de previsões corretas onde o modelo previu a classe negativa corretamente

FP (Falsos Positivos): Número de previsões incorretas onde o modelo previu a classe positiva erroneamente

FN (Falsos Negativos): Número de previsões incorretas onde o modelo previu a classe negativa erroneamente

Ex 2: Precisão de Modelos de M.L.

Média Populacional vs. Média Amostral:

- **Média Populacional (μ):** Acurácia média verdadeira dos modelos em todos os conjuntos de dados possíveis
- **Média Amostral ($\bar{x}$):** Acurácia média calculada a partir dos 10 conjuntos de dados amostrados

Resultados:

- Modelo X: Média amostral $\bar{x}_X = 85\%$
- Modelo Y: Média amostral $\bar{x}_Y = 80\%$

Conclusão: As médias amostrais sugerem que o Modelo X pode ser mais preciso, mas precisamos considerar a variabilidade amostral

Ex 2: Precisão de Modelos de M.L.

Média Populacional vs. Média Amostral:

- **Média Populacional (μ):** Acurácia média verdadeira dos modelos em todos os conjuntos de dados possíveis
- **Média Amostral (x̄):** Acurácia média calculada em um conjunto de dados específico

Como expressar nossa incerteza nas estimativas por meio de Intervalos de Confiança?

- Modelo X: Média amostral x̄_X = 85%
- Modelo Y: Média amostral x̄_Y = 80%

Conclusão: As médias amostrais sugerem que o Modelo X pode ser mais preciso, mas precisamos considerar a variabilidade amostral

Estimando os Intervalos de Confiança

Estimativas Precisas: Em muitas situações, é impraticável ou impossível medir toda a população

- Em vez disso, usamos uma amostra e queremos inferir sobre a população

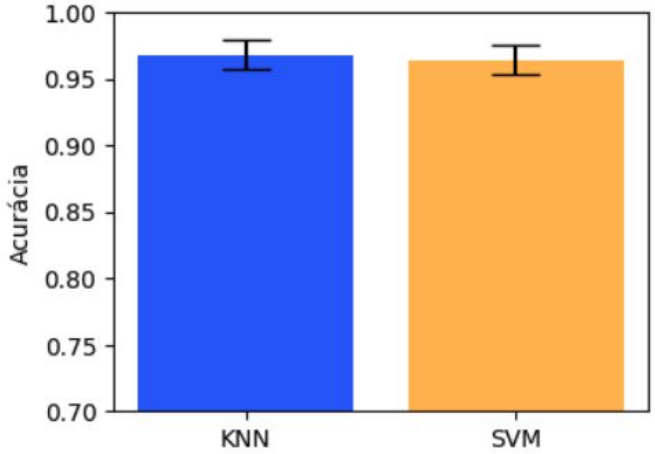
Incerteza das Estimativas: As estimativas pontuais (como a média amostral) podem não ser exatas

- O intervalo de confiança fornece uma faixa de valores possíveis para o parâmetro populacional, considerando a variabilidade da amostra

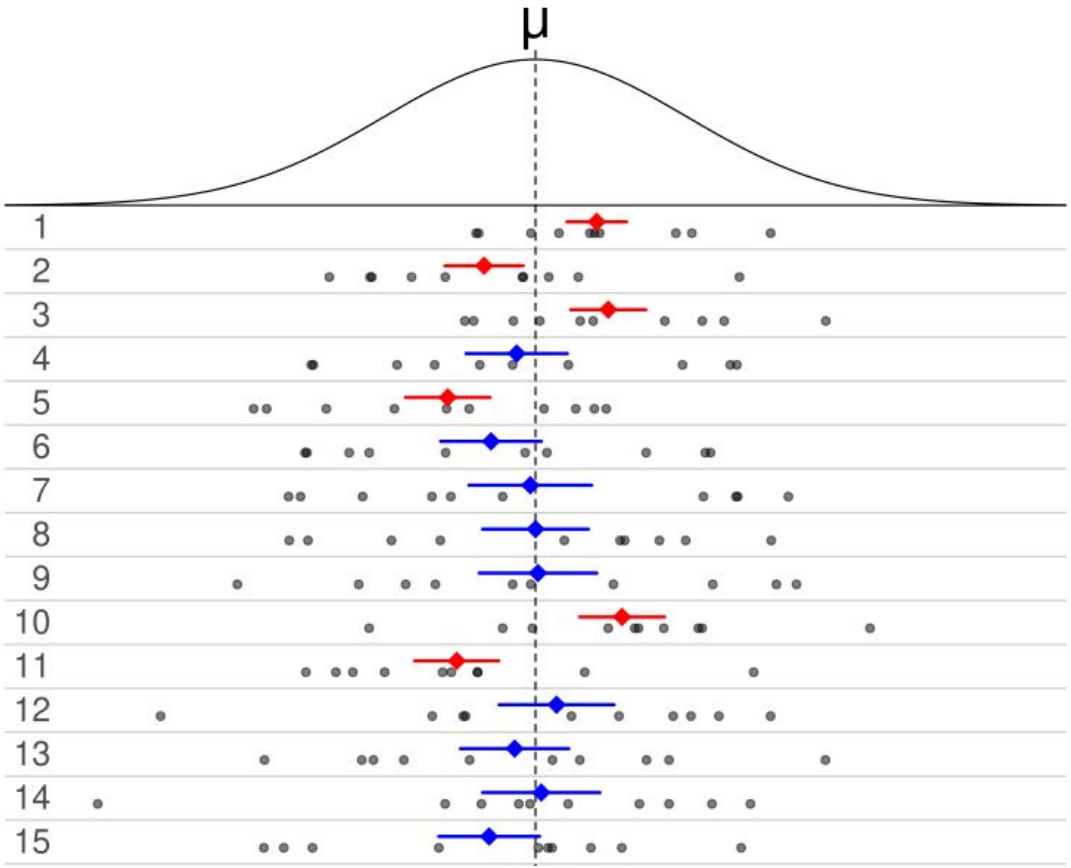
Estimando os Intervalos de Confiança

Como funciona? Um intervalo de valores é calculado a partir de dados amostrais, possui uma determinada probabilidade de conter o valor verdadeiro do parâmetro populacional.

- Representado na forma (c1,c2), onde c1 e c2 são os limites inferior e superior do intervalo

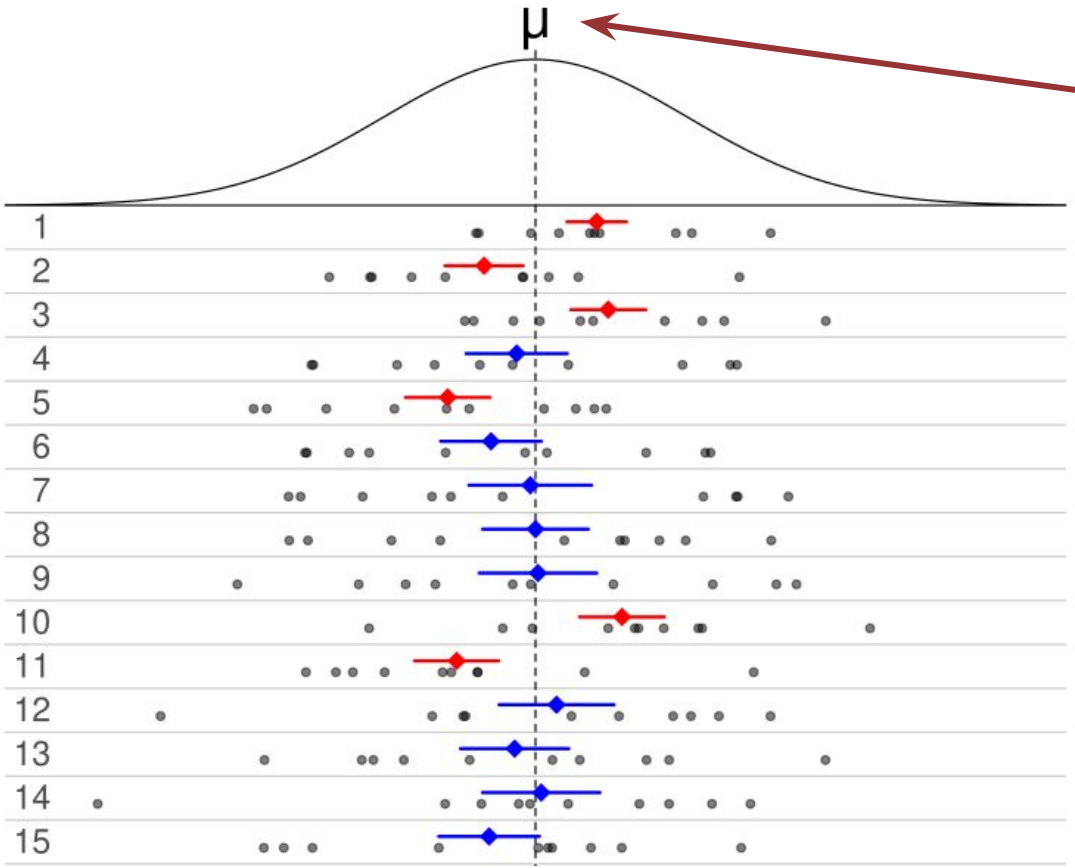


Significado de um Intervalo de Confiança



Fonte: https://en.wikipedia.org/wiki/Confidence_interval

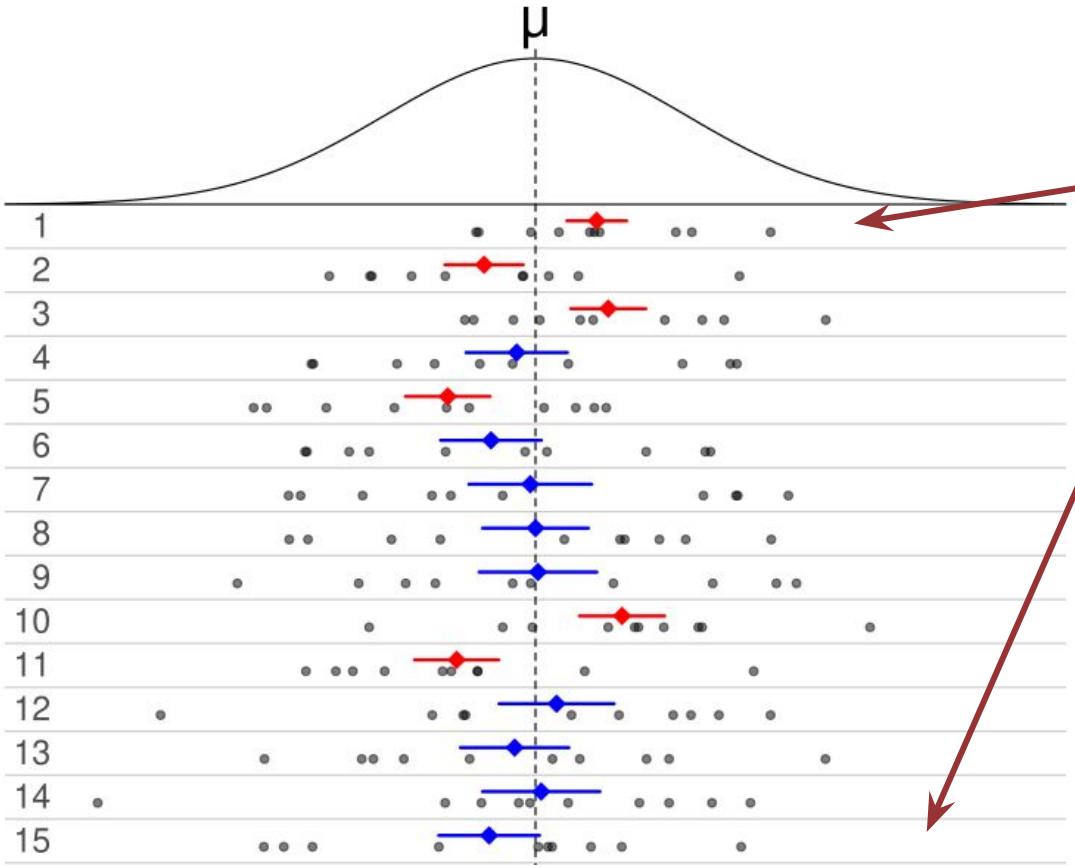
Significado de um Intervalo de Confiança



Média populacional: Desconhecida

Fonte: https://en.wikipedia.org/wiki/Confidence_interval

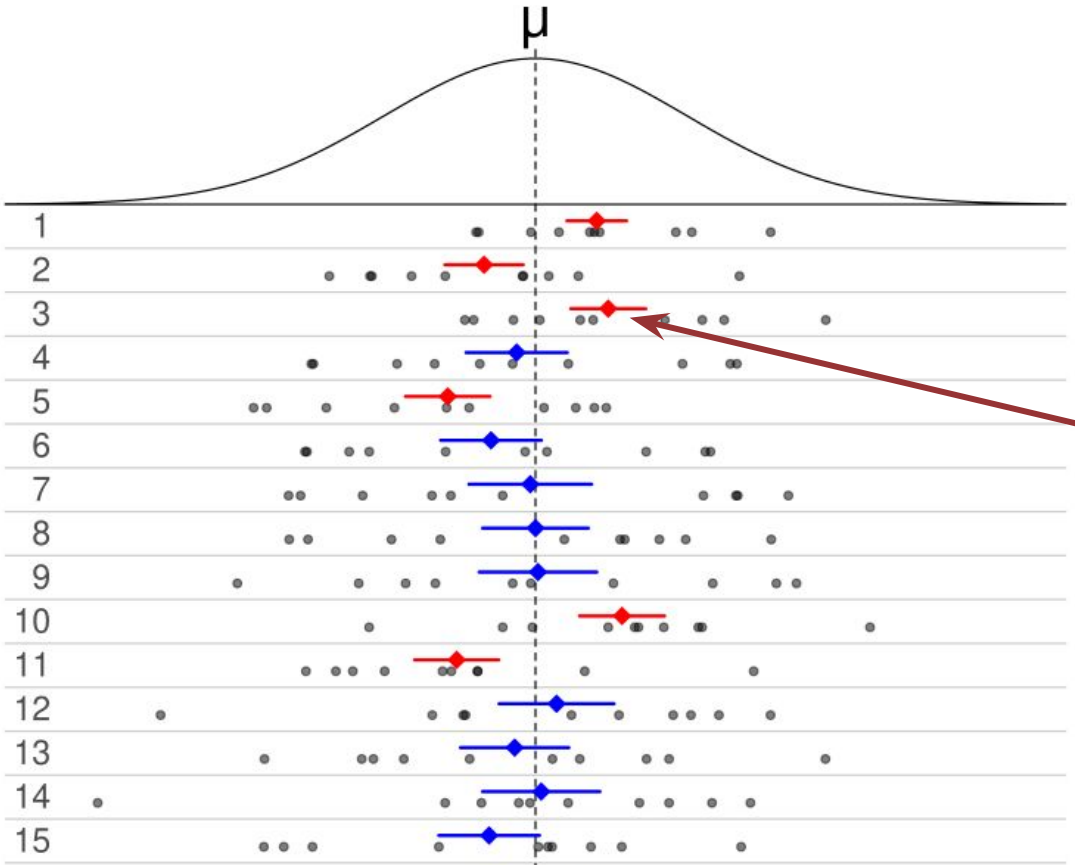
Significado de um Intervalo de Confiança



Considere 15 amostras a partir da população

Fonte: https://en.wikipedia.org/wiki/Confidence_interval

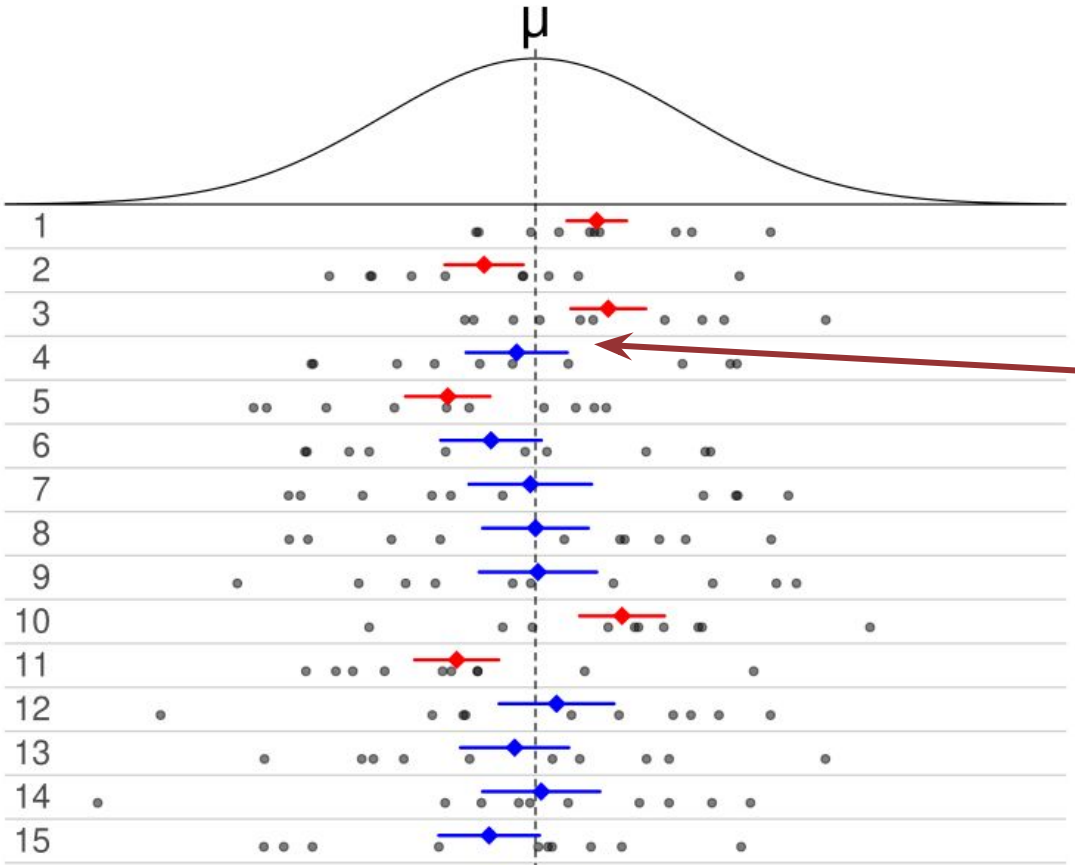
Significado de um Intervalo de Confiança



Considere a média e um intervalo de confiança para cada amostra indicado por esse intervalo

Fonte: https://en.wikipedia.org/wiki/Confidence_interval

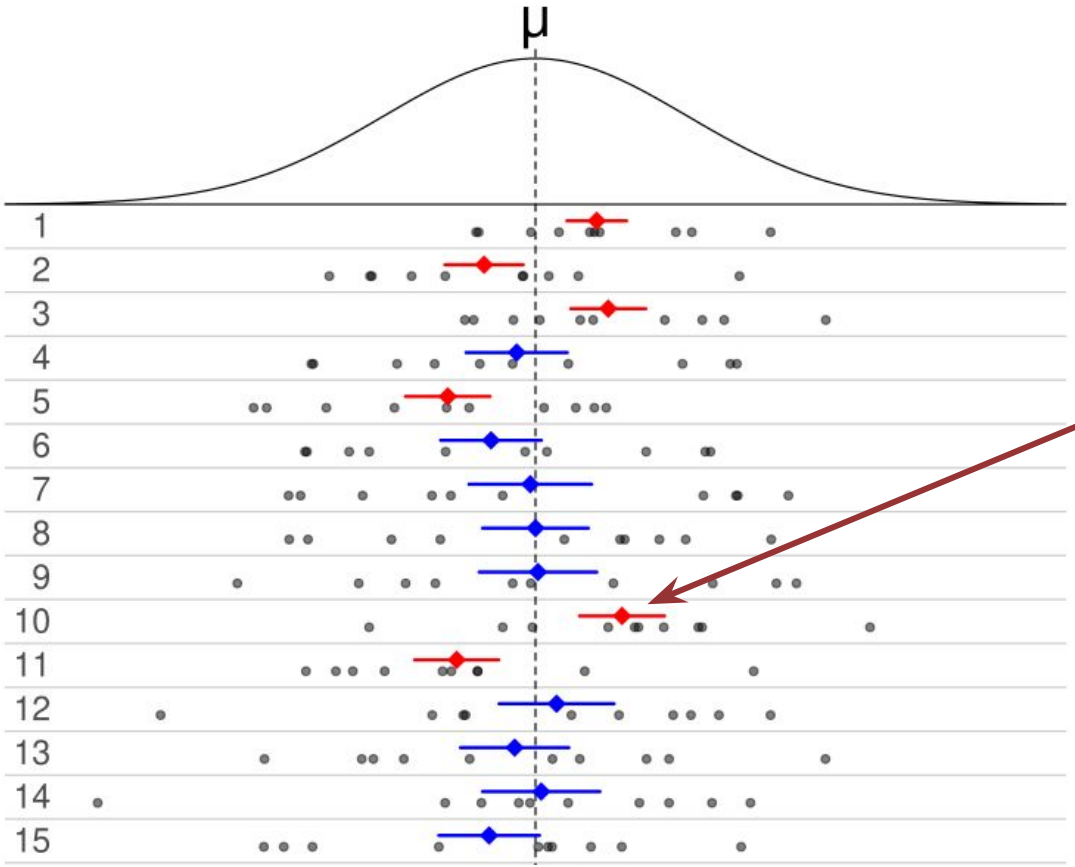
Significado de um Intervalo de Confiança



Linhas azuis representam I.C.s que contém a média populacional

Fonte: https://en.wikipedia.org/wiki/Confidence_interval

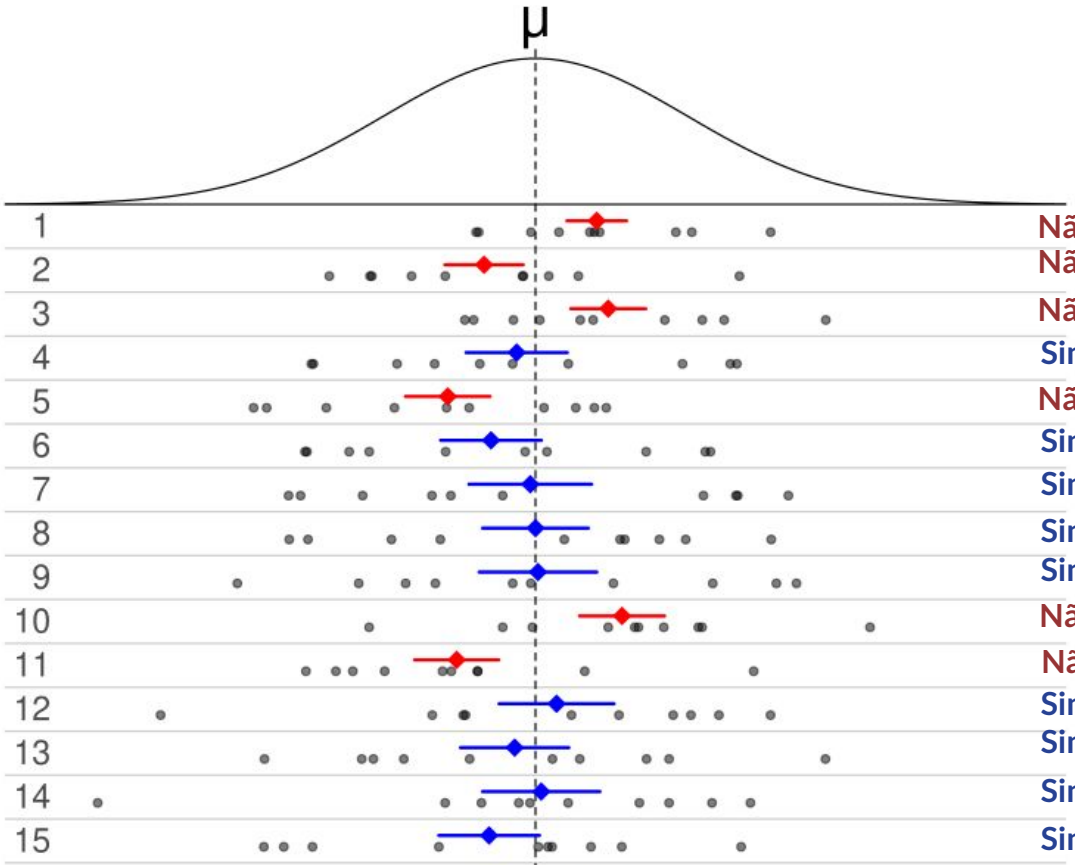
Significado de um Intervalo de Confiança



Linhas vermelhas representam I.C.s que não contém a média populacional

Fonte: https://en.wikipedia.org/wiki/Confidence_interval

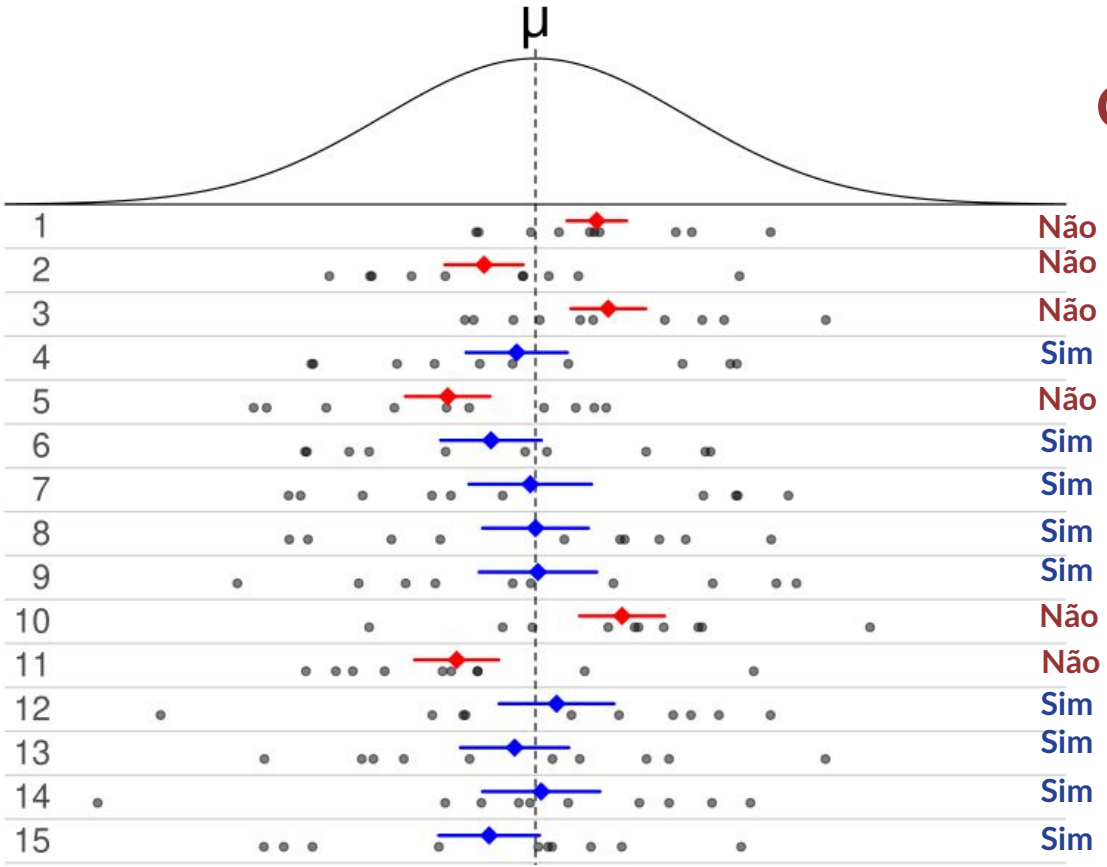
Significado de um Intervalo de Confiança



Contém a média?

Não
Não
Não
Sim
Não
Sim
Sim
Sim
Sim
Não
Não
Sim
Sim
Sim
Sim

Significado de um Intervalo de Confiança

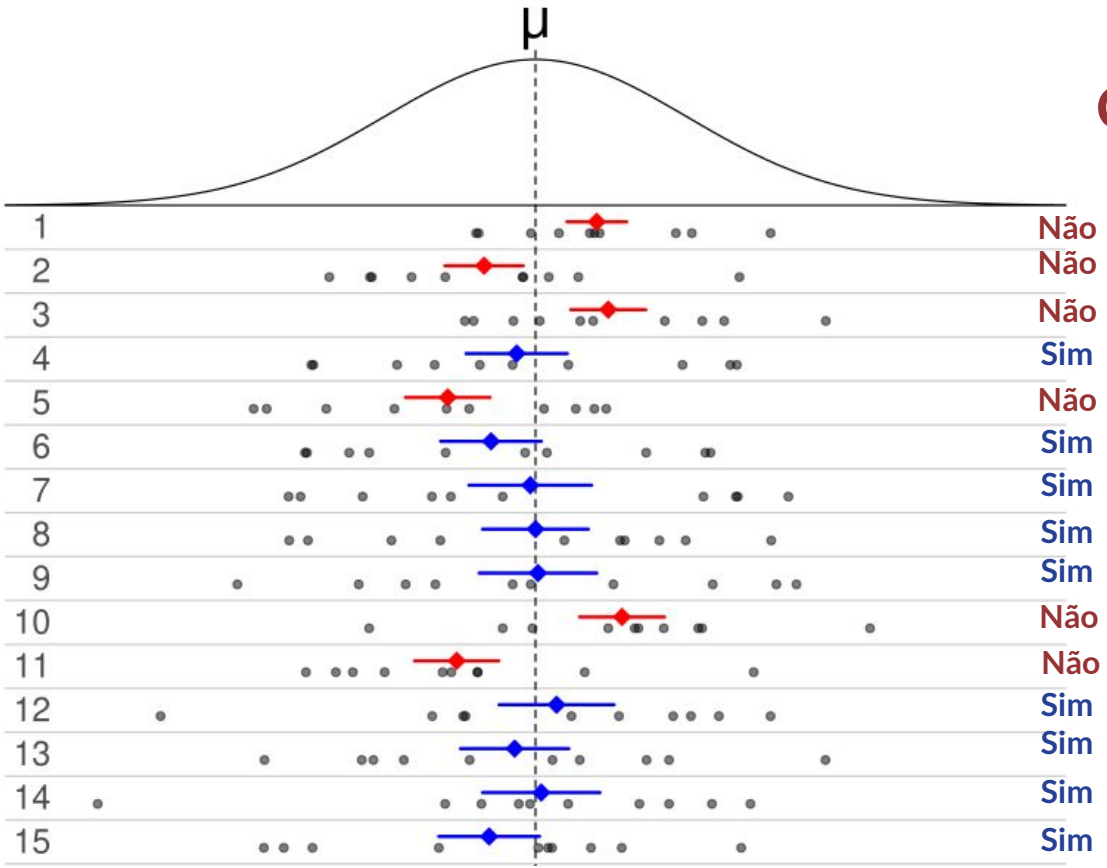


Contém a média?

Ao final, você terá:
Sim >= 100(1-α)
Não < 100(α)

O procedimento fornece estimativas significativas porque produz intervalos que geralmente contêm o parâmetro

Significado de um Intervalo de Confiança

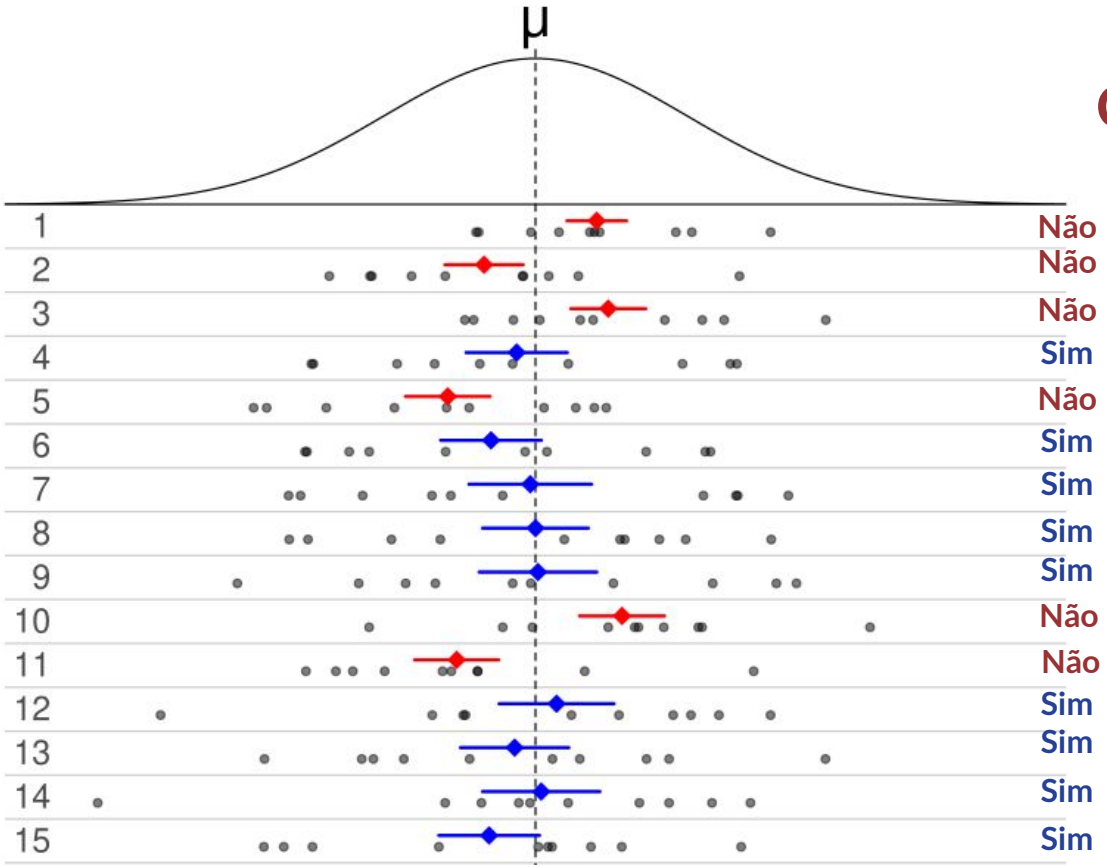


Contém a média?

Ao final, você terá:
Sim >= 100(1-α)
Não < 100(α)

Um I.C. indica onde o parâmetro populacional provavelmente residirá. Por exemplo, um intervalo de confiança [8, 12] de 95% de uma dada média sugere que você pode ter 95% de confiança de que a média da população está entre 8 e 12

Significado de um Intervalo de Confiança



Contém a média?

Ao final, você terá:
Sim >= 100(1-α)
Não < 100(α)

Cuidado! Um IC de 95% não significa que há 95% de chance de a média verdadeira estar neste intervalo. Significa que, se repetíssemos a amostragem muitas vezes e construíssemos um IC de 95% em cada amostra, cerca de 95% desses intervalos conteriam a média verdadeira.

Estimando os Intervalos de Confiança

Para amostras grandes (n > 30): O **Teorema Central do Limite** diz que, sob condições adequadas (observações independentes, de mesma distribuição e com variância finita), a distribuição da média amostral, devidamente padronizada, aproxima-se da normal à medida que a amostra aumenta

- Isso permite o uso de intervalos de confiança baseados na distribuição normal padrão (**Distribuição z**)

Para amostras pequenas (n <= 30): Quando a distribuição original é desconhecida, assume-se que os dados são normalmente distribuídos para calcular intervalos de confiança usando a **distribuição *t* de *Student***

- Não pode conter muitos *outliers*

Teorema Central do Limite

Quando repetimos a coleta de amostras independentes de tamanho n, a distribuição das médias amostrais se aproxima de uma distribuição normal à medida que n aumenta, mesmo que a distribuição original dos dados não seja normal:

$$\bar{x}_n = \frac{x_1 + x_2 + \cdots + x_n}{n} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Teorema Central do Limite

Quando repetimos a coleta de amostras independentes de tamanho n, a distribuição das médias amostrais se aproxima de uma distribuição normal à medida que n aumenta, mesmo que a distribuição original dos dados não seja normal:

$$\bar{x}_n = \frac{x_1 + x_2 + \cdots + x_n}{n} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

À medida que o tamanho da amostra *n* aumenta, o desvio padrão (erro padrão diminui)

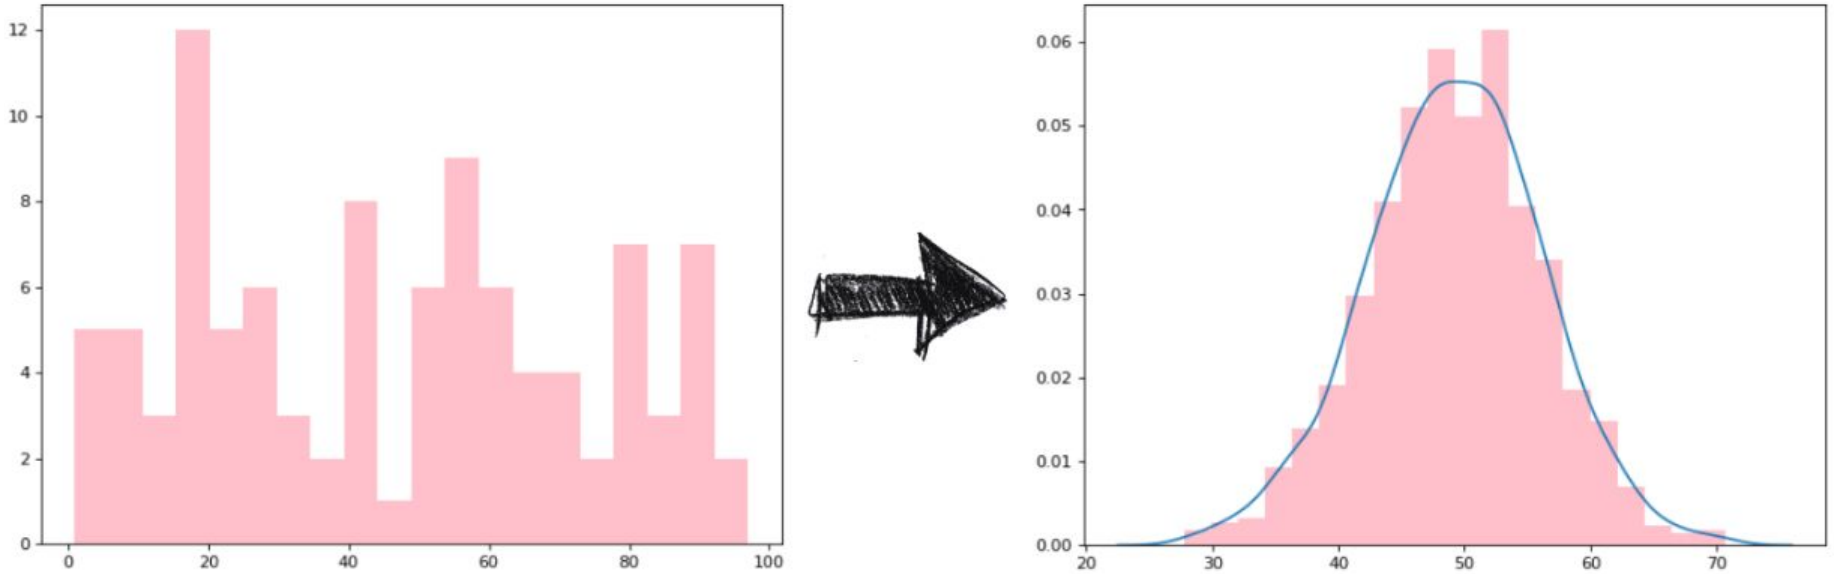
Teorema Central do Limite

Verdade se cada amostra for grande o suficiente (n indo para infinito), a distribuição da média amostral é aproximadamente normal

E isto é verdade para a grande maioria das distribuições

Uma razão para distribuições com formato de sino (normais) aparecerem tantas vezes na natureza

Teorema Central do Limite



Mesmo que a distribuição original não seja normal, a distribuição da média de várias amostras seguirá uma distribuição aproximadamente normal

Intervalo de Confiança para a Média

Termos Importantes:

- **Intervalo de Confiança:** $(c1, c2)$
- **Nível de Significância:** α
- **Nível de Confiança:** $100(1-\alpha)$
- **Coeficiente de Confiança:** $1-\alpha$

A Distribuição z (n>30)

A distribuição z é uma distribuição normal com média 0 e desvio padrão 1. Ela é simétrica em torno da média

Intervalo em cada lado da média

$$\left(\bar{x} - z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}\right)$$

A Distribuição z (n>30)

A distribuição z é uma distribuição normal com média 0 e desvio padrão 1. Ela é simétrica em torno da média

Intervalo em cada lado da média

$$\left(\bar{x} - z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}\right)$$

Média

A Distribuição z (n>30)

A distribuição z é uma distribuição normal com média 0 e desvio padrão 1. Ela é simétrica em torno da média

Intervalo em cada lado da média

$$\left(\bar{x} - z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}\right)$$

Alpha: Nível de significância

A Distribuição z (n>30)

A distribuição z é uma distribuição normal com média 0 e desvio padrão 1. Ela é simétrica em torno da média

Intervalo em cada lado da média

$$\left(\bar{x} - z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}\right)$$

Erro padrão

A Distribuição z (n>30)

A distribuição z é uma distribuição normal com média 0 e desvio padrão 1. Ela é simétrica em torno da média

Intervalo em cada lado da média

$$\left(\bar{x} - z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}\right)$$

Valor crítico da distribuição normal padrão z N(0, 1)

A Distribuição z (n>30)

Representa o número de desvios padrão da média que corresponde ao nível de confiança desejado

Por exemplo, para um intervalo de confiança de 95%, $z_{1-\alpha/2}$ é aproximadamente $z_{1-\alpha/2} = z_{1-0.05/2} = z_{1-0.05/2} = 0.975$

z-Score	p-value	%
1.93	0.97320	97.32%
1.94	0.97381	97.38%
1.95	0.97441	97.44%
1.96	0.97500	97.50%

Link de uma tabela onde você pode consultar o valor crítico de z

A Distribuição t (n<=30)

A fórmula é basicamente a mesma. O intervalo é exato para amostras independentes de uma população normal

- Funciona para pequenas amostras (n<=30)
    - Assimetria forte e valores extremos podem comprometer o procedimento
- Similar a Normal (*bell-shaped*, porém mais espalhada) e depende do tamanho da amostra *n*

$$\left(\bar{x} - t_{1-\alpha/2,\, df} \cdot \frac{s}{\sqrt{n}}, \bar{x} + t_{1-\alpha/2,\, df} \cdot \frac{s}{\sqrt{n}} \right)$$

A Distribuição t (n<=30)

$$\left(\bar{x} - t_{1-\alpha/2,\,df} \cdot \frac{s}{\sqrt{n}}, \bar{x} + t_{1-\alpha/2,\,df} \cdot \frac{s}{\sqrt{n}}\right)$$

Valor crítico da distribuição t de student

A Distribuição t (n<=30)

$$\left(\bar{x} - t_{1-\alpha/2,\, df} \cdot \frac{s}{\sqrt{n}}, \bar{x} + t_{1-\alpha/2,\, df} \cdot \frac{s}{\sqrt{n}}\right)$$

Graus de liberdade (n-1)

Link de uma tabela onde você pode consultar o valor crítico da distribuição *t de* student

A Distribuição t (n<=30)

$$\left(\bar{x} - t_{1-\alpha/2,\,df} \cdot \frac{s}{\sqrt{n}}, \bar{x} + t_{1-\alpha/2,\,df} \cdot \frac{s}{\sqrt{n}}\right)$$

ν	0.90	0.95	0.975	0.99	0.995	0.999
1.	3.078	6.314	12.706	31.821	63.657	318.309
2.	1.886	2.920	4.303	6.965	9.925	22.327
3.	1.638	2.353	3.182	4.541	5.841	10.215
4.	1.533	2.132	2.776	3.747	4.604	7.173
5.	1.476	2.015	2.571	3.365	4.032	5.893
6.	1.440	1.943	2.447	3.143	3.707	5.208
7.	1.415	1.895	2.365	2.998	3.499	4.785

Graus de liberdade

Link de uma tabela onde você pode consultar o valor crítico da distribuição *t de* student

A Distribuição t (n<=30)

$$\left(\bar{x} - t_{1-\alpha/2,\,df} \cdot \frac{s}{\sqrt{n}}, \bar{x} + t_{1-\alpha/2,\,df} \cdot \frac{s}{\sqrt{n}}\right)$$

ν	0.90	0.95	0.975	0.99	0.995	0.999
1.	3.078	6.314	12.706	31.821	63.657	318.309
2.	1.886	2.920	4.303	6.965	9.925	22.327
3.	1.638	2.353	3.182	4.541	5.841	10.215
4.	1.533	2.132	2.776	3.747	4.604	7.173
5.	1.476	2.015	2.571	3.365	4.032	5.893
6.	1.440	1.943	2.447	3.143	3.707	5.208
7.	1.415	1.895	2.365	2.998	3.499	4.785

Graus de liberdade

Ex: Se temos 5 valores e conhecemos a média, apenas 4 deles podem variar livremente - o último é determinado

A Distribuição t (n<=30)

$$\left(\bar{x} - t_{1-\alpha/2,\,df} \cdot \frac{s}{\sqrt{n}}, \bar{x} + t_{1-\alpha/2,\,df} \cdot \frac{s}{\sqrt{n}}\right)$$

ν	0.90	0.95	0.975	0.99	0.995	0.999
1.	3.078	6.314	12.706	31.821	63.657	318.309
2.	1.886	2.920	4.303	6.965	9.925	22.327
3.	1.638	2.353	3.182	4.541	5.841	10.215
4.	1.533	2.132	2.776	3.747	4.604	7.173
5.	1.476	2.015	2.571	3.365	4.032	5.893
6.	1.440	1.943	2.447	3.143	3.707	5.208
7.	1.415	1.895	2.365	2.998	3.499	4.785

Coeficiente de confiança

Link de uma tabela onde você pode consultar o valor crítico da distribuição *t de* student

Exemplo

Você desenvolve e testa um novo modelo medindo sua acurácia em vários conjuntos de dados de teste

Dados do problema:

- Tamanho da Amostra (# testes): 3,532
- Média: 74.0
- Desvio padrão: 9.9

Como calcular o intervalo de confiança do modelo?

Exemplo

Qual fórmula devemos usar?

Exemplo

Qual fórmula devemos usar? Distribuição z > 30

$$\left(\bar{x} - z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}\right)$$

Considerando um intervalo de confiança de **90%:**

$$\left(74.0 - 1.645 \cdot \frac{9.9}{\sqrt{3532}}, 74.0 + 1.645 \cdot \frac{9.9}{\sqrt{3532}}\right)$$

$$(74.0 - 0.274025, 74.0 + 0.274025)$$

$$(73.725975, 74.274025)$$

Exemplo

Qual fórmula devemos usar? Distribuição z > 30

$$\left(\bar{x} - z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}\right)$$

Considerando um intervalo de confiança de **95%:**

$$\left(74.0 - 1.960 \cdot \frac{9.9}{\sqrt{3532}}, 74.0 + 1.960 \cdot \frac{9.9}{\sqrt{3532}}\right)$$

$$(74.0 - 0.326498, 74.0 + 0.326498)$$

$$(73.673502, 74.326498)$$

Exemplo

Qual fórmula devemos usar? Distribuição z > 30

$$\left(\bar{x} - z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}\right)$$

Considerando um intervalo de confiança de **99%:**

$$\left(74.0 - 2.576 \cdot \frac{9.9}{\sqrt{3532}}, 74.0 + 2.576 \cdot \frac{9.9}{\sqrt{3532}}\right)$$

$$(74.0 - 0.429112, 74.0 + 0.429112)$$

$$(73.570888, 74.429112)$$

Exemplo

Comparando os resultados:

- Intervalo de Confiança de 90%: (73.726, 74.274)
- Intervalo de Confiança de 95%: (73.674, 74.326)
- Intervalo de Confiança de 99%: (73.571, 74.429)

Conclusão: Quanto maior o nível de confiança, maior é margem de erro para assegurar que a média populacional esteja dentro do intervalo

Algumas considerações

90%: Intervalos de confiança mais estreitos

- Fornecem uma estimativa mais precisa da média populacional, mas com menor certeza

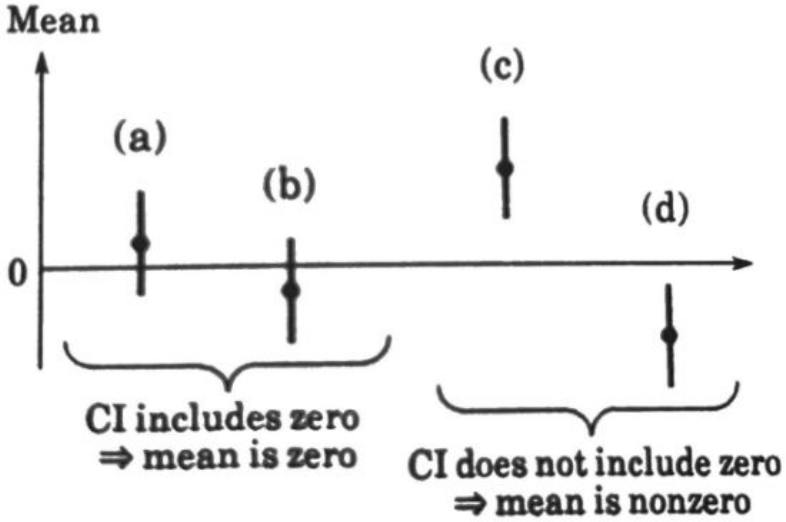
99%: Intervalos de confiança mais amplos

- Fornecem uma estimativa menos precisa, mas com maior certeza de que a média populacional está contida no intervalo

Teste da Média Zero

Um uso comum de um intervalo de confiança é verificar se uma variável aleatória é significativamente diferente de zero

O teste consiste em calcular o intervalo de confiança e verificar se ele inclui o valor de referência (ex: zero)



Teste da Média Zero

Exemplo: Dois modelos foram testados em sete conjunto de dados. As diferenças entre as acurácias deles foram ={1.5, 2.6, -1.8, 1.3, -0.5, 1.7, 2.4}

É possível afirmar com 99% de confiança que um é melhor do que o outro?

Teste da Média Zero

Dados do problema:

- Tamanho da amostra (n): 7
- Graus de liberdade (*df*): n−1=7−1=6
- Média das diferenças: 7.20/7 = 1.03
- Desvio Padrão: 1.60
- Nível de Significância (α): 0.01
- Coeficiente de Confiança: 1−α = 1-0.01=0.99
- Nível de confiança: 100(1-α) = 100(1-0.01) = 99%
- Intervalo de Confiança: (c1, c2)

Teste da Média Zero

Qual fórmula usar? n=7 <= 30:

Teste da Média Zero

Qual fórmula usar? n=7 <= 30:

$$\left(\bar{x} - t_{1-\alpha/2,\, df} \cdot \frac{s}{\sqrt{n}}, \bar{x} + t_{1-\alpha/2,\, df} \cdot \frac{s}{\sqrt{n}}\right)$$

Teste da Média Zero

Qual fórmula usar? n=7 <= 30:

$$\left(\bar{x} - t_{1-\alpha/2,\, df} \cdot \frac{s}{\sqrt{n}}, \bar{x} + t_{1-\alpha/2,\, df} \cdot \frac{s}{\sqrt{n}}\right)$$

Substituindo os valores:

$$\left(1.03 - 3.707 \cdot \frac{1.60}{\sqrt{7}}, 1.03 + 3.707 \cdot \frac{1.60}{\sqrt{7}}\right)$$

Teste da Média Zero

Qual fórmula usar? n=7 <= 30:

$$\left(\bar{x} - t_{1-\alpha/2,\, df} \cdot \frac{s}{\sqrt{n}}, \bar{x} + t_{1-\alpha/2,\, df} \cdot \frac{s}{\sqrt{n}} \right)$$

Substituindo os valores:

$$\left(1.03 - 3.707 \cdot \frac{1.60}{\sqrt{7}}, 1.03 + 3.707 \cdot \frac{1.60}{\sqrt{7}} \right)$$

Calculando a margem de erro:

$$3.707 \cdot \frac{1.60}{\sqrt{7}} = 3.707 \cdot \frac{1.60}{2.646} \approx 3.707 \cdot 0.604 \approx 2.239$$

Teste da Média Zero

Intervalo de Confiança:

$$(1.03 - 2.239, 1.03 + 2.239) = (-1.209, 3.269)$$

O intervalo de confiança **inclui zero!**

Portanto, não podemos dizer com 99% de confiança que a diferença média entre os algoritmos é diferente de zero

- Portanto, conclui-se que os modelos não apresentam diferença significativa de desempenho

Teste da Média Igual a Qualquer Valor

O procedimento para testar se a média é zero **pode ser aplicado para qualquer outro valor**

Inclusive, para testar se a média é igual a um dado valor para um dado α. Basta construir um intervalo de confiança como antes

Se o valor testado estiver incluído no I.C., a hipótese de que a média é igual a um dado valor para α não pode ser rejeitada no nível de confiança considerado

Testando Média Zero

Exemplo: Dois modelos foram testados em sete conjuntos de dados. As diferenças entre a acurácia deles foram ={1.5, 2.6, -1.8, 1.3, -0.5, 1.7, 2.4}

É possível afirmar com 99% de confiança que a diferença entre eles é igual a 1?

$$(1.03 - 2.239, 1.03 + 2.239) = (-1.209, 3.269)$$

Sim!

Comparando Duas Alternativas

A maioria dos experimentos requer comparar duas ou mais soluções/algoritmos/modelos/etc para escolher a melhor

I.C.s permitem a comparação de dois cenários

- Para mais de dois, veremos outras técnicas no curso

O procedimento estatístico para comparar dois experimentos é uma extensão do teste para média zero estudado anteriormente

Abordagens para observações distintas

Pareadas: Cada unidade é avaliada nas duas condições, ou as unidades são associadas em pares por um critério relevante.

A comparação considera a diferença dentro de cada par

Exemplos:

- Dois algoritmos avaliados nos mesmos conjuntos de dados: cada conjunto fornece um par de resultados
- Tempo de resposta antes e depois da atualização para os mesmos usuários: cada usuário fornece um par de medidas
- Dois métodos de compressão aplicados aos mesmos arquivos: cada arquivo fornece um par de resultados

Abordagens para observações distintas

Não pareadas (independentes): as condições são avaliadas em grupos independentes, sem correspondência individual entre suas observações

Exemplos:

- Dois programas avaliados em grupos distintos e independentes de máquinas, sem pareamento entre elas
- Um grupo de tratamento e um grupo de controle formados por indivíduos diferentes, sem pareamento
- Duas campanhas de *marketing* avaliadas em grupos distintos e independentes de usuários

Comparando Duas Alternativas: Pareadas

Método:

1. Calcule a diferença entre os ***n* pares** de observações
2. Realize o cálculo de I.C. para a diferença média
3. Se o intervalo inclui 0 (zero), os objetos de comparação (ex.: sistemas, algoritmos, modelos etc) não apresentam diferença significativa no nível de confiança considerado
4. Se o intervalo não inclui zero, o sinal da diferença indica qual dos objetos é melhor, baseado nos dados experimentais

Comparando Duas Alternativas: Não Pareadas

Método:

1. Calcule a média e o desvio padrão de cada grupo separadamente
2. Compute a diferença da média entre os dois grupos
3. Compute o desvio padrão da diferença média

$$s_{\bar{x}_1 - \bar{x}_2} = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Comparando Duas Alternativas: Não Pareadas

Método (Continuação):

4. Calcule os graus de liberdade (Fórmula de *Welch-Satterthwaite*)

$$df = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1 - 1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2 - 1}}$$

5. Calcule o I.C.

$$\left((\bar{x}_1 - \bar{x}_2) - t_{1-\alpha/2,\, df} \cdot s_{\bar{x}_1 - \bar{x}_2}, (\bar{x}_1 - \bar{x}_2) + t_{1-\alpha/2,\, df} \cdot s_{\bar{x}_1 - \bar{x}_2}\right)$$

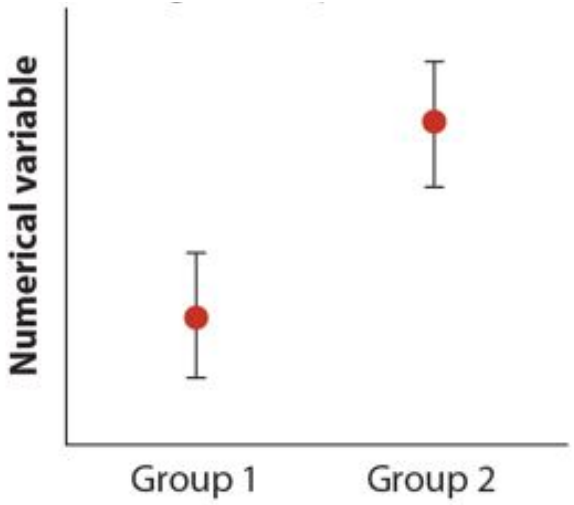
Comparando Duas Alternativas: Não Pareadas

Método (Continuação):

6. Por fim:
    a. Se o I.C. **inclui zero**, a diferença é não significativa com um nível de confiança de *100(1- α)%*
    b. Se o I.C. **não inclui zero**, então o sinal da diferença média indica qual algoritmo/modelo/etc é melhor
        i. Considerando $\bar{x}_1 - \bar{x}_2$, se positivo o primeiro é melhor. Se negativo, o contrário

Comparando Duas Alternativas: Não Pareadas

Um teste visual mais simples para amostras não pareadas pode ser usado calculando o I.C. para cada alternativa individualmente

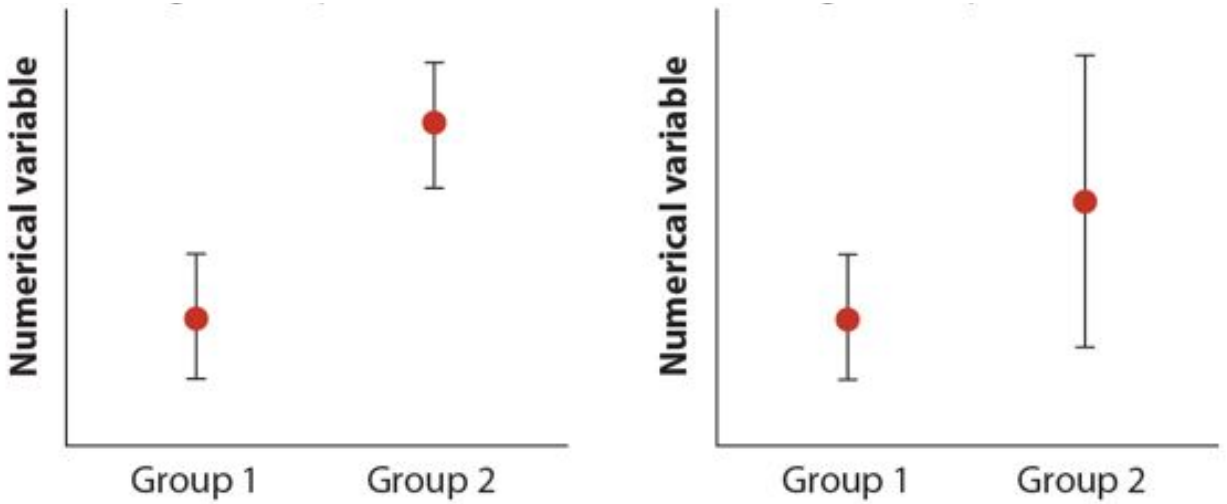


IC.'s não sobrepostos. 2>1

Fonte: https://shorturl.at/Q6jXe

Comparando Duas Alternativas: Não Pareadas

Um teste visual mais simples para amostras não pareadas pode ser usado calculando o I.C. para cada alternativa individualmente

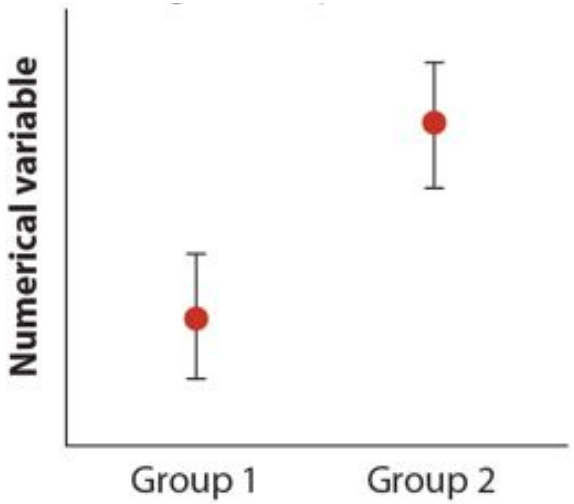


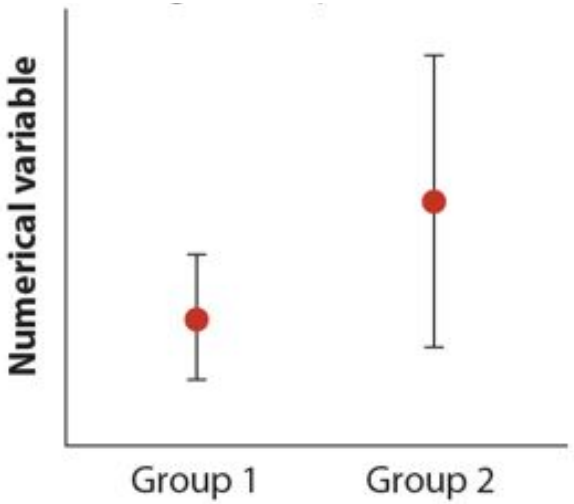
IC.'s sobrepostos e a média de um está no I.C. do outro. Alternativas não são diferentes

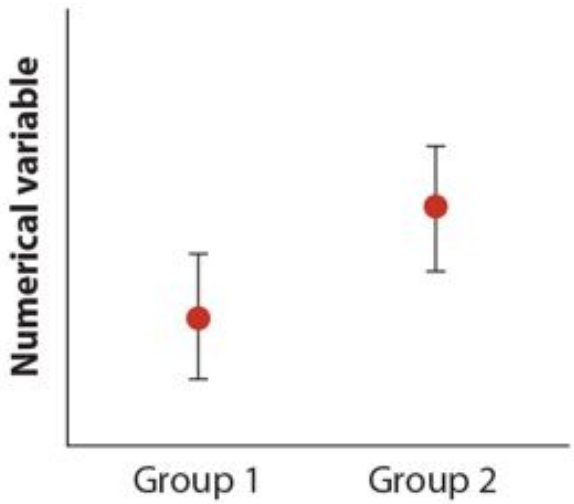
Fonte: https://shorturl.at/Q6jXe

Comparando Duas Alternativas: Não Pareadas

Um teste visual mais simples para amostras não pareadas pode ser usado calculando o I.C. para cada alternativa individualmente







IC.'s sobrepostos mas sem média: Precisa de um teste t.

Métodos Paramétricos vs Não Paramétricos

Métodos Paramétricos: Requerem suposições sobre a distribuição dos dados (por exemplo, normalidade)

Métodos Não Paramétricos: Não assumem uma distribuição específica para os dados, oferecendo maior flexibilidade

- ***Bootstrapping*:** Técnica não paramétrica para estimar a distribuição de uma estatística a partir de uma amostra de dados
  - Envolve reamostrar dados com reposição para criar uma distribuição empírica da estatística, determinando os limites de confiança
  - Amplamente utilizado na literatura

Bootstrapping: Passos

1- Reamostrar com Reposição:

- Pegue uma amostra de dados original de tamanho *n*
- Gere várias novas amostras (também de tamanho *n*) escolhendo aleatoriamente da amostra original com reposição
- Cada amostragem gera um novo conjunto de dados que pode ter alguns dados repetidos e outros ausentes

2- Recalcular a Estatística:

- Calcule a estatística de interesse (por exemplo, média, mediana) para cada nova amostra gerada

Bootstrapping: Passos

3- Construir a Distribuição:

- Repita o processo de reamostragem muitas vezes (por exemplo, 1000 ou 10.000 vezes)
- Construa a distribuição da estatística recalculada

4- Determinar o Intervalo de Confiança: Ordene os valores da estatística recalculada. Selecione os percentis desejados para formar o intervalo de confiança

- Por exemplo, para um intervalo de confiança de 95%, use os percentis 2.5% e 97.5%

Algumas considerações

Os níveis de confiança 90%, 95% e 99% são os valores comuns

Em geral, use o maior valor que lhe permita estabelecer conclusões sólidas num processo experimental!

Intervalos de confiança são ferramentas essenciais em estatísticas para estimar parâmetros populacionais

- Teste de hipóteses também podem ser usados para esse mesmo propósito. Mas são mais difíceis de serem interpretados!

Algumas considerações

Existem vários outros tipos de intervalo de confiança:

- **Unilateral:** Quando interessa saber se a média é maior ou menor que um valor específico
- **Proporção:** Intervalo que estima a proporção de uma característica na população (Usado em pesquisas de opinião e estudos populacionais)
- **Variância:** Intervalo que estima a variabilidade de uma população. Usado em análises de dispersão de dados
- ...

Escolher o tipo correto de intervalo de confiança depende do objetivo do estudo e da natureza dos dados

Algumas considerações

Existem outros testes para múltiplas comparações:

- ANOVA (Análise de Variância): Verifica se pelo menos um grupo difere significativamente dos outros.Requer suposições de normalidade e homocedasticidade
    - Detecta diferença global
- Teste de Kruskal-Wallis (não paramétrico): Alternativa à ANOVA quando as suposições não são atendidas. Compara medianas entre grupos
    - Detecta diferença global
- Testes pós-hoc (Tukey, Dunn, etc.): **Usados após ANOVA ou Kruskal-Wallis** se o resultado for significativo, para identificar quais grupos diferem entre si

Dúvidas?

Créditos

Este material é baseado nos livros textos da disciplina em questão e foi desenvolvido pelo professor Carlos Henrique Gomes Ferreira. Além disso, ele está licenciado sob uma **Licença Creative Commons Atribuição 4.0 Internacional (CC BY 4.0)**. Versão 1.0. 02/2024.